# ScopeAD: Observation Expansion and Support-Referenced Asymmetric Fusion for Few-Shot Industrial Anomaly Localization

Anonymous CVPR submission

Paper ID *****

## Abstract

*소수 정상 이미지를 사용하는 few-shot 산업 이상 국소화에서는 서포트에 없는 정상 외관 변화도 큰 최근접 거리를 만들 수 있어, 고점수만으로 정상 변동과 결함을 구분하기 어렵다. 제한된 서포트에서 비교 단서를 확보하기 위해 표현 계층과 입력 해상도를 확장하면, 관측별 거리 척도와 결합 기여도를 함께 다룰 필요가 있다. 본 논문은 이러한 관측 확장과 정상 참조 기반 비대칭 결합으로 구성된* ***ScopeAD****를 제안한다. ScopeAD는 동결 백본의 계층·해상도별 뱅크에서 거리를 개별적으로 계산한다. 정상 참조 거리의 상위 분위수와 계층별 상대 비중으로 결합 계수를 정의하여 깊은 계층에 더 큰 비중을 두고, 해상도별 맵을 통합한다. 백본의 추가 학습이나 쿼리 시점 파라미터 갱신은 사용하지 않는다. MVTec AD 2 공개 개발 벤치마크의 16-shot 평가에서 세 seed 평균* ***60.06 %*** $\text{AUPRO}_{0.05}$*를 기록하여 SuperAD보다* ***4.17 pp*** *높았다. 같은 벤치마크의 16-shot seed 0 구성 비교에서는 특징 연결 구성 대비 2.09 pp, 최선 단일 해상도 대비 2.10 pp의 차이를 보였다. 실험은 관측 구성과 결합 대안을 비교하고, 정규화의 조건별 효과와 다해상도 추론의 비용을 함께 분석한다.*

## 1. 서론

다품종 소량 생산과 잦은 라인 전환이 일어나는 제조 현장에서는 제품마다 결함 데이터를 충분히 모으거나 모델을 다시 학습하기 어려워, 소수의 정상 이미지만으로 결함 위치를 찾는 few-shot 이상 국소화가 실용적인 대안이 된다. 대표적인 방식은 동결된 사전학습 백본 [10]에서 추출한 정상 패치 특징으로 참조 뱅크를 만들고, 쿼리 패치와의 최근접 거리를 이상 점수로 쓰는 것이다 [3, 13, 17]. 이 점수는 정상 쿼리 패치라면 참조 뱅크 안에 가까운 이웃이 있다는 가정에 기댄다. 그러나 실제 공정에서는 조명 드리프트, 부품 자세 변동, 표면 난반사 같은 획득 조건 변화가 계속 발생하며 [6, 19], 몇 장의 정상 서포트로는 이를 모두 담을 수 없다. 서포트에 없는 정상 변동이 나타나면 결함이 없는 패치도 최근접 거리가 커지고, 이 값은 실제 결함이 만든 큰 거리와 같은 구간에 놓일 수 있다.

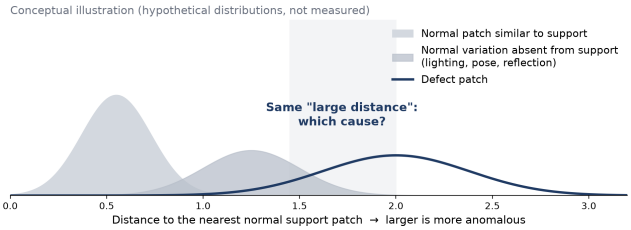



Figure 1. **Conceptual illustration of High-Score Ambiguity in few-shot inspection.** With sparse normal support, unobserved normal variations and true defects can both produce large nearest-neighbor distances. Raising the decision threshold to limit false alarms from normal high scores can also reduce defect coverage.

따라서 큰 거리값만으로는 그 원인이 결함인지 서포트에 없던 정상 외관 변화인지 확정할 수 없으며, 본 논문은 이를 **High-Score Ambiguity**라 부른다(Fig. 1). 이 모호성은 오경보를 엄격히 제한하는 저-FPR 구간에서 특히 문제가 되는데, 정상 위치의 고점수로 인한 오경보를 줄이려고 판정 임계값을 높이면 함께 검출할 수 있는 결함 영역도 줄어들기 때문이다 [2].

정상 서포트를 충분히 확보하면 더 다양한 정상 외관을 참조 뱅크에 담을 수 있지만, few-shot 조건에서는 사용할 수 있는 이미지 수가 제한된다. 따라서 한정된 서포트에서 결함 판단에 쓸 수 있는 시각적 단서를 충분히 확보하는 것이 중요하다. 본 논문은 이를 위해 표현 계층과 입력 해상도의 두 축으로 관측을 확장하되, 다층 특징을 단일 벡터로 묶어 하나의 이웃만 찾는 기존 접근 [13]과 달리 각 계층·해상도를 독립된 매칭 단위로 분리하는 방향을 취한다. ViT는 계층마다 국소 외관과 전역 문맥을 반영하는 방식이 다르므로, 여러 계층의 특징은 서로 다른 수준의 비교 단서를 제공한다 [11, 12]. 또한 입력 해상도는 각 패치가 나타내는 원본 영상의 공간 범위를 바꾸며, 패치 크기가 고정된 백본에서는 해상도가 높을수록 더 작은 영역이 하나의 토큰에 대응한다 [5, 14]. 따라서 여러 계층과 해상도에서 참조 매칭을 개별적으로 수행하면, 미세한 국소 차이와 더 넓은 영역의 문맥적 차이를 각자의 표현·공간 척도에서 독립적인 비교 단서로 확보할 수 있다.

그러나 이렇게 분리하여 확보한 다관측 매칭 거리를 하나의 이상 점수로 통합할 때, 원시 거리를 단순 합산하거나 평균하면 두 가지 구체적인 문제가 발생한다. 첫째, 계층의 깊이와 입력 해상도에 따라 정상 참조 거리가 형성하는 기본 분포의 척도가 서로 다르므로, 보정 없이 동일한 계수를 적용하면 평소 거리 값이 큰 특정 관측이 최종 이상 점수를 일방적으로 지배하여 결합 결과가 왜곡된다. 둘째, 관측 간 거리 척도를 맞추더라도 모든 계층을 동등한 비중으로 결합하면 계층별 민감도 차이로 인한 한계가 나타난다. 얕은 계층의 특징은 미세한 국소 결함을 포착하는 데 유리하지만 조명이나 표면 질감 같은 정상 외관 변화에도 민감하게 반응하는 반면, 깊은 계층은 전역 문맥을 바탕으로 정상 변이에 비교적 강건하다. 따라서 계층별 특성을 구분하지 않고 점수를 합치면, 얕은 계층에서 발생한 정상 변이의 큰 거리가 결합 점수에 그대로 유입되어 저-FPR 구간에서의 오경보(High-Score Ambiguity)를 다시 악화시킨다. 결국 다관측 통합이 유효하려면 관측 간 거리 단위의 불균형과 계층별 오경보 민감도 차이를 동시에 해결해야 한다.

이를 해결하기 위해 본 논문은 다관측 확장과 정상 참조 기반 선형 결합(Support-Referenced Linear Fusion)으로 구성된 **ScopeAD**를 제안한다. ScopeAD는 계층·해상도별 독립 뱅크에서 산출한 매칭 거리를 통합할 때, 단순 이상 맵 평균 [17]이나 단일 스케일 보정 [16]과 달리 관측별 정상 참조 척도와 계층별 고정 가중치를 함께 사용하여 선형 결합 계수를 정의한다. 구체적으로 각 관측의 정상 서포트 내부 거리 분포로부터 기준 단위를 추정해 관측 간 척도를 정규화한 뒤, 깊은 계층의 정규화 점수 평균에 얕은 계층의 정규화 점수를 작은 고정 가중치로 더한다. 이 선형 결합을 각 해상도에 적용한 후, 해상도별 맵을 원본 좌표에서 평균하여 최종 이상 맵을 생성한다. ScopeAD는 백본의 추가 학습이나 쿼리 시점 파라미터 갱신 없이 동작하며, 계층 가중치는 개발 평가에서 한 번 정한 뒤 모든 데이터셋과 shot 조건에 고정한다.

본 논문의 기여는 다음과 같다.

- 제한된 정상 서포트에서 다양한 비교 단서를 활용하도록, 동결 백본의 계층·입력 해상도를 확장하고 관측별 매칭 거리를 독립적으로 유지하는 few-shot 이상 국소화 방법을 구성한다.
- 정상 서포트에서 추정한 기준 척도와 계층별 고정 가중치를 함께 사용하여 관측별 결합 계수를 정의하는 정상 참조 기반 선형 결합을 제안한다.
- 관측 구성과 결합 대안에 대한 비교로 전체 설계의 효과와 한계를 분석하고, MVTec AD 2 [6]의 다중 시드 저-FPR 성능, MVTec AD·VisA의 교차 데이터셋 성능 및 계산 비용을 보고한다.

## 2. Related Work

### 2.1. Frozen-Feature Reference Matching in Few-Shot AD

소수의 정상 참조를 활용하는 이상 탐지 방법은 패치 매칭, 영상 정합, 특징 복원 및 정상 부분공간 모델링으로 나눌 수 있다. 패치 매칭 계열의 PatchCore [13]는 사전학습 CNN의 다층 특징을 연결한 정상 메모리 뱅크와 최근접 거리를 사용하며, AnomalyDINO [3]와 SuperAD [17]는 동결 DINOv2 특징을 활용한다. RegAD [8]와 FastRecon [4]는 각각 영상 정합과 특징 복원으로 정상 참조와의 차이를 측정하고, SubspaceAD [9]는 정상 부분공간에 대한 잔차를 사용한다. MVTec AD 2의 few-shot 연구 [15]도 동결 특징의 계층 선택과 참조 수에 따른 결과를 분석한다. 이러한 정상 모델링 방식에 더해, ScopeAD는 최근접 매칭에서 계층·해상도별 관측을 확장하고 정상 참조 척도와 계층별 가중치를 함께 사용하는 점수 결합에 초점을 둔다.

### 2.2. Multi-Scale Observation and Score Fusion

다층·다해상도 관측은 서로 다른 수준의 공간 정보를 결합하는 접근이다. DPT [12]는 여러 ViT 계층의 토큰을 학습된 디코더로 결합하고, $S^2$ [14]는 동결 백본의 다중 척도 특징을 타일 처리와 재조립으로 구성한다. 이상 탐지에서는 PatchCore의 특징 연결과 SuperAD의 계층별 이상 맵 평균처럼 특징 또는 점수 단계에서 관측을 결합한다 [13, 17]. FreePatch [16]는 정상 참조 정보를 활용하여 패치 매칭 점수를 보정하는 접근이다. 이러한 접근은 관측을 특징 단계에서 합칠지 개별 매칭 후 점수 단계에서 합칠지, 그리고 정상 참조 정보를 결합에 어떻게 사용할지에 따라 구분할 수 있다. ScopeAD는 계층·입력 해상도별 매칭 거리를 유지하고, 관측별 정상 참조 척도와 계층별 상대 가중치를 함께 사용하는 비대칭 결합으로 이를 통합한다. 구체적인 결합 계수와 정상 참조 추정은 Sec. 3.3에서 정의한다.

### 2.3. Distribution Shift and Low-FPR Localization

획득 조건 변화에 대응하는 연구는 정상 외관의 변화와 결함을 구별하는 문제를 다룬다. AeBAD 연구 [19]는 실제 도메인 변화를 포함한 데이터셋과 masked multi-scale reconstruction 방법을 제안하며, MVTec AD 2 [6]는 조명 변화와 작은 결함을 포함한 평가 환경을 제공한다. 평가 측면에서 AUPIMO [2]는 낮은 오경보 허용치에서의 국소화 품질을 측정하여 전체 곡선 지표를 보완한다. ScopeAD는 정상 서포트로 정한 점수 척도와 고정 결합 규칙을 쿼리에 적용하며, 추가 학습이나 쿼리 적응 없이 분포 변화 조건의 저-FPR 국소화를 평가한다. 이때 정상 거리의 척도 보정과 고정 배포 임계값의 오경보율 보장은 구분한다.

## 3. 방법 (Method)

소수의 정상 참조 이미지만으로 저-FPR 구간에서 신뢰할 수 있는 이상 국소화를 달성하려면, 제한된 표본에서 비교 단서를 극대화함과 동시에 미관측 정상 변이로 인한 추정 분산(High-Score Ambiguity)을 억제해야 한다. 이를 위해 ScopeAD는 **(1) 다중 관측의 주변부 매칭 분리**, **(2) 교차 검증 기반의 비모수적 정상 경계 정렬**, **(3) 계층 간 민감도 차이를 반영한 가중 선형 결합**, 그리고 **(4) 공간적 앙상블 및 극값 전파**가 상호 보완적으로 작동하는 통합 프레임워크를 구성한다(Fig. 2).

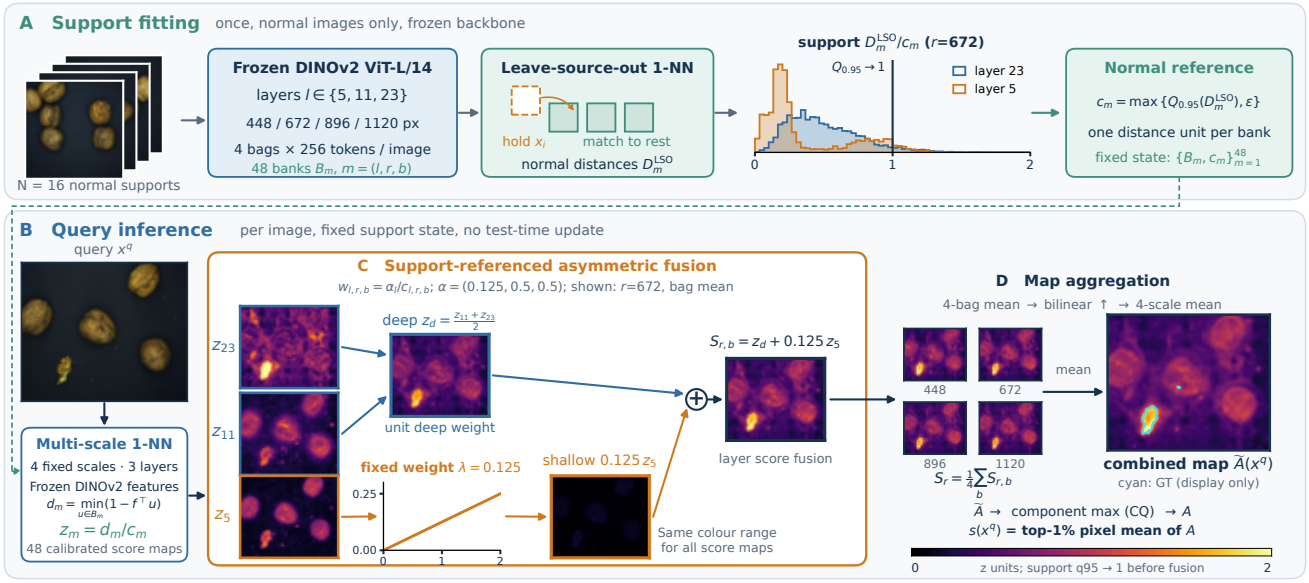



Figure 2. **Overview of the ScopeAD framework.** (A) Building 48 observation-specific memory banks from normal support images and precomputing upper-quantile normal scales $c_m = \mathcal{Q}_{0.95}(D_m^{\mathrm{LSO}})$ via Leave-Source-Out matching. (B) Observation expansion across 4 resolutions and 3 layers, evaluating 1-NN cosine distances normalized by $c_m$. (C) Layer fusion combining the deep-layer baseline with shrinkage-weighted shallow signals ($z_d + 0.125\, z_5$). (D) Spatial aggregation across bags and resolutions yielding the final anomaly localization map and image-level score.

### 3.1. 시스템 개요 및 문제 정의

입력은 $N$장의 정상 서포트 이미지 집합 $\mathcal{S} = \{x_1^s, \ldots, x_N^s\}$, 테스트 쿼리 이미지 $x^q$, 그리고 사전학습 후 동결된 비전 트랜스포머 백본이다. 특징을 추출할 표현 계층 집합을 $\mathcal{L}$, 입력 해상도(짧은 변 기준) 집합을 $\mathcal{R}$, 서브샘플링 앙상블을 위한 배그(bag) 수를 $B$로 정의한다. 모델은 추가 학습이나 쿼리 시점의 파라미터 갱신 없이, 서포트 집합 $\mathcal{S}$의 내재적 통계량만을 피팅하여 픽셀 단위 결함 맵 $A(x^q) \in \mathbb{R}^{H\times W}$와 이미지 단위 이상 점수 $s(x^q) \in \mathbb{R}$를 출력한다.

### 3.2. 관측 확장과 주변부 참조 매칭

**주변부 매칭을 위한 컴포넌트 분리.** 다층 특징을 단일 고차원 벡터로 연결(concatenation)하여 최근접 이웃을 탐색하면, 분산이 큰 특정 계층이 거리 계산을 지배하여 타 계층의 비교 단서가 왜곡된다 [13]. 이를 방지하기 위해 계층 $l \in \mathcal{L}$, 해상도 $r \in \mathcal{R}$, 배그 $b \in \{1, \ldots, B\}$의 조합 $m = (l, r, b)$를 독립된 주변부(marginal) 관측 단위인 컴포넌트로 정의하고, 각 컴포넌트마다 전용 메모리 뱅크 $B_m$을 분리 구축한다. 쿼리 $x^q$의 공간 위치 $p$에서 추출한 $\ell_2$ 정규화 특징 $f_m(x^q, p)$는 각 관측 고유의 표현·공간 척도 안에서 독립적으로 최근접 매칭된다:

$$d_m(x^q, p) = \min_{u \in B_m} \left[1 - f_m(x^q, p)^\top u\right]. \qquad (1)$$

**표본 추출 분산 제어를 위한 패치 배깅.** 1-NN 거리 추정량은 유한한 참조 표본의 구성에 민감하며, 다해상도 확장은 참조 토큰 수의 급증을 수반한다. 연산 복잡도를 제어하면서 단일 표본 추출의 분산을 완화하기 위해 부트스트랩 집계(bagging) 원리를 도입한다. 각 해상도 $r$에서 서포트 이미지마다 $K$개의 패치 토큰을 무작위 비복원 추출하여 단일 배그를 구성하며, 독립된 난수 시드로 $B$개의 배그를 생성한다. 동일 배그 내의 모든 계층은 동일한 공간 위치 인덱스를 공유하여 계층 간 공간 정합성을 유지한다.

### 3.3. 정상 참조 기반 선형 결합

분리된 컴포넌트에서 산출된 원시 거리 $d_{l,r,b}$들은 관측마다 기저 분포의 척도와 정상 변이에 대한 민감도가 서로 다르다. 이를 하나의 일관된 이상 점수로 통합하기 위해, 각 관측의 정상 상한 경계 척도 $c_{l,r,b}$와 계층별 신뢰 가중치 $\alpha_l$이 결합된 선형 추정량을 정의한다:

$$S_{r,b}(x^q, p) = \sum_{l \in \mathcal{L}} w_{l,r,b}\, d_{l,r,b}(x^q, p), \quad w_{l,r,b} = \frac{\alpha_l}{c_{l,r,b}}. \qquad (2)$$

여기서 $c_{l,r,b}$는 이질적인 관측 간 거리 분포의 척도를 정렬하고, $\alpha_l$은 정렬된 통계적 단위 위에서 계층 간 역할 비중을 조율한다.

**교차 검증 기반의 비모수적 정상 경계 추정.** 테스트 쿼리가 겪는 '미관측 정상 외관과의 비교' 조건을 서포트 집합 내부에서 모사하기 위해, 교차 검증 방식의 최근접 거리 표본 $D_m$을 수집하여 귀무 분포(정상 거리 분포)를 추정한다. 다중 샷($N > 1$)에서는 동일 이미지 내 인접 패치와

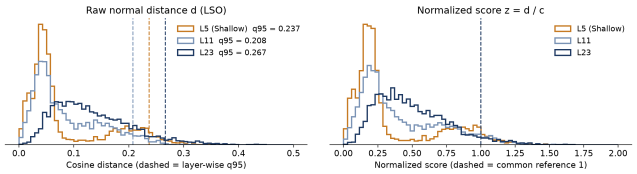



Figure 3. **Observation-wise distance scale discrepancy and quantile alignment.** Left: Raw Leave-Source-Out (LSO) normal distance distributions across different backbone layers (Layers 5, 11, 23) and resolutions exhibit substantial scale disparities. Right: By dividing each component distance by its empirical upper quantile ($c_m = \mathcal{Q}_{0.95}(D_m^{\mathrm{LSO}})$), the critical threshold $z = 1.0$ is unified across all 48 component banks into a dimensionless, comparable coordinate before fusion.

의 자기 매칭으로 인한 낙관적 편향(optimistic bias)을 배제하고자, 각 서포트 이미지 $i$의 패치 집합 $B_m^{(i)}$를 해당 이미지를 제외한 나머지 뱅크에 매칭하는 Leave-Source-Out (LSO) 표본을 구성한다:

$$D_m^{\mathrm{LSO}} = \bigcup_{i=1}^{N} \left\{ \min_{u \in B_m \setminus B_m^{(i)}} \left[1 - v^\top u\right] : v \in B_m^{(i)} \right\}. \quad (3)$$

단일 샷($N = 1$)에서는 이미지 간 변이를 관측할 수 없으므로, 동일 이미지 내에서 자기 자신의 위치 인덱스만 제외한 Leave-Token-Out (LTO) 표본으로 이미지 내 정상 변이 분포를 대리 추정한다:

$$D_m^{\mathrm{LTO}} = \left\{ \min_{j \neq i} \left(1 - v_i^\top v_j\right) : i = 1, \ldots, K \right\}. \quad (4)$$

관측별 정상 거리 분포 $D_m$은 계층과 해상도에 따라 비대칭성과 꼬리 두께가 상이하므로, 특정 분포 형태를 가정하는 모수적 통계량 대신 비모수적 순서 통계량(order statistic)을 사용하여 정상 경계를 정의한다. 구체적으로 서포트 내 극단적 단일 이상치 패치에 대한 강건성을 확보하면서 정상 변이의 실질적 상한을 포착하도록, 분위수 수준 $q \in (0, 1)$의 경험적 분위수 연산자 $\mathcal{Q}_q(D_m)$으로 기준 척도 $c_m$을 추정한다:

$$c_m = \max\left\{\mathcal{Q}_q(D_m), \epsilon\right\}, \quad z_m(x^q, p) = \frac{d_m(x^q, p)}{c_m}, \quad (5)$$

여기서 $\epsilon > 0$은 수치적 하한이다. 이 변환을 통해 모든 관측의 정규화 점수 $z_m(x^q, p)$는 해당 관측의 경험적 정상 경계($z_m = 1$) 대비 상대적 초과 비율이라는 통일된 통계적 의미를 갖는다(Fig. 3). 분위수 연산자의 양의 동차성(positive homogeneity)에 의해 임의의 척도 변환 $a_m > 0$에 대해

$$\frac{a_m d_m}{\mathcal{Q}_q(a_m D_m)} = \frac{d_m}{\mathcal{Q}_q(D_m)} \quad (6)$$

가 성립하므로, 특정 관측이 원시 거리 스케일 차이만으로 결합 점수를 지배하는 왜곡이 제거된다.

**계층 간 보완적 가중 결합.** 정상 경계 기준으로 척도가 정렬된 점수 $z_m$ 위에서, 표현 계층의 특성에 따른 오경보 민감도 차이를 제어한다. 전역 문맥을 반영하여 정상 외관 변이에 대해 낮은 분산(높은 안정성)을 보이는 심층 집합 $\mathcal{L}_{\mathrm{deep}} \subset \mathcal{L}$의 평균을 기준 추정량($z_{d,r,b}$)으로 삼고, 미세 결함에 민감하나 정상 질감 변화에 따른 분산이 큰 얕은 계층 $l_s \in \mathcal{L}$의 기여를 가중치 $\lambda \geq 0$으로 수축(shrinkage) 시켜 결합한다:

$$z_{d,r,b}(x^q, p) = \frac{1}{|\mathcal{L}_{\mathrm{deep}}|} \sum_{l \in \mathcal{L}_{\mathrm{deep}}} z_{l,r,b}(x^q, p), \quad (7)$$

$$S_{r,b}(x^q, p) = z_{d,r,b}(x^q, p) + \lambda\, z_{l_s,r,b}(x^q, p). \quad (8)$$

이는 심층 추정량을 통해 저-FPR 구간에서의 결정 경계 안정성을 확보함과 동시에, 제한된 가중치 $\lambda$를 통해 얕은 계층이 포착한 고주파 국소 결함 단서를 보완적으로 수용하는 장치이다.

### 3.4. 공간 앙상블 및 영역 일관성 보정

각 해상도 $r$에서 $B$개 배그의 점수를 평균하여 패치 표본 추출에 따른 분산을 줄인 뒤, 해상도별 맵을 원본 크기 $(H, W)$로 양선형 보간하여 다중 공간 척도의 기댓값 맵 $\tilde{A}(x^q)$를 산출한다:

$$S_r(x^q, p) = \frac{1}{B} \sum_{b=1}^{B} S_{r,b}(x^q, p), \quad (9)$$

$$\tilde{A}(x^q) = \frac{1}{|\mathcal{R}|} \sum_{r \in \mathcal{R}} \mathrm{Resize}_{H,W}\left[S_r(x^q)\right]. \quad (10)$$

패치 단위 매칭은 인접 픽셀 간 공간적 연속성을 명시적으로 강제하지 않으므로, 단일 결함 내부에서도 국소적인 점수 편차가 발생할 수 있다. 이를 보완하기 위해 $\tilde{A}(x^q)$의 상위 $\tau$-분위수 이상인 고신뢰 이상 픽셀들이 형성하는 8-연결 영역(connected components)을 검출하고, 각 영역 내부의 점수를 해당 영역의 극값(최댓값)으로 일관되게 전파하여 최종 결함 맵 $A(x^q)$를 얻는다. 최종 이미지 단위 이상 점수 $s(x^q)$는 전체 영상 크기 대비 미세 결함의 면적 비율을 고려하여, $A(x^q)$의 상위 $\rho$ 비율 픽셀 집합 $\Omega_\rho$에 대한 극단부 평균(tail mean)으로 산출한다:

$$s(x^q) = \frac{1}{|\Omega_\rho|} \sum_{p \in \Omega_\rho} A(x^q, p). \quad (11)$$

## 4. 실험 (Experiments)

본 절에서는 ScopeAD의 few-shot 성능을 비교하고, 관측 확장과 결합 설계가 결과에 미치는 영향을 분석한다. 주 비교에 이어 관측 구성과 계산 비용, 결합 대안, 획득 조건별 진단, 합성 열화 비교 순으로 근거를 제시한다.

### 4.1. 평가 설정 (Evaluation Setup)

**데이터셋 및 분할.** MVTec AD 2 [6]는 실제 산업 환경의 조명 드리프트와 미세 결함을 포괄하는 8개 클래스 벤치마

크다. 공개 개발 평가 세트인 test_public은 총 1,084장(정상 379장, 결함 705장)으로 구성되며, 기준(Regular) 환경 외에 Shift 1–3 등의 획득 조건 변화를 포함한다. 정상 서포트 이미지는 train/good에서 고정 시드와 매니페스트로 선별한다. 교차 데이터셋 검증을 위해 기존 MVTec AD(15개 클래스) [1]와 VisA(12개 클래스) [20] 벤치마크를 함께 평가한다.

**Few-shot 설정 및 비교군.** 클래스당 정상 서포트 이미지 수 $N$은 $\{1, 2, 4, 8, 16\}$으로 설정한다. ScopeAD(Ours, linear0125)는 DINOv2 ViT-L/14 백본을 동결 사용하며, 계층 $\{5, 11, 23\}$과 4개 해상도 $\{448, 672, 896, 1120\}$, FP16 autocast, cap256, $z_d + 0.125\, z_5$ 결합을 적용한다. 비교 대상 방법군은 PatchCore [13], SuperAD [17], Anomaly-DINO [3], FastRecon [4], RAD [18], SubspaceAD [9], RegAD [8]다. 동일한 shot과 seed의 비교는 서포트 경로, 쿼리 및 평가기를 공유한다. 비교 파이프라인의 해상도 설정값은 1120을 기준으로 하며, ScopeAD는 짧은 변 길이의 최댓값을 1120으로 설정하고 종횡비를 유지한다. RegAD는 STN 제약으로 공식 224 설정을 유지한다. 이 비교는 백본, 전체 토큰 수 또는 계산량까지 일치시킨 비교는 아니다. 주요 평가 지표는 클래스 매크로 $\mathrm{AUPRO}_{0.05}$, $\mathrm{pAUROC}_{0.05}$, 그리고 이미지 단위 I-AUROC다. 각 클래스에서 AUPRO는 결함 연결영역별 검출 비율을 평균한 PRO 곡선을 FPR $[0, 0.05]$에서 적분하고 0.05로 나눈다. pAUROC는 같은 구간의 pixel ROC 면적에 무작위 기준 0.5, 완전 분류 기준 1의 표준화를 적용한다. 이미지 AUROC와 교차 데이터셋 표의 pixel AUROC는 전체 FPR 구간을 사용하며, 모든 지표는 클래스별 값을 동일 가중 평균한다.

**개발 조건과 실행 규약.** 결합 가중치는 AD2 test_public 2-shot seed 0에서 선택했으므로, AD2 공개 결과는 개발에 사용된 벤치마크의 평가로 해석한다. MVTec AD와 VisA에는 동일한 가중치를 적용한다. 각 평가 클래스의 뱅크 및 척도 추정에는 정상 서포트만 사용한다. ScopeAD는 Sec. 3.4의 고점수 연결영역 후처리를 포함한다. AD2 1/4/8-shot 반복 평가와 16-shot 용량 비교의 실행 기록에서, 잡음 진단에 따른 저해상도 전환은 모든 쿼리에서 비활성 상태였음을 확인했다. 따라서 이 실행에서는 각 구성에 지정된 해상도 집합을 모든 쿼리에 고정하여 사용했다.

### 4.2. Few-shot 주 비교 (Few-shot Main Benchmark)

표 1는 MVTec AD 2 test_public에서의 few-shot 주 비교 결과다. ScopeAD는 평가한 모든 shot에서 SuperAD보다 높은 평균 AUPRO를 보였다. 여기서 평균 차이는 관측된 효과이며, 통계적 유의성 검정의 결과는 아니다. 특히 16-shot에서 3-seed 평균 **60.06 %** $\mathrm{AUPRO}_{0.05}$를 달성하여 SuperAD(55.89 %) 대비 **+4.17 pp**, pAUROC@0.05에서 **+3.01 pp** 높은 성능을 기록했다. 1-shot AUPRO는 $51.31 \pm 4.01$ %로, seed 0의 54.81 %보다 평균이 낮고 서포트 선택에 따른 변동도 크다. 소수 참조에 대한 평균 성능과 표본 선택 민감도를 함께 고려해야 한다.

표 2는 기존 MVTec AD 및 VisA 벤치마크에서의 교차 평가 결과다. 이미지 AUROC는 보고된 비교군 중 두 데이터셋의 모든 shot에서 최고 또는 차순위다. 반면 pixel AUROC는 MVTec AD 1/4/8/16-shot에서 3위이며 VisA 1-shot에서는 4위로, 지표별 우위가 일치하지 않는다. 표 3는 2-shot과 16-shot의 세 서포트 선택에 따른 변동을 보여준다. 표의 0.00은 소수 둘째 자리까지 표시한 값이며 변동이 없음을 뜻하지 않는다. 이 비교는 전체 FPR 구간의 성능을 평가하므로 AD2의 low-FPR 결과와 구분한다.

### 4.3. 관측 구성: 해상도와 매칭 방식

**동일 서포트의 다해상도 관측.** 표 4에서 네 해상도 결합은 최선 단일 해상도보다 AUPRO가 2-shot에서 +4.95 pp, 16-shot에서 +2.10 pp 높다. 448 단독과의 16-shot 차이 +7.56 pp는 고해상도 사용과 다해상도 결합을 함께 포함하므로, 다해상도 구성의 근거는 최선 단일 해상도와 용량 일치 대조군을 중심으로 해석한다. 이 비교는 정상 이미지 수를 늘리지 않고 입력의 공간적 관측 조건을 확장하는 선택을 지지한다. 추가 관측이 독립적인 정상 표본을 제공한다는 뜻은 아니다.

**특징 연결과 관측별 매칭.** 표 6의 layer concat 구성은 계층 특징을 연결한 뒤 하나의 최근접 이웃을 찾는다. ScopeAD는 계층마다 이웃을 찾고 정상 참조 기반 비대칭 결합을 적용하며, 16-shot AUPRO가 concat보다 2.09 pp 높다. 이 비교에서는 이웃 선택, 거리 기준화 및 계층 가중 방식이 함께 달라진다. 따라서 이는 전체 구성의 비교이며, bank 분리만의 독립 효과로 해석하지 않는다.

### 4.4. 용량 및 계산 비용

표 5는 bank 용량과 실행 비용을 함께 비교한다. 4개 해상도에 각각 256개 토큰을 할당한 구성과 1120 단독에 1024개를 할당한 구성은 계층·배그당 총 bank 토큰 수가 같다. 다해상도 구성은 이 용량 일치 대조군보다 AUPRO가 +2.44 pp 높지만, 쿼리 시간도 1182ms에서 1526ms로 증가한다. 따라서 bank 용량 통제와 계산량 통제를 구분해야 한다. 다해상도에서 토큰 수를 1024로 늘리면 AUPRO는 59.57에서 59.17로 감소하고 메모리 사용량은 증가하여, 더 큰 bank가 항상 유리하지는 않았다.

비용 측정은 FP16 autocast, batch size 1이며 CUDA 동기화를 포함한다. 각 클래스의 네 구성은 같은 GPU에서 측정했고 클래스별 측정값을 동일 가중 평균했다. 피팅 시간에는 서포트 디코딩, 특징 추출, bank 구축 및 척도 추정이 포함되며 모델 로딩, 서포트 선택 및 1회 warmup은 제외한다. 쿼리 시간에는 예측과 후처리가 포함된다. 이 값은 해당 실행 환경의 측정이며 비교 방법 전체의 속도 순위를 의미하지 않는다.

### 4.5. 정상 참조 기반 비대칭 결합의 대안 비교

식 (2)의 결합 계수 $w_{l,r,b} = \alpha_l / c_{l,r,b}$에 대해, 계층 가중치 $\alpha_l$과 정상 참조 척도 $c_{l,r,b}$를 각각 변경한 대안을 비교한다. 표 6은 대표 조건인 16-shot 결과를, 부록 A은 전체 가중치 및 shot별 정규화 결과를 제시한다.

**비대칭 가중과 동일가중.** $\lambda = 0.5$는 세 계층의 정규화 점수에 같은 계수를 부여하며, 전체 평균과 상수배 관계다.

Table 1. MVTec AD 2 `test_public` 해상도 설정값 1120 기준 few-shot 비교 (%). 각 값은 3개 시드 평균 ± 표본 표준편차다. ScopeAD의 seed는 0, 1, 2이며 각 seed에서 8개 클래스를 평균한 뒤 시드 간 통계를 계산한다. † RegAD는 공식 체크포인트의 STN 제약으로 224 측정값을 병기했다. 굵은 글씨는 최고 평균값, 밑줄은 차순위다.

| Shot | Metric | PatchCore | AnomalyDINO | FastRecon | RAD | SubspaceAD | SuperAD | RegAD (224)† | Ours (ScopeAD) |
|---|---|---|---|---|---|---|---|---|---|
| 1 | AUPRO@0.05 | 38.45 ± 1.85 | 35.95 ± 2.24 | 14.92 ± 2.27 | 26.42 ± 1.71 | 44.87 ± 1.87 | 46.31 ± 3.73 | 12.73 ± 0.38 | **51.31 ± 4.01** |
| | pAUROC@0.05 | 64.19 ± 0.68 | 70.67 ± 0.69 | 55.70 ± 0.67 | 59.57 ± 0.35 | 70.56 ± 0.56 | 70.13 ± 1.14 | 57.76 ± 0.30 | **72.93 ± 1.69** |
| | I-AUROC | 65.51 ± 1.91 | 66.83 ± 1.08 | 58.10 ± 4.46 | 58.68 ± 3.03 | 67.02 ± 2.27 | 67.68 ± 0.32 | 57.73 ± 1.82 | **73.47 ± 1.23** |
| 2 | AUPRO@0.05 | 42.25 ± 2.08 | 38.20 ± 1.90 | 16.73 ± 2.39 | 31.61 ± 1.47 | 45.90 ± 0.75 | 49.80 ± 2.33 | 15.05 ± 0.30 | **56.03 ± 2.99** |
| | pAUROC@0.05 | 65.43 ± 0.38 | 72.26 ± 0.56 | 57.14 ± 1.03 | 61.78 ± 0.15 | 71.53 ± 0.18 | 71.52 ± 0.58 | 58.76 ± 0.49 | **75.86 ± 0.59** |
| | I-AUROC | 67.53 ± 1.55 | 68.95 ± 3.84 | 57.63 ± 6.82 | 59.37 ± 2.54 | 70.42 ± 1.79 | 70.19 ± 2.16 | 60.56 ± 3.94 | **74.93 ± 1.54** |
| 4 | AUPRO@0.05 | 46.94 ± 1.00 | 40.32 ± 0.75 | 21.88 ± 1.73 | 36.51 ± 1.02 | 47.14 ± 0.76 | 54.25 ± 0.86 | 17.40 ± 1.07 | **58.73 ± 0.12** |
| | pAUROC@0.05 | 66.90 ± 0.22 | 73.09 ± 0.91 | 59.26 ± 0.80 | 63.84 ± 0.41 | 72.45 ± 0.20 | 73.59 ± 0.13 | 60.36 ± 0.48 | **76.94 ± 0.60** |
| | I-AUROC | 68.62 ± 2.28 | 70.90 ± 0.97 | 59.73 ± 4.40 | 62.31 ± 4.84 | 71.02 ± 0.56 | 70.97 ± 2.08 | 63.79 ± 2.34 | **75.88 ± 0.46** |
| 8 | AUPRO@0.05 | 49.98 ± 1.90 | 41.64 ± 1.01 | 27.32 ± 0.14 | 40.79 ± 0.79 | 47.28 ± 0.40 | 55.44 ± 1.21 | 19.25 ± 0.64 | **59.74 ± 1.03** |
| | pAUROC@0.05 | 68.22 ± 0.53 | 73.71 ± 0.20 | 61.74 ± 0.50 | 65.62 ± 0.69 | 72.56 ± 0.21 | 74.31 ± 0.38 | 62.02 ± 0.32 | **77.51 ± 0.17** |
| | I-AUROC | 69.20 ± 0.75 | 71.29 ± 1.69 | 63.46 ± 4.29 | 65.84 ± 0.43 | 70.46 ± 1.18 | 70.75 ± 0.58 | 64.34 ± 1.05 | **75.99 ± 0.58** |
| 16 | AUPRO@0.05 | 52.73 ± 1.36 | 42.30 ± 1.25 | 35.23 ± 0.57 | 42.58 ± 1.10 | 47.63 ± 0.14 | 55.89 ± 1.07 | 20.28 ± 0.80 | **60.06 ± 0.88** |
| | pAUROC@0.05 | 69.36 ± 0.51 | 73.97 ± 0.23 | 65.63 ± 0.43 | 66.62 ± 0.89 | 72.78 ± 0.07 | 74.60 ± 0.52 | 63.46 ± 0.76 | **77.61 ± 0.37** |
| | I-AUROC | 69.00 ± 0.53 | 72.07 ± 1.27 | 67.45 ± 1.16 | 67.60 ± 1.35 | 70.46 ± 1.07 | 69.79 ± 0.52 | 65.64 ± 1.34 | **75.92 ± 0.82** |

Table 2. MVTec AD 및 VisA few-shot 교차 데이터셋 비교 (Seed 0 단일 실행). 각 셀은 I-AUROC / P-AUROC (전체 FPR 구간, %) 순서다. 굵은 글씨는 최고값, 밑줄은 차순위다. —는 해당 조건의 결과를 보고하지 않음을 뜻하며 순위에서 제외한다.

| Dataset | Shot | PatchCore | AnomalyDINO | FastRecon | RAD | SubspaceAD | SuperAD | RegAD | Ours (ScopeAD) |
|---|---|---|---|---|---|---|---|---|---|
| MVTec AD | 1 | 88.12 / 96.22 | 92.52 / 94.49 | 88.84 / 96.60 | 80.83 / 93.25 | 89.25 / 96.92 | 92.54 / **96.93** | — / — | **92.76** / 96.77 |
| | 2 | 92.67 / 96.97 | 95.17 / 95.56 | 93.51 / 97.29 | 84.15 / 94.27 | 90.95 / 97.24 | 95.43 / 97.36 | — / — | **96.13 / 97.39** |
| | 4 | 95.06 / 97.37 | 95.92 / 96.07 | 95.61 / **97.87** | 85.38 / 94.67 | 91.35 / 97.16 | 96.65 / 97.70 | — / — | **96.99** / 97.68 |
| | 8 | 96.13 / 97.80 | 96.67 / 96.45 | 96.76 / **98.16** | 87.85 / 95.29 | 92.94 / 97.17 | 97.39 / 97.95 | — / — | **97.60** / 97.93 |
| | 16 | 98.15 / 97.99 | 97.48 / 96.80 | 98.52 / **98.38** | 90.29 / 95.61 | 92.51 / 97.19 | **98.94** / 98.09 | — / — | 98.74 / 98.05 |
| VisA | 1 | 86.09 / 95.56 | 87.06 / 95.62 | 84.65 / 96.75 | 72.67 / 95.37 | 85.44 / **98.09** | **90.29** / 97.06 | 71.12 / 93.41 | 89.88 / 96.73 |
| | 2 | 87.87 / 96.29 | 90.64 / 96.63 | 87.67 / 97.43 | 77.24 / 96.37 | — / — | **92.20 / 97.68** | 71.59 / 94.59 | 92.15 / 97.32 |
| | 4 | 89.52 / 96.92 | 91.37 / 97.57 | 89.21 / 97.91 | — / — | — / — | 92.94 / **98.02** | 76.42 / 96.14 | **94.19** / 97.82 |
| | 8 | 92.36 / 97.18 | 93.11 / 97.99 | 91.53 / 98.11 | — / — | — / — | 94.50 / **98.29** | 80.19 / 96.64 | **95.01** / 98.25 |
| | 16 | 93.64 / 97.30 | 93.53 / 98.30 | 93.38 / 98.32 | — / — | — / — | 95.19 / 98.43 | 81.22 / 96.98 | **95.99 / 98.49** |

Table 3. ScopeAD 3-seed 교차 데이터셋 성능 (%, mean ± sample SD).

| Dataset | 2-shot (I-AUROC / P-AUROC) | 16-shot (I-AUROC / P-AUROC) |
|---|---|---|
| MVTec AD | 96.04 ± 0.30 / 97.38 ± 0.04 | 98.52 ± 0.20 / 98.05 ± 0.00 |
| VisA | 92.38 ± 1.04 / 97.40 ± 0.08 | 95.78 ± 0.18 / 98.50 ± 0.02 |

Table 4. 단일 대 다중 해상도 비교 (linear0125, AD2, seed 0, %).

| 해상도 구성 | 2-shot (AUPRO / pAUROC) | 16-shot (AUPRO / pAUROC) |
|---|---|---|
| 448 단독 | 51.14 / 75.80 | 52.01 / 76.52 |
| 672 단독 | 54.38 / 74.97 | 55.01 / 76.17 |
| 896 단독 | 52.65 / 73.46 | 55.12 / 74.62 |
| 1120 단독 | 54.27 / 72.47 | 57.47 / 74.86 |
| **4개 해상도 결합** | **59.33 / 76.48** | **59.57 / 77.46** |

$\lambda = 0.125$는 이 동일가중 대안보다 AUPRO가 16-shot에서 1.36 pp, 개발에 사용한 2-shot에서 4.41 pp 높았다. 검사한 양의 가중치 중에서는 0.125가 두 shot에서 가장 높았으나, 16-shot에서 0.25와의 차이는 0.09 pp로 작다(표 9). 이 결과는 깊은 계층에 더 큰 비중을 두는 결합을 지지한다. Deep-only인 $\lambda = 0$ 비교가 없으므로 얕은 계층 추가 자체의 이득이나 정상 반응의 선택적 제거를 입증하지는 않는다.

**정상 참조 척도의 선택.** q95는 MAD보다 모든 shot에서 AUPRO가 0.76–1.69 pp 높았다(표 10). 반면 미정규화 대비 AUPRO 차이는 1/2/4/8/16-shot 순서로 −0.25, +0.27, −0.33, −0.01, +0.40 pp이며, pAUROC에서도 일관된 개선은 없다. q95는 관측별 거리를 정상 참조 단위로 표현하여 비대칭 결합 계수를 정의하는 선택으로 사용한다. 이러한 구조적 역할과 식 (6)의 척도 불변성은 실제 성능 향상을 보장하지 않는다.

### 4.6. 획득 조건별 진단

표 7는 같은 클래스 집합에서 획득 조건별 성능을 분리한 진단이다. Regular AUPRO 61.76에 비해 Shift 1–3은 58.10–60.48로 낮아, 고정 결합 이후에도 조건 변화에 따른 저하가 남는다. 이 결과는 공개 개발 세트 내부의 분석이며 미관측 환경에 대한 독립 검증이나 비교 방법 대비 shift 우위를 뜻하지 않는다.

### 4.7. 합성 열화 조건 비교

표 8은 Hendrycks와 Dietterich [7]의 합성 열화 평가 방식을 따라 테스트 이미지에만 열화를 적용한 결과다. ScopeAD의 AUPRO는 Brightness와 Contrast에서 비교군 중

Table 5. 현재 선형 결합의 용량 및 비용 비교 (AD2 16-shot, seed 0, 8-class macro). 토큰 수는 이미지당·계층당·배그당 값이다. 지표는 AUPRO@0.05 / pAUROC@0.05 (%). 비용은 클래스별 측정값의 평균이며, 시간은 피팅 초(s) 및 쿼리당 밀리초(ms), 메모리는 쿼리 단계 PyTorch peak allocated GiB다. 전체 GPU 메모리 사용량과는 다르다.

| 해상도 | 토큰 수 | AUPRO / pAUROC | Fit (s) | Query (ms) | Peak (GiB) |
|---|---|---|---|---|---|
| 4개 해상도 | 256 | 59.57 / 77.46 | 20.62 | 1526 | 3.07 |
| 1120 단독 | 256 | 57.47 / 74.86 | 12.77 | 993 | 1.91 |
| 1120 용량 일치 | 1024 | 57.14 / 75.49 | 14.42 | 1182 | 3.04 |
| 4개 해상도 | 1024 | 59.17 / 77.56 | 27.04 | 1941 | 6.69 |

Table 6. 결합 대안 및 관측 구성 비교 (AD2 `test_public` 16-shot, seed 0, 8-class macro, %). Full은 관측별 bank, q95, $\lambda = 0.125$, 네 해상도를 사용한다. 결합 대안은 거리를 기준화하는 방식 또는 계층 가중치를 변경한다. 관측 구성 비교의 concat은 매칭과 결합을 함께 변경한다. ΔAUPRO는 Full 대비 AUPRO 차이(pp)이며 두 지표의 FPR 상한은 0.05다.

| 구성 | AUPRO | pAUROC | ΔAUPRO |
|---|---|---|---|
| **Full: q95,** $\lambda = 0.125$ | **59.57** | 77.46 | 0.00 |
| *결합 대안* | | | |
| 정규화 제거 | 59.17 | **77.65** | −0.40 |
| 계층 동일가중 ($\lambda = 0.5$) | 58.21 | 76.31 | −1.36 |
| MAD 정규화 | 58.52 | 77.17 | −1.05 |
| *관측 구성 비교* | | | |
| Layer concat bank | 57.48 | 74.80 | −2.09 |
| 448 단일 해상도 | 52.01 | 76.52 | −7.56 |

Table 7. ScopeAD 선형 결합의 AD2 획득 조건별 성능 (16-shot, seed 0, %). 네 조건이 모두 존재하는 동일한 7개 클래스(can, fabric, rice, sheet_metal, vial, wallplugs, walnuts)의 macro이며 fruit_jelly는 제외한다. 각 shift 번호는 데이터셋의 클래스별 획득 조건을 따른다.

| 조건 | AUPRO@0.05 | pAUROC@0.05 |
|---|---|---|
| Regular | 61.76 | 78.16 |
| Shift 1 | 60.48 | 78.10 |
| Shift 2 | 58.10 | 76.64 |
| Shift 3 | 59.45 | 77.04 |

가장 높고, Clean에서는 FastRecon 다음이다. 반면 Defocus blur에서는 FastRecon과 SuperAD보다, Gaussian noise에서는 PatchCore와 SuperAD보다 낮다. Gaussian noise에서 ScopeAD의 AUPRO는 Clean 대비 16.99 pp 낮아져, PatchCore의 9.94 pp와 SuperAD의 13.39 pp보다 하락 폭이 크다. pAUROC에서는 어느 조건에서도 최고값이 아니며, Contrast에서만 차순위다. 따라서 이 결과는 ScopeAD가 합성 열화 전반에서 우위라는 근거가 아니라, 밝기·대비 변화에서의 강점과 잡음·초점 열화에서 남는 취약성을 함께 보여준다. 서포트에 열화를 적용하지 않은 단일 seed 평가이므로 조건 간 차이의 통계적 유의성은 검정하지 않았다. 비교군의 해상도와 백본 설정은 방법별로 다르다.

## 5. 논의 및 한계 (Discussion & Limitations)

**관측 확장의 이득과 비용.** 다해상도 결합은 AD2 seed 0에서 최선 단일 해상도보다 AUPRO가 2-shot에서 4.95 pp, 16-shot에서 2.10 pp 높았다. 16-shot의 총 bank 용량 일치 비교에서도 2.44 pp 차이가 나타났으며, 관측별 매칭과 비대칭 결합을 함께 적용한 구성은 특징 연결 구성보다 2.09 pp 높았다. 후자의 비교는 bank 분리만의 효과를 분리하지 않는다. 이 결과는 주어진 서포트의 여러 표현을 개별적으로 비교하고 결합하는 설계를 지지한다. 다만 다해상도 추론은 용량 일치 단일 해상도보다 시간이 더 들며, 학습이 없다는 사실이 낮은 추론 비용을 뜻하지는 않는다. 또한 개선은 클래스별로 균일하지 않다. 16-shot에서 fabric의 AUPRO는 1120 단독의 66.62에서 다해상도의 59.28로 낮아져, 동일 가중 해상도 결합이 항상 유리하지 않음을 보여준다.

**정상 참조 기반 비대칭 결합의 근거와 범위.** 결합 계수 $w_{l,r,b} = \alpha_l / c_{l,r,b}$는 정상 참조 거리의 단위와 계층별 상대 비중을 함께 정의한다. 수치적 하한이 활성화되지 않을 때 정규화된 기여도는 곱셈적 거리 척도 변화에 불변이지만, 이 성질이 이상 판별력의 향상을 보장하지는 않는다. q95의 미정규화 대비 성능 차이는 작고 방향이 혼재하며, 비대칭 가중은 평가한 2/16-shot에서 동일가중보다 높은 AUPRO를 보였다. 이 결과는 비교한 대안들에 대한 결합 설계의 근거다. Deep-only 비교가 없으므로 얕은 계층 추가 자체의 이득은 확인되지 않았으며, 정상 질감 반응만을 선택적으로 제거한다는 기전도 검증하지 않았다.

**Few-shot 추정과 평가 범위.** 관측 확장은 동일한 이미지에서 얻는 비교 단서를 늘리지만, 서포트에 없던 정상 외관을 직접 관측하게 하지는 않는다. 특히 1-shot은 이미지 내부의 leave-token-out 거리를 기준으로 삼으며 이미지 간 정상 변이를 추정할 수 없다. 1-shot의 세 seed AUPRO 표준편차 4.01 pp는 서포트 선택 민감도가 남아 있음을 보여준다. 결합 가중치는 AD2 공개 개발 평가에서 선택했으므로, 해당 벤치마크의 성과를 미관측 환경에 대한 검증과 구분한다. 현재 선형 방법의 private 서버 평가는 본문에 포함하지 않는다. MVTec AD와 VisA의 전체 구간 AUROC는 다른 데이터셋으로의 적용 가능성을 보여주지만, 모든 조건의 pixel AUROC 우위나 low-FPR 우위를 뒷받침하지는 않는다.

**획득 조건 변화와 배포 임계값.** 동일 클래스 집합에서도 획득 조건에 따라 성능이 낮아지므로 High-Score Ambiguity가 해소되었다고 결론내릴 수 없다. 또한 AUPRO와

Table 8. MVTec AD 합성 열화 비교 (15개 클래스, 16-shot, seed 0, 열화 강도 3, 서포트는 열화 없음). 각 셀은 AUPRO@0.05 / pAUROC@0.05 (%)이며, 굵은 글씨는 각 지표의 최고값, 밑줄은 차순위다. † FastRecon은 DINOv2-L/14 기반 국소 이웃 능형 복원 변형이며 원 논문의 재현 결과가 아니다. ‡ RegAD는 공식 구현과 구별되는 DINOv2 밀집 매칭 변형이다. RAD는 로컬 DINOv3 ViT-B/16 캐시 경로로 실행했다.

| 방법 | Clean | Brightness | Contrast | Defocus blur | Gaussian noise |
|---|---|---|---|---|---|
| PatchCore | 83.97 / 88.80 | 83.43 / 88.38 | 77.15 / 85.27 | 81.58 / 87.41 | **74.03 / 83.66** |
| AnomalyDINO | 77.62 / 85.31 | 72.54 / 82.61 | 72.08 / 82.48 | 70.69 / 81.06 | 33.02 / 66.81 |
| FastRecon† | **85.74 / 90.82** | 77.53 / 86.35 | 69.72 / 84.47 | **82.35 / 88.90** | 57.70 / 77.37 |
| RAD | 80.12 / 87.03 | 78.70 / 86.04 | 74.96 / 84.33 | 70.44 / 81.13 | 49.23 / 72.05 |
| SubspaceAD | 83.89 / 86.98 | 80.45 / 84.91 | 78.49 / 83.39 | 78.17 / 83.39 | 64.61 / 78.01 |
| SuperAD | 84.49 / 89.15 | 83.68 / **88.47** | 82.27 / **87.86** | 82.17 / 87.74 | 71.10 / 82.45 |
| RegAD‡ | 38.11 / 78.65 | 36.14 / 77.02 | 32.01 / 74.77 | 37.33 / 77.91 | 28.12 / 70.00 |
| Ours (ScopeAD) | 85.42 / 88.98 | **84.64** / 88.35 | **83.40** / 87.59 | 81.46 / 86.38 | 68.43 / 80.19 |

pAUROC는 임계값을 변화시키며 계산하는 지표이며, 고정 배포 임계값의 오경보율을 보장하지 않는다. 서포트 기반 척도 추정과 고점수 연결영역 후처리 역시 테스트 정상 분포에서의 정확한 FPR을 보장하지 않는다. 실제 배포에서는 목표 오경보율에 맞는 임계값 검증과 획득 조건 변화에 따른 성능 점검이 필요하다.

## 6. 결론 (Conclusion)

본 논문은 소수 정상 서포트를 사용하는 산업 이상 국소화를 위해 관측 확장과 정상 참조 기반 비대칭 결합으로 구성된 **ScopeAD**를 제안했다. 동결 백본의 계층·해상도별 거리를 개별적으로 계산하고, 정상 참조 척도와 계층별 상대 비중으로 정의한 계수를 통해 결합한다. MVTec AD 2 공개 개발 벤치마크의 16-shot 평가에서 세 seed 평균 60.06 % $\text{AUPRO}_{0.05}$를 기록하여 SuperAD보다 4.17 pp 높았다. AD2 16-shot seed 0의 구성 비교에서는 특징 연결 구성 대비 2.09 pp, 최선 단일 해상도 대비 2.10 pp의 차이가 나타났다. 이 결과는 제한된 서포트에서 여러 관측을 유지하고 결합하는 설계의 유효성을 뒷받침한다. 한편 정규화의 미정규화 대비 이득은 조건에 따라 달랐으며, 서포트 선택 민감도, 다해상도 추론 비용, 획득 조건 변화에 따른 성능 저하는 남아 있다.

## References

[1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD – a comprehensive real-world dataset for unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019. 5

[2] Joao P. C. Bertoldo, Dick Ameln, Ashwin Vaidya, and Samet Akcay. AUPIMO: Redefining visual anomaly detection benchmarks with high speed and low tolerance. *arXiv preprint arXiv:2401.01984*, 2024. 1, 2

[3] Simon Damm, Mike Laszkiewicz, Johannes Lederer, and Asja Fischer. Anomalydino: Boosting patch-based few-shot anomaly detection with dinov2. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1319–1329, 2025. 1, 2, 5

[4] Zheng Fang, Xiaoyang Wang, Haocheng Li, Jiejie Liu, Qiugui Hu, and Jimin Xiao. Fastrecon: Few-shot industrial anomaly detection via fast feature reconstruction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 17481–17490, 2023. 2, 5

[5] Stephanie Fu, Mark Hamilton, Laura E. Brandt, Axel Feldmann, Zhoutong Zhang, and William T. Freeman. FeatUp: A model-agnostic framework for features at any resolution. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 1

[6] Lars Heckler-Kram, Jan-Hendrik Neudeck, Ulla Scheler, Rebecca König, and Carsten Steger. The MVTec AD 2 dataset: Advanced scenarios for unsupervised anomaly detection. *International Journal of Computer Vision*, 134(4), 2026. 1, 2, 4

[7] Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2019. 6

[8] Chaoqin Huang, Haoyan Guan, Aofan Jiang, Ya Zhang, Michael Spratling, and Yan-Feng Wang. Registration based few-shot anomaly detection. *arXiv preprint arXiv:2207.07361*, 2022. 2, 5

[9] Camile Lendering, Erkut Akdag, and Egor Bondarau. Subspacead: Training-free few-shot anomaly detection via subspace modeling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 28557–28566, 2026. 2, 5

[10] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023. 1

[11] Maithra Raghu, Thomas Unterthiner, Simon Kornblith, Chiyuan Zhang, and Alexey Dosovitskiy. Do vision transformers see like convolutional neural networks? In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 12116–12128, 2021. 1

[12] Rene Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In *Proceedings of*

*the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 12179–12188, 2021. 1, 2

[13] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14298–14308, 2022. 1, 2, 3, 5

[14] Baifeng Shi, Ziyang Wu, Maolin Mao, Xin Wang, and Trevor Darrell. When do we not need larger vision models? In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2024. 1, 2

[15] Weilin Tu. Few-shot anomaly detection on MVTec AD 2: A systematic study and a strong frozen baseline. *IEEE Access*, 14:152500–152511, 2026. 2

[16] Jin Wang, Ying-Hang Li, Bo-Wen Jiang, and Shi-Chao Li. FreePatch: A training-free multiscale patch matching method for few-shot industrial anomaly detection. In *International Conference on Computer Vision, Graphics, and Artificial Intelligence (CVGAI 2026)*, 2026. 2

[17] Huaiyuan Zhang, Hang Chen, Yu Cheng, Shunyi Wu, Linghao Sun, Linao Han, Zeyu Shi, and Lei Qi. Superad: A training-free anomaly classification and segmentation method for cvpr 2025 vand 3.0 workshop challenge track 1: Adapt & detect. *arXiv preprint arXiv:2505.19750*, 2025. 1, 2, 5

[18] Xingwu Zhang, Guanxuan Li, Paul Henderson, Gerardo Aragon-Camarasa, and Zijun Long. Is task-specific training necessary for anomaly detection? *arXiv preprint arXiv:2601.22763*, 2026. Version 3. 5

[19] Zilong Zhang, Zhibin Zhao, Xingwu Zhang, Chuang Sun, and Xuefeng Chen. Industrial anomaly detection with domain shift: A real-world dataset and masked multi-scale reconstruction. *Computers in Industry*, 151:103990, 2023. 1, 2

[20] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. *arXiv preprint arXiv:2207.14315*, 2022. 5

Table 9. Shallow 가중치 $\lambda$ 비교 (AD2 `test_public`, seed 0, %; 두 지표 모두 FPR 상한 0.05). $z_d = (z_{11} + z_{23})/2$에 $\lambda z_5$를 더한다. $\lambda = 0.5$는 계층 동일가중 평균과 비례한다.

| $\lambda$ | 2-shot (AUPRO / pAUROC) | 16-shot (AUPRO / pAUROC) |
|---|---|---|
| **0.125** | **59.33 / 76.48** | **59.57 / 77.46** |
| 0.25 | 58.43 / 76.00 | 59.48 / 77.21 |
| 0.5 | 54.92 / 74.39 | 58.21 / 76.31 |
| 1 | 48.39 / 71.31 | 54.02 / 74.04 |
| 2 | 40.48 / 67.00 | 47.33 / 70.19 |

Table 10. AD2 정규화 방식 비교 (AUPRO@0.05 / pAUROC@0.05, seed 0, %). none은 미정규화, ΔAUPRO는 q95 − MAD의 차이(pp)다.

| Shot | none | MAD | q95 | ΔAUPRO |
|---|---|---|---|---|
| 1 | 55.06 / 73.84 | 53.59 / 72.73 | 54.81 / 73.32 | +1.22 |
| 2 | 59.06 / 76.47 | 58.57 / 76.34 | 59.33 / 76.48 | +0.76 |
| 4 | 59.02 / 77.25 | 57.00 / 76.29 | 58.69 / 76.87 | +1.69 |
| 8 | 58.69 / 77.67 | 57.28 / 76.67 | 58.68 / 77.35 | +1.40 |
| 16 | 59.17 / 77.65 | 58.52 / 77.17 | 59.57 / 77.46 | +1.05 |

# A. 정상 참조 기반 비대칭 결합의 추가 분석

본문의 대표 결합 대안 비교를 보완하기 위해 전체 양의 가중치 탐색과 shot별 정규화 결과를 제시한다. 모든 값은 AD2 `test_public`, seed 0의 8-class macro이며 추가 실행 결과가 아니다.

## A.1. 계층 가중치

$z_d = (z_{11} + z_{23})/2$에 $\lambda z_5$를 더한다. $\lambda = 0.5$에서는 각 계층의 계수가 같고, $\lambda = 1$에서는 얕은 계층의 계수가 각 깊은 계층의 두 배다. 가중치는 2-shot 개발 결과에서 선택했으며 이후 고정했다. 표에 deep-only ($\lambda = 0$) 결과는 포함되지 않는다.

## A.2. 정상 참조 척도

동일한 계층 가중치를 유지하고 none, MAD, q95를 비교한다. q95와 MAD의 AUPRO 차이는 모든 shot에서 양수이나, q95와 none의 차이는 shot과 지표에 따라 방향이 달라진다. 따라서 이 결과는 q95의 일관된 성능 우위나 정규화의 필수성을 뒷받침하지 않는다.