ScopeAD: Observation Expansion and Support-Referenced Asymmetric Fusion for Few-Shot Industrial Anomaly Localization

Anonymous CVPR submission

Paper ID *****

Abstract

소수의 정상 이미지만 사용하는 few-shot 산업 이상 국소화에서는 서포트에 없는 정상 외관 변화도 큰 최근접 거리를 만들 수 있어, 높은 점수만으로 정상 변동과 결함을 구분하기 어렵다. 본 논문은 제한된 서포트에서 비교 단서를 늘리기 위해 동결 백본의 표현 계층과 입력 해상도를 독립 매칭 단위로 확장하고, 그 거리를 정상 서포트 기준으로 통합하는 ***ScopeAD****를 제안한다. ScopeAD는 각 관측의 거리를 정상 참조 거리의 상위 분위수(Q95)로 나누어 단위를 맞추고, 깊은 계층의 평균에 얕은 계층을 작은 가중치로 더한다. 해상도 축에서는 위치별 점수 순위에 따라 Rényi 가중치를 적용하여 산술 평균에서 생기는 국소 반응의 희석을 줄인다. 백본의 추가 학습이나 쿼리 시점 파라미터 갱신은 사용하지 않는다. MVTec AD 2에서 ScopeAD는 1–16-shot의 모든 조건에서 비교 방법보다 높은 $\mathrm{AUPRO}_{0.05}$, $\mathrm{pAUROC}_{0.05}$, I-AUROC를 기록했으며, 1-shot $\mathrm{AUPRO}_{0.05}$는 52.18 %로 차순위보다 5.87 pp 높다. 구성 요소 분석에서는 다해상도 관측과 관측별 독립 매칭이 가장 큰 향상을 주었고, Q95 보정 아래에서 Rényi 집계가 추가 향상을 주었다. MVTec AD와 VisA에서도 비교 방법과 대등한 성능을 보였다.*

1. 서론

다품종 소량 생산과 빈번한 라인 전환이 발생하는 제조 환경에서는 제품별 결함 표본을 충분히 수집하기 어렵다. 이에 따라 소수의 정상 참조 이미지만으로 결함 위치를 특정하는 few-shot anomaly localization이 실용적인 대안으로 활용된다. 대표적으로, 동결된 사전학습 백본 [12]으로 정상 패치의 메모리 뱅크를 구축한 후, 테스트 패치와의 최근접 이웃 거리를 계산하여 이상치를 탐지하는 방법이 있다 [3, 15, 19]. 이러한 거리 기반 점수는 정상 패치가 메모리 뱅크의 특징과 유사하다는 가정에 기반한다. 그러나 실제 공정에서는 조명 드리프트, 부품 자세 변동, 표면 난반사 등 다양한 distribution shift가 빈번히 발생한다 [6, 21]. 소수의 정상 표본만 주어지는 few-shot 환경에서는 이러한 외부 조건 변화에 따른 정상 외관의 변동폭을 메모리 뱅크에 충분히 담기 어렵다. 그 결과 서포트 셋에서 관측되지 않은 정상 변동 영역에서도 최근접 거리가 상승하여 실제 결함 점수와 겹칠 수 있다. 이처럼 정상 표본의 희소성과 획득 환경 변화가 함께 작용하면, 단일 거리값만으로는 고점수의 원인이 실제 결함인지 미관측 정상 변동인지 판별하기 어렵다. 본 논문은 이러한 한계를 **High-Score Ambiguity**로 정의한다(Fig. 1). 이 현상은 오경보를 엄격히 제한해야 하는 low-FPR 구간의 결함 국소화 성능을 저해한다. 정상 위치의 높은 점수를 배제하기 위해 임계값을 높이면, 그만큼 탐지 가능한 결함 영역 또한 함께 줄어들기 때문이다 [2].

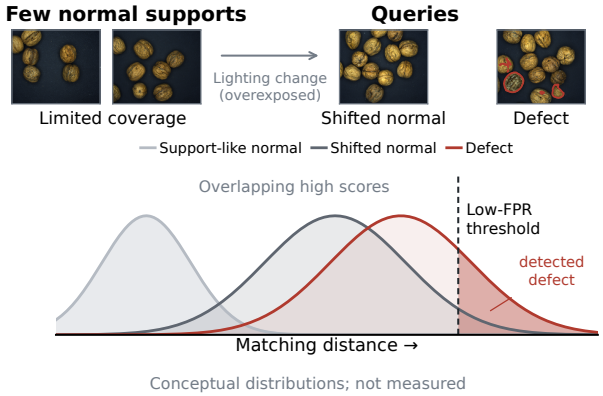


Figure 1. **Few-shot 서포트와 획득 조건 변화.** 적은 정상 참조는 정상 외관의 일부만 포함한다. 조명이 바뀌면 정상 쿼리와 결함 쿼리가 모두 큰 매칭 거리를 가질 수 있고, 저-FPR 임계값에서는 결함 분포의 꼬리만 검출된다. 이미지는 MVTec AD 2 walnuts 표본이며(서포트는 regular, 쿼리는 overexposed, 결함은 빨간 윤곽), 분포는 측정값이 아닌 개념도다.

이러한 High-Score Ambiguity 환경에서는 단일 해상도·단일 계층의 정보만으로 정상 변동과 결함을 안정적으로 분리하기 어렵다. 서포트 이미지 수 자체를 늘릴 수 없다면, 한정된 정상 표본으로부터 결함 판정에 유효한 비교 단서를 여러 관점에서 추출하는 관측 확장(observation expansion)이 필요하다. 본 논문은 이를 위해 표현 계층과 입력 해상도의 두 축으로 관측 공간을 확장한다. ViT의 계층은 국소 외관부터 전역 문맥까지 깊이에 따라 서로

다른 추상화 수준을 담고 있으며 [13, 14], 입력 해상도는 고정 패치 크기 백본에서 각 토큰이 담당하는 물리적 수용영역(receptive field)의 크기를 결정한다 [5, 16]. 하지만 이처럼 서로 다른 척도의 단서들을 기존처럼 단일 고차원 벡터로 연결해 매칭하면 [15], 분산이 큰 특정 계층이 이웃 탐색을 지배하여 다른 계층의 비교 단서가 묻힐 수 있다. 따라서 본 논문은 각 계층과 해상도의 조합마다 독립된 메모리 뱅크를 구축하고 개별 1-NN 매칭을 수행하여, 국소 결함 단서와 전역 문맥 차이를 각자의 표현·공간 척도에서 별도의 비교 단서로 유지한다.

그러나 독립적으로 확보한 다관측 거리를 보정 없이 결합하면 **High-Score Ambiguity**가 줄어들지 않고 오히려 커질 수 있는 두 가지 왜곡이 발생한다. 첫째는 관측 간 척도 불균형(scale discrepancy)이다. 특징 공간의 거리 스케일은 계층 깊이와 입력 해상도에 따라 다르므로, 단순 합산하면 평균 거리가 큰 관측이 전체 점수를 지배하고 그 관측의 오경보가 결합 점수에 그대로 반영된다. 둘째는 축 고유 특성을 무시한 평균화의 한계이다. 척도를 정규화하더라도 단순 산술 평균을 적용하면, 정상 외관 변동에 민감한 얕은 계층의 오경보가 그대로 누적되거나, 특정 해상도에서만 강하게 나타나는 결함 반응이 다른 해상도의 낮은 점수와 섞여 희석(dilution)된다. 따라서 다관측 통합에는 관측 간 스케일을 공통 척도로 맞추는 단계와, 각 축의 표현적·공간적 역할에 맞추어 결함 신호를 보존하는 결합 규칙이 함께 필요하다.

본 논문은 이 두 문제를 다루는 점수 통합 방법 **ScopeAD**를 제안한다. ScopeAD는 정상 서포트 내부의 교차 매칭 거리에서 관측별 상위 분위수를 구하고, 이를 기준 단위로 삼아 관측 간 척도를 맞춘다. 계층 결합에서는 전역 문맥을 담은 깊은 계층을 주축으로 삼고, 얕은 계층의 국소 단서는 작은 가중치로만 더한다. 해상도 결합에서는 위치마다 해상도 점수를 정렬한 뒤 높은 순위에 큰 Rényi 가중치를 주어, 평균에 따른 국소 반응의 희석을 줄인다. 이 과정은 백본 추가 학습이나 쿼리 적응(query adaptation) 없이 정상 서포트만으로 이루어진다. MVTec AD 2의 few-shot 평가에서 ScopeAD는 모든 shot에서 비교 방법보다 높은 저-FPR 국소화 성능을 보였고, MVTec AD와 VisA에서도 경쟁력 있는 성능을 유지했다.

본 논문의 기여는 다음과 같다.

- 제한된 정상 서포트에서 다양한 비교 단서를 확보하도록, 동결 백본의 계층과 입력 해상도를 독립 매칭 단위로 분리·확장하는 few-shot 이상 국소화 방법 ScopeAD를 제시한다.
- 정상 참조 척도 정렬, 계층별 비대칭 가중합, 위치별 해상도 순위 집계를 결합하여 거리 단위와 관측별 기여를 함께 다루는 점수 통합 방법을 제안한다.
- MVTec AD 2에서 저-FPR 국소화 성능, 구성 요소별 기여, 보정과 집계의 상호작용을 평가하고, MVTec AD·VisA 교차 평가와 계산 비용을 보고한다.

2. 관련 연구

2.1. Few-shot 이상 탐지의 참조 매칭

Few-shot 이상 탐지는 소수의 정상 이미지에서 얻은 참조와 쿼리를 비교하여 결함을 찾는다. 제한된 참조를 활용하기 위해 이미지 간 정합을 학습하거나 [7], 언어 정보로 정상과 이상의 구분을 보완하는 방법이 연구되었다 [8, 11]. 관련 접근으로는 보조 데이터에서 비교 규칙이나 프롬프트를 학습하는 방법 [22, 23]과, 정상 서포트 대신 레이블 없는 테스트 이미지끼리 비교하는 방법 [10]도 있다. 본 논문과 같이 정상 서포트와 동결된 시각 특징을 사용하는 접근은 정상 참조와의 차이를 최근접 이웃 거리 [3, 15, 19], 복원 오차 [4], 부분공간 거리 [9]로 측정한다. 특히 동결 특징의 패치 매칭은 백본의 추가 학습 없이 새로운 제품의 정상 참조를 구성할 수 있으며 [3, 19], MVTec AD 2의 few-shot 연구 [17]에서도 특징 계층과 서포트 수에 따른 성능 차이가 분석되었다. ScopeAD는 이러한 참조 매칭을 계층과 해상도의 여러 관측으로 확장하고, 여기서 얻은 거리 점수를 통합하는 데 초점을 둔다. 비교 단서를 늘리는 동시에 관측마다 다른 거리 단위와 기여도를 조절하여, 서론에서 논의한 정상 변동과 결함의 점수 중첩을 줄이고자 한다.

2.2. 다중 척도 관측과 점수 결합

여러 계층과 해상도의 특징을 함께 활용하면 국소 질감과 전역 문맥을 서로 다른 관점에서 비교할 수 있다. 다층 ViT 특징을 재조합하는 DPT [14]와 다중 해상도 입력으로 동결 백본의 표현을 확장하는 S^2 [16]는 이러한 접근의 예다. 이상 탐지에서는 여러 특징을 먼저 합쳐 매칭하거나, 개별 매칭 점수를 구한 뒤 결합할 수 있다. PatchCore [15]의 특징 연결 방식은 여러 계층이 하나의 최근접 이웃을 공유하는 반면, SuperAD [19]와 FreePatch [18]는 개별 점수를 결합하는 접근을 사용한다. 점수 수준의 결합은 각 관측의 비교 결과를 유지할 수 있지만, 관측마다 거리 단위가 다르면 큰 거리값을 내는 관측에 결합 점수가 치우칠 수 있다. 단위를 맞춘 뒤에도 계층별 정상 변동 민감도와 해상도별 결함 반응이 다르므로, 모든 점수를 같은 비중으로 평균하는 방식에는 한계가 있다. ScopeAD는 정상 서포트로 거리 단위를 맞춘 뒤 계층별 기여도를 조절하고, 해상도 크기가 아닌 위치별 점수 순위에 따라 집계하여 강한 국소 반응의 희석을 줄이고자 한다(Secs. 3.3 and 3.4).

2.3. 획득 조건 변화와 저-FPR 국소화

정상 참조와 쿼리의 획득 조건이 달라지면, 결함이 없어도 외관 차이로 인해 매칭 거리가 커질 수 있다. 이러한 변화를 평가하기 위해 AeBAD [21]는 실제 공정의 도메인 변화를, MVTec AD 2 [6]는 학습 자료에 없는 조명 조건을 포함한다. Few-shot 설정에서는 정상 서포트가 이러한 변화를 충분히 담기 어려우므로, 정상 영역의 점수 상승이 오경보를 얼마나 유발하는지 살펴볼 필요가 있다. 전체 FPR 구간을 요약하는 AUROC와 달리, AUPIMO [2]는 오경보를 낮게 제한한 구간에서 결함 영역을 얼마나 검출하는지 평가한다. 본 논문은 MVTec AD 2의 정상 서포트

수를 제한하여 적은 참조 표본과 획득 조건 변화가 함께 있는 상황을 구성하고, 백본 추가 학습이나 쿼리 시점 최적화 없이 동작하는 ScopeAD의 저-FPR 국소화 성능을 평가한다. MVTec AD와 VisA에서는 기존 벤치마크에서도 성능이 유지되는지 함께 확인한다.

3. 방법

ScopeAD는 관측 확장(observation expansion)과 정상 참조 기반 점수 통합을 결합하여, 소수 서포트와 환경 변화로 인한 High-Score Ambiguity를 완화하는 이상 국소화 프레임워크다(Fig. 2). 그 중심에서 ScopeAD는 표현 계층과 입력 해상도를 독립 매칭 단위로 분리하는 관측 확장을 수행하여, 특정 계층이나 해상도가 거리 계산을 지배하는 간섭을 배제하고 단일 영역에 대한 다각적 시각 단서를 확보한다. 이렇게 확보된 다관측 거리들을 효과적으로 결합하기 위해 세 가지 요소를 단계적으로 통합한다: (1) 서포트 교차 매칭 분포의 상위 분위수로 기준 단위를 정렬하는 **정상 참조 척도화(Reference Scaling)**, (2) 전역 문맥을 담은 심층 특징을 기저로 삼고 얕은 계층의 반응을 수축 결합하는 **계층별 비대칭 결합(Asymmetric Layer Fusion)**, 그리고 (3) 위치별 해상도 점수 순위에 따라 상위 반응을 안정적으로 보존하는 **Rényi 순서 통계량 집계(Rényi Order-Rank Aggregation)**이다. 추론 시 ScopeAD는 백본의 추가 학습이나 쿼리 적응 없이, 정상 서포트의 무감독 통계량만을 활용하여 단일 패스에서 픽셀 단위 결함 맵과 이미지 점수를 산출한다.

3.1. 문제 설정

입력으로 N장의 정상 서포트 이미지 집합 $\mathcal{S} = \{x_1^s, \ldots, x_N^s\}$, 테스트 쿼리 이미지 x^q, 그리고 동결된 사전학습 비전 트랜스포머(ViT) 백본이 주어진다. 특징을 추출할 백본 계층 집합을 $\mathcal{L}$, 입력 해상도(짧은 변 기준) 집합을 $\mathcal{R}$, 서브샘플 배그(bag) 수를 B로 정의한다. 본 연구에서는 $\mathcal{L} = \{5, 11, 23\}$, $\mathcal{R} = \{448, 672, 896, 1120\}$, $B = 4$를 사용하여 총 $|\mathcal{L}| \times |\mathcal{R}| \times B = 48$개의 독립 관측을 구성한다(Sec. 4.1). ScopeAD는 백본의 추가 학습이나 쿼리 적응(query adaptation) 없이, 오직 정상 서포트의 무감독 통계량만을 기반으로 픽셀 단위 결함 국소화 맵 $A(x^q) \in \mathbb{R}^{H \times W}$ 및 이미지 단위 이상 점수 $s(x^q) \in \mathbb{R}$를 산출한다.

3.2. 관측 확장과 독립 참조 매칭

관측별 독립 매칭 (Independent Matching). 획득 조건이 달라지면 정상 영역이라도 특정 계층의 국소 질감이나 특정 해상도의 패치에서 거리가 급격히 상승할 수 있다. 기존처럼 다층 특징을 단일 벡터로 연결해 매칭하면 [15], 분산이나 척도가 큰 특정 관측이 최근접 이웃 탐색 전체를 지배하여 정상 외관 변화에 따른 국소적 거리 상승이 다른 모든 계층의 비교 단서를 왜곡하게 된다. 이러한 간섭을 차단하기 위해 ScopeAD는 계층 $l \in \mathcal{L}$, 해상도 $r \in \mathcal{R}$, 배그 인덱스 $b \in \{1, \ldots, B\}$의 조합 $m = (l, r, b)$를 개별 관측 단위로 분리하고, 각 관측마다 독립적인 정상 메모리 뱅크 B_m을 구축한다. 쿼리 이미지 x^q의 공간 위치 p에서 추출된 ℓ_2 정규화 패치 토큰 $f_m(x^q, p)$는 오직 대응하는 뱅크 B_m 내에서만 독립적으로 최근접 이웃을 탐색하여 코사인 거리 점수를 계산한다:

$$d_m(x^q, p) = \min_{u \in B_m} \left[1 - f_m(x^q, p)^\top u\right]. \quad (1)$$

이 분리 매칭 구조에서는 각 관측이 고유한 표현·공간 척도 안에서 가장 가까운 정상을 개별적으로 찾는다. 그 결과 특정 척도에서 발생한 정상 외관 변동의 섭동이 다른 관측으로 전파되지 않고 격리되며, 국소 질감 단서와 전역 문맥 단서가 독립적인 거리 신호로 온전히 보존되어 후속 통합 단계에서 상호 검증의 기반을 마련한다.

패치 서브샘플 배깅 (Patch Subsample Bagging). 입력 해상도가 증가함에 따라 서포트 패치 토큰의 수가 급격히 팽창하며, 단일 무작위 샘플링은 토큰 구성에 따른 추정 분산을 유발할 수 있다. 이를 완화하기 위해 각 해상도 r에서 서포트 이미지당 K개($K = 256$)의 패치 토큰을 비복원 균등 추출하여 단일 배그를 구성하며, 서로 다른 난수 시드로 B개의 배그를 생성한다. 이때 일관된 공간 대응을 유지하기 위해 동일 배그 내의 모든 계층은 완전히 일치하는 공간 좌표의 토큰을 공유한다. 각 배그에서 산출된 이상 점수는 이후 Eq. (6)에서 앙상블 평균된다.

3.3. 정상 참조 기반 비대칭 선형 결합

독립적으로 획득한 원시 거리 d_m을 통합하기 위해서는 (1) 관측 간 척도 불균형(scale discrepancy)과 (2) 계층별 의미론적 민감도 차이를 단계적으로 다루어야 한다. 특징 공간의 차원과 표현 특성에 따라 원시 거리의 통계적 척도가 상이하므로(Fig. 3), 보정 없이 결합하면 스케일이 큰 관측의 오경보가 결합 점수에 그대로 반영된다. 또한 척도를 정규화하더라도 국소 질감에 민감한 얕은 계층은 조명이나 자세 변화 등 정상 외관 변동에 큰 거리를 유발하기 쉽다. 따라서 ScopeAD는 서포트 교차 매칭 기반의 척도 c_m으로 단위를 정렬한 뒤, 비대칭 계층 가중치 α_l을 적용하여 선형 결합을 수행한다.

서포트 교차 매칭 기반 척도 추정 (Cross-Validation Scale Estimation). 미지의 쿼리 이미지와의 매칭 환경을 모사하기 위해, 서포트 집합 내부의 교차 매칭 거리 표본 D_m을 활용하여 관측별 기준 척도를 추정한다. 다중 샷($N > 1$) 환경에서는 동일 이미지 내의 자기 유사 패치와 매칭되어 거리가 과소 추정되는 편향을 방지하고자, 서포트 이미지 i의 토큰 부분집합 $B_m^{(i)}$를 해당 이미지를 제외한 나머지 뱅크 토큰들과 매칭하는 Leave-Source-Out (LSO) 방식을 적용한다:

$$D_m^{\mathrm{LSO}} = \bigcup_{i=1}^{N} \left\{ \min_{u \in B_m \setminus B_m^{(i)}} \left[1 - v^\top u\right] : v \in B_m^{(i)} \right\}. \quad (2)$$

단일 샷($N = 1$) 환경에서는 이미지 간 교차 비교가 불가능하므로, 단일 이미지 내에서 자기 자신을 제외한 타

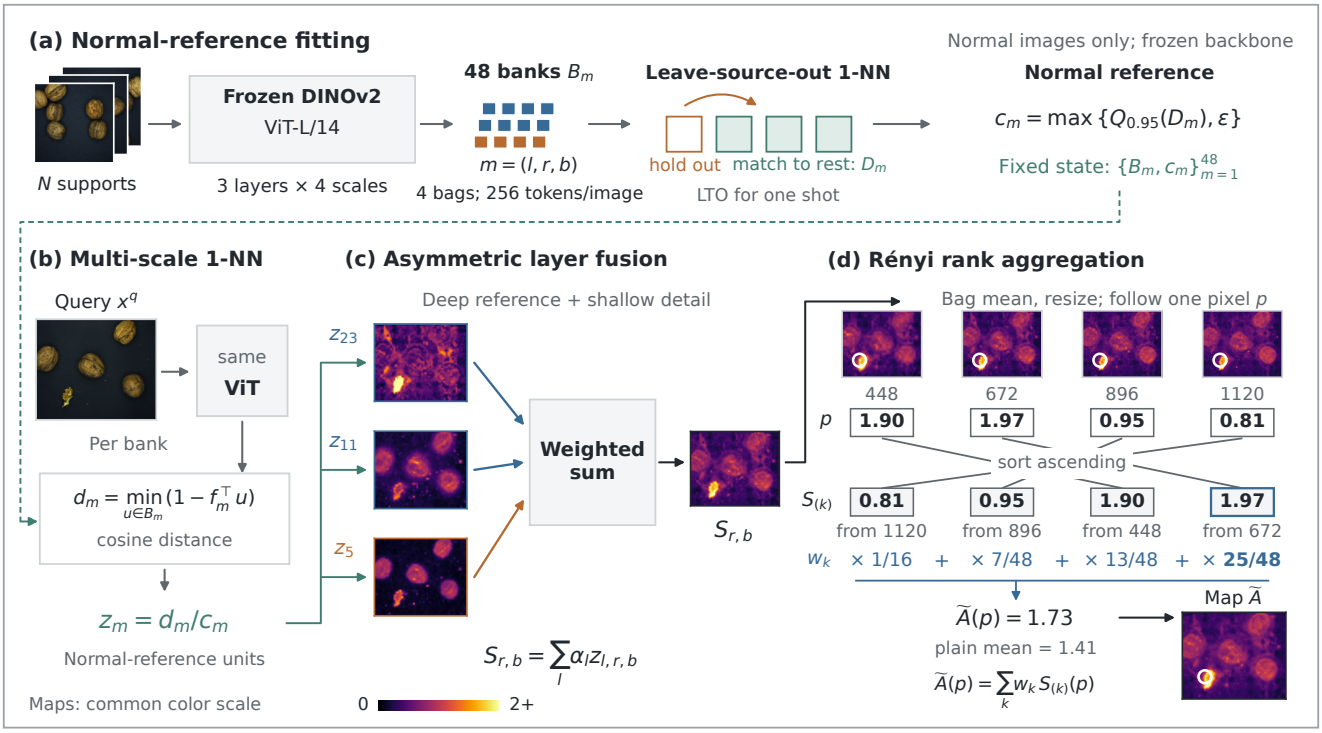


Figure 2. **Overview of ScopeAD.** (a) 정상 서포트 표본으로부터 leave-source-out (1-shot의 경우 leave-token-out) 교차 매칭을 통해 48개의 독립 메모리 뱅크를 구축하고 참조 척도 c_m을 추정한다. (b) 코사인 1-NN 거리 d_m을 해당 척도로 정규화하여 공통 단위 점수 $z_m = d_m/c_m$을 도출한다. (c) 전역 문맥을 담은 깊은 계층을 주축으로 얕은 계층의 단서를 보조 결합하는 비대칭 선형 가중합을 수행한다. (d) 배그 평균 및 원본 해상도 보간 후, 각 픽셀 위치에서 정렬된 해상도 점수에 Rényi 순서 통계량 가중치를 적용하여 최종 이상 맵을 집계한다. 가중치는 해상도 크기가 아닌 점수 크기 순위에 따라 비대칭적으로 부여된다. 예시는 결함 픽셀 p의 실제 점수다(평균 1.41).

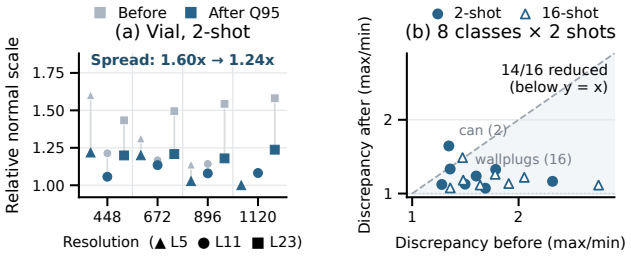


Figure 3. **정상 참조 보정(Q95)을 통한 관측 간 거리 척도 정렬.** (a) Vial 2-shot 정상 쿼리에서 12개 관측(4개 해상도 × 3개 계층)의 상대 정상 척도. 보정 전(회색)에는 관측마다 정상 거리 척도가 최대 1.60배까지 불균일하여 특정 관측이 결합을 왜곡하지만, Q95 보정 후(청색)에는 모든 관측이 공통 기준선 근처로 균일하게 정렬된다(최대 편차 1.60배 → 1.24배). (b) MVTec AD 2 전 클래스(8개 클래스 × 2개 shot)에서 관측 간 척도 불균형(최대/최소 척도 비율). 16개 조건 중 14개 조건에서 보정 후 척도 편차가 대각선($y = x$) 아래로 크게 감소하여 안정적으로 정렬됨을 보인다.

위치 토큰들과 매칭하는 Leave-Token-Out (LTO) 표본을 대리 통계량으로 사용한다:

$$D_m^{\mathrm{LTO}} = \left\{ \min_{j \neq i} \left(1 - v_i^\top v_j\right) : i = 1, \ldots, K \right\}. \tag{3}$$

각 관측의 정상 거리 분포는 비대칭성과 꼬리 두께가 상이하므로, 특정 확률분포 형태를 가정하는 모수적 통계량 대신 비모수적 순서 통계량인 상위 분위수 $\mathcal{Q}_q$로 기준 척도 c_m을 정의하고 정규화 점수 z_m을 산출한다:

$$c_m = \max\left\{\mathcal{Q}_q(D_m),\, \epsilon\right\}, \qquad z_m(x^q, p) = \frac{d_m(x^q, p)}{c_m}, \tag{4}$$

여기서 $q = 0.95$는 서포트 집합 내에서 관측되는 정상 거리의 상위 경계를 대표하는 분위수이며, $\epsilon = 10^{-4}$는 수치적 안정성을 위한 하한값이다. 기준 척도 c_m은 각 관측 뱅크가 포착한 정상 외관 변동의 실질적 상한선을 뜻한다. 따라서 $z_m = d_m/c_m$ 변환은 이질적인 원시 거리들을 '정상 변동 상한 대비 초과율'이라는 동일한 무차원 판정선($z_m = 1.0$) 위에 정렬한다(Fig. 3). 이를 통해 원시 거리의 절대적인 기저 크기가 큰 특정 계층이나 해상도가 결합 점수를 일방적으로 지배하여, 정상 외관 변동이 결합 점수에서 오경보로 전파되는 왜곡을 완화한다.

계층 간 비대칭 결합 (Asymmetric Layer Fusion). 척도가 정렬된 점수 z_m 공간에서도 계층 간 역할 차이가 존재한다. 조명이나 표면 텍스처 등 획득 조건이 달라지면 국소 외관에 반응하는 얕은 계층은 정상 영역에서도 거리가 크게 치솟기 쉽다. 반면 전역 문맥을 담은 심층 계층은 획득 환경이 변화하더라도 정상 구조의 의미론적 일관성을 유지하므로, 정상 영역의 점수를 상대적으로 낮게 보존하는 안정적인 기저 판정선을 제공한다. 이를 반영하여 깊은 계층들($\mathcal{L}_{\text{deep}} = \{11, 23\}$)의 정규화 점수 평균을 기저 점수로 삼고, 정상 변동에 취약한 얕은 계층($l = 5$)은 작은 가중치 $\lambda = 0.125$로 축소 결합한다:

$$S_{r,b}(x^q, p) = \frac{1}{2} \sum_{l \in \{11,23\}} z_{l,r,b}(x^q, p) + \lambda \, z_{5,r,b}(x^q, p). \tag{5}$$

이 비대칭 결합은 환경 변화로 인한 얕은 계층의 오경보 유입을 전역 문맥 기저선으로 억제하면서, 국소 미세 결함 단서만을 선별적으로 보완한다. 정규화 점수 정의($z_m = d_m / c_m$)에 따라, 이는 원시 거리 $d_{l,r,b}$를 계층 가중치 $\alpha = (0.125, 0.5, 0.5)$와 각 관측의 기준 척도 $c_{l,r,b}$의 비율인 $w_{l,r,b} = \alpha_l / c_{l,r,b}$로 선형 결합하는 것과 같다.

3.4. 다해상도 순서 통계량 집계

앞선 계층 결합을 거친 이상 점수는 여전히 R개의 입력 해상도별 맵으로 분리되어 있다. 먼저 각 해상도 r에서 B개 배그의 점수를 평균하여 패치 서브샘플링에 따른 추정 분산을 완화한 뒤, 양선형 보간(bilinear interpolation)을 통해 모든 해상도 맵 S_r을 원본 이미지 크기 (H, W)로 공간 정렬한다:

$$S_r(x^q, p) = \frac{1}{B} \sum_{b=1}^{B} S_{r,b}(x^q, p). \tag{6}$$

Rényi 순서 통계량 집계 (Order-Statistics Aggregation). 공간 축이 정렬된 다해상도 점수 맵들을 결합할 때, 단순 산술 평균($1/R = 0.25$)은 특정 해상도에서만 뚜렷하게 관측되는 유효 결함 피크를 타 해상도의 낮은 점수와 섞어 희석시킨다. 반대로 결함 피크를 보존하기 위해 단순히 최댓값(max)만을 취하면, 정상 영역에서 단일 해상도에 우연히 발생한 단발성 잡음 스파이크가 그대로 최종 결함 점수로 채택되어 오경보를 유발한다. 따라서 다해상도 결합에는 최상위 반응의 피크는 온전히 보존하면서도, 단일 관측 잡음의 돌출을 다관측 지지 반응으로 완충(damping)하는 비대칭 가중 체계가 필요하다.

이러한 상위 편향 가중치를 자의적인 휴리스틱 튜닝 없이 결정하기 위해, 이상 탐지의 극치 꼬리 거동(tail behavior)을 다루는 표준 지수 분포의 순서 통계량 기댓값 간격(Rényi representation, $a_k = \sum_{j=1}^{k} \frac{1}{R-j+1}$)을 참조 모형으로 채택한다. 조화 수열(harmonic sum)에 기반한 이 기댓값 구조는 최상위 순위로 갈수록 가중치가 자연스럽게 완만히 증가하는 특성을 갖는다. $R = 4$일 때 정규화된 Rényi 순위 가중치 $w = (\frac{1}{16}, \frac{7}{48}, \frac{13}{48}, \frac{25}{48}) \approx (0.063, 0.146, 0.271, 0.521)$를 통해 다해상도 결합 맵을 산출한다:

$$\tilde{A}(x^q, p) = \sum_{k=1}^{R} w_k \, S_{(k)}(x^q, p). \tag{7}$$

이 가중 체계는 다해상도 이상 맵 결합에 두 가지 실질적인 이점을 제공한다: (1) 최상위 점수 순위에 약 52.1% (25/48)의 지배적인 가중치를 부여하여 특정 해상도에 집중된 결함 피크 신호의 희석을 직접적으로 방어한다. (2) 동시에 차상위 순위들($k = 2, 3$)에도 약 41.7%(20/48)의 완만한 지지 가중치를 분배함으로써, max 집계처럼 한 해상도에서만 외톨이로 튄 국소 잡음 스파이크가 최종 결함으로 과대 채택되는 불안정성을 효과적으로 완충한다. 특히 앞 절의 **정상 참조 척도 보정**(c_m)이 모든 해상도의 정상 기저 점수를 $z = 1.0$ 기준으로 균일화해 두었기 때문에, 특정 해상도의 기저 잡음이 상위 순위를 차지해 오경보를 유발하는 위험 없이 유효 결함 반응만을 안전하게 보존할 수 있다. Rényi 집계와 보정의 상호작용 메커니즘 분석은 Sec. 4.4에서 다룬다.

이미지 수준 이상 점수. 최종 픽셀 단위 결함 국소화 맵은 $A(x^q) = \tilde{A}(x^q)$로 정의된다. 이미지 수준 이상 점수 $s(x^q)$는 $A(x^q)$ 내 상위 1% 픽셀 집합 $\Omega_{0.01}(|\Omega_{0.01}| = \max\{1, \lfloor 0.01HW \rfloor\})$의 평균값으로 정의된다:

$$s(x^q) = \frac{1}{|\Omega_{0.01}|} \sum_{p \in \Omega_{0.01}} A(x^q, p). \tag{8}$$

4. 실험

Few-shot 주 비교에 이어 구성 요소의 기여, 보정과 집계의 상호작용, 계산 비용과 파라미터 민감도를 평가한다.

4.1. 평가 설정

데이터셋. MVTec AD 2 [6]는 학습 자료에 없는 조명 조건을 포함하여, 제한된 정상 참조의 외관 범위를 벗어나는 쿼리를 평가할 수 있다. 평가에는 정답 마스크가 공개된 `test_public`(정상 379장, 결함 705장, 8개 클래스)을 사용하고, 정상 서포트 이미지는 `train/good`에서 고정 시드와 매니페스트로 선별한다. 기존 벤치마크에서의 성능을 확인하기 위해 MVTec AD(15개 클래스) [1]와 VisA (12개 클래스) [24]도 평가한다.

Few-shot 설정 및 비교군. 클래스당 정상 서포트 이미지 수 N은 $\{1, 2, 4, 8, 16\}$이다. ScopeAD는 동결된 DINOv2 ViT-L/14 백본에서 계층 $\{5, 11, 23\}$과 4개 해상도 $\{448, 672, 896, 1120\}$을 사용하며, FP16 autocast와 서포트 이미지당 토큰 상한 256을 적용한다. 정상 참조 분위수 $q = 0.95$와 얕은 계층 가중치 $\lambda = 0.125$는 모든 데이터셋과 shot에 동일하게 고정한다. 비교 방법은 PatchCore [15], SuperAD [19], AnomalyDINO [3], FastRecon [4], RAD [20], SubspaceAD [9], RegAD [7]다. 같은 shot과 seed에서는 서포트 이미지, 쿼리 및 평가기를 공유하며, 비교 방법은 단일 1120 해상도를 사용한다(RegAD

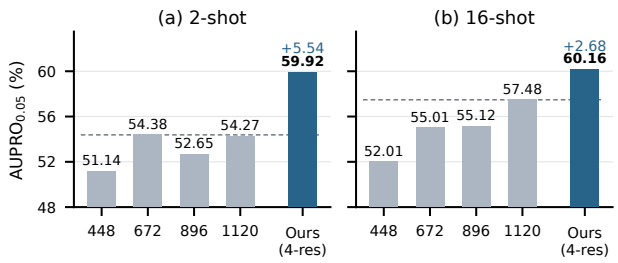


Figure 4. **단일 해상도와 4해상도 결합의** $\mathrm{AUPRO}_{0.05}$ **(MVTec AD 2, seed 0).** 회색 막대는 최종 방법을 한 해상도에만 적용한 결과로, Tab. 3의 A와 다르다. 점선은 가장 높은 단일 해상도이며, 파란 숫자는 그 대비 ScopeAD의 향상 폭(pp)이다.

는 STN 제약으로 224). 지표는 클래스 macro $\mathrm{AUPRO}_{0.05}$, $\mathrm{pAUROC}_{0.05}$ 및 이미지 단위 I-AUROC다.

4.2. Few-shot 주 비교

Tab. 1는 MVTec AD 2 `test_public`에서의 few-shot 주 비교 결과다. ScopeAD는 1, 2, 4, 8, 16-shot에서 세 지표 모두 비교 방법 중 가장 높은 평균을 기록했다. 1-shot에서 $\mathrm{AUPRO}_{0.05}$는 52.18 %로 차순위인 SuperAD(46.31 %)보다 5.87 pp, PatchCore(38.45 %)보다 13.73 pp 높고, 16-shot에서는 60.74 %다. FPR을 5 % 이하로 제한한 구간에서 결함 영역을 더 많이 찾았다는 뜻이다. 세 시드의 평균과 표본 표준편차를 보고한다.

Tab. 2는 MVTec AD와 VisA의 결과다. 두 벤치마크는 MVTec AD 2보다 획득 조건 변화가 작고 기존 방법의 성능도 높다. ScopeAD는 MVTec AD의 2, 4-shot과 VisA의 4, 8, 16-shot에서 가장 높은 I-AUROC를 보였고, 나머지 조건에서도 최고값과의 차이가 작다. P-AUROC는 SuperAD나 FastRecon보다 다소 낮은 조건이 있지만, 모든 조건에서 96 % 이상을 유지했다. 따라서 MVTec AD 2를 위한 설계가 기존 벤치마크의 성능을 크게 낮추지 않는다.

4.3. 구성 요소 분석

Tab. 3는 단일 해상도 기준선(A)에서 최종 모델(F)까지 구성 요소를 차례로 더한 결과다. 가장 큰 향상은 다중 해상도와 개별 뱅크에서 나온다. 2-shot에서 A에서 C까지 7.72 pp 높아진다. 이후 얕은 계층 결합, 보정, Rényi 집계를 더해 F는 2-shot 59.92 %, 16-shot 60.16 %다. 누적 비교는 추가 순서에 의존하므로 보정과 집계의 상호작용은 Sec. 4.4에서 따로 분석한다.

다해상도 관측과 토큰 수. Tab. 4에서 단일 1120 해상도의 토큰 상한을 1024로 늘려 총 토큰 상한을 맞추면 $\mathrm{AUPRO}_{0.05}$는 57.13 %로, 같은 총량을 4개 해상도(각 256)에 나눈 ScopeAD(60.16 %)보다 3.03 pp 낮다. 따라서 다해상도의 이득은 토큰 수 증가만으로 설명되지 않는다. 같은 방법을 해상도 하나에만 적용한 결과와 비교해도, 4해상도 결합은 가장 높은 단일 해상도보다 2-shot에서 5.54 pp, 16-shot에서 2.68 pp 높다(Fig. 4).

특징 연결 대 관측별 독립 매칭. 여러 계층 특징을 하나의 벡터로 연결해 최근접 이웃을 찾는 방식(Layer concat)과 비교하면, 관측별 독립 매칭은 MVTec AD 2의 $\mathrm{AUPRO}_{0.05}$를 2-shot에서 7.21 pp(52.12 → 59.33 %), 16-shot에서 2.09 pp(57.48 → 59.57 %) 높였다. MVTec AD (98.19 → 98.74 %)와 VisA(94.09 → 95.99 %)의 16-shot I-AUROC도 높아졌다. 독립 매칭은 계층마다 다른 정상 이웃을 선택할 수 있다. 다만 이 비교는 차원 증가와 계층 간 간섭의 효과를 따로 분리하지 않는다.

4.4. 정상 참조 보정과 Rényi 집계의 작동 분석

보정과 집계의 상호작용. Tab. 5에서 Mean을 Rényi로 바꾼 $\mathrm{AUPRO}_{0.05}$ 차이는 보정이 없을 때 2/16-shot에서 $+0.20/-0.01$ pp, Q95 보정 아래에서 $+0.75/+0.68$ pp다. Mean 집계에서 Q95만 적용한 효과는 $-0.09/+0.32$ pp이므로, 두 구성 요소의 이득은 함께 적용될 때 주로 나타난다. 차이의 차이 (Q95+R − Q95+Mean) − (none+R − none+Mean)는 $+0.54/+0.69$ pp다. 세 seed를 클래스 안에서 평균한 뒤 8개 클래스를 재표집한 95 % bootstrap 구간은 각각 $[-0.31, +1.82]$, $[-0.29, +2.24]$ pp로 0을 포함하므로, 이 결합 이득이 모든 클래스에서 나타난다고 보기는 어렵다. $\mathrm{pAUROC}_{0.05}$에서는 같은 상호작용이 나타나지 않았다.

상호작용의 원인. 집계와 보정의 상호작용 메커니즘을 분석하기 위해, 4개 해상도의 평균 $\mu(p) = \frac{1}{4}\sum_{r=1}^{4} S_r(p)$와 인접 순위 간격 $g_i(p) = S_{(i+1)}(p) - S_{(i)}(p)$를 정의하면 Rényi 결합 점수는 다음과 같이 대수적으로 정확히 분해된다:

$$\tilde{A}(p) = \mu(p) + E(p), \quad E(p) = \frac{9g_1(p) + 14g_2(p) + 13g_3(p)}{48}. \tag{9}$$

추가 응답 항 $E(p) \geq 0$는 해상도 간 응답 편차가 클수록 커지므로, 결함뿐 아니라 정상 영역의 큰 응답도 함께 키울 수 있다. 그러나 Q95 보정 후에는 정상 및 배경 영역의 상대 추가 응답(E/μ)이 크게 감소한 반면 결함 영역의 응답은 안정적으로 유지되었다(Appendix A.3). 즉 정상 참조 보정이 정상 영역의 해상도 간 기저 편차를 줄여줌으로써, Rényi 집계가 정상 잡음의 돌출 없이 유효 결함 반응만을 안전하게 증폭하도록 만든다는 점을 실증한다. 보정 분모를 계층과 해상도 성분으로 나누어 적용하면 Rényi 아래의 이득은 주로 해상도 성분에서 나타났다(Resolution−Global $+0.55/+0.82$ pp). 계층 성분만의 효과는 shot에 따라 방향이 달랐다(Appendix A.4). 해상도 성분의 이득은 fabric 클래스의 기여가 크며, 클래스별 분석은 Appendix A.5에 보고한다.

4.5. 계산 비용과 파라미터 민감도

계산 비용. Tab. 4에서 4해상도 ScopeAD(cap 256)는 이미지당 1.37초, 최대 3.12 GiB를 사용한다. 토큰 상한을 1024로 늘리면 $\mathrm{AUPRO}_{0.05}$는 0.17 pp 높아지지만, 쿼리 시간은 1.31배, 최대 메모리는 2.15배 늘어난다. 따라서 cap 256을 기본값으로 사용한다.

파라미터 민감도. $q = 0.90, 0.95, 0.99$에서 $\mathrm{AUPRO}_{0.05}$의 범위는 2-shot 59.81–59.92 %, 16-shot 60.15–60.19 %

Table 1. MVTec AD 2 `test_public` few-shot 성능 비교 (8개 클래스 macro, seed 0/1/2 평균 ± 표본 표준편차, %). † RegAD는 공식 STN 제약으로 224 측정값을 병기했다. 굵은 글씨는 최고 평균값, 밑줄은 차순위다.

Shot	Metric	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD (224)†	Ours (ScopeAD)
1	$\text{AUPRO}_{0.05}$	38.45 ± 1.85	35.95 ± 2.24	14.92 ± 2.27	26.42 ± 1.71	44.87 ± 1.87	46.31 ± 3.73	12.73 ± 0.38	**52.18 ± 4.07**
	$\text{pAUROC}_{0.05}$	64.19 ± 0.68	70.67 ± 0.69	55.70 ± 0.67	59.57 ± 0.35	70.56 ± 0.56	70.13 ± 1.14	57.76 ± 0.30	**73.01 ± 1.60**
	I-AUROC	65.51 ± 1.91	66.83 ± 1.08	58.10 ± 4.46	58.68 ± 3.03	67.02 ± 2.27	67.68 ± 0.32	57.73 ± 1.82	**73.59 ± 0.36**
2	$\text{AUPRO}_{0.05}$	42.25 ± 2.08	38.20 ± 1.90	16.73 ± 2.39	31.61 ± 1.47	45.90 ± 0.75	49.80 ± 2.33	15.05 ± 0.30	**56.78 ± 2.77**
	$\text{pAUROC}_{0.05}$	65.43 ± 0.38	72.26 ± 0.56	57.14 ± 1.03	61.78 ± 0.15	71.53 ± 0.18	71.52 ± 0.58	58.76 ± 0.49	**75.83 ± 0.51**
	I-AUROC	67.53 ± 1.55	68.95 ± 3.84	57.63 ± 6.82	59.37 ± 2.54	70.42 ± 1.79	70.19 ± 2.16	60.56 ± 3.94	**75.04 ± 1.48**
4	$\text{AUPRO}_{0.05}$	46.94 ± 1.00	40.32 ± 0.75	21.88 ± 1.73	36.51 ± 1.02	47.14 ± 0.76	54.25 ± 0.86	17.40 ± 1.07	**59.49 ± 0.12**
	$\text{pAUROC}_{0.05}$	66.90 ± 0.22	73.09 ± 0.91	59.26 ± 0.80	63.84 ± 0.41	72.45 ± 0.20	73.59 ± 0.13	60.36 ± 0.48	**76.96 ± 0.55**
	I-AUROC	68.62 ± 2.28	70.90 ± 0.97	59.73 ± 4.40	62.31 ± 4.84	71.02 ± 0.56	70.97 ± 2.08	63.79 ± 2.34	**76.14 ± 0.50**
8	$\text{AUPRO}_{0.05}$	49.98 ± 1.90	41.64 ± 1.01	27.32 ± 0.14	40.79 ± 0.79	47.28 ± 0.40	55.44 ± 1.21	19.25 ± 0.64	**60.40 ± 0.89**
	$\text{pAUROC}_{0.05}$	68.22 ± 0.53	73.71 ± 0.20	61.74 ± 0.50	65.62 ± 0.69	72.56 ± 0.21	74.31 ± 0.38	62.02 ± 0.32	**77.57 ± 0.17**
	I-AUROC	69.20 ± 0.75	71.29 ± 1.69	63.46 ± 4.29	65.84 ± 0.43	70.46 ± 1.18	70.75 ± 0.58	64.34 ± 1.05	**76.39 ± 0.67**
16	$\text{AUPRO}_{0.05}$	52.73 ± 1.36	42.30 ± 1.25	35.23 ± 0.57	42.58 ± 1.10	47.63 ± 0.14	55.89 ± 1.07	20.28 ± 0.80	**60.74 ± 0.72**
	$\text{pAUROC}_{0.05}$	69.36 ± 0.51	73.97 ± 0.23	65.63 ± 0.43	66.62 ± 0.89	72.78 ± 0.07	74.60 ± 0.52	63.46 ± 0.76	**77.77 ± 0.34**
	I-AUROC	69.00 ± 0.53	72.07 ± 1.27	67.45 ± 1.16	67.60 ± 1.35	70.46 ± 1.07	69.79 ± 0.52	65.64 ± 1.34	**76.40 ± 0.95**

Table 2. MVTec AD 및 VisA few-shot 교차 데이터셋 비교 (seed 0, %). 각 셀은 I-AUROC / P-AUROC이다. 굵은 글씨는 최고값, 밑줄은 차순위다. —는 해당 조건의 보고 결과가 없음을 뜻한다.

Dataset	Shot	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD	Ours (ScopeAD)
MVTec AD	1	88.12 / 96.22	92.52 / 94.49	88.84 / 96.60	80.83 / 93.25	89.25 / 96.92	**92.54 / 96.93**	— / —	92.32 / 96.62
	2	92.67 / 96.97	95.17 / 95.56	93.51 / 97.29	84.15 / 94.27	90.95 / 97.24	95.43 / **97.36**	— / —	**95.49** / 97.28
	4	95.06 / 97.37	95.92 / 96.07	95.61 / **97.87**	85.38 / 94.67	91.35 / 97.16	96.65 / 97.70	— / —	**96.82** / 97.59
	8	96.13 / 97.80	96.67 / 96.45	96.76 / **98.16**	87.85 / 95.29	92.94 / 97.17	**97.39** / 97.95	— / —	97.35 / 97.86
	16	98.15 / 97.99	97.48 / 96.80	98.52 / **98.38**	90.29 / 95.61	92.51 / 97.19	**98.94** / 98.09	— / —	98.66 / 97.99
VisA	1	86.09 / 95.56	87.06 / 95.62	84.65 / 96.75	72.67 / 95.37	85.44 / **98.09**	**90.29** / 97.06	71.12 / 93.41	88.52 / 96.53
	2	87.87 / 96.29	90.64 / 96.63	87.67 / 97.43	77.24 / 96.37	— / —	**92.20 / 97.68**	71.59 / 94.59	91.59 / 97.14
	4	89.52 / 96.92	91.37 / 97.57	89.21 / 97.91	— / —	— / —	92.94 / **98.02**	76.42 / 96.14	**94.28** / 97.69
	8	92.36 / 97.18	93.11 / 97.99	91.53 / 98.11	— / —	— / —	94.50 / **98.29**	80.19 / 96.64	**94.97** / 98.12
	16	93.64 / 97.30	93.53 / 98.30	93.38 / 98.32	— / —	— / —	95.19 / **98.43**	81.22 / 96.98	**95.86** / 98.37

Table 3. 주요 구성 요소의 누적 ablation (MVTec AD 2 `test_public`, seed 0, $\text{AUPRO}_{0.05}$, %). A는 단일 해상도 기준선(1120, 깊은 계층 [11, 23] 연결 뱅크, 보정 없음)이며, B–F는 이전 행에 구성 요소를 차례로 추가한 결과다. F가 최종 모델이다.

구성	2-shot	16-shot
A. Single-resolution	50.51	53.78
B. + Multi-resolution	55.62	57.90
C. + Separate banks	58.23	57.93
D. + Shallow fusion	59.06	59.17
E. + Scale calibration	59.33	59.57
F. + Rényi aggregation (Ours)	**59.92**	**60.16**

Table 4. 토큰 상한(cap)에 따른 성능과 비용 (MVTec AD 2 16-shot, seed 0, FP16, %). cap은 해상도별 서포트 이미지당 뱅크 토큰 상한이다. 단일 1120 cap 1024는 4해상도 cap 256과 총 토큰 상한이 같다. Fit(초)과 Query(ms/이미지)는 클래스 평균이며, Peak는 쿼리 시 최대 GPU 메모리(GiB)다.

구성	cap	$\text{AUPRO}_{0.05}$	$\text{pAUROC}_{0.05}$	Fit	Query	Peak
단일 1120	256	57.48	74.86	11.09	861	1.91
단일 1120	1024	57.13	75.49	12.48	1053	3.04
4해상도 (Ours)	256	**60.16**	77.52	17.21	1365	3.12
4해상도	1024	60.33	77.94	22.42	1789	6.71

로 작다(seed 0). 얕은 계층 가중치 λ를 0.125에서 0.25로 바꾸면 2-shot은 0.60 pp 낮아지고 16-shot은 0.20 pp 높아지며, 0.5에서는 두 shot 모두 낮아진다(Tab. 6).

Table 5. 집계 방식과 척도 보정의 상호작용 (MVTec AD 2, seed 0/1/2 평균 ± 표본 표준편차, %). 굵은 값은 각 지표의 최고 평균이다.

집계 방식	척도 보정	2-shot	16-shot
$\text{AUPRO}_{0.05}$			
Mean	없음	56.12 ± 2.76	59.73 ± 0.86
Mean	Q95	56.03 ± 3.00	60.06 ± 0.88
Rényi	없음	56.32 ± 2.49	59.72 ± 0.77
Rényi (Ours)	Q95	**56.78 ± 2.77**	**60.74 ± 0.72**
$\text{pAUROC}_{0.05}$			
Mean	없음	76.10 ± 0.49	77.76 ± 0.32
Mean	Q95	75.86 ± 0.59	77.60 ± 0.37
Rényi	없음	**76.18 ± 0.40**	**77.96 ± 0.25**
Rényi (Ours)	Q95	75.83 ± 0.51	77.77 ± 0.34

5. 논의 및 한계

관측 확장의 효과와 비용. 다해상도 결합은 총 토큰 상한을 맞춘 단일 해상도 대조군보다 높은 $\text{AUPRO}_{0.05}$를 보였고, 관측별 독립 매칭도 특징 연결보다 높은 성능을 보였다. 반면 여러 해상도를 추론하므로 단일 해상도보다 쿼리 시간과 메모리가 늘어난다.

보정과 집계의 효과 범위. Q95 보정과 Rényi 집계의 결합 이득은 $\text{AUPRO}_{0.05}$에서 나타났으며 $\text{pAUROC}_{0.05}$로 이어지지 않았다. 클래스별로 효과의 방향이 다르고 fabric의

기여가 크므로, 이 이득을 모든 결함 유형에 대한 일관된 개선으로 볼 수는 없다. 또한 정상 영역의 추가 응답 감소는 점수 분포의 변화이며, 고정 임계값에서의 오경보율 감소를 직접 보여주지는 않는다.

서포트 편차와 배포 임계값. 관측 확장은 주어진 정상 표본의 비교 단서를 늘리지만 미관측 정상 외관을 직접 보지는 못하므로, 서포트 선택에 따른 성능 변동이 남는다(1-shot 표준편차 4.07 pp). 또한 $\mathrm{AUPRO}_{0.05}$와 $\mathrm{pAUROC}_{0.05}$는 FPR 구간에 대한 적분 지표이므로, 실제 라인에 적용하려면 목표 오경보율에 맞춘 임계값 교정이 별도로 필요하다.

6. 결론

본 논문은 동결 백본의 계층과 해상도를 독립 매칭 단위로 확장하고, 정상 참조 분위수 정규화, 비대칭 계층 결합, Rényi 순위 집계로 점수를 통합하는 **ScopeAD**를 제안했다. MVTec AD 2의 few-shot 평가에서 ScopeAD는 모든 shot에서 비교 방법보다 높은 저-FPR 국소화 성능을 보였으며(16-shot $\mathrm{AUPRO}_{0.05}$ 60.74 %), MVTec AD와 VisA에서도 경쟁력 있는 성능을 유지했다.

References

[1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD – a comprehensive real-world dataset for unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019. 5

[2] Joao P. C. Bertoldo, Dick Ameln, Ashwin Vaidya, and Samet Akcay. AUPIMO: Redefining visual anomaly detection benchmarks with high speed and low tolerance. *arXiv preprint arXiv:2401.01984*, 2024. 1, 2

[3] Simon Damm, Mike Laszkiewicz, Johannes Lederer, and Asja Fischer. Anomalydino: Boosting patch-based few-shot anomaly detection with dinov2. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1319–1329, 2025. 1, 2, 5

[4] Zheng Fang, Xiaoyang Wang, Haocheng Li, Jiejie Liu, Qiugui Hu, and Jimin Xiao. Fastrecon: Few-shot industrial anomaly detection via fast feature reconstruction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 17481–17490, 2023. 2, 5

[5] Stephanie Fu, Mark Hamilton, Laura E. Brandt, Axel Feldmann, Zhoutong Zhang, and William T. Freeman. FeatUp: A model-agnostic framework for features at any resolution. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[6] Lars Heckler-Kram, Jan-Hendrik Neudeck, Ulla Scheler, Rebecca König, and Carsten Steger. The MVTec AD 2 dataset: Advanced scenarios for unsupervised anomaly detection. *International Journal of Computer Vision*, 134(4), 2026. 1, 2, 5

[7] Chaoqin Huang, Haoyan Guan, Aofan Jiang, Ya Zhang, Michael Spratling, and Yan-Feng Wang. Registration based few-shot anomaly detection. *arXiv preprint arXiv:2207.07361*, 2022. 2, 5

[8] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19606–19616, 2023. 2

[9] Camile Lendering, Erkut Akdag, and Egor Bondarau. Subspacead: Training-free few-shot anomaly detection via subspace modeling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 28557–28566, 2026. 2, 5

[10] Xurui Li, Ziming Huang, Feng Xue, and Yu Zhou. MuSc: Zero-shot industrial anomaly classification and segmentation with mutual scoring of the unlabeled images. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[11] Xiaofan Li, Zhizhong Zhang, Xin Tan, Chengwei Chen, Yanyun Qu, Yuan Xie, and Lizhuang Ma. PromptAD: Learning prompts with only normal samples for few-shot anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16848–16858, 2024. 2

[12] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023. 1

[13] Maithra Raghu, Thomas Unterthiner, Simon Kornblith, Chiyuan Zhang, and Alexey Dosovitskiy. Do vision transformers see like convolutional neural networks? In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 12116–12128, 2021. 2

[14] Rene Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 12179–12188, 2021. 2

[15] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14298–14308, 2022. 1, 2, 3, 5

[16] Baifeng Shi, Ziyang Wu, Maolin Mao, Xin Wang, and Trevor Darrell. When do we not need larger vision models? In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2024. 2

[17] Weilin Tu. Few-shot anomaly detection on MVTec AD 2: A systematic study and a strong frozen baseline. *IEEE Access*, 14:152500–152511, 2026. 2

[18] Jin Wang, Ying-Hang Li, Bo-Wen Jiang, and Shi-Chao Li. FreePatch: A training-free multiscale patch matching method for few-shot industrial anomaly detection. In *International Conference on Computer Vision, Graphics, and Artificial Intelligence (CVGAI 2026)*, 2026. 2

[19] Huaiyuan Zhang, Hang Chen, Yu Cheng, Shunyi Wu, Linghao Sun, Linao Han, Zeyu Shi, and Lei Qi. Superad: A training-free anomaly classification and segmentation method for cvpr 2025 vand 3.0 workshop challenge track 1: Adapt & detect. *arXiv preprint arXiv:2505.19750*, 2025. 1, 2, 5

[20] Xingwu Zhang, Guanxuan Li, Paul Henderson, Gerardo Aragon-Camarasa, and Zijun Long. Is task-specific training necessary for anomaly detection? *arXiv preprint arXiv:2601.22763*, 2026. Version 3. 5

[21] Zilong Zhang, Zhibin Zhao, Xingwu Zhang, Chuang Sun, and Xuefeng Chen. Industrial anomaly detection with domain shift: A real-world dataset and masked multi-scale reconstruction. *Computers in Industry*, 151:103990, 2023. 1, 2

[22] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[23] Jiawen Zhu and Guansong Pang. Toward generalist anomaly detection via in-context residual learning with few-shot sample prompts. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 17826–17836, 2024. 2

[24] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. *arXiv preprint arXiv:2207.14315*, 2022. 5

A. 결합 규칙과 파라미터의 추가 분석

본문의 분석을 보완하기 위해 계층 가중치와 해상도 집계 대안, 보정과 집계의 메커니즘 분석을 제시한다. 계층 가중치와 집계 대안 표는 MVTec AD 2 `test_public`, seed 0의 8개 클래스 macro이며, 메커니즘 분석은 별도로 명시한 3-seed 결과를 사용한다.

A.1. 계층 가중치

최종 구성(Q95, Rényi)에서 $z_d = (z_{11} + z_{23})/2$에 더하는 얕은 계층 가중치 λ를 바꾸어 비교한다(Tab. 6). $\lambda = 0.5$에서는 세 계층의 계수가 같다. $\lambda = 0$은 얕은 계층의 점수 기여만 제외한다.

Table 6. 얕은 계층 가중치 λ의 민감도 (MVTec AD 2, seed 0, Q95, Rényi, $\text{AUPRO}_{0.05}$, %). 굵은 값은 최고값이다.

λ	2-shot	16-shot
0	59.05	59.11
0.0625	59.76	59.73
0.125 (사용값)	**59.92**	60.16
0.25	59.32	**60.36**
0.5	56.23	59.47

얕은 계층을 제외하거나($\lambda = 0$) 가중치를 0.5로 높이면 두 shot 모두 성능이 낮아진다. 16-shot에서는 0.25가 0.125보다 0.20 pp 높아, 최적값은 shot에 따라 조금 다르다.

A.2. 해상도 집계 대안

최종 구성의 특징, 뱅크, Q95 보정, 계층 가중치를 고정하고 해상도 집계 규칙만 바꾸었다(Tab. 7). 선형 순위 가중치는 $(0.1, 0.2, 0.3, 0.4)$다. 두 순위 가중 집계는 Mean보다 $\text{AUPRO}_{0.05}$가 높고, Rényi와 선형 가중의 차이는 0.1 pp 이내다. 따라서 이 결과는 높은 순위에 큰 가중치를 주는 집계의 효과를 보여주며, 특정 Rényi 가중치가 다른 순위 가중치보다 뚜렷하게 낫다는 근거는 아니다.

Table 7. 해상도 집계 대안 (MVTec AD 2, seed 0, Q95, %). 각 셀은 $\text{AUPRO}_{0.05}$ / $\text{pAUROC}_{0.05}$이며, 굵은 값은 열별 최고값이다.

집계 방식	2-shot	16-shot
Mean	59.33 / **76.48**	59.57 / 77.46
Order (linear)	59.91 / 76.45	60.08 / **77.55**
Order (Rényi, Ours)	**59.92** / 76.36	**60.16** / 77.52

A.3. 보정과 Rényi 집계의 메커니즘 분석

상대 추가 응답(E/μ). Rényi 집계에서 정상 이미지의 E/μ는 Q95 보정 후 2-shot에서 7.74 → 7.10 %, 16-shot에서 8.56 → 7.55 %로 감소했다(Fig. 5(a)). 결함 영역에서는 5.34 → 5.36 %, 6.36 → 6.11 %로 변화가 작았다. 결함과 정상 배경의 E/μ 차이는 $+0.74/+0.80$ pp 커졌고, 정상 이미지 E/μ의 Q99는 $-1.30/-1.61$ pp 줄었다. 이는 상대 추가 응답 분포의 변화이며, 고정 임계값에서의 오경보율 변화를 직접 측정한 것은 아니다.

순위 변경과 점수 크기 변경의 분리. Q95로 순위만 정하고 원점수를 합산하는 조건과, 원점수 순위를 유지한 채 Q95 점수를 합산하는 조건을 비교했다(Fig. 5(b)). 순위만 바꾼 효과는 $+0.05/-0.14$ pp인 반면, 크기만 바꾼 효과는 $+0.46/+0.70$ pp로 최종 이득의 대부분을 차지했다. 따라서 보정의 효과는 주로 점수 크기의 조정에서 나온다.

보정 오차에 대한 민감도. 보정 분모에 평균 1의 log-normal 오차를 넣으면(Fig. 5(c)), $\sigma = 0.3$에서 Mean의 $\text{AUPRO}_{0.05}$변화는 $-0.03/+0.06$ pp인 반면 Rényi는 $-0.74/-0.47$ pp였다. Rényi 집계는 Mean보다 분모의 정확도에 더 민감하다.

단위에 따른 분포 비교. E/μ는 해당 픽셀의 평균 응답을 분모로 쓰므로 결함에서 μ가 커지는 효과도 포함한다. 이를 확인하기 위해 다른 fold 정상 이미지 μ의 Q95로 나눈 E도 측정했다. 이 값의 정상/결함 평균은 2-shot에서 4.31 → 3.80 / 6.18 → 6.19 %, 16-shot에서 4.57 → 3.80 / 8.01 → 7.66 %로, 정상 추가 응답이 줄고 결함 응답이 상대적으로 유지되는 방향은 같았다. 결함−배경 E/μ 차이 변화의 클래스 bootstrap 95 % 구간은 $[+0.06, +1.72]/[+0.00, +2.02]$ pp이며, 16-shot 하한이 0에 가깝다. 정상 이미지 E/μ의 Q99 변화 구간은 $[-2.29, -0.50]/[-3.00, -0.48]$ pp이고, 감소한 클래스는 7/8과 6/8이다.

클래스와 이미지의 불확실성. Tab. 8의 coverage 상호작용은 클래스에 따라 부호가 다르다. 클래스 bootstrap 구간은 0을 포함하지만, 서포트·임계값·클래스를 고정하고 이미지만 재표집한 구간은 $[+0.18, +1.16]/[+0.61, +1.92]$ pp다. 두 구간은 서로 다른 변동을 나타내며, 후자는 클래스 구성이나 서포트 선택의 변동을 포함하지 않는다.

결함 크기와 대비. GT 면적이 이미지의 0.1 % 미만인 작은 영역의 coverage 상호작용은 $+0.86/+1.53$ pp지만 fabric을 제외하면 $-0.18/-0.06$ pp다. 0.1–1 % 및 1 % 이상 구간은 can이 없어 7개 클래스 범위다. 회색조 대비(GT 영역 평균과 8픽셀 주변 정상 영역의 차이를 주변 표준편차로 나눈 값)와 결함 크기의 상관 방향은 클래스마다 달랐다. 따라서 작은 결함이나 저대비 결함 전반에서 이득이 있다고 보기는 어렵다.

해상도 순위 점유율. Fig. 6는 seed 0에서 각 픽셀의 최고 점수를 낸 해상도의 비율이다. Q95 보정 후 448의 정상 점유율은 47.5/50.7 %에서 33.9/36.4 %로 줄고, 16-shot 작은 결함의 1120 점유율은 14.5 %에서 29.2 %로 늘었다. 정상 픽셀의 1120 점유율도 13.7 %에서 22.3 %로 늘었으므로, 이 그림은 순위 편중의 변화를 보여주는 보조 자료로 사용한다.

A.4. 계층•해상도 보정 축의 분리

분모 분해. 정상 서포트 Q95 $c_{l,r,b}$의 로그를 각 배그에서 다음과 같이 분해한다:

$$\log c_{l,r,b} = \gamma_b + u_{l,b} + v_{r,b} + h_{l,r,b}. \tag{10}$$

γ_b는 계층·해상도 전체 평균이고, $u_{l,b}$와 $v_{r,b}$는 각 축 평균에서 γ_b를 뺀 값이며, $h_{l,r,b}$는 잔여 항이다. Global, Layer, Resolution, Separable은 각각 $\exp(\gamma_b)$, $\exp(\gamma_b + u_{l,b})$,

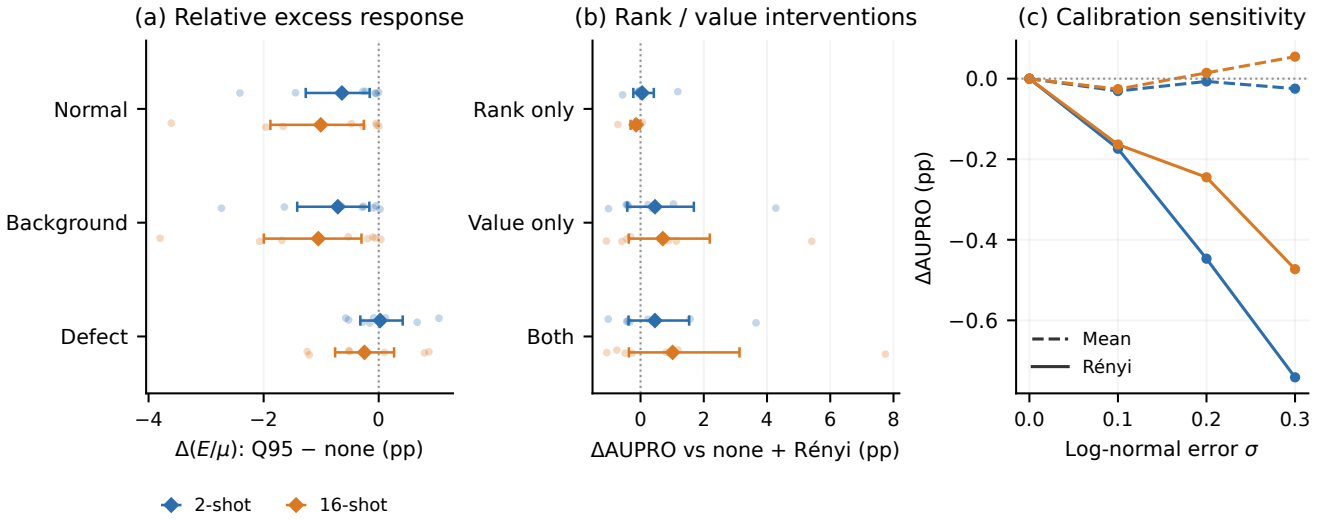


Figure 5. **Q95 보정과 Rényi 집계의 결합 메커니즘 분석.** MVTec AD 2, 2/16-shot, seed 0/1/2에서 같은 특징과 거리를 재사용했다. (a) 상대 추가 응답 E/μ의 Q95−None 변화. Normal은 정상 이미지, Background는 결함 이미지의 정상 배경, Defect는 결함 영역이다. 같은 픽셀 표본으로 조건 간 차이를 계산하고 이미지·seed·클래스 순으로 평균했다. 작은 점은 3-seed 평균 클래스 효과, 마름모와 오차 막대는 macro와 클래스 bootstrap 95 % 구간이다. (b) None+Rényi 대비 순위만, 점수 크기만, 둘 다 보정한 경우의 $\text{AUPRO}_{0.05}$ 차이. 작은 점과 구간은 (a)와 같다. (c) Q95 분모에 평균 1의 log-normal 오차를 넣었을 때 오차가 없는 경우 대비 $\text{AUPRO}_{0.05}$ 변화. 각 σ에서 seed별 3회 오차를 두 집계에 동일하게 주고 평균했다. 색은 shot, 점선/실선은 Mean/Rényi다.

Table 8. **클래스별 검출 변화와 해상도 응답 집중도의 연관.** MVTec AD 2, 3-seed 평균. Coverage 상호작용은 (Q95+R − Q95+Mean) − (None+R − None+Mean)이며, GT 영역 coverage를 이미지 안에서 평균한 뒤 이미지와 seed를 평균한 값이다. 임계값은 정상 이미지의 교차검증으로 목표 FPR 1 %에 맞추었으며, 실제 평가 FPR은 조건마다 다르다. ρ는 Q95 상태의 응답 집중도와 Mean→Rényi coverage 차이의 클래스 내 Spearman 상관이다.

클래스	2-shot 상호작용 (pp)	16-shot 상호작용 (pp)	2-shot ρ	16-shot ρ
can	−0.05	−0.06	0.48	0.39
fabric	+7.24	+11.50	0.56	0.31
fruit_jelly	+0.23	+0.72	0.48	0.46
rice	−0.38	−0.71	0.38	0.22
sheet_metal	−1.86	−1.78	0.48	0.43
vial	+0.12	−0.18	0.30	0.03
wallplugs	−0.19	−0.59	0.51	0.52
walnuts	+0.05	+0.79	0.29	0.30
Macro	+0.65	+1.21	—	—
fabric 제외	−0.30	−0.26	—	—

Table 9. **Q95 보정 분모의 계층·해상도 성분 분리.** MVTec AD 2, 2/16-shot, seed 0/1/2 평균 $\text{AUPRO}_{0.05}$ (%). Global은 배그별 공통 배율만, Layer/Resolution은 공통 배율에 해당 축 성분만, Separable은 두 축 성분을 함께 적용한다. Full은 원래 Q95다.

	2-shot		16-shot	
분모	Mean	Rényi	Mean	Rényi
None	56.12	56.32	59.73	59.72
Global	56.12	56.32	59.73	59.72
Layer	55.91	56.13	59.90	59.82
Resolution	56.26	56.87	59.89	60.55
Separable	56.02	56.78	60.02	60.73
Full Q95	56.03	56.78	60.06	60.74

$\exp(\gamma_b + v_{r,b})$, $\exp(\gamma_b + u_{l,b} + v_{r,b})$를 분모로 쓴다. Full은 원래 $c_{l,r,b}$이며 None은 1이다. 모든 축 개입은 배그 공통 척도를 유지하므로 Global을 대조로 사용한다. 특징, 뱅크, 계층 가중치, FP16을 고정하고 분모만 바꾸었으며(8개 클래스 × 2/16-shot × 3 seed), None과 Full의 결과는 Tab. 5와 일치한다.

축 효과. Rényi 아래에서 Resolution−Global은 +0.55/ + 0.82 pp이며, seed별 macro 효과는 2-shot +0.56/+0.64/+ 0.45 pp, 16-shot +0.82/ + 0.78/ + 0.87 pp로 모두 양수다. Mean 아래의 같은 효과는 +0.15/ + 0.15 pp로 작다. Layer−Global은 Rényi 아래에서 −0.19/ + 0.10 pp로 shot에 따라 방향이 달랐고, Full−Separable은 두 shot 모두 0.01 pp 이내로 잔여 항의 macro 영향은 작았다. 다만 Resolution−Global에서 양의 효과를 보인 클

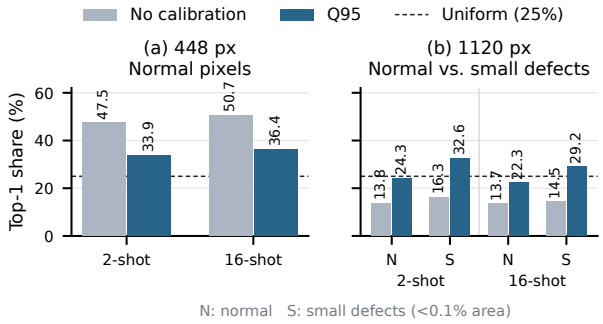


Figure 6. **정상 참조 보정과 해상도 순위 점유율.** MVTec AD 2, seed 0, 8개 클래스 macro. 점선은 균등 점유율 25 %다.

래스는 두 shot 모두 8개 중 4개이고, fabric의 효과가 $+5.18/+7.26$ pp로 크다. 클래스 bootstrap 95 % 구간은 $[-0.36, +1.99]/[-0.40, +2.80]$ pp로 0을 포함하며, fabric을 제외하면 $-0.11/-0.10$ pp다.

A.5. 평균 응답 조건부 분석과 영역•픽셀 가중

같은 평균 응답 구간에서의 비교. 두 보정 조건의 같은 픽셀을 보정 전 평균 응답 μ의 10분위 구간에 배정했다. 구간 경계는 다른 정상 fold에서 정했다. 이미지→seed→클래스 순으로 집계하면 정상과 배경의 Q95−None E/μ 변화는 두 shot 모두 10개 구간 전체에서 음수였다. 결함−배경 변화는 8개 클래스가 모두 관측된 구간(2-shot 5–9, 16-shot 6–9)에서 모두 양수였다. 따라서 평균 응답 수준이 다른 픽셀이 섞여서 생긴 현상으로 보기는 어렵다. 다만 보정 후의 μ까지 고정한 비교는 아니다.

Fabric의 영역 수와 결함 픽셀 수. Fabric의 GT 영역 192개 중 180개(93.75 %)는 이미지 면적의 0.1 % 미만이지만, 이 영역들은 전체 결함 픽셀의 1.39 %만 차지한다. 목표 FPR 1 % 임계값에서 Q95+Rényi−None+Rényi의 영역 평균 coverage 변화는 작은 영역에서 $+6.85/+10.41$ pp, 나머지 영역에서 $-1.36/-0.84$ pp다(2/16-shot). 같은 변화를 GT 픽셀 수로 가중하면 작은 영역의 TPR 기여는 $+0.06/+0.08$ pp, 나머지는 $-2.66/-1.64$ pp다. 즉 많은 작은 영역의 coverage 증가와 큰 영역의 손실이 함께 나타나며, 영역 단위 지표($\mathrm{AUPRO}_{0.05}$)와 픽셀 단위 지표($\mathrm{pAUROC}_{0.05}$)가 다르게 움직이는 이유를 설명한다.