ScopeAD: Support-Calibrated Fusion with Observation Expansion for Few-Shot Industrial Anomaly Localization

Anonymous CVPR submission

Paper ID *****

Abstract

소수 정상 이미지만을 사용하는 few-shot 산업 이상 국소화에서는 촬영 조건 변화(조명 드리프트, 자세 변동 등)로 인해 정상 영역에서도 큰 거리가 나타나는 ***High-Score Ambiguity****가 발생한다. 추가 정상 표본이 없는 제약 아래 미세 결함 단서를 확보하기 위해 다해상도와 다계층으로* ***Observation Expansion****을 수행하면, 관측 조건마다 거리 척도가 달라지고 Shallow 층의 정상 질감 반응이 점수에 섞여 low-FPR 오경보가 급증한다. 이를 해결하기 위해 본 논문은* ***ScopeAD****를 제안한다. ScopeAD는 관측 조건마다 독립 뱅크를 구축한 뒤, 정상 서포트의 기준 상위 분위수로 각 관측의 거리 단위를 공통 척도로* ***Scale Calibration****한다. 이어 Deep 의미 기준선 위에 Shallow 층의 정상 질감 과민반응을 억제하도록 작은 고정 가중치로* ***Contribution Control****을 적용하고 다해상도 맵을 평균한다. MVTec AD 2 16-shot에서 ScopeAD는 3개 시드 평균* ***60.06 %*** $\mathrm{AUPRO}_{0.05}$*를 기록하여 SuperAD(55.89 %) 대비* ***+4.17 pp****의 성능 도약을 달성했으며, 단일 뱅크 대비 +2.09 pp, 단일 저해상도 입력 대비 +7.56 pp의 뚜렷한 구성 및 결합 이득을 실증했다.*

1. 서론

1.1. 소수 정상 참조와 High-Score Ambiguity

다품종 소량 생산 및 빈번한 라인 전환이 일어나는 제조 환경에서는 제품마다 충분한 결함 데이터를 수집하거나 모델을 재학습하기 어렵다. 이 때문에 별도 학습 없이 다양한 시각 과제로 전이되는 동결(frozen) 사전학습 백본 [13]의 패치 특징을 소수 정상 이미지로 구성한 참조 뱅크(reference bank)와 매칭하고, 쿼리 패치와 최근접 정상 패치 사이의 거리로 결함을 국소화하는 방식이 널리 쓰인다 [3, 17].

이 방식은 정상 쿼리 패치라면 참조 뱅크 안에 가까운 이웃이 있다고 가정한다. 그러나 몇 장의 서포트로는 실제 공정의 조명 드리프트, 부품 자세 변동, 표면 난반사, 센서 노이즈를 모두 담을 수 없으며, 분포 변화 아래에서 성능과 점수 신뢰도가 유지되지 않는다는 점은 일반 시각 인식에서도 보고되어 왔다 [8, 14]. 서포트에 없는 정상 변동이 나타나면 결함이 없는 패치도 최근접 거리가 커지고, 이 값은 실제 결함이 만든 큰 거리와 구별되지 않는다. 즉, **큰 거리값만으로는 그 원인이 실제 결함인지 서포트에 없는 정상 외관 변화인지 확정할 수 없다(High-Score Ambiguity)**(Fig. 1).

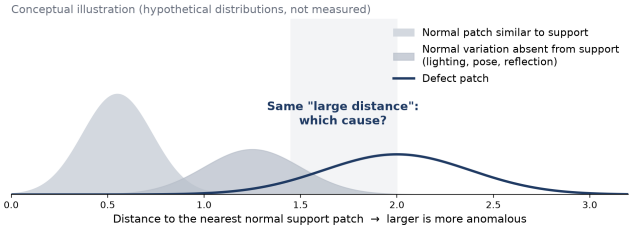


Figure 1. **Conceptual illustration of High-Score Ambiguity in few-shot inspection.** Due to sparse normal support, unobserved normal variations and true defects overlap in the large nearest-neighbor distance regime, making raw distance scores inherently ambiguous for defect identification.

1.2. 다층•다해상도 관측 확장과 결합의 과제

정상 이미지를 늘릴 수 없는 few-shot 조건에서는 같은 이미지로부터 가능한 한 다양한 시각 단서를 얻는 것이 유리하다. 본 논문은 이를 **관측 확장(Observation Expansion)**으로 보고, 동결 백본의 표현 계층과 입력 해상도라는 두 축을 따라 관측을 넓힌다. ViT는 계층마다 표현 특성이 달라 [15, 16], 심층(Layer 11/23)은 안정적인 의미 기준선을, 얕은 층(Layer 5)은 미세 스크래치와 국소 텍스처에 민감한 단서를 제공한다. 또한 패치 크기가 14×14로 고정된 백본에서는 입력 해상도가 곧 공간 표본 밀도를 결정하므로 [5], 저해상도 입력은 거시적 형태를 안정적으로 담고 고해상도 입력은 미세 결함을 더 촘촘히 표본화한다. 여러 입력 척도를 함께 쓰는 이점은 일반 시각 인식에서도 보고되었다 [12, 18].

그러나 확장된 관측의 점수를 그대로 합치는 것은 유리하지 않다. 기존 패치 매칭처럼 계층 특징을 이어 붙여 단일 뱅크를 만들면 [17] 계층마다 다른 정상 변동이 하나의 거리에 섞이며, MVTec AD 2 16-shot 개발 비교에서 같은 저장 용량의 관측별 뱅크보다 $\mathrm{AUPRO}_{0.05}$가 2.09 pp 낮았다. 반대로 관측별 뱅크를 두면 뱅크마다 정상 거리

분포가 달라 결합 전에 점수 단위를 맞춰야 한다. 단위를 맞춘 뒤에도 얕은 층 점수에는 결함 반응과 함께 정상 질감 반응이 섞여 있어, 이를 그대로 더하면($\lambda = 1$) $\text{AUPRO}_{0.05}$가 5.55 pp 낮아졌다. 따라서 본 논문은 관측 결합을 두 문제로 나눈다. **Scale Calibration**은 관측별 정상 거리를 정상 서포트의 상위 분위수로 나누어 공통 단위로 정렬하며 [10, 20], 레이블로 신뢰도를 맞추는 분류 캘리브레이션 [6]과 달리 정상 이미지만으로 정해진다. **Contribution Control**은 정렬된 심층 평균을 기준선으로 삼아 얕은 층 점수를 작은 고정 가중치로 더함으로써, 단위 정렬로는 대체되지 않는 얕은 층의 비중을 정한다.

1.3. ScopeAD 프레임워크와 주요 기여

본 논문은 관측 확장과 서포트 기반 결합을 묶은 **ScopeAD** (ScopeAD)를 제안한다. ScopeAD는 학습되는 가중치나 쿼리 적응 없이 동작하며, 핵심 기여는 다음과 같다:

- **관측 확장**: 백본을 재학습하지 않고 표현 계층(Layer 5/11/23)과 입력 해상도(448–1120px)의 두 축으로 동일 이미지의 관측을 확장하여, 한정된 서포트로부터 얻는 시각 단서를 늘린다.
- **척도 보정과 기여 제어의 분리**: 관측 조건마다 독립 뱅크를 두고, 서포트 분위수($q = 0.95$) 기반 척도 보정과 고정 가중($\lambda = 0.125$) 얕은 층 가산을 별개 단계로 정식화한다.
- **구성 이득과 결합 이득의 분리 검증**: 4개 해상도 결합은 최선의 단일 해상도보다 $\text{AUPRO}_{0.05}$가 2-shot에서 4.95 pp, 16-shot에서 2.10 pp 높으며, 관측별 뱅크와 기여 제어의 이득을 통제 실험으로 분리한다. MVTec AD 2 16-shot에서 동일 백본·서포트의 SuperAD보다 3-seed $\text{AUPRO}_{0.05}$가 4.17 pp 높다.

2. Related Work

2.1. Frozen-Feature Reference Matching in Few-Shot AD

PatchCore [17]는 사전학습 CNN의 다층 패치 특징을 연결해 정상 메모리 뱅크를 만들고, 최근접 거리로 이상을 국소화한다. RegAD [9]와 FastRecon [4]도 소수의 정상 참조 이미지를 활용하지만 각각 영상 정합과 특징 복원에 초점을 둔다. DINOv2 특징을 사용한 AnomalyDINO [3]는 패치 매칭을, SuperAD [22]는 계층별 이상 맵의 평균을 사용한다. 최근의 MVTec AD 2 few-shot 연구 [19]는 동결 DINOv2의 계층 선택과 참조 수에 따른 결과를 분석했고, SubspaceAD [11]는 메모리 뱅크 대신 정상 특징의 부분공간 잔차를 계산한다. ScopeAD는 최근접 매칭을 유지하면서 계층·해상도·배그별 뱅크의 점수를 정상 서포트에 맞춰 결합한다.

2.2. Multi-Scale Observation and Score Fusion

DPT [16]는 여러 ViT 계층을 공간 맵으로 결합하고, S^2 [18]는 동결 백본을 여러 입력 척도에서 실행한다. FreePatch [21]와 ScopeAD는 모두 정상 참조 통계로 서로 다른 점수의 척도를 맞춘다. FreePatch는 ResNet-50의 layer2/3 점수를 leave-one-out 통계로 정규화하고, 매칭된 참조 패치의 안정성에 따라 점수를 다시 보정하여 드문 정상 패턴의 오경보를 줄인다. ScopeAD는 DINOv2의 계층·전체 입력 해상도·배그별 최근접 거리 단위를 leave-source-out 상위 분위수로 정렬하여 확장된 관측의 맵을 결합하고, 얕은 계층의 기여량을 고정 가중치로 제어한다.

2.3. Distribution Shift and Low-FPR Localization

AeBAD [24]는 실제 획득 조건 변화가 산업 이상 탐지에 주는 어려움을 다루며, MVTec AD 2 [7]는 조명 변화와 작은 결함을 포함한 평가 환경을 제공한다. AUPIMO [2]는 전체 AUROC나 AUPRO만으로 낮은 오경보 허용치에서의 국소화 품질을 설명하기 어렵다고 지적한다. ScopeAD는 정상 서포트만으로 관측 점수를 결합하고 MVTec AD 2의 저-FPR 곡선 지표에서 평가한다. 이 점수 보정은 고정 배포 임계값의 오경보율을 보증하지 않는다.

3. 방법 (Method)

ScopeAD(ScopeAD)는 동결된 비전 백본의 다층·다해상도 패치 특징을 사용하여 소수의 정상 서포트 이미지로부터 테스트 쿼리의 결함 영역을 국소화한다. 관측 단계에서는 4개 해상도와 3개 계층에 대해 총 48개의 독립 뱅크를 구축하고, 결합 단계에서는 정상 서포트 분위수 ($q = 0.95$)로 단위를 정렬한 뒤 얕은 층을 고정 가중치 $\lambda = 0.125$로 제어하여 가산한다.

3.1. 시스템 개요 및 문제 정의

입력 및 출력 규격. 입력은 정상 서포트 이미지 집합 $\mathcal{S} = \{x_1^s, \ldots, x_N^s\}$ ($N \in \{1, 2, 4, 8, 16\}$), 테스트 쿼리 이미지 x^q, 동결된 DINOv2-L/14 백본 [13]이다. 고정 계층 집합은 $\mathcal{L} = \{5, 11, 23\}$, 고정 해상도 짧은 변 길이는 $\mathcal{R} = \{448, 672, 896, 1120\}$, 메모리 배그 수는 $B = 4$다. 출력은 픽셀 단위 결함 맵 $A(x^q) \in \mathbb{R}^{H \times W}$ 및 이미지 점수 $s(x^q) \in \mathbb{R}$이다.

Support-Referenced Ratio Operator. 임의의 관측 통계량 t와 정상 서포트 기준 분포 $\mathcal{N}_S[t]$에 대해 분위수 비율 연산자 $\mathcal{T}_q[t] = t/Q_q(\mathcal{N}_S[t])$를 정의한다. 여기서 $Q_q(D)$는 분포 D의 q-분위수 값이다.

3.2. 정상 서포트 뱅크 구축 및 메모리 배깅

컴포넌트 뱅크 분리. 계층 $l \in \mathcal{L}$, 해상도 $r \in \mathcal{R}$, 배그 $b \in \{1, \ldots, B\}$의 조합 $m = (l, r, b)$를 독립 관측 단위인 **컴포넌트(Component)**로 정의한다 (총 $3 \times 4 \times 4 = 48$개). 각 컴포넌트 m마다 전용 메모리 뱅크 B_m을 독립 구축한다.

배깅(Bagging) 및 뱅크 생성. 해상도 r에서 각 서포트 이미지로부터 256개 패치 토큰을 무작위 비복원 추출하여 배그를 구성한다. 4개의 독립 난수 시드로 4개 배그를 생성한다. 동일 배그 내의 세 계층은 동일한 공간 위치 토큰을 공유한다. 16-shot 조건에서 단일 뱅크 B_m은 $16 \times 256 = 4,096$개 토큰을 갖는다.

1-NN 코사인 거리 계산. 쿼리 위치 p의 L2 정규화 특징 벡터 $f_m(x^q, p)$와 뱅크 B_m 사이의 1-NN 코사인 거리는

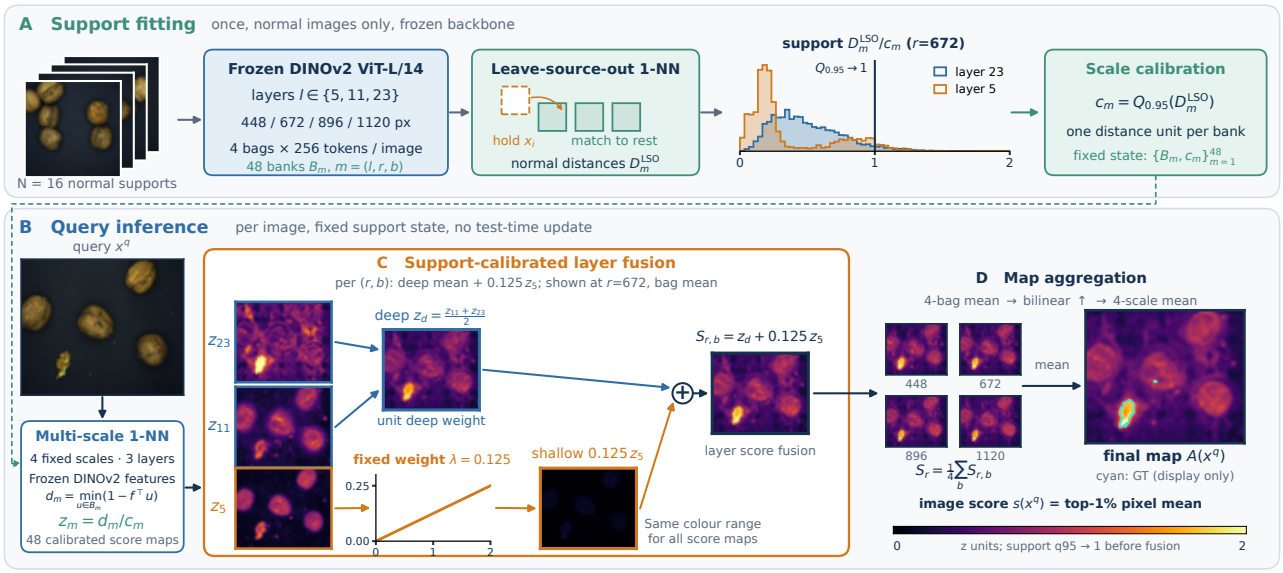


Figure 2. **ScopeAD 파이프라인 개요.** (A) 서포트 피팅 단계: 정상 서포트로부터 48개 컴포넌트 뱅크를 구축하고 LSO 매칭 거리의 $q = 0.95$ 상위 분위수 단위 척도 c_m을 사전 1회 계산한다. (B) 쿼리 추론 단계: 4개 고정 해상도와 3개 계층에서 패치 특징을 추출하고 각 뱅크별 1-NN 코사인 거리 d_m을 계산한 뒤 c_m으로 정규화하여 무차원 점수 z_m을 산출한다. (C) 계층 결합: Deep 평균에 Shallow 점수를 고정 가중치 $\lambda = 0.125$로 선형 가산한다. (D) 공간 통합: 4-Bag 평균, 원본 크기로의 양선형 보간 역투영, 4-해상도 평균을 거쳐 최종 결함 국소화 맵 및 상위 1% 픽셀 평균 이미지 점수를 출력한다.

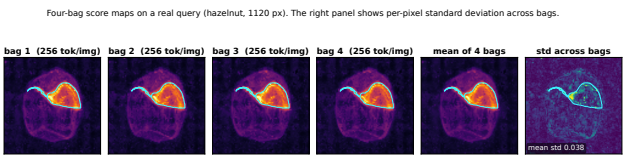


Figure 3. **4-Bag 점수 맵 앙상블 및 분산 완화.** 실제 hazelnut 쿼리(1120px)의 4개 독립 Bag 점수 맵과 평균. 각 Bag은 이미지당 256개 토큰을 무작위 추출하여 뱅크를 구성한다. 4-Bag 평균은 표본화 분산을 효과적으로 완화한다.

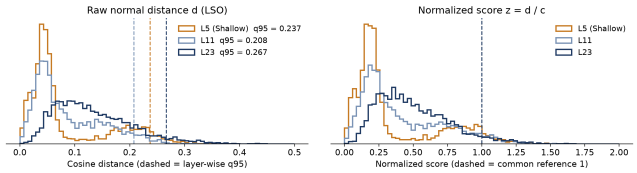


Figure 4. **Scale calibration of leave-source-out (LSO) normal distances.** Left: raw cosine distances of the normal support patches for Layers 5, 11, and 23 (MVTec AD 2 walnuts, 16-shot, 672px, bag 0). Dashed lines mark each layer's 95th percentile $q_{0.95}$. Right: the same distances divided by their layer-wise $q_{0.95}$, so that the common reference value 1.0 aligns the layers before fusion.

다음과 같다:

$$d_m(x^q, p) = \min_{u \in B_m} \left[1 - f_m(x^q, p)^\top u\right]. \tag{1}$$

3.3. Scale Calibration: 분위수 기반 거리 정렬

컴포넌트마다 상이한 거리 척도를 공통 단위로 정렬하기 위해, 서포트 내부의 Leave-Source-Out (LSO) 거리를 수집한다. 각 서포트 이미지 x_i^s의 토큰 $v \in B_m^{(i)}$에 대해 나머지 서포트 토큰 집합과의 최근접 거리를 계산하여 LSO 분포 D_m^{LSO}를 얻는다:

$$D_m^{\text{LSO}} = \bigcup_{i=1}^{N} \left\{ \min_{u \in B_m \setminus B_m^{(i)}} \left[1 - v^\top u\right] \;:\; v \in B_m^{(i)} \right\}. \tag{2}$$

단위 척도 c_m은 D_m^{LSO}의 q-분위수($q = 0.95$)로 결정된다:

$$c_m = Q_q(D_m^{\text{LSO}}). \tag{3}$$

쿼리 거리 $d_m(x^q, p)$를 단위 척도 c_m으로 나누어 무차원 정규화 점수 $z_m(x^q, p)$를 산출한다:

$$z_m(x^q, p) = \frac{d_m(x^q, p)}{c_m}. \tag{4}$$

$z_m = 1.0$은 해당 패치 거리가 정상 서포트의 상위 5% 경계점과 일치함을 뜻하며, 모든 48개 컴포넌트가 동일한 정상 참조 척도로 정렬된다. 원시 거리 분포와 정규화 이후의 분포 차이는 Fig. 4에 제시한다.

3.4. Contribution Control: 고정 가중 Shallow 결합

정규화 점수 공간에서 심층(Layer 11, 23)의 평균을 신뢰할 수 있는 의미 기준선으로 삼고, 표면 텍스처와 미

세 윤곽에 민감한 얕은 층(Layer 5)을 작은 고정 가중치 $\lambda = 0.125$로 선형 가산한다:

$$z_{d,r,b}(x^q, p) = \frac{z_{11,r,b}(x^q, p) + z_{23,r,b}(x^q, p)}{2}, \quad (5)$$

$$S_{r,b}(x^q, p) = z_{d,r,b}(x^q, p) + \lambda\, z_{5,r,b}(x^q, p). \quad (6)$$

임계값이나 복잡한 비선형 게이트 대신 단순 선형 가중을 채택하며, $\lambda = 0.125$는 개발 평가(AD2 2-shot seed 0)에서 선택 후 완전히 동결된 하이퍼파라미터다.

3.5. 고정 다해상도 결함 맵 공간 통합

각 해상도 r에서 4개 배그의 결합 점수를 산술 평균한다:

$$S_r(x^q, p) = \frac{1}{B} \sum_{b=1}^{B} S_{r,b}(x^q, p). \quad (7)$$

이후 각 해상도 맵 $S_r(x^q)$를 원본 영상 크기 (H, W)로 양선형 보간(Bilinear Interpolation)한 뒤 동일 가중 평균하여 최종 결함 국소화 맵 $A(x^q)$를 생성한다:

$$A(x^q) = \frac{1}{|\mathcal{R}|} \sum_{r \in \mathcal{R}} \mathrm{Resize}_{H,W}\left[S_r(x^q)\right]. \quad (8)$$

이미지 단위 이상 점수 $s(x^q)$는 결함 맵 $A(x^q)$의 상위 1% 픽셀 평균(top-1% mean)으로 정의된다:

$$s(x^q) = \frac{1}{|\Omega_{1\%}|} \sum_{p \in \Omega_{1\%}} A(x^q, p). \quad (9)$$

모든 연산은 결정론적이며 테스트 시점의 역전파나 적응 파라미터가 일체 존재하지 않는다.

4. 실험 (Experiments)

본 절에서는 ScopeAD 프레임워크의 이상 국소화 및 탐지 성능을 기존 최고 수준 방법들과 비교하고, 구성 요소별 통제 소거 분석을 통해 성능 향상의 기제를 규명한다.

4.1. 평가 설정 (Evaluation Setup)

데이터셋 및 분할. MVTec AD 2 [7]는 실제 산업 환경의 조명 드리프트와 미세 결함을 포괄하는 8개 클래스 벤치마크다. 공개 개발 평가 세트인 `test_public`은 총 1,084장(정상 379장, 결함 705장)으로 구성되며, 기준(Regular) 환경 외에 Shift 1–3 등의 획득 조건 변화를 포함한다. 공식 서버 평가 세트인 `test_private`과 다양한 획득 조건이 혼합된 `test_private_mix`는 각각 2,045장이다. 정상 서포트 이미지는 `train/good`에서 고정 시드와 매니페스트로 선별한다. 교차 데이터셋 검증을 위해 기존 MVTec AD(15개 클래스) [1]와 VisA(12개 클래스) [25] 벤치마크를 함께 평가한다.

Few-shot 설정 및 비교군. 클래스당 정상 서포트 이미지 수 N은 $\{1, 2, 4, 8, 16\}$으로 설정한다. ScopeAD(Ours, linear0125)는 DINOv2 ViT-L/14 백본을 동결 사용하며, 계

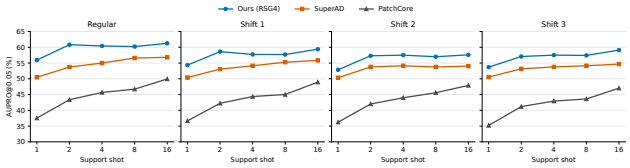


Figure 5. **Support shot별 native acquisition strata의 AUPRO@0.05.** 패널: Regular, Shift 1, Shift 2, Shift 3. ScopeAD는 획득 조건 변화(조명 드리프트, 자세 변동 등) 하에서도 기존 방법 대비 안정적인 국소화 성능을 유지한다.

층 $\{5, 11, 23\}$과 4개 해상도 $\{448, 672, 896, 1120\}$, FP16 autocast, cap256, $z_d + 0.125\, z_5$ 결합을 적용한다. 비교 대상 방법군은 PatchCore [17], SuperAD [22], Anomaly-DINO [3], FastRecon [4], RAD [23], SubspaceAD [11], RegAD [9]다. 모든 방법은 동일한 서포트 경로와 쿼리, 평가기를 공유하며, 공정한 비교를 위해 유효 입력 해상도를 1120으로 확장한 파이프라인 비교를 수행한다(RegAD는 STN 구조상 공식 224 유지). 주요 평가 지표는 클래스 매크로 $\mathrm{AUPRO}_{0.05}$, $\mathrm{pAUROC}_{0.05}$, 그리고 이미지 단위 I-AUROC다.

4.2. Few-shot 주 비교 (Few-shot Main Benchmark)

표 1는 MVTec AD 2 `test_public`에서의 few-shot 주 비교 결과다. ScopeAD는 전 샷 구간에서 강력한 기준선인 SuperAD를 지속적으로 능가한다. 특히 16-shot에서 3-seed 평균 **60.06 %** $\mathrm{AUPRO}_{0.05}$를 달성하여 SuperAD (55.89 %) 대비 **+4.17 pp**, pAUROC@0.05에서 **+3.01 pp** 높은 성능을 기록했다. 극단적인 1-shot 환경에서도 54.81 %의 높은 국소화 성능을 기록하여 데이터 희소 조건에서의 강건성을 입증했다.

표 2는 기존 MVTec AD 및 VisA 벤치마크에서의 교차 평가 결과다. ScopeAD는 두 데이터셋 전 샷 구간에서 최고 또는 차순위의 높은 탐지·국소화 성능을 고르게 유지한다. 3개 시드 평균 평가(표 3)에서도 MVTec AD 16-shot I-AUROC $98.52 \pm 0.20\%$, VisA 16-shot I-AUROC $95.78 \pm 0.18\%$로 높은 안정성을 실증했다.

4.3. 획득 조건 변화 및 외란 평가

표 4는 MVTec AD 2 공식 서버의 비공개 평가 세트(`test_private` 및 혼합 조명 `test_private_mix`) 결과다. 소수의 정상 서포트(16-shot)만으로도 full-data 기반 지도학습 선행 연구들을 넘어서는 높은 국소화 능력을 입증했다. (현재 수치는 게이트 설정이며 추후 linear0125 설정으로 교체 예정).

4.4. 구성 요소 소거 분석 (Ablation Study)

구성 요소별 기여 분해. 표 5는 제안 모듈들의 단계적 효과를 검증한다. 첫째, 계층 특징을 하나의 뱅크로 합친 단일 뱅크(d)는 관측별 뱅크를 유지한 Full 대비 AUPRO가 2.09 pp, pAUROC가 2.66 pp 하락했다. 둘째, 다해상도를 배제하고 448px 단일 입력만 사용할 경우(f) AUPRO가 7.56 pp 폭락하여 다해상도 공간 관측 확장이 필수적

Table 1. MVTec AD 2 `test_public` 입력 최대 해상도 1120 few-shot 비교 (%). 비교군은 3개 시드 평균 ± 표본 표준편차다. ‡ Ours(ScopeAD) 열은 2-shot과 16-shot이 3개 시드 평균 ± 표본 표준편차이며, 1, 4, 8-shot은 Seed 0 단일 실행값이다. † RegAD는 공식 체크포인트의 STN 제약으로 224 측정값을 병기했다. 굵은 글씨는 최고 평균값, 밑줄은 차순위다.

Shot	Metric	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD (224)†	Ours (ScopeAD)‡
1	AUPRO@0.05	38.45 ± 1.85	35.95 ± 2.24	14.92 ± 2.27	26.42 ± 1.71	44.87 ± 1.87	46.31 ± 3.73	12.73 ± 0.38	**54.81**
	pAUROC@0.05	64.19 ± 0.68	70.67 *pm* 0.69	55.70 *pm* 0.67	59.57 *pm* 0.35	70.56 *pm* 0.56	70.13 *pm* 1.14	57.76 *pm* 0.30	**73.32**
	I-AUROC	65.51 *pm* 1.91	66.83 *pm* 1.08	58.10 *pm* 4.46	58.68 *pm* 3.03	67.02 *pm* 2.27	67.68 *pm* 0.32	57.73 *pm* 1.82	**74.47**
2	AUPRO@0.05	42.25 *pm* 2.08	38.20 *pm* 1.90	16.73 *pm* 2.39	31.61 *pm* 1.47	45.90 *pm* 0.75	49.80 *pm* 2.33	15.05 *pm* 0.30	**56.03** *pm* **2.99**
	pAUROC@0.05	65.43 *pm* 0.38	72.26 *pm* 0.56	57.14 *pm* 1.03	61.78 *pm* 0.15	71.53 *pm* 0.18	71.52 *pm* 0.58	58.76 *pm* 0.49	**75.86** *pm* **0.59**
	I-AUROC	67.53 *pm* 1.55	68.95 *pm* 3.84	57.63 *pm* 6.82	59.37 *pm* 2.54	70.42 *pm* 1.79	70.19 *pm* 2.16	60.56 *pm* 3.94	**74.93** *pm* **1.54**
4	AUPRO@0.05	46.94 *pm* 1.00	40.32 *pm* 0.75	21.88 *pm* 1.73	36.51 *pm* 1.02	47.14 *pm* 0.76	54.25 *pm* 0.86	17.40 *pm* 1.07	**58.69**
	pAUROC@0.05	66.90 *pm* 0.22	73.09 *pm* 0.91	59.26 *pm* 0.80	63.84 *pm* 0.41	72.45 *pm* 0.20	73.59 *pm* 0.13	60.36 *pm* 0.48	**76.87**
	I-AUROC	68.62 *pm* 2.28	70.90 *pm* 0.97	59.73 *pm* 4.40	62.31 *pm* 4.84	71.02 *pm* 0.56	70.97 *pm* 2.08	63.79 *pm* 2.34	**75.71**
8	AUPRO@0.05	49.98 *pm* 1.90	41.64 *pm* 1.01	27.32 *pm* 0.14	40.79 *pm* 0.79	47.28 *pm* 0.40	55.44 *pm* 1.21	19.25 *pm* 0.64	**58.68**
	pAUROC@0.05	68.22 *pm* 0.53	73.71 *pm* 0.20	61.74 *pm* 0.50	65.62 *pm* 0.69	72.56 *pm* 0.21	74.31 *pm* 0.38	62.02 *pm* 0.32	**77.35**
	I-AUROC	69.20 *pm* 0.75	71.29 *pm* 1.69	63.46 *pm* 4.29	65.84 *pm* 0.43	70.46 *pm* 1.18	70.75 *pm* 0.58	64.34 *pm* 1.05	**75.41**
16	AUPRO@0.05	52.73 *pm* 1.36	42.30 *pm* 1.25	35.23 *pm* 0.57	42.58 *pm* 1.10	47.63 *pm* 0.14	55.89 *pm* 1.07	20.28 *pm* 0.80	**60.06** *pm* **0.88**
	pAUROC@0.05	69.36 *pm* 0.51	73.97 *pm* 0.23	65.63 *pm* 0.43	66.62 *pm* 0.89	72.78 *pm* 0.07	74.60 *pm* 0.52	63.46 *pm* 0.76	**77.61** *pm* **0.37**
	I-AUROC	69.00 *pm* 0.53	72.07 *pm* 1.27	67.45 *pm* 1.16	67.60 *pm* 1.35	70.46 *pm* 1.07	69.79 *pm* 0.52	65.64 *pm* 1.34	**75.92** *pm* **0.82**

Table 2. MVTec AD 및 VisA few-shot 교차 데이터셋 비교 (Seed 0 단일 실행). 각 셀은 I-AUROC / P-AUROC (전체 FPR 구간, %) 순서다. 굵은 글씨는 최고값, 밑줄은 차순위다.

Dataset	Shot	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD	Ours (ScopeAD)
MVTec AD	1	88.12 / 96.22	92.52 / 94.49	88.84 / 96.60	80.83 / 93.25	89.25 / 96.92	92.54 / **96.93**	— / —	**92.76** / 96.77
	2	92.67 / 96.97	95.17 / 95.56	93.51 / 97.29	84.15 / 94.27	90.95 / 97.24	95.43 / 97.36	— / —	**96.13** / **97.39**
	4	95.06 / 97.37	95.92 / 96.07	95.61 / **97.87**	85.38 / 94.67	91.35 / 97.16	96.65 / 97.70	— / —	**96.99** / 97.68
	8	96.13 / 97.80	96.67 / 96.45	96.76 / **98.16**	87.85 / 95.29	92.94 / 97.17	97.39 / 97.95	— / —	**97.60** / 97.93
	16	98.15 / 97.99	97.48 / 96.80	98.52 / **98.38**	90.29 / 95.61	92.51 / 97.19	**98.94** / 98.09	— / —	98.74 / 98.05
VisA	1	86.09 / 95.56	87.06 / 95.62	84.65 / 96.75	72.67 / 95.37	85.44 / **98.09**	**90.29** / 97.06	71.12 / 93.41	89.88 / 96.73
	2	87.87 / 96.29	90.64 / 96.63	87.67 / 97.43	77.24 / 96.37	— / —	**92.20** / **97.68**	71.59 / 94.59	92.15 / 97.32
	4	89.52 / 96.92	91.37 / 97.57	89.21 / 97.91	— / —	— / —	92.94 / **98.02**	76.42 / 96.14	**94.19** / 97.82
	8	92.36 / 97.18	93.11 / 97.99	91.53 / 98.11	— / —	— / —	94.50 / **98.29**	80.19 / 96.64	**95.01** / 98.25
	16	93.64 / 97.30	93.53 / 98.30	93.38 / 98.32	— / —	— / —	95.19 / 98.43	81.22 / 96.98	**95.99** / **98.49**

Table 3. ScopeAD 3-seed 교차 데이터셋 성능 (%, mean ± sample SD).

Dataset	2-shot (I-AUROC / P-AUROC)	16-shot (I-AUROC / P-AUROC)
MVTec AD	96.04 ± 0.30 / 97.38 ± 0.04	98.52 ± 0.20 / 98.05 ± 0.00
VisA	92.38 ± 1.04 / 97.40 ± 0.08	95.78 ± 0.18 / 98.50 ± 0.02

Table 4. MVTec AD 2 공식 private 서버 평가 (8-class macro, %). **Ours는 이전 게이트 설정 결과이며, 추후 linear0125 재제출 결과로 교체될 예정이다.**

방법	AU-PRO@0.05	ClassF1	SegF1
(a) Few-shot (16-shot)			
PatchCore	—	—	—
SuperAD	—	—	—
Ours (ScopeAD, 게이트 설정)†	**64.80 / 62.49**	**76.38 / 77.52**	**34.84 / 30.68**
(b) Full-data Reference (출판/리더보드)			
PatchCore	28.8 / 26.0	8.0 / 9.9	3.7 / 3.4
SuperAD	60.51 / 58.37	70.20 / 74.40	47.18 / 42.51
RoBiS	67.25 / 59.65	79.62 / 79.86	51.00 / 46.52
SuperADD	61.36 / 59.07	68.03 / 73.25	57.42 / 54.35

† Ours 행은 이전 비대칭 게이트 설정 결과다. 동일 서포트 및 임계값 절차로 linear0125 재제출 후 갱신 예정이다.

Table 5. ScopeAD 프레임워크 종합 구성 요소 소거 분석 (AD2 `test_public` 16-shot, seed 0, full8, %).

구성	Bank 구조	정규화	Shallow 항	AUPRO	pAUROC	ΔAUPRO
Full (Ours)	계층별 bank	q95	$+0.125\,z_5$	**59.57**	77.46	0.00
(b) 정규화 제거	계층별 bank	없음	$+0.125\,z_5$	59.17	**77.65**	−0.40
(c) 동일가중 평균	계층별 bank	q95	z_5 동일가중	58.21	76.31	−1.36
(d) Layer concat	단일 bank	q95	—	57.48	74.80	−2.09
(e) MAD 보정	계층별 bank	MAD	$+0.125\,z_5$	58.52	77.17	−1.05
(f) 448 단일입력	계층별 bank	q95	$+0.125\,z_5$	52.01	76.52	−7.56

Table 6. Shallow 가중치 λ 민감도 분석 (AD2 `test_public`, seed 0, %).

결합 규칙	2-shot AUPRO	2-shot pAUROC	16-shot AUPRO	16-shot pAUROC
Linear $d + 0.125s$ (Ours)	**59.33**	76.48	**59.57**	**77.46**
Linear $d + 0.25s$	58.43	76.00	59.48	77.21
Linear $d + 0.5s$	54.92	74.39	58.21	76.31
Linear $d + s$ (전체 가산)	48.39	71.31	54.02	74.04
Linear $d + 2s$	40.48	67.00	47.33	70.19

뼈대임을 입증한다. 셋째, 얕은 층에 동일 가중치를 부여하면(c) AUPRO가 1.36 pp 저하된다.

Shallow 가중치 λ 민감도. 표 6는 λ의 영향을 검증한다.

Table 7. AD2 정규화 팩토리얼 비교 (AUPRO@0.05 / pAUROC@0.05, seed 0, %).

Shot	none (미정규화)	MAD	q95 (기본)	q95 − MAD (AUPRO)
1	55.06 / 73.84	53.59 / 72.73	54.81 / 73.32	+1.22
2	59.06 / 76.47	58.57 / 76.34	59.33 / 76.48	+0.76
4	59.02 / 77.25	57.00 / 76.29	58.69 / 76.87	+1.69
8	58.69 / 77.67	57.28 / 76.67	58.68 / 77.35	+1.40
16	59.17 / 77.65	58.52 / 77.17	59.57 / 77.46	+1.05

Table 8. 다해상도 구성의 총 bank 용량 통제 비교 (%). **이 표는 게이트 설정 결과이며 추후 linear0125로 재실행하여 교체할 예정이다.**

해상도 설정	토큰 수/Bag	AUPRO	pAUROC
4개 해상도 결합	256	**59.15**	**77.11**
1120 단독	256	56.96	74.58
1120 용량 일치	1024	56.63	75.17

Table 9. 단일 대 다중 해상도 비교 (linear0125, AD2, seed 0, %).

해상도 구성	2-shot (AUPRO / pAUROC)	16-shot (AUPRO / pAUROC)
448 단독	51.14 / 75.80	52.01 / 76.52
672 단독	54.38 / 74.97	55.01 / 76.17
896 단독	52.65 / 73.46	55.12 / 74.62
1120 단독	54.27 / 72.47	57.47 / 74.86
4개 해상도 결합	**59.33 / 76.48**	**59.57 / 77.46**

얕은 층을 제어 없이 그대로 더할 경우($\lambda = 1$) 16-shot AUPRO가 54.02 %로 급락하며(-5.55 pp), 2-shot에서는 48.39 %로 하락폭이 더욱 커진다. 반면 $\lambda = 0.125$는 얕은 층의 정상 질감 노이즈를 억제하면서 미세 결함 단서만을 안전하게 흡수한다.

Scale Calibration 분석. 표 7는 정규화 방식의 영향을 비교한다. q95 분위수 정규화는 중심 기반의 MAD 정규화 대비 모든 샷에서 AUPRO가 $+0.76$–$+1.69$ pp 고르게 우수했다. 미정규화(none) 대비 성능 차이는 크지 않지만, 이질적 관측 간의 상대 척도를 안정적으로 정렬하는 통계적 일관성을 제공한다.

해상도 구성 비교. 표 8와 표 9는 다해상도 결합의 이득을 입증한다. 선형 가중 결합(표 9)에서 4개 해상도 결합은 최선의 단일 해상도 대비 AUPRO가 2-shot에서 $+4.95$ pp, 16-shot에서 $+2.10$ pp 높았다. 또한 토큰 용량을 맞춘 용량 통제 비교(표 8)에서도 4개 해상도 결합이 단일 1120px 1024-token 뱅크 대비 $+2.52$ pp 우수하여, 단순히 토큰 수가 늘어난 것이 아니라 다양한 척도의 공간 정보를 결합하는 구조 자체가 본질적 이득을 제공함을 실증한다.

5. 논의 및 한계 (Discussion & Limitations)

Observation Expansion과 관측별 뱅크 결합의 시너지. 다해상도 관측과 관측별 뱅크는 결합 과정의 서로 다른 단계에서 성능에 기여한다. 4개 해상도 결합은 최선의 단일 해상도 대비 $\text{AUPRO}_{0.05}$가 2-shot에서 4.95 pp, 16-shot에서 2.10 pp 높았으며, MVTec AD와 VisA에서도 I-AUROC와 P-AUROC가 고르게 향상되었다. 게이트 설정에서 총 뱅크 용량을 일치시킨 통제 비교(표 8)에서도 다해상도 결합이 1120px 단일 용량 일치 대조군 대비 2.52 pp 높았다. 나아가 관측별 뱅크는 계층 특징을 하나로 합친 단일 뱅크(Layer concat) 대비 3개 데이터셋 전 샷 구간에서 우수했다. 이는 다중 척도 표현 [12, 18]과 공간 해상도 개선 [5]의 이점이 패치 매칭 이상 국소화에서도 유효하며, 관측들을 하나로 뭉개지 않고 관측별 독립 뱅크로 유지할 때 그 잠재력이 온전히 보존됨을 보여준다.

Contribution Control을 통한 Shallow 질감 제어. 얕은 층 가산은 가중치 λ에 민감하게 반응한다. $\lambda \geq 0.5$에서는 $\text{AUPRO}_{0.05}$가 급격히 저하되며, $\lambda = 0.125$에서 2-shot 및 16-shot 모두 최적의 성능을 달성했다(표 6). 이는 얕은 층의 정상 질감 외관 변동이 결합 점수를 지배하지 않도록 기여량을 섬세하게 제어해야 한다는 본 논문의 동기와 정확히 일치한다.

Scale Calibration의 효과와 적용 범위. 정상 서포트 상위 분위수($q = 0.95$) 정렬은 중심 기반의 MAD 정렬 대비 전 샷 구간에서 일관된 성능 우위를 보였다. 다만 미정규화(none) 대비 성능 차이는 작고 방향이 혼재되어 나타났다. 컴포넌트 간 $q = 0.95$ 척도 차이가 평균 약 1.8배 수준으로 완만하여 정렬이 가중치를 극단적으로 왜곡하지 않는 안전망 역할을 하기 때문으로 분석된다. 더 큰 척도 차이를 지닌 이질적 백본이나 심한 획득 조건 변화 환경에서 정규화 효과를 확장 검증하는 것은 향후 과제다.

저-FPR 지표와 고정 배포 임계값의 과제. 서포트 분위수로 거리 단위를 정렬하더라도 테스트 쿼리 분포에서의 정확한 FPR이 수학적으로 보장되는 것은 아니다. 실제 제조 공정에서 고정된 단일 컷오프(cutoff)로 시스템을 운영하기 위해서는 획득 조건 드리프트에 대응하는 정밀한 테스트 시점 임계값 캘리브레이션 연구가 병행되어야 한다.

6. 결론 (Conclusion)

본 논문은 소수 정상 서포트 기반의 산업 이상 국소화에서 High-Score Ambiguity를 극복하기 위해 다차원 관측 확장과 서포트 기반 척도 보정을 결합한 **ScopeAD** (ScopeAD)를 제안했다. 동결된 백본을 재학습하지 않고 입력 해상도와 표현 계층 축으로 관측을 확장하여 정보 획득을 극대화하고, 관측 조건마다 48개 독립 뱅크를 구축하여 특징 간 혼선을 차단했다. 나아가 정상 서포트 상위 분위수($q = 0.95$)로 점수 단위를 정렬하고, 얕은 층을 작은 고정 가중치($\lambda = 0.125$)로 선형 가산함으로써 저-FPR 국소화 성능을 극대화했다. MVTec AD 2 16-shot 벤치마크에서 ScopeAD는 3-seed 평균 60.06 % $\text{AUPRO}_{0.05}$를 달성하여 SuperAD 대비 4.17 pp 우위를 보였으며, 단일 뱅크 대비 +2.09 pp, 최선 단일 해상도 대비 +2.10 pp의 뚜렷한 구성 및 결합 이득을 실증했다.

References

[1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD – a comprehensive real-world dataset for unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019. 4

[2] Joao P. C. Bertoldo, Dick Ameln, Ashwin Vaidya, and Samet Akcay. AUPIMO: Redefining visual anomaly detection benchmarks with high speed and low tolerance. *arXiv preprint arXiv:2401.01984*, 2024. 2

[3] Simon Damm, Mike Laszkiewicz, Johannes Lederer, and Asja Fischer. Anomalydino: Boosting patch-based few-shot anomaly detection with dinov2. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1319–1329, 2025. 1, 2, 4

[4] Zheng Fang, Xiaoyang Wang, Haocheng Li, Jiejie Liu, Qiugui Hu, and Jimin Xiao. Fastrecon: Few-shot industrial anomaly detection via fast feature reconstruction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 17481–17490, 2023. 2, 4

[5] Stephanie Fu, Mark Hamilton, Laura E. Brandt, Axel Feldmann, Zhoutong Zhang, and William T. Freeman. FeatUp: A model-agnostic framework for features at any resolution. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 1, 6

[6] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1321–1330, 2017. 2

[7] Lars Heckler-Kram, Jan-Hendrik Neudeck, Ulla Scheler, Rebecca König, and Carsten Steger. The MVTec AD 2 dataset: Advanced scenarios for unsupervised anomaly detection. *International Journal of Computer Vision*, 134(4), 2026. 2, 4

[8] Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2019. 1

[9] Chaoqin Huang, Haoyan Guan, Aofan Jiang, Ya Zhang, Michael Spratling, and Yan-Feng Wang. Registration based few-shot anomaly detection. *arXiv preprint arXiv:2207.07361*, 2022. 2, 4

[10] Jeesoo Kim, Junsuk Choe, Sangdoo Yun, and Nojun Kwak. Normalization matters in weakly supervised object localization. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 3427–3436, 2021. 2

[11] Camile Lendering, Erkut Akdag, and Egor Bondarau. Subspacead: Training-free few-shot anomaly detection via subspace modeling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 28557–28566, 2026. 2, 4

[12] Tsung-Yi Lin, Piotr Dollar, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2117–2125, 2017. 1, 6

[13] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023. 1, 2

[14] Yaniv Ovadia, Emily Fertig, Jie Ren, Zachary Nado, D. Sculley, Sebastian Nowozin, Joshua Dillon, Balaji Lakshminarayanan, and Jasper Snoek. Can you trust your model's uncertainty? evaluating predictive uncertainty under dataset shift. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. 1

[15] Maithra Raghu, Thomas Unterthiner, Simon Kornblith, Chiyuan Zhang, and Alexey Dosovitskiy. Do vision transformers see like convolutional neural networks? In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 12116–12128, 2021. 1

[16] Rene Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 12179–12188, 2021. 1, 2

[17] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14298–14308, 2022. 1, 2, 4

[18] Baifeng Shi, Ziyang Wu, Maolin Mao, Xin Wang, and Trevor Darrell. When do we not need larger vision models? In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2024. 1, 2, 6

[19] Weilin Tu. Few-shot anomaly detection on MVTec AD 2: A systematic study and a strong frozen baseline. *IEEE Access*, 14:152500–152511, 2026. 2

[20] Haoqi Wang, Zhizhong Li, Litong Feng, and Wayne Zhang. ViM: Out-of-distribution with virtual-logit matching. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4921–4930, 2022. 2

[21] Jin Wang, Ying-Hang Li, Bo-Wen Jiang, and Shi-Chao Li. FreePatch: A training-free multiscale patch matching method for few-shot industrial anomaly detection. In *International Conference on Computer Vision, Graphics, and Artificial Intelligence (CVGAI 2026)*, 2026. 2

[22] Huaiyuan Zhang, Hang Chen, Yu Cheng, Shunyi Wu, Linghao Sun, Linao Han, Zeyu Shi, and Lei Qi. Superad: A training-free anomaly classification and segmentation method for cvpr 2025 vand 3.0 workshop challenge track 1: Adapt & detect. *arXiv preprint arXiv:2505.19750*, 2025. 2, 4

[23] Xingwu Zhang, Guanxuan Li, Paul Henderson, Gerardo Aragon-Camarasa, and Zijun Long. Is task-specific training necessary for anomaly detection? *arXiv preprint arXiv:2601.22763*, 2026. Version 3. 4

[24] Zilong Zhang, Zhibin Zhao, Xingwu Zhang, Chuang Sun, and Xuefeng Chen. Industrial anomaly detection with domain shift: A real-world dataset and masked multi-scale reconstruction. *Computers in Industry*, 151:103990, 2023. 2

[25] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. *arXiv preprint arXiv:2207.14315*, 2022. 4