ScopeAD: Observation Expansion and Support-Referenced Asymmetric Fusion for Few-Shot Industrial Anomaly Localization

Anonymous CVPR submission

Abstract

*동결 특징 기반의 최근접 이웃 매칭은 소수의 정상 참조 이미지만으로 결함을 찾는 few-shot 산업 이상 탐지 방식이다. 그러나 조명이나 자세 같은 획득 조건이 바뀌면 서포트에 없는 정상 외관에서도 거리가 커져, 높은 점수가 실제 결함 때문인지 미관측 정상 변동 때문인지 구분하기 어렵다. 본 논문은 이 문제를 **High-Score Ambiguity**로 정의한다. 단일 관측에서 정상과 결함의 점수가 비슷한 위치라도, 다른 표현 계층이나 입력 해상도에서는 두 영역의 반응 차이가 드러난다. 이 관찰을 바탕으로, 동일한 정상 서포트를 여러 계층과 해상도에서 독립 비교한 뒤 단일 점수로 통합하는 **ScopeAD**를 제안한다. ScopeAD는 정상 서포트 내부 교차 비교 거리의 통계적 분포를 기준으로 관측 간 척도를 정렬하고, 깊은 계층을 중심으로 얕은 계층을 보조 결합한다. 이어 위치별 해상도 점수 순위에 Rényi 가중치를 적용하여, 특정 해상도에서 포착된 결함 반응이 단순 평균 과정에서 희석되는 것을 줄인다. 모든 과정은 백본의 추가 학습이나 쿼리 시점 적응 없이 이루어진다. MVTec AD 2에서 ScopeAD는 1–16-shot 전 구간에서 비교 방법 중 가장 높은 $\text{AUPRO}_{0.05}$를 달성했으며 (1-shot 52.18 %, 차순위 대비 +5.87 pp), 획득 조건 변화 환경(2-shot)에서도 동일 오경보율(1 %) 하에 결함 픽셀 재현율을 36.2 %에서 45.5 %로 높였다. 아울러 MVTec AD와 VisA에서도 경쟁력 있는 성능을 보였다.*

1. 서론

다품종 소량 생산과 빈번한 라인 전환이 발생하는 제조 환경에서는 제품별 결함 표본을 충분히 수집하기 어렵다. 이에 따라 소수의 정상 참조 이미지만으로 결함 위치를 특정하는 few-shot 이상 탐지(few-shot anomaly detection)가 실용적인 대안으로 활용된다. 대표적으로, 동결된 사전학습 백본 [12]으로 정상 패치의 메모리 뱅크를 구축한 후, 테스트 패치와의 최근접 이웃 거리를 계산하여 이상치를 탐지하는 방법이 있다 [3, 16, 20]. 이러한 거리 기반 점수는 정상 패치가 메모리 뱅크의 특징과 유사하다는 가정에 기반한다. 그러나 실제 공정에서는 조명 드리프트, 부품 자세 변동, 표면 난반사 등 다양한 distribution shift가 빈번히 발생한다 [6, 22]. 소수의 정상 표본만 주어지는 few-shot 환경에서는 이러한 외부 조건 변화에 따른 정상 외관의 변동폭을 메모리 뱅크에 충분히 담기 어렵다. 그 결과 서포트 셋에서 관측되지 않은 정상 변동 영역에서도 최근접 거리가 상승하여 실제 결함 점수와 겹칠 수 있다. 이처럼 정상 표본의 희소성과 획득 환경 변화가 함께 작용하면, 단일 거리값만으로는 고점수의 원인이 실제 결함인지 미관측 정상 변동인지 판별하기 어렵다. 본 논문은 이러한 한계를 **High-Score Ambiguity (HSA)**로 정의한다(Fig. 1). 정상 영역의 오탐을 배제하고자 임계값을 높일수록 실제 결함 검출 영역 또한 함께 축소되므로, 이 현상은 저-FPR 구간의 결함 국소화 성능을 저해한다 [2]. 실제로 MVTec AD 2에서 기본 조건 성능이 가장 높은 기존 방법도, 획득 조건이 바뀐 영상에서는 $\text{AUPRO}_{0.05}$가 최대 10.73 pp 낮아진다(Tab. 2).

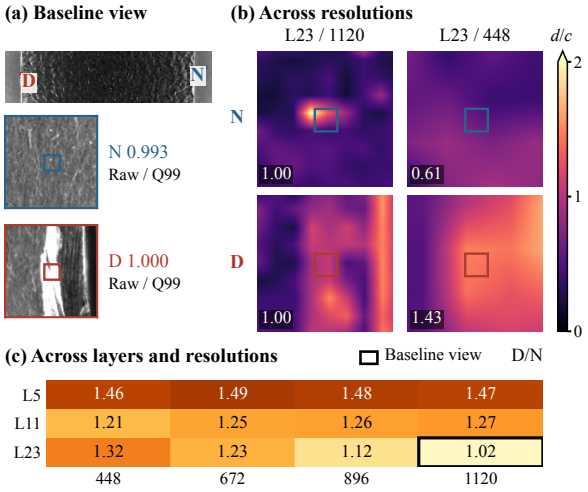


Figure 1. **단일 관측의 모호함과 관측 확장의 단서.** MVTec AD 2에서 정상 서포트 이미지 2장(2-shot)을 기준으로 계산한 패치 거리를 분석했다. 기준 관측(L23/1120)에서 정상·결함 점수가 비슷한 위치를 고정하고, 같은 위치를 각 계층·해상도에서 따로 측정했다(결합 없음). (a,b) Sheet metal `007_shift_2`에서 사후 선택한 정상 N·결함 D 영역의 기준 점수와 해상도별 거리 맵(d/c, 수치는 영역 평균). (c) 8개 클래스 고정 위치의 관측별 결함/정상 평균 비(D/N).

High-Score Ambiguity(HSA) 완화를 위해서는 단일 관측에서 유사한 거리를 보이는 미관측 정상 변동과 실제

결함을 구분할 추가 단서가 요구된다. Fig. 1은 판별 단서가 타 관측 공간에 존재함을 보여준다. 구체적으로 기준 관측에서 유사한 이상 점수를 나타내는 정상 및 결함 영역이라도, 더 낮은 입력 해상도에서는 결함 반응이 유지되는 반면 정상 변동에 의한 반응은 크게 감소한다(Fig. 1b). 8개 클래스를 합친 위치 집단에서도 같은 경향이 나타난다. 기준 관측에서 정상과 결함의 평균 점수가 비슷한 위치($D/N = 1.02$)에서도, 나머지 11개 관측에서는 모두 결함 영역의 평균 점수가 더 높게 형성된다(1.12–1.49, Fig. 1c). 이러한 차이는 계층과 해상도가 서로 다른 시각적 단서를 포착하기 때문에 나타날 수 있다. 표현 계층은 국소 외관부터 전역 문맥까지 깊이에 따른 추상화 수준을 담고 [13, 14], 입력 해상도는 고정 패치 백본에서 한 토큰이 덮는 원본 영상의 공간 범위를 바꾼다 [5, 17]. 이를 바탕으로 추가 학습이나 서포트 증강 없이, 동일한 정상 서포트를 계층과 해상도의 두 축으로 분리·전개하는 관측 확장(observation expansion)을 수행한다.

확장된 다중 관측을 활용할 때는 각 관측 고유의 단서가 손실되지 않도록 매칭 방식을 설계해야 한다. 특징 연결 공간에서는 거리 기여가 큰 계층이 최근접 이웃 선택을 지배할 수 있다 [16]. ScopeAD는 계층·해상도별로 뱅크를 분리하여 각 관측의 비교 단서를 유지한다. 그러나 이처럼 독립 산출된 점수들을 통합할 때는 관측 간 척도 불균형(Fig. 3)과 단순 평균 시 국소 결함 반응이 희석되는 두 가지 문제가 뒤따른다. 이에 본 논문은 소수의 정상 서포트만으로 이 다중 점수를 통합하는 **ScopeAD**를 제안한다. ScopeAD는 서포트 내부 교차 매칭(cross-matching) 거리의 상위 분위수(Q99)로 관측 간 거리 척도를 먼저 정렬한 뒤, 깊은 계층을 주축으로 삼고 얕은 계층의 단서를 작은 가중치로 더한다. 이어 위치별 다중 해상도 점수의 상위 순위에 높은 Rényi 가중치를 부여하여, 특정 해상도에서 포착된 결함 반응의 희석을 완화한다. MVTec AD 2의 2-shot 사후 진단에서, 선택 구간 내 정상·결함 구분 AUROC는 단일 관측의 58.0 %에서 ScopeAD의 79.6 %로 높아졌고, shift 조건의 FPR 1%에서 결함 픽셀 재현율은 36.2 %에서 45.5 %로 높아졌다(Fig. 4). 또한 MVTec AD 2의 $\mathrm{AUPRO}_{0.05}$의 전 구간에서 비교 방법 중 가장 높은 성능을 기록했으며, MVTec AD와 VisA에서도 경쟁력 있는 성능을 보였다.

본 논문의 기여는 다음과 같다.

- 제한된 정상 서포트의 계층과 입력 해상도를 독립 매칭 단위로 분리·확장하여 High-Score Ambiguity를 완화하는 few-shot 이상 국소화 방법 ScopeAD를 제시한다.
- 정상 참조 척도 보정, 계층별 비대칭 가중합, 위치별 해상도 순위 집계로 이루어진 점수 통합 규칙을 제안하고, 척도 정렬과 순위 집계를 함께 적용할 때 이득이 커짐을 분석한다.
- 단일 관측이 구분하지 못하는 위치에서의 정상·결함 분리와 같은 오경보율에서의 결함 픽셀 재현율로 HSA 완화를 분석하고, MVTec AD 2의 저-FPR 국소화 성능, 공식 `test_private` 평가, 구성 요소·하이퍼파라미터 분석, MVTec AD·VisA 결과를 보고한다.

2. 관련 연구

2.1. Few-shot 이상 탐지의 참조 매칭

Few-shot 이상 탐지는 소수의 정상 참조 이미지와 테스트 쿼리 간의 특징 차이를 비교하여 결함을 탐지 및 국소화한다. 제한된 참조 표본의 한계를 보완하기 위해 이미지 간 기하학적 정합을 학습하거나 [7], 시각-언어 모델의 사전 지식을 결합하여 정상과 이상을 구분하는 방법론이 제안되었다 [8, 11]. 또한 보조 데이터셋에서 일반화된 비교 규칙 및 프롬프트를 메타 학습하는 접근 [23, 24]이나, 정상 서포트 없이 레이블이 없는 테스트 이미지 간 상호 유사도를 비교하는 방식 [10]도 연구되었다. 반면, 본 논문과 같이 소수의 정상 서포트와 동결된(frozen) 사전학습 특징만을 활용하는 접근은 정상 참조와의 차이를 최근접 이웃 거리 [3, 16, 20], 특징 복원 오차 [4], 또는 부분공간 투영 거리 [9]로 정량화한다. 특히 동결 특징 기반 패치 매칭은 백본에 대한 추가 학습 없이 새로운 제품군에 즉각 적용할 수 있어 실용적이며 [3, 20], 최근 MVTec AD 2 few-shot 연구 [18]에서도 백본 계층과 서포트 수에 따른 매칭 특성이 분석되었다. 그러나 단일 관측에 의존하는 기존 참조 매칭은 획득 조건이 변화할 때 미관측 정상 변동과 실제 결함의 거리가 동시에 상승하는 High-Score Ambiguity에 취약하다. ScopeAD는 단일 관측 대신 계층과 해상도별 독립 매칭 결과를 함께 사용한다.

2.2. 다중 척도 관측과 점수 결합

다중 계층과 해상도의 특징을 활용하면 국소 외관 질감부터 전역 문맥까지 다각적인 비교 단서를 확보할 수 있다. 다층 ViT 특징을 조립하여 밀집 예측에 활용하는 DPT [14]나 다중 해상도 입력으로 동결 백본의 표현 척도를 확장하는 S^2 [17]가 대표적이다. 이상 탐지 분야에서는 이러한 다중 척도 단서를 특징 수준에서 연결(concatenation)하여 통합 매칭하거나 [16], 관측별 개별 점수를 산출한 후 결합하는 방식 [19, 20]이 주로 활용되었다. 특징 연결 방식은 하나의 공간에서 최근접 이웃을 선택하는 반면, 개별 점수 결합 방식은 관측별 매칭 결과를 통합한다. 그러나 점수 결합 방식 역시 관측 간 거리 척도 불균형(scale discrepancy)을 보정하지 않으면 기저 거리가 큰 특정 관측으로 결합 점수가 편향되는 한계를 지닌다. 나아가 척도를 정렬한 이후에도 모든 관측을 균등하게 평균하면, 특정 관측에 집중된 결함 반응이 다른 관측의 낮은 점수에 희석(dilution)될 수 있다. ScopeAD는 정상 서포트를 기준으로 척도를 맞춘 뒤 위치별 점수 순위를 이용해 결합한다(Secs. 3.3 and 3.4).

2.3. 획득 조건 변화와 저-FPR 국소화

실제 제조 환경에서 획득 조건 변화(distribution shift)가 발생하면, 무결함 정상 영역이라도 외관 차이로 인해 참조 매칭 거리가 크게 증가할 수 있다. 이러한 도메인 변화를 반영하기 위해 AeBAD [22]는 공정 내 배경 및 조명 변화를 도입했으며, MVTec AD 2 [6]는 학습 데이터에 부재한 극단적 조명 및 노출 조건을 포함하여 평가 난이도를 높였다. 특히 소수의 정상 표본만 주어지는 few-shot

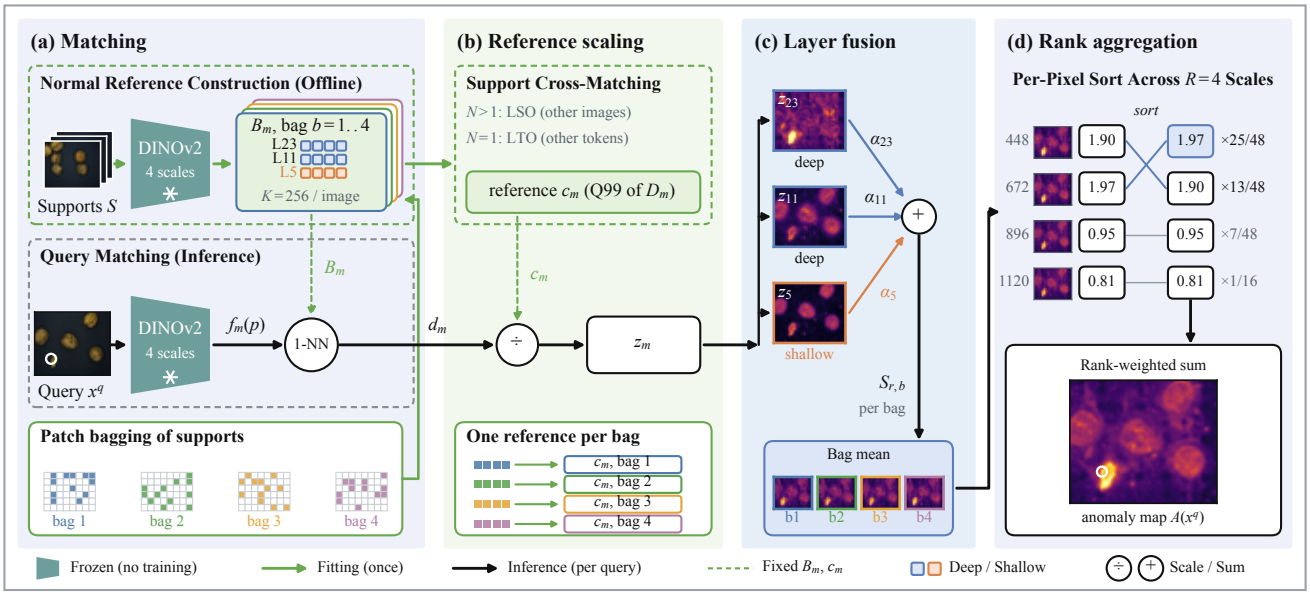


Figure 2. **Overview of ScopeAD.** (a) 정상 서포트로 관측 $m = (l, r, b)$별 뱅크 B_m을 구축하고 쿼리 패치를 각 뱅크에서 독립적으로 매칭한다. (b) 서포트 교차 매칭으로 관측별 기준 c_m을 정하고 쿼리 거리를 z_m으로 정규화한다. (c) 계층별 점수를 결합한 뒤 배그 평균으로 해상도별 점수를 얻는다. (d) 픽셀마다 해상도별 점수를 순위에 따라 가중합해 최종 이상 맵 $A(x^q)$를 얻는다. 맵과 수치는 MVTec AD 2 walnuts의 예시이다.

환경에서는 서포트가 이러한 외관 변동폭을 포괄하지 못하므로, 정상 영역의 점수 상승이 낮은 오경보율에서 결함 검출을 얼마나 줄이는지 평가할 필요가 있다. 그러나 전체 FPR 구간을 요약하는 표준 AUROC는 오경보를 엄격히 제한하는 구간의 성능 차이를 잘 드러내지 못한다. AUPIMO [2]와 저-FPR 구간의 $\text{AUPRO}_{0.05}$는 낮은 오경보율에서의 결함 영역 검출률을 직접 평가한다. 본 논문은 MVTec AD 2에서 few-shot 조건과 획득 조건 변화가 함께 있을 때의 저-FPR 국소화 성능을 비교한다.

3. 제안 방법

ScopeAD는 정상 서포트를 계층·해상도별로 독립 매칭하고, 산출된 거리 맵을 순차적으로 통합한다(Fig. 2). 먼저 서포트 교차 매칭 거리의 상위 분위수로 관측 간 척도를 맞춘다. 다음으로 계층별 점수를 비대칭 가중합하고 배그별 결과를 평균한다. 마지막으로 공간 정렬한 해상도별 점수에 위치별 순위 가중치를 적용하여 최종 이상 맵을 얻는다. 메모리 뱅크와 기준 척도는 추론 전에 구성하며, 백본 추가 학습이나 쿼리 적응은 수행하지 않는다.

3.1. 문제 설정

입력으로 N장의 정상 서포트 이미지 집합 $\mathcal{S} = \{x_1^s, \ldots, x_N^s\}$, 테스트 쿼리 이미지 x^q, 그리고 동결된 사전학습 비전 트랜스포머(ViT) 백본이 주어진다. 특징을 추출할 백본 계층 집합을 $\mathcal{L}$, 입력 해상도(짧은 변 기준) 집합을 $\mathcal{R}$, 서브샘플 배그(bag) 수를 N_b로 정의한다. 본 연구에서는 $\mathcal{L} = \{5, 11, 23\}$, $\mathcal{R} = \{448, 672, 896, 1120\}$, $N_b = 4$를 사용하여 총 $|\mathcal{L}| \times |\mathcal{R}| \times N_b = 48$개의 관측별 매칭 단위를 구성한다(Sec. 4.1). 이 관측들은 같은 이미지에서 추출되므로 서로 상관될 수 있으며, 여기서 독립 매칭은 각 관측이 별도 뱅크에서 최근접 이웃을 탐색한다는 뜻이다. ScopeAD는 픽셀 단위 결함 국소화 맵 $A(x^q) \in \mathbb{R}^{H \times W}$와 이미지 단위 이상 점수 $s(x^q) \in \mathbb{R}$를 출력한다.

3.2. 관측 확장과 독립 참조 매칭

다중 계층 특징을 연결하여 매칭하면, 연결 공간에서 거리 기여가 큰 계층이 최근접 이웃 선택을 지배할 수 있다 [16]. ScopeAD는 계층 $l \in \mathcal{L}$, 해상도 $r \in \mathcal{R}$, 배그 인덱스 $b \in \{1, \ldots, N_b\}$의 조합 $m = (l, r, b)$별로 메모리 뱅크 B_m을 구성한다. 쿼리 이미지 x^q의 공간 위치 p에서 추출된 ℓ_2 정규화 패치 토큰 $f_m(x^q, p)$는 오직 대응하는 뱅크 B_m 내에서만 독립적으로 최근접 이웃을 탐색하여 코사인 거리 점수를 계산한다:

$$d_m(x^q, p) = \min_{u \in B_m} \left[1 - f_m(x^q, p)^\top u\right]. \qquad (1)$$

이 구조에서는 각 관측이 자신의 표현 층위와 공간 척도 내에서 최적의 정상 토큰을 독립 탐색하므로, 특정 관측의 거리 상승이 타 관측의 이웃 선택에 간섭하지 않고 국소 질감과 전역 문맥 신호가 관측별 거리 신호로 보존된다.

이때 입력 해상도가 커질수록 서포트 패치 토큰 수가 급증하므로, 메모리와 계산 비용을 통제하고 토큰 구성에 따른 점수 변동을 줄이기 위해 패치 서브샘플 배깅을 적용한다. 구체적으로 각 해상도 r에서 서포트 이미지당 $K = 256$개의 패치를 비복원 균등 추출하여 단일 배그를 구성하며, 서로 다른 난수로 $N_b = 4$개의 배그를 생성한다. 계층 간 공간적 대응 관계를 유지하기 위해 동일 배그

내의 모든 계층($l \in \mathcal{L}$)은 완전히 일치하는 공간 좌표의 토큰을 공유하며, 각 배그에서 독립 계산된 이상 점수는 이후 다해상도 통합 단계(Eq. (6))에서 앙상블 평균된다.

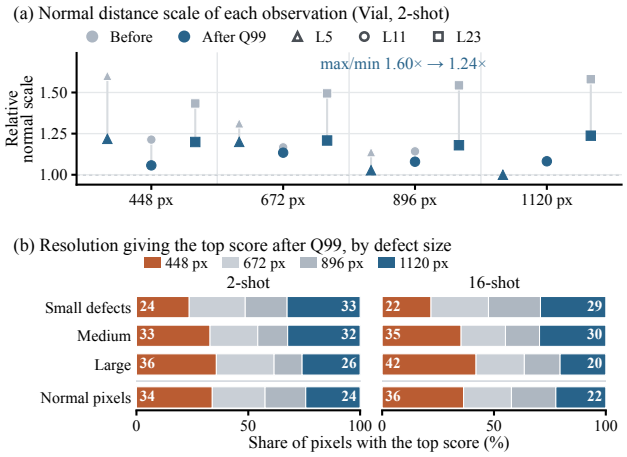


Figure 3. **Q99 보정에 따른 척도 정렬과 결함 크기별 최고 점수 해상도.** (a) Vial 2-shot에서 12개 관측의 서포트 Q99 보정 전후 정상 거리 척도(정상 쿼리 거리의 Q99, 최솟값=1). (b) Q99 보정 후 위치별로 가장 높은 점수를 낸 해상도의 비율(MVTec AD 2, 8개 클래스 평균). 결함 크기는 이미지 면적 대비 0.1 % 미만(small), 0.1–1 %(medium), 1 % 이상(large)이다.

3.3. 정상 참조 기반 비대칭 선형 결합

독립 매칭으로 산출된 원시 거리 d_m을 통합하려면 먼저 계층 깊이와 입력 해상도에 따른 관측 간 척도 불균형(scale discrepancy)을 해소해야 한다. 관측마다 정상 거리 척도가 다르므로(Fig. 3의 Vial에서 최대 1.60배) 보정 없이 결합하면 기저 거리가 큰 관측이 결합 점수와 순위를 지배할 수 있다. 따라서 새 이미지와 비교할 때 정상 패치 사이에서도 발생하는 기준 거리의 크기를 측정하여 관측 간 척도를 정렬한다. 이를 위해 정상 서포트 내부의 교차 매칭 거리 표본 D_m을 먼저 수집한다. 다중 샷($N > 1$) 환경에서는 동일 이미지 내 자기 유사 패치와 매칭되어 거리가 과소 추정되는 편향을 막기 위해, 서포트 이미지 i의 토큰 부분집합 $B_m^{(i)}$를 해당 이미지를 제외한 나머지 뱅크 토큰들과 매칭하는 Leave-Source-Out (LSO) 방식을 적용한다:

$$D_m^{\mathrm{LSO}} = \bigcup_{i=1}^{N} \left\{ \min_{u \in B_m \setminus B_m^{(i)}} \left[1 - v^\top u\right] : v \in B_m^{(i)} \right\}. \quad (2)$$

단일 샷($N = 1$) 환경에서는 이미지 간 교차가 불가능하므로, 단일 이미지 내에서 자신을 제외한 타 위치 토큰들과 매칭하는 Leave-Token-Out (LTO) 표본을 대리 통계량으로 사용한다:

$$D_m^{\mathrm{LTO}} = \left\{ \min_{j \neq i} \left(1 - v_i^\top v_j\right) : i = 1, \ldots, K \right\}. \quad (3)$$

이렇게 얻은 거리 표본 집합 D_m으로부터 각 관측의 기준 척도 c_m을 산출한다. 관측에 따라 거리 분포의 비대칭성과 꼬리 두께가 상이하므로, 특정 분포를 가정하는 대신 비모수적 순서 통계량인 상위 분위수 $\mathcal{Q}_q$로 c_m을 정의하고 정규화 점수 z_m을 계산한다:

$$c_m = \max\left\{\mathcal{Q}_q(D_m),\, \epsilon\right\}, \qquad z_m(x^q, p) = \frac{d_m(x^q, p)}{c_m}, \quad (4)$$

여기서 $q = 0.99$이며, $\epsilon = 10^{-4}$는 수치적 안정성을 위한 하한값이다. 정규화 점수 z_m은 정상 참조 거리의 상위 기준값 대비 비율을 뜻하며, $z_m = 1$ 자체가 결함 판정 임계값은 아니다. 이 정렬로 관측 간 정상 거리 척도의 편차가 줄어든다(Fig. 3a).

척도를 정렬한 뒤에도 계층마다 포착하는 정보의 특성이 다르므로 단순 균등 평균 대신 비대칭 결합을 적용한다. 계층별 결합 가중치는 국소화 성능을 기준으로 비교했다(Tab. 7). 본 논문은 깊은 두 계층의 정규화 점수 평균을 기저 점수로 사용하고, 얕은 계층은 $\lambda = 0.125$의 가중치로 보조 결합한다:

$$S_{r,b}(x^q, p) = \frac{1}{2} \sum_{l \in \{11,23\}} z_{l,r,b}(x^q, p) + \lambda\, z_{5,r,b}(x^q, p). \quad (5)$$

정규화 점수가 $z_m = d_m / c_m$이므로, Eq. (5)은 원시 거리 $d_{l,r,b}$에 계수 $\alpha_l / c_{l,r,b}$를 곱해 합산한 선형 결합과 같으며, 여기서 $(\alpha_5, \alpha_{11}, \alpha_{23}) = (0.125, 0.5, 0.5)$이다.

3.4. 다해상도 순서 통계량 집계

계층 결합 후 각 해상도 r에서 N_b개 배그 점수를 평균하고, 양선형 보간으로 원본 이미지 크기 (H, W)에 공간 정렬한다:

$$S_r(x^q, p) = \frac{1}{N_b} \sum_{b=1}^{N_b} S_{r,b}(x^q, p). \quad (6)$$

결함 크기에 따라 반응이 강한 해상도가 다르므로(Fig. 3b), ScopeAD는 해상도별 고정 가중치 대신 위치별 점수 순위에 따라 가중치를 부여한다. 이는 산술 평균의 신호 희석과 최댓값 집계의 잡음 민감도를 절충하여 상위 순위에 더 큰 비중을 두기 위함이다. 구체적으로 위치 p에서 $R = |\mathcal{R}|$개 해상도의 점수를 $S_{(1)}(x^q, p) \le \cdots \le S_{(R)}(x^q, p)$로 오름차순 정렬한다. 이때 결함 검증 표본이 없는 환경에서 가중치 간격을 임의 조정하는 휴리스틱을 피하고자, 관측 수 R로부터 닫힌형태로 유도되는 비모수적 순서 통계량 가중치를 쓴다. 표준 지수 분포 순서통계량의 기댓값인 Rényi 표현 $a_k = \sum_{j=1}^{k} (R - j + 1)^{-1}$을 정규화하여 $w_k = a_k / \sum_{j=1}^{R} a_j$로 정하며, $R = 4$일 때 $w = (\frac{1}{16}, \frac{7}{48}, \frac{13}{48}, \frac{25}{48})$이다. 최종 이상 맵 $A(x^q) = \tilde{A}(x^q)$는 이 가중치를 적용해 산출한다:

$$\tilde{A}(x^q, p) = \sum_{k=1}^{R} w_k\, S_{(k)}(x^q, p). \quad (7)$$

Table 1. MVTec AD 2 `test_public` few-shot 비교 (8개 클래스 macro, 평균 ± 표본 표준편차, %). †: RegAD는 STN 제약으로 해상도 224에서 평가. 굵은 값과 밑줄은 최고·차순위 평균이다.

Shot	Metric	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD (224)†	Ours (ScopeAD)
1	$\text{AUPRO}_{0.05}$	38.45 ± 1.85	35.95 ± 2.24	14.92 ± 2.27	26.42 ± 1.71	44.87 ± 1.87	46.31 ± 3.73	12.73 ± 0.38	**52.18 ± 4.07**
	$\text{pAUROC}_{0.05}$	64.19 ± 0.68	70.67 ± 0.69	55.70 ± 0.67	59.57 ± 0.35	70.56 ± 0.56	70.13 ± 1.14	57.76 ± 0.30	**73.01 ± 1.60**
	I-AUROC	65.51 ± 1.91	66.83 ± 1.08	58.10 ± 4.46	58.68 ± 3.03	67.02 ± 2.27	67.68 ± 0.32	57.73 ± 1.82	**73.59 ± 0.36**
2	$\text{AUPRO}_{0.05}$	42.25 ± 2.08	38.20 ± 1.90	16.73 ± 2.39	31.61 ± 1.47	45.90 ± 0.75	49.80 ± 2.33	15.05 ± 0.30	**56.78 ± 2.77**
	$\text{pAUROC}_{0.05}$	65.43 ± 0.38	72.26 ± 0.56	57.14 ± 1.03	61.78 ± 0.15	71.53 ± 0.18	71.52 ± 0.58	58.76 ± 0.49	**75.83 ± 0.51**
	I-AUROC	67.53 ± 1.55	68.95 ± 3.84	57.63 ± 6.82	59.37 ± 2.54	70.42 ± 1.79	70.19 ± 2.16	60.56 ± 3.94	**75.04 ± 1.48**
4	$\text{AUPRO}_{0.05}$	46.94 ± 1.00	40.32 ± 0.75	21.88 ± 1.73	36.51 ± 1.02	47.14 ± 0.76	54.25 ± 0.86	17.40 ± 1.07	**59.49 ± 0.12**
	$\text{pAUROC}_{0.05}$	66.90 ± 0.22	73.09 ± 0.91	59.26 ± 0.80	63.84 ± 0.41	72.45 ± 0.20	73.59 ± 0.13	60.36 ± 0.48	**76.96 ± 0.55**
	I-AUROC	68.62 ± 2.28	70.90 ± 0.97	59.73 ± 4.40	62.31 ± 4.84	71.02 ± 0.56	70.97 ± 2.08	63.79 ± 2.34	**76.14 ± 0.50**
8	$\text{AUPRO}_{0.05}$	49.98 ± 1.90	41.64 ± 1.01	27.32 ± 0.14	40.79 ± 0.79	47.28 ± 0.40	55.44 ± 1.21	19.25 ± 0.64	**60.40 ± 0.89**
	$\text{pAUROC}_{0.05}$	68.22 ± 0.53	73.71 ± 0.20	61.74 ± 0.50	65.62 ± 0.69	72.56 ± 0.21	74.31 ± 0.38	62.02 ± 0.32	**77.57 ± 0.17**
	I-AUROC	69.20 ± 0.75	71.29 ± 1.69	63.46 ± 4.29	65.84 ± 0.43	70.46 ± 1.18	70.75 ± 0.58	64.34 ± 1.05	**76.39 ± 0.67**
16	$\text{AUPRO}_{0.05}$	52.73 ± 1.36	42.30 ± 1.25	35.23 ± 0.57	42.58 ± 1.10	47.63 ± 0.14	55.89 ± 1.07	20.28 ± 0.80	**60.74 ± 0.72**
	$\text{pAUROC}_{0.05}$	69.36 ± 0.51	73.97 ± 0.23	65.63 ± 0.43	66.62 ± 0.89	72.78 ± 0.07	74.60 ± 0.52	63.46 ± 0.76	**77.77 ± 0.34**
	I-AUROC	69.00 ± 0.53	72.07 ± 1.27	67.45 ± 1.16	67.60 ± 1.35	70.46 ± 1.07	69.79 ± 0.52	65.64 ± 1.34	**76.40 ± 0.95**

이미지 단위 이상 점수는 최종 이상 맵의 상위 1% 픽셀 집합 $\Omega_{0.01}$의 평균으로 계산한다. 집합 크기는 $|\Omega_{0.01}| = \max\{1, \lfloor 0.01HW \rfloor\}$이다:

$$s(x^q) = \frac{1}{|\Omega_{0.01}|} \sum_{p \in \Omega_{0.01}} A(x^q, p). \tag{8}$$

4. 실험

4.1. 평가 설정

데이터셋 및 평가 지표. 조명 및 노출 등 다양한 획득 조건 변화를 포함하는 MVTec AD 2 [6](`test_public`, 8개 클래스)를 주 벤치마크로 사용하며, 표준 환경 검증을 위해 MVTec AD(15개) [1] 및 VisA(12개) [25]를 함께 평가한다. 정상 서포트 수는 $N \in \{1, 2, 4, 8, 16\}$이며, 다중 서포트 분할에 대한 평균을 보고한다. 평가 지표로는 저-FPR 구간(FPR ≤ 0.05)의 결함 국소화 성능을 정밀 측정하는 클래스 macro $\text{AUPRO}_{0.05}$및 $\text{pAUROC}_{0.05}$와, 이미지 단위 판별 지표인 I-AUROC를 채택한다. 기존 벤치마크에는 픽셀 단위 P-AUROC도 병기한다.

비교군 및 구현 세부사항. 동결된 DINOv2 ViT-L/14 백본에서 계층 $\{5, 11, 23\}$과 4개 해상도 $\{448, 672, 896, 1120\}$을 추출하고, 토큰 상한은 해상도별 서포트 이미지당 256으로 설정한다. 정상 참조 분위수는 $q = 0.99$로 설정하며, 계층별 결합 가중치는 깊은 계층 $\{11, 23\}$에 각 0.5, 얕은 계층 5에 $\lambda = 0.125$를 부여하여 모든 실험에 동일하게 적용한다. 비교 방법은 PatchCore [16], SuperAD [20], AnomalyDINO [3], FastRecon [4], RAD [21], SubspaceAD [9], RegAD [7]이며, 동일한 서포트 분할과 평가 프로토콜 하에 단일 1120 해상도(RegAD는 STN 제약상 224)에서 평가를 수행한다.

4.2. Main results

먼저 획득 조건 변화가 포함된 few-shot 환경에서 ScopeAD가 기존 방법 대비 저-FPR 구간의 결함 국소화 성능을 개선하는지 확인한다. Tab. 1에서 ScopeAD는 1–16-shot 전 구간에 걸쳐 $\text{AUPRO}_{0.05}$, $\text{pAUROC}_{0.05}$, I-AUROC 모두 최고 평균을 기록했으며, 차순위 대비 각각 4.85–6.98 pp, 2.34–3.57 pp, 4.33–5.91 pp 높았다. 1-shot $\text{AUPRO}_{0.05}$는 52.18 %로 동일 백본 기반의 PatchCore (38.45 %)와 차순위 SuperAD(46.31 %)를 각각 13.73 pp, 5.87 pp 상회했다. 또한 ScopeAD의 2-shot $\text{AUPRO}_{0.05}$ (56.78 %)는 모든 비교 방법의 16-shot 평균(최고 55.89 %)보다 높았다.

획득 조건별 성능. Tab. 2는 기본 조건(regular)과 획득 조건이 바뀐 영상(과노출·저노출·`shift_*`)의 $\text{AUPRO}_{0.05}$를 분리하여 비교한 결과다. ScopeAD는 변화 조건 평가에서 2-shot 56.60 %, 16-shot 60.74 %를 기록하며 모든 비교 방법군을 상회했다. 기본 조건에서는 SubspaceAD가 가장 높은 성능을 보였으나 변화 조건에서는 2-shot과 16-shot에서 각각 9.21 pp, 10.73 pp의 큰 폭으로 하락한 반면, ScopeAD의 성능 하락폭은 각각 1.49 pp, 1.68 pp에 그쳐 획득 조건 변화에 대한 강건성을 보였다.

공식 비공개 벤치마크 평가. MVTec AD 2 공식 블라인드 리더보드(Tab. 3)에서 ScopeAD는 16-shot 기준 `test_private`(66.53 %)와 조건 혼합 평가셋 `test_private_mixed`(64.40 %) 모두에서 few-shot 최고 $\text{AUPRO}_{0.05}$를 기록했으며, 차순위 SuperAD보다 각각 3.71 pp, 4.32 pp 높았다. 전체 정상 데이터를 사용한 참고 모델과 비교하면 RoBiS보다 `test_private`에서 0.72 pp 낮고 `test_private_mixed`에서 4.75 pp 높았다. 반면 SegF1은 few-shot SuperAD와 전체 데이터 모델보다 낮았다. 본 평가에서는 SuperADD [15]의 임계값 규칙인 정상 픽셀 점수의 95백분위수 × 1.421을 ScopeAD에 별도 조정 없이 적용했다. 임계값 선택이 결과에 영향을 주었을 가능성은 있으나, 현재 평가만으로 낮은 SegF1의 원인을 분리할 수는 없다. 전체 데이터 모델은 더 많은 정상 데이터와 각자의 후처리를 사용하므로 직접 비교에도 한계가 있다.

MVTec AD와 VisA. 획득 조건 변화가 제한적인 MVTec AD 및 VisA(Tab. 4)에서는 ScopeAD의 우위가 뚜렷하지

Table 4. MVTec AD 및 VisA few-shot 비교 (%). 각 셀은 I-AUROC / P-AUROC. 굵은 값과 밑줄은 최고·차순위다.

Dataset	Shot	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD (224)	Ours (ScopeAD)
MVTec AD	1	88.12 / 96.22	92.52 / 94.49	88.84 / 96.60	80.83 / 93.25	89.25 / 96.92	**92.54** / **96.93**	77.52 / 93.88	92.32 / 96.62
	2	92.67 / 96.97	95.17 / 95.56	93.51 / 97.29	84.15 / 94.27	90.95 / 97.24	95.43 / **97.36**	81.60 / 95.14	**95.49** / 97.28
	4	95.06 / 97.37	95.92 / 96.07	95.61 / **97.87**	85.38 / 94.67	91.35 / 97.16	96.65 / 97.70	84.13 / 96.32	**96.82** / 97.59
	8	96.13 / 97.80	96.67 / 96.45	96.76 / **98.16**	87.85 / 95.29	92.94 / 97.17	**97.39** / 97.95	86.36 / 96.85	97.35 / 97.86
	16	98.15 / 97.99	97.48 / 96.80	98.52 / **98.38**	90.29 / 95.61	92.51 / 97.19	**98.94** / 98.09	89.56 / 97.22	98.66 / 97.99
VisA	1	86.09 / 95.56	87.06 / 95.62	84.65 / 96.75	72.67 / 95.37	85.44 / **98.09**	**90.29** / 97.06	71.12 / 93.41	88.52 / 96.53
	2	87.87 / 96.29	90.64 / 96.63	87.67 / 97.43	77.24 / 96.37	86.36 / **98.21**	**92.20** / 97.68	71.59 / 94.59	91.59 / 97.14
	4	89.52 / 96.92	91.37 / 97.57	89.21 / 97.91	79.16 / 97.45	86.85 / **98.26**	92.94 / 98.02	76.42 / 96.14	**94.28** / 97.69
	8	92.36 / 97.18	93.11 / 97.99	91.53 / 98.11	86.32 / 97.93	88.29 / **98.33**	94.50 / 98.29	80.19 / 96.64	**94.97** / 98.12
	16	93.64 / 97.30	93.53 / 98.30	93.38 / 98.32	88.56 / 98.18	88.99 / 98.37	95.19 / **98.43**	81.22 / 96.98	**95.86** / 98.37

Table 2. 획득 조건별 $AUPRO_{0.05}$ (MVTec AD 2 `test_public`, 평균, %). 기본: regular 조건. 변화: 과노출·저노출과 클래스별 1–4개의 shift 조건에서 각각 계산한 $AUPRO_{0.05}$의 평균. 클래스마다 계산한 뒤 8개 클래스를 동일 비중으로 평균했다. 굵은 값과 밑줄은 열별 최고·차순위다.

	2-shot		16-shot	
방법	기본	변화	기본	변화
PatchCore	42.98	42.30	54.32	52.97
AnomalyDINO	42.79	39.52	49.91	44.12
FastRecon	17.61	16.82	38.19	35.54
RAD	31.53	31.71	43.14	43.02
SubspaceAD	**58.86**	49.65	**63.10**	52.37
SuperAD	51.06	49.96	58.58	56.33
RegAD (224)	16.75	14.95	24.11	20.88
Ours (ScopeAD)	58.09	**56.60**	62.42	**60.74**

Table 3. MVTec AD 2 공식 비공개 평가 (%). 각 셀은 `test_private` / `test_private_mix`. $*$: 전체 정상 데이터 사용. 굵은 값과 밑줄은 few-shot 내 최고·차순위다.

방법	$AUPRO_{0.05}$	ClassF1	SegF1
Few-shot (16-shot)			
AnomalyDINO	50.35 / 44.86	77.87 / 77.91	26.65 / 18.62
PatchCore	58.33 / 57.03	**78.21** / 78.02	29.96 / 27.75
SuperAD	62.82 / 60.08	78.14 / 78.19	**39.43** / **33.86**
Ours (ScopeAD)	**66.53** / **64.40**	78.03 / **78.86**	36.33 / 32.47
Full-data Reference*			
SuperAD*	60.51 / 58.37	70.20 / 74.40	47.18 / 42.51
SuperADD* [15]	61.36 / 59.07	68.03 / 73.25	57.42 / 54.35
RoBiS*	67.25 / 59.65	79.62 / 79.86	51.00 / 46.52

않았다. I-AUROC는 10개 조건 중 5개에서 최고였고(나머지는 SuperAD가 0.04–1.77 pp 높음), P-AUROC는 조건별 최고치보다 0.06–1.56 pp 낮았다. 저-FPR $AUPRO_{0.05}$에서도 SubspaceAD가 MVTec AD 1–4-shot과 VisA 전 shot에서 가장 높았다(VisA 격차 1-shot 10.32 pp, 16-shot 0.92 pp). 획득 조건 변화가 포함된 MVTec AD 2의 결과와 비교하면, ScopeAD의 상대적 이점은 평가 환경에 따라 달라졌다.

4.3. Ablation study

제안 방법의 구성 요소별 기여도를 분석하고, 다해상도 확장의 이득이 단순 토큰 수 증가로 설명되는지 검증한다. 이어 주요 하이퍼파라미터에 대한 민감도를 평가한다. 모든 ablation과 비용 분석은 공정한 내부 조건 비교를 위해 동일한 고정 서포트 분할 조건에서 수행했다.

구성 요소별 기여도. Tab. 5는 단일 해상도 기준선(A)

Table 5. 구성 요소의 누적 ablation (MVTec AD 2 `test_public`, $AUPRO_{0.05}$, %). A: 1120 해상도, 계층 [11, 23] 연결 뱅크, 보정 없음. B–F: 이전 행에 구성 요소를 순차 추가. 굵은 값과 밑줄은 최고·차순위다.

구성	2-shot	16-shot
A. Single-resolution	50.51	53.78
B. + Multi-resolution	55.62	57.90
C. + Separate banks	58.23	57.93
D. + Shallow fusion	59.06	59.17
E. + Scale calibration	59.33	59.57
F. + Rényi aggregation (Ours)	**59.92**	**60.19**

Table 6. 해상도 조합 및 토큰 상한에 따른 성능과 비용 (MVTec AD 2, 16-shot, FP16; 성능은 %). cap은 해상도별 서포트당 토큰 상한이다. 시간은 클래스 평균, Peak는 쿼리 최대 GPU 메모리다. 굵은 값과 밑줄은 1·2위다.

구성	cap	$AUPRO_{0.05}$	$pAUROC_{0.05}$	Fit (s)	Query (ms)	Peak (GiB)
단일 1120	256	57.48	74.86	**11.09**	**861**	**1.91**
단일 1120	1024	57.13	75.49	12.48	1053	3.04
2-res {672, 1120}	256	59.15	76.28	13.65	980	2.15
4-res (Ours)	256	60.19	77.52	17.21	1365	3.12
4-res	1024	**60.33**	**77.94**	22.42	1789	6.71

에서 최종 모델(F)에 이르기까지 각 구성 요소를 순차적으로 누적 적용한 결과다. 전체 성능 향상폭은 2-shot과 16-shot에서 각각 +9.41 pp, +6.41 pp에 달했다. 이러한 향상의 과반은 다해상도 확장(B, +5.11/ + 4.12 pp)에서 비롯되어, 관측 확장이 전체 성능 개선의 핵심 요인임을 보여준다. 관측별 독립 뱅크(C)는 특징을 연결하여 매칭하는 B와 달리 각 관측에서 최근접 이웃을 독립적으로 탐색하여, 특정 계층이 다른 계층의 이웃 선택에 간섭하지 않도록 한다. B에서 C로 전환하면 2/16-shot 성능이 각각 +2.61/ + 0.03 pp 높아져, 독립 매칭의 추가 이득은 서포트가 적은 2-shot에서 두드러졌다. 독립 뱅크 구성(C)과 최종 구성(F)의 $AUPRO_{0.05}$차이는 2/16-shot에서 각각 1.69/2.26 pp였다. 표에 제시한 두 shot 설정에서는 각 단계에서 성능이 증가했다.

토큰 수와 계산 비용. 동일한 토큰 예산에서는 한 해상도의 토큰 수를 늘리는 것보다 여러 해상도에 토큰을 분배하는 편이 효과적이었다. Tab. 6에서 4개 해상도에 각각 256개 토큰을 사용하는 ScopeAD는 단일 1120 해상도에 1024개 토큰을 사용하는 구성보다 $AUPRO_{0.05}$가 3.06 pp 높았다. 이는 다해상도의 이득이 토큰 수 증가만으로 설명

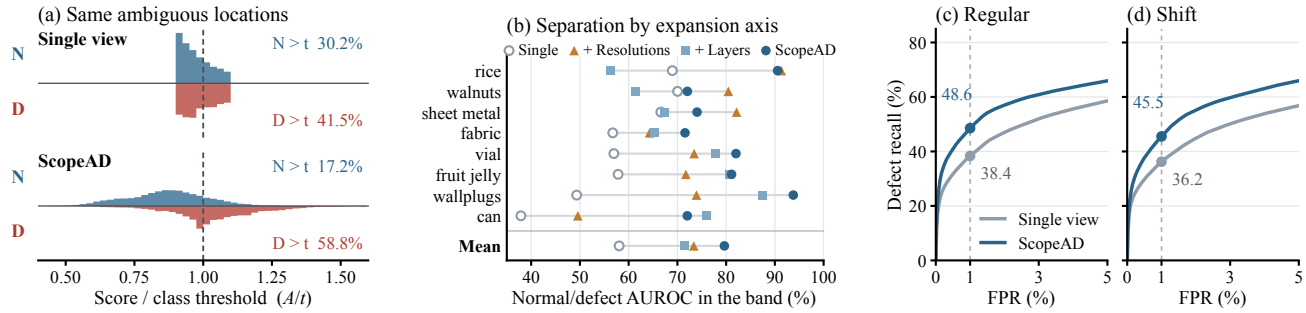


Figure 4. **HSA 구간의 정상·결함 점수와 결함 픽셀 재현율** (MVTec AD 2 `test_public`, 2-shot, 사후 분석). (a) 단일 관측(L23/1120) 점수가 클래스 임계값 t의 0.9–1.1배인 정상(N)·결함(D) 위치를 단일 관측과 ScopeAD로 점수화한 분포. t는 구성별 클래스 테스트 정상 Q99이며, 수치는 t를 넘는 위치의 비율이다. (b) 같은 위치의 클래스별 정상·결함 구분 AUROC. +Resolutions는 L23의 4개 해상도, +Layers는 1120 해상도의 세 계층 가중합이며, 둘 다 Q99 보정을 쓴다. 클래스는 두 축의 AUROC 차이 순으로 정렬했다. (c,d) Regular와 shift 조건의 결함 픽셀 재현율–FPR 곡선(8개 클래스 평균). 수치는 FPR 1%에서의 결함 픽셀 재현율이다.

Table 7. 하이퍼파라미터에 따른 $\text{AUPRO}_{0.05}$ (MVTec AD 2 `test_public`, %). 왼쪽은 $q = 0.95$에서 얕은 계층 가중치 λ를 바꾼 결과이며, 사용값 행에는 $q = 0.99$의 최종 구성 결과를 표시했다. 오른쪽은 $\lambda = 0.125$에서 정상 참조 분위수 q를 바꿨다. *는 사용값이다. 굵은 값과 밑줄은 열별 최고·차순위다.

λ	2-shot	16-shot	q	2-shot	16-shot
0	59.05	59.11	0.5	58.62	59.55
0.0625	<u>59.76</u>	59.73	0.8	59.53	60.01
0.125*	**59.92**	<u>60.19</u>	0.9	<u>59.81</u>	60.15
0.25	59.32	**60.36**	0.95	**59.92**	<u>60.16</u>
0.5	56.23	59.47	0.99*	**59.92**	**60.19**

되지 않음을 보여준다. 4개 해상도의 부분집합 조합을 보면, 중간 문맥과 미세 분해능을 대표하는 2개 해상도 조합 672, 1120만으로도 2/16-shot에서 각각 58.10 %, 59.15 %를 달성하여 단일 최고 해상도(54.38 %, 57.48 %)를 상회하면서 쿼리 시간을 980 ms(4해상도 대비 약 28 % 절감)로 줄일 수 있다. 4개 해상도를 모두 쓸 때 결함 크기별 다양성이 온전히 포괄되어 최고 성능(59.92 %, 60.19 %)에 도달한다. 실제 공정에서는 저해상도로 정상을 조기 판정(early rejection)하고 모호한 구간에 한해 고해상도를 선택 순전파하여 평균 지연시간을 단축할 수 있다. 반면, 다해상도 구성에서 토큰 상한을 더 늘렸을 때의 성능 이득은 계산 비용 증가에 비해 작았다. cap을 256에서 1024로 늘리면 $\text{AUPRO}_{0.05}$는 0.14 pp 높아지는 데 그쳤으나, 쿼리 시간과 최대 메모리는 각각 1.31배, 2.15배로 증가했다. 따라서 성능과 계산 비용을 고려해 cap 256을 기본값으로 사용한다.

하이퍼파라미터. Tab. 7의 결과는 얕은 계층을 배제하거나 깊은 계층과 균등하게 결합하기보다, 낮은 가중치로 반영하는 편이 효과적임을 보여준다. 다만 최적 가중치는 shot에 따라 달랐다. 사용값 $\lambda = 0.125$는 2-shot에서 가장 높은 $\text{AUPRO}_{0.05}$를 보였으나, 16-shot에서는 $\lambda = 0.25$보다 0.17 pp 낮았다. 다만 다른 가중치 행은 $q = 0.95$ 조건이므로, 이 차이를 가중치만의 효과로 해석할 수는 없다. 분위수 q는 0.8–0.99 범위에서 성능 차이가 작아, 이 구간에서 낮은 민감도가 관찰되었다. 이 비교에서 $q = 0.95$를 0.99로 바꾸면 2-shot 성능은 반올림 기준으로 같고, 16-shot 성능은 0.03 pp 높아졌다. 두 패널의 사용값 행에는 동일한 최종 구성($\lambda = 0.125$, $q = 0.99$)의 결과를 표시했다. 반면 $q = 0.5$에서는 2-shot 성능이 사용값보다 1.30 pp 낮아, 정상 참조의 중앙값보다 높은 분위수를 사용하는 것이 유리했다.

순위 가중치와 비모수성. 선형 순위 가중치 $(0.1, 0.2, 0.3, 0.4)$의 2/16-shot $\text{AUPRO}_{0.05}$는 59.91/60.08 %였으며, Rényi 가중치는 59.92/60.19 %로 차이가 0.11 pp 이내였다(Tab. 9). 이는 특정 가중치 수치보다 상위 순위를 강조하는 정렬 구조 자체가 핵심임을 보여준다. 따라서 Rényi 집계는 사후 가중치 튜닝 없이 관측 수 R로부터 유일하게 정해지는 비모수적(hyperparameter-free) 대표 기준선으로서 일반화 안정성을 제공한다.

4.4. 분석: HSA 완화와 점수 통합

단일 관측이 정상과 결함을 구분하지 못하는 위치에서 ScopeAD가 둘을 어떻게 분리하는지 분석하고(Fig. 4), 이 분리에 쓰이는 척도 보정과 Rényi 집계가 어떻게 함께 작동하는지 확인한다.

HSA 구간의 정상과 결함. 클래스 임계값 t는 각 구성의 점수에서 클래스별 테스트 정상 픽셀의 99백분위수(Q99)로 정했다. 즉 t를 넘는 정상 픽셀이 1 %가 되는, 오경보율 1 %의 판정 기준이다. HSA 구간은 단일 관측(L23/1120)의 클래스별 임계값 t를 기준으로 점수가 $0.9t$ 이상 $1.1t$ 이하인 정상 및 결함 위치로 정의하고 고정했다. 이하에서는 이 구간의 정상·결함 구분 AUROC를 구간 내 AUROC로 표기한다. 단일 관측의 구간 내 AUROC는 58.0 %로, 높은 점수만으로는 둘을 거의 구분하지 못한다. 같은 위치를 ScopeAD로 점수화하면 t를 넘는 정상 위치는 30.2 %에서 17.2 %로 줄고, 결함 위치는 41.5 %에서 58.8 %로 늘었다(Fig. 4a). Q99 보정을 고정하고 관측만 바꾼 비교에서, 해상도를 늘리면 구간 내 AUROC가 73.4 %, 계층을 늘리면 71.5 %, 두 축을 함께 늘리면 79.8 %로 높아졌다. 두 축은 서로 다른 클래스에서 단서를 주었다(Fig. 4b). 예를 들어

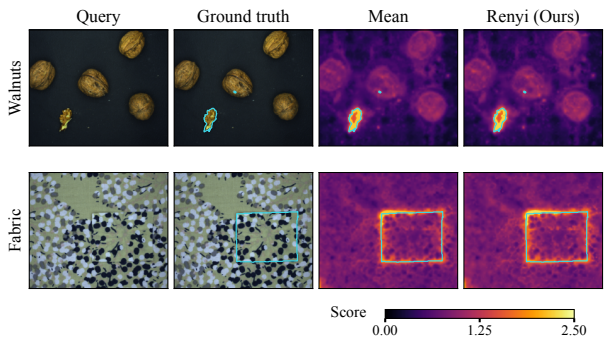


Figure 5. **MVTec AD 2 결함 국소화 정성 비교.** 열은 쿼리, 정답, 4해상도 Mean, 4해상도 Rényi 순이다(16-shot). 위: Walnuts `006_shift_2`, 아래: Fabric `000_regular`. 보정과 계층 결합을 고정하고 집계만 바꿨으며, 두 결과에 동일한 후처리를 적용했다. 짧은 변 256픽셀의 표시용 맵과 공통 색상 범위 $[0, 2.5]$를 사용했다. 하늘색 윤곽은 정답이다.

Table 8. 집계 방식과 척도 보정의 상호작용 (MVTec AD 2, $\text{AUPRO}_{0.05}$, 평균 ± 표본 표준편차, %). 굵은 값과 밑줄은 최고·차순위 평균이다.

집계 방식	척도 보정	2-shot	16-shot
Mean	없음	56.12 ± 2.76	59.73 ± 0.86
Mean	Q99	56.03 ± 3.00	60.06 ± 0.88
Rényi	없음	56.32 ± 2.49	59.72 ± 0.77
Rényi (Ours)	Q99	**56.78** ± **2.77**	**60.74** ± **0.72**

해상도 확장은 rice(91.3 %)에서, 계층 확장은 can(76.0 %)과 wallplugs(87.4 %)에서 크게 높았다. ScopeAD의 구간 내 AUROC는 8개 클래스 모두에서 단일 관측보다 높았으며, Rényi 집계는 평균 집계보다 구간 내 AUROC를 더 높이지는 않았다(79.6 대 79.8 %). HSA 구간 분석과 별도로, 조건별 영상 평가에서도 저-FPR 검출률의 개선이 관찰되었다. FPR 1%에서 결함 픽셀 재현율은 regular 조건에서 38.4 %에서 48.6 %로, shift 조건에서 36.2 %에서 45.5 %로 높아졌다(Fig. 4c,d). 다만 이는 2-shot 사후 진단이며, `walnuts`에서는 검출률이 낮아졌다. Fig. 5는 동일한 다해상도 점수에 Mean과 Rényi 집계를 적용한 결함 지도의 비교다. 정성 사례만으로 두 집계 방식의 성능 우위를 판단할 수 없으며, 색상 대비만으로 오경보율을 비교할 수도 없다.

보정과 집계의 상호작용 기전. ScopeAD는 관측 척도 정렬과 순위 집계를 함께 적용하여 저-FPR 국소화 성능을 높인다(Tab. 8). 이 시너지는 Rényi 집계의 비선형 추가 응답 구조에서 비롯된다. Rényi 결합 점수는 평균 응답 $\mu(p)$와 해상도 간 순위 간격에 따른 비음수 추가 응답 $E(p) \geq 0$의 합으로 정의된다. 순위 집계는 결함이 특정 해상도에 집중될 때 신호를 보존하는 장점이 있지만, 척도를 보정하지 않으면 관측별 기저 거리 차이 때문에 정상 영역에서도 순위 간격이 벌어져 정상 잡음 비율(E/μ)이 커진다. 정상 서포트의 Q99 보정은 관측 간 기저 편차를 정렬하여 정상 영역의 불필요한 간격을 줄인다. 그 결과 정상 이미지의 상대 추가 응답(E/μ)은 줄어드는 반면(2-shot 7.74 → 7.10 %, 16-shot 8.56 → 7.55 %), 특정 해상도에서 강하게 반응하는 실제 결함 영역의 순위 간격은 유지된다(Fig. 13). 즉, Q99 보정이 정상 영역의 거짓 순위 반응을 억제하고 Rényi 집계가 유효한 결함 반응을 보존함으로써 저-FPR 구간의 결함-배경 대비를 강화한다.

5. 논의 및 한계

ScopeAD는 추가 학습 없이 관측 확장과 순위 통합으로 획득 조건 변화에 강건한 결함 국소화를 달성했으나 몇 가지 실용적 한계를 지닌다. 첫째, 관측 확장은 미관측 정상 변동 자체를 생성하지 못하므로, 정상 표본이 극히 적을 때는 서포트 선택에 따른 점수 분산이 존재하며(1-shot 표준편차 4.07 pp) 라인 배치 시 목표 오경보율에 따른 임계값 교정이 요구된다. 둘째, 다해상도 순전파로 인해 단일 해상도 대비 쿼리 시간과 메모리가 증가한다. 이는 본문에서 제시한 중간·고해상도 2개 조합({672, 1120})이나 저해상도 조기 판정(early rejection) 기반의 계층적 추론으로 실시간성을 확보할 수 있다. 셋째, HSA 진단(Fig. 4)은 `test_public` 사후 분석에 기반하므로, 클래스별 이득 편차와 미관측 산업 도메인으로의 일반화 특성은 향후 연구 과제다.

6. 결론

본 논문은 동결 백본의 계층과 해상도를 독립 매칭 단위로 전개하고, 정상 참조 Q99 보정, 비대칭 계층 결합, 비모수적 Rényi 순위 집계로 점수를 통합하는 **ScopeAD**를 제안했다. 제안 방법은 추가 학습이나 쿼리 적응 없이도 획득 조건 변화 환경에서 발생하는 High-Score Ambiguity를 완화하고, 저-FPR 구간의 결함-배경 대비를 강화한다. MVTec AD 2 벤치마크의 1–16-shot 전 구간과 공식 비공개 평가에서 기존 비교군을 일관되게 상회하는 최고 저-FPR 국소화 성능을 달성했으며, 정적 벤치마크에서도 경쟁력 있는 결과를 확인했다. 본 연구는 소수의 정상 참조만 주어지는 환경에서 동결 특징의 다각적 관측 확장과 원칙적 순위 통합이 실용적인 대안이 됨을 시사한다.

References

[1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD – a comprehensive real-world dataset for unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019. 5

[2] Joao P. C. Bertoldo, Dick Ameln, Ashwin Vaidya, and Samet Akcay. AUPIMO: Redefining visual anomaly detection benchmarks with high speed and low tolerance. *arXiv preprint arXiv:2401.01984*, 2024. 1, 3

[3] Simon Damm, Mike Laszkiewicz, Johannes Lederer, and Asja Fischer. Anomalydino: Boosting patch-based few-shot anomaly detection with dinov2. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1319–1329, 2025. 1, 2, 5

[4] Zheng Fang, Xiaoyang Wang, Haocheng Li, Jiejie Liu, Qiugui Hu, and Jimin Xiao. Fastrecon: Few-shot industrial

anomaly detection via fast feature reconstruction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 17481–17490, 2023. 2, 5

[5] Stephanie Fu, Mark Hamilton, Laura E. Brandt, Axel Feldmann, Zhoutong Zhang, and William T. Freeman. FeatUp: A model-agnostic framework for features at any resolution. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[6] Lars Heckler-Kram, Jan-Hendrik Neudeck, Ulla Scheler, Rebecca König, and Carsten Steger. The MVTec AD 2 dataset: Advanced scenarios for unsupervised anomaly detection. *International Journal of Computer Vision*, 134(4), 2026. 1, 2, 5

[7] Chaoqin Huang, Haoyan Guan, Aofan Jiang, Ya Zhang, Michael Spratling, and Yan-Feng Wang. Registration based few-shot anomaly detection. *arXiv preprint arXiv:2207.07361*, 2022. 2, 5

[8] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19606–19616, 2023. 2

[9] Camile Lendering, Erkut Akdag, and Egor Bondarau. Subspacead: Training-free few-shot anomaly detection via subspace modeling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 28557–28566, 2026. 2, 5

[10] Xurui Li, Ziming Huang, Feng Xue, and Yu Zhou. MuSc: Zero-shot industrial anomaly classification and segmentation with mutual scoring of the unlabeled images. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[11] Xiaofan Li, Zhizhong Zhang, Xin Tan, Chengwei Chen, Yanyun Qu, Yuan Xie, and Lizhuang Ma. PromptAD: Learning prompts with only normal samples for few-shot anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16848–16858, 2024. 2

[12] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023. 1

[13] Maithra Raghu, Thomas Unterthiner, Simon Kornblith, Chiyuan Zhang, and Alexey Dosovitskiy. Do vision transformers see like convolutional neural networks? In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 12116–12128, 2021. 2

[14] Rene Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 12179–12188, 2021. 2

[15] Lukas Roming, Felix Lehnerer, Jonas V. Funk, Andreas Michel, Georg Maier, Thomas Längle, and Jürgen Beyerer. Superadd: Training-free class-agnostic anomaly segmentation – cvpr 2026 vand 4.0 workshop challenge industrial track. *arXiv preprint arXiv:2605.14808*, 2026. 5, 6

[16] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14298–14308, 2022. 1, 2, 3, 5

[17] Baifeng Shi, Ziyang Wu, Maolin Mao, Xin Wang, and Trevor Darrell. When do we not need larger vision models? In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2024. 2

[18] Weilin Tu. Few-shot anomaly detection on MVTec AD 2: A systematic study and a strong frozen baseline. *IEEE Access*, 14:152500–152511, 2026. 2

[19] Jin Wang, Ying-Hang Li, Bo-Wen Jiang, and Shi-Chao Li. FreePatch: A training-free multiscale patch matching method for few-shot industrial anomaly detection. In *International Conference on Computer Vision, Graphics, and Artificial Intelligence (CVGAI 2026)*, 2026. 2

[20] Huaiyuan Zhang, Hang Chen, Yu Cheng, Shunyi Wu, Linghao Sun, Linao Han, Zeyu Shi, and Lei Qi. Superad: A training-free anomaly classification and segmentation method for cvpr 2025 vand 3.0 workshop challenge track 1: Adapt & detect. *arXiv preprint arXiv:2505.19750*, 2025. 1, 2, 5

[21] Xingwu Zhang, Guanxuan Li, Paul Henderson, Gerardo Aragon-Camarasa, and Zijun Long. Is task-specific training necessary for anomaly detection? *arXiv preprint arXiv:2601.22763*, 2026. Version 3. 5

[22] Zilong Zhang, Zhibin Zhao, Xingwu Zhang, Chuang Sun, and Xuefeng Chen. Industrial anomaly detection with domain shift: A real-world dataset and masked multi-scale reconstruction. *Computers in Industry*, 151:103990, 2023. 1, 2

[23] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[24] Jiawen Zhu and Guansong Pang. Toward generalist anomaly detection via in-context residual learning with few-shot sample prompts. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 17826–17836, 2024. 2

[25] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. *arXiv preprint arXiv:2207.14315*, 2022. 5

A. 결합 규칙과 파라미터의 추가 분석

본문의 분석을 보완하기 위해 계층 가중치와 해상도 집계 대안, 보정과 집계의 메커니즘 분석을 제시한다. 계층 가중치와 집계 대안 표는 MVTec AD 2 `test_public`, seed 0의 8개 클래스 macro이며, 메커니즘 분석은 별도로 명시한 3-seed 결과를 사용한다.

A.1. 계층 가중치

본문 Tab. 7의 가중치 비교는 $q = 0.95$에서 수행했으며, 사용값 행은 $q = 0.99$의 최종 구성 결과로 표시했다. $\lambda = 0.5$에서는 세 계층의 계수가 같다. $\lambda = 0$은 얕은 계층의 점수 기여만 제외한다.

얕은 계층을 제외하거나($\lambda = 0$) 가중치를 0.5로 높이면 두 shot 모두 성능이 낮아진다. 16-shot에서는 0.25가 0.125보다 0.17 pp 높아, 두 행은 q도 달라 이 차이는 가중치만의 효과를 나타내지 않는다.

A.2. 해상도 집계 대안

최종 구성의 특징, 뱅크, Q99 보정, 계층 가중치를 고정하고 해상도 집계 규칙만 바꾸었다(Tab. 9). 선형 순위 가중치는 $(0.1, 0.2, 0.3, 0.4)$다. 두 순위 가중 집계는 Mean보다 $\mathrm{AUPRO}_{0.05}$가 높고, Rényi와 선형 가중의 차이는 0.11 pp 이내다. 따라서 이 결과는 높은 순위에 큰 가중치를 주는 집계의 효과를 보여주며, 특정 Rényi 가중치가 다른 순위 가중치보다 뚜렷하게 낫다는 근거는 아니다.

Table 9. 해상도 집계 대안 (MVTec AD 2, seed 0, Q99, %). 각 셀은 $\mathrm{AUPRO}_{0.05}$ / $\mathrm{pAUROC}_{0.05}$이며, 굵은 값과 밑줄은 각 지표의 최고·차순위다.

집계 방식	2-shot	16-shot
Mean	59.33 / **76.48**	59.57 / 77.46
Order (linear)	<u>59.91</u> / <u>76.45</u>	<u>60.08</u> / **77.55**
Order (Rényi, Ours)	**59.92** / 76.36	**60.19**

A.3. 관측 확장 motivation의 실측 프로토콜

본문의 설명 사례. Fig. 1 (a,b)는 Wallplugs의 `012_overexposed` 표본에서 동일한 정상·결함 영역을 관측 간에 추적한다. (a)의 기준 점수는 배그 평균한 원시 L23/1120 거리를 클래스 정상 Q99(t)로 나눈 값이고, (b)의 거리는 관측별 서포트 Q99(c)로 나눈 값 d/c다. 두 단위는 서로 다르므로 (a)와 (b)의 수치를 직접 비교하지 않는다. (b)의 두 해상도 맵은 같은 원본 좌표와 색상 범위를 사용하며, 수치는 각 사각형 내부의 평균이다. 영역 크기와 원시 점수 조건은 아래 기준 관측 사례와 동일하다. 기존 기준 점수만으로 고정했던 9개 영역 쌍 중 표시 사례는 L23/448의 결함/정상 평균 거리 비가 가장 큰 쌍(4.39)이다. 다만 이 사례는 원래 L23/448과 전체 결합에서 결함 점수가 더 높은 7개 쌍 중 최종 점수 비의 상위 중앙값으로 선정했다. 이후의 단독 관측 재검토에서도 같은 사례가 선택되지만, 최초 선택에 결합 결과를 사용한 이력은 남는다. 9개 쌍의 중앙값은 1.38이며, 1개 쌍은 L23/448에서 정상 거리가 결함보다 크다. 따라서 이 사례는 단서가 드러나는 모습을 설명하기 위해 유리하게 고른 사례이며, 대표 표본이나 검출 성공률 평가가 아니다. 원시 점수는 정상 Q99 단위로 정상 0.989, 결함 1.008이다. 서포트 Q99 단위의 L23/1120 거리는 1.085와 1.105, L23/448 거리는 0.235와 1.033이다.

관측별 단독 대비(결합 전). Fig. 1(c)는 아래의 고정 위치 집단에서 12개 관측을 하나씩 사용한다. 각 클래스에서 관측별 결함 평균을 정상 평균으로 나누고, 이 비를 8개 클래스에 대해 평균했다. 각 관측에서 같은 단위의 정상·결함 거리를 비교하며, 관측 간 보정 방법의 우월성을 검증하는 분석은 아니다. 기준 관측 L23/1120의 비는 1.017이고 나머지 관측은 1.116(L23/896)에서 1.494(L5/672)이다. 클래스별로 비가 가장 큰 관측은 L23/448 (`fabric`, `rice`, `sheet_metal`, `walnuts`), L5/1120 (`can`, `fruit_jelly`), L5/672(`vial`, `wallplugs`)이다. 위치별로는 각 관측의 값을 같은 클래스의 정상 위치 중앙값과 사분위 범위로 표준화한 뒤, 결함 위치마다 표준화 값이 가장 큰 관측을 셌다. 어느 관측도 클래스 평균 22 %를 넘지 않는다. 정상 위치 중 적어도 한 관측에서 해당 관측의 정상 Q90을 넘는 비율은 클래스별 39–52 %이다. 이 집단에서 평균 대비가 가장 큰 계층은 L5이다. 이 결과는 추가 관측의 단서를 보여줄 뿐, 얕은 계층의 가중치를 낮추는 설계의 근거는 아니다. 아래 정상 조건 변화 진단(Fig. 6)도 그 설명을 지지하지 않는다. 참고로 결합 후 결과 측면에서, 같은 집단의 결함/정상 평균 비는 ScopeAD의 전체 결합에서 1.209이다. 이는 결과 분석이며 Fig. 1에는 포함하지 않았다. 거리 맵의 문맥 범위는 원본 좌표에서 각 영역 한 변의 6배로 정했고, 두 관측에 동일한 좌표와 $[0, 2]$ 색상 범위를 적용했다. 초과값은 색상 막대로 표시했다. 관측별 또는 영역별 min–max 재정규화는 하지 않았다.

정상 조건 변화에 대한 계층별 진단. Fig. 6는 기존 2-shot, seed 0 거리 캐시의 `good` 이미지만 사용한다. 일반 조건 64장과 같은 ID의 변화 조건 315장, 총 379장이다. 클래스별 ID 수는 Can 12개, Fabric 11개, Fruit Jelly 5개, Rice 7개, Sheet Metal 4개, Vial 5개, Wallplugs 10개, Walnuts 10개다. 각 이미지에서 원본 좌표의 64×64 고정 격자 중심을 표본화하고, 계층별 원시 1-NN 거리의 Q99를 구한다. 배그 평균과 보간은 기존 평가와 동일하며, 계층·해상도 결합과 서포트 Q99 보정은 적용하지 않는다. 이미지 내 Q99는 서포트 보정에 쓰는 Q99와 구분한다. 변화 조건의 이미지 Q99를 동일 클래스·ID의 일반 조건 Q99로 나눈다. 먼저 ID별로 조건의 로그 비를 평균하고, 이어 ID와 클래스에 동일 비중을 두어 평균한 뒤 지수화한다. 따라서 그림의 검은 선은 클래스 균등 기하평균이다. ID를 맞춘 이미지 간 분포 비교이며, 픽셀 간 정합은 가정하지 않는다. 조건은 `overexposed`, `underexposed`, 모든 `shift_*`를 포함한다. 변화 조건은 일반적으로 클래스당 5개이며, `fruit_jelly`는 3개, `vial`은 6개다. 단일 원인에 대한 인과 실험이 아닌 기존 공개 개발 자료의 사후 분석이다. 주 분석은 해상도 1120이다. L5/L11/L23의 기하평균 비는 1.0095/1.0131/1.0564로, L5보다 L23에서 더 큰 증가가 나타난다. L5의 비가 L23보다 큰 클래스는 8개 중 `can` 하나다. 나머지 세 해상도에서도 클래스 균등

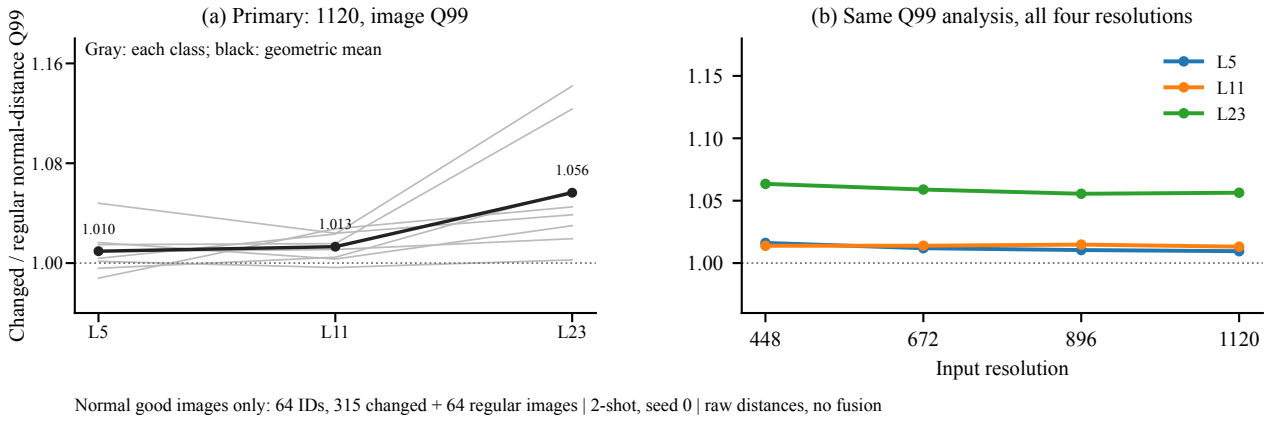


Figure 6. **정상 이미지 조건 변화의 계층별 거리 진단.** 결합 전 원시 거리의 이미지 Q99를 동일 ID의 일반 조건 Q99로 나눴다. (a) 해상도 1120의 클래스별 비와 클래스 균등 기하평균, (b) 네 해상도의 기하평균이다. 정상 이미지 379장, 64개 ID, 2-shot, seed 0. 이 조건에서 L5의 정상 반응 증가가 더 크지는 않다. 회색 선은 클래스 간 차이이며 신뢰구간이 아니다.

Q99 비는 L23이 더 크다(Fig. 6). 표본 격자를 128×128로 늘리면 주 분석 비는 1.0105/1.0138/1.0556이며, 모든 해상도에서 격자별 비의 최대 절대 차이는 0.00144 이하다. 원본 보간 검증의 최대 절대 오차는 2×10^{-5} 미만이다. 이미지별 Q50/Q99와 조건별 결과도 재현 자료에 보존했다. 이 결과는 얕은 계층이 정상 조건 변화에 더 민감하다는 주장을 지지하지 않는다. 그렇다고 깊은 계층이 항상 불리하거나 L5의 가중치를 높여야 한다는 뜻도 아니다. 계층별 정상 거리 변화와 최종 결합의 탐지 성능은 서로 다른 질문이다. 계층 가중치는 Tab. 7의 비교 결과를 근거로 제시하며, 이 진단으로 특정 가중치의 최적성을 주장하지 않는다.

집단 반응의 보조 분석. Figs. 7 and 8는 2-shot, seed 0의 기존 정상 서포트와 1,084개 쿼리 캐시를 재사용한다. 추가 적합이나 백본 추론 없이 관측별 거리를 재생하고, 정답은 점수 산출 후 진단에만 사용했다. 기준 관측은 배그 평균한 Raw L23/1120이다. 정상·결함의 분포는 각 이미지의 정상 픽셀 100개당 1개, 결함 픽셀 10개당 1개를 원본 좌표 순서로 추출해 계산했다. 정상 표본은 정상 이미지와 결함 이미지의 정상 배경을 모두 포함하며, 전체 획득 조건을 합친 클래스별 정상 Q99를 t로 두었다. 프로파일에는 기존 분석에서 $0.9 \le A_{\text{raw}}/t \le 1.1$인 위치 중 순서상 균등 간격으로 보존한 클래스·정상/결함별 최대 2,000개 표본을 그대로 사용했다. 정상은 클래스마다 2,000개이며, 결함은 `can`의 204개와 나머지 클래스의 각 2,000개다. 관측이나 최종 결합 결과에 따라 위치를 다시 선택하지 않았다.

반응 프로파일과 기여량. 프로파일의 거리는 서포트에서 추정한 관측별 Q99로 나눈 값이다. 평균과 사분위 범위는 각 클래스의 총 비중을 동일하게 두어 계산했다. 음영은 위치 간 반응 분포의 사분위 범위이며, 신뢰구간이나 시드 간 불확실성이 아니다. 계층별 가산 기여량은 $(d_{11}/c_{11} + d_{23}/c_{23})/2$와 $0.125d_5/c_5$로 분해했다. 해상도 결합은 각 위치에서 점수를 오름차순 정렬하고 $[1/16, 7/48, 13/48, 25/48]$을 곱한 기여량을 구한 뒤 평균했다. 집단 평균을 먼저 정렬한 값이 아니며, 위치별 기여량의 합은 저장된 최종 점수와 2×10^{-6} 이내에서 일치한다. CQ와 noise guard는 적용하지 않았다. 원시 거리의 t 단위와 보정 거리의 c 단위가 다르므로, 패널 사이의 수치 차이를 정상 점수의 절대 감소로 해석할 수 없다. Fig. 8는 동일 표본의 클래스별 프로파일을 제시한다. 클래스에 동일 비중을 둔 L23/1120의 정상·결함 평균은 1.006/1.024이며, L23/448에서는 0.768/1.019이다. 두 관측의 결함 평균에서 정상 평균을 뺀 차이는 각각 0.018과 0.252이다. 이 차이는 8개 클래스 모두에서 확대된다. 이는 동일한 고정 집단에서 관측에 따라 추가 구분 단서가 나타난다는 기술적 근거이며, 평균 차이만으로 분포의 겹침이나 검출 오류가 감소한다고 결론내리지 않는다. 이는 기준 점수에 조건을 둔 기술적 분석으로, 탐지 성능이나 결합 규칙의 인과적 우월성 검증이 아니다.

기준 관측만으로 고른 공간 사례와 반례. 공간 사례의 클래스는 기존 기준 구간에 속한 결함 표본 비율의 상위 중앙값으로 정했다(`wallplugs`). 해당 클래스의 비정규 획득 결함 이미지 중 정상·결함 영역을 모두 고를 수 있는 9개 이미지를 같은 비율로 정렬하고 상위 중앙값을 택했다. 영역은 원본 좌표의 정사각형으로, 한 변은 $2\lfloor\min(H,W)/128\rfloor+1$이다. 정사각형 내부가 전부 정상 또는 전부 결함이고, 평균 원시 점수 A_{raw}/t가 $[0.9, 1.1]$에서 1에 가장 가까운 영역을 각각 선택했다. 두 평균의 차이는 0.02 이하여야 하며, 동점은 좌표와 경로 순서로 처리했다. 선택 정보를 저장한 뒤에만 다른 관측의 점수를 읽었다.

선정된 `000_shift_1` 이미지의 두 영역은 각각 33×33 픽셀이다(Fig. 9). 정상·결함의 원시 점수는 t 단위로 1.000과 1.003으로 거의 같지만, 서포트 단위의 Rényi 결합 점수는 1.147과 0.915로 정상 쪽이 더 높다. 평균 결

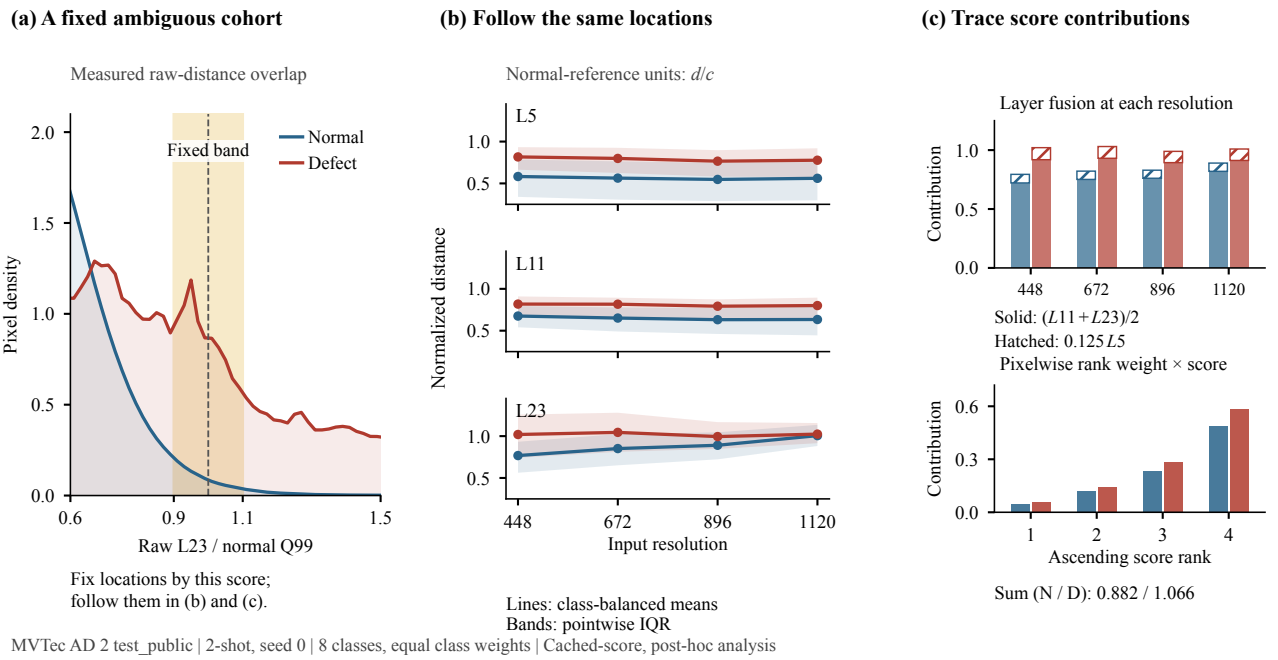


Figure 7. **고정된 모호한 위치 집단의 반응과 점수 기여량.** (a) 단일 관측의 정상·결함 점수 분포와 고정 분석 구간이다. (b) 동일 위치의 정상 서포트 Q99 단위 반응을 클래스에 동일 비중을 두어 평균했다. 음영은 같은 비중의 사분위 범위다. (c) 동일 위치의 계층별 가산 기여량과 위치별 순위 가중치를 적용한 기여량이다. 이 집단 분석은 본문의 사후 선택 사례와 구분된다.

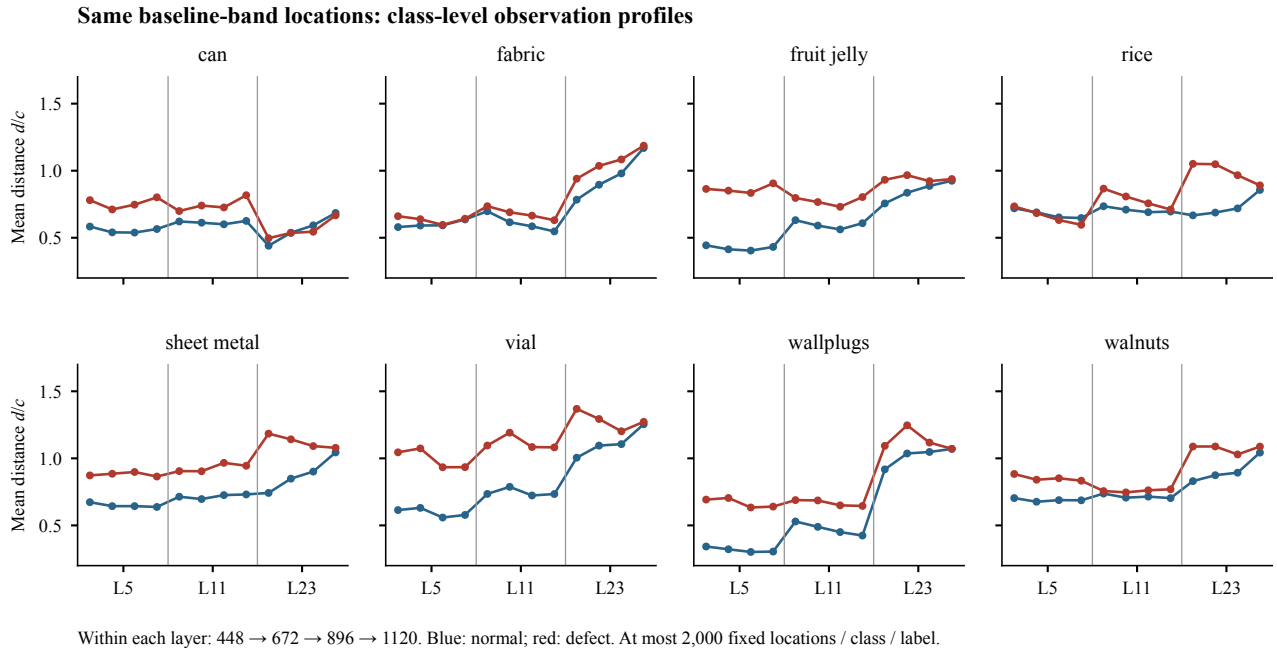


Figure 8. **고정된 모호한 위치 집단의 클래스별 반응.** 파랑은 정상, 빨강은 결함이다. 계층별 네 점은 448, 672, 896, 1120 해상도 순이며, 세로선은 계층 경계다. 모든 점은 정상 서포트 Q99 단위의 거리다. 클래스·정상/결함별 최대 2,000개의 동일 위치를 관측 간에 추적했다.

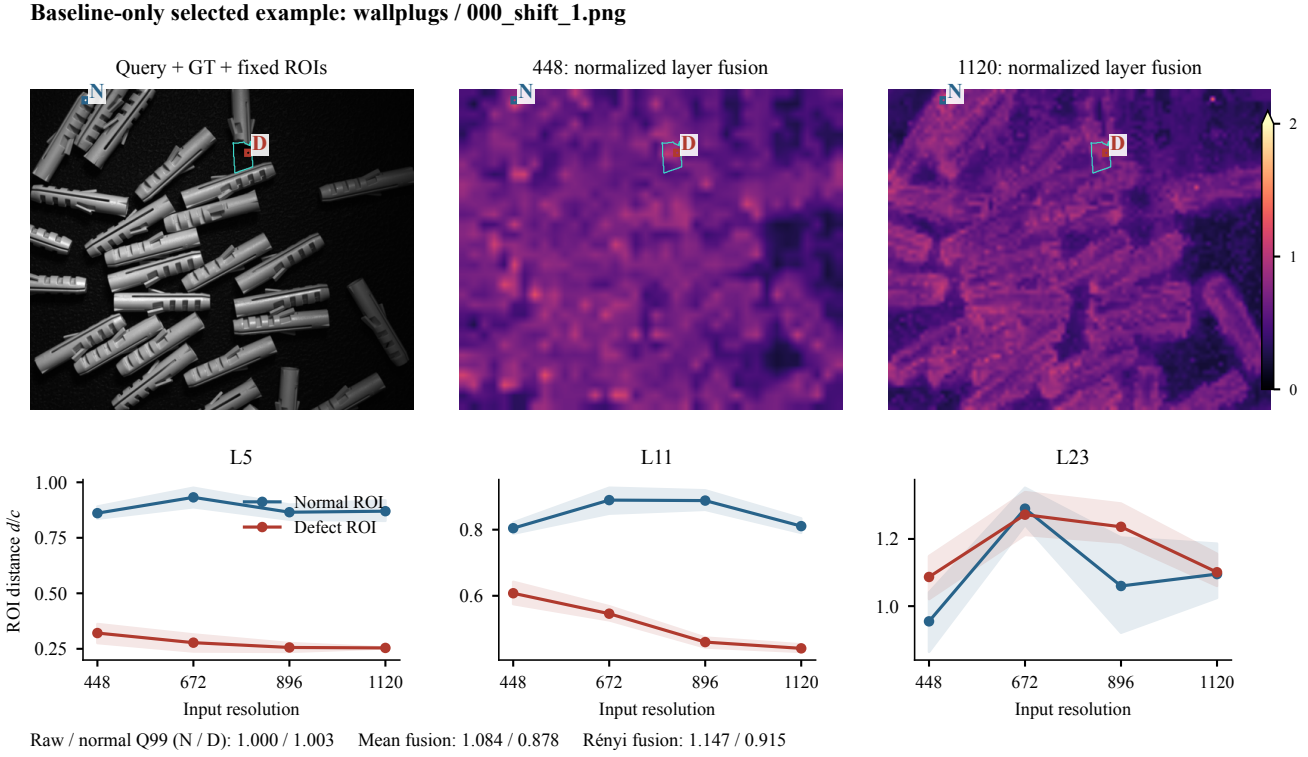


Figure 9. **기준 관측으로만 선택한 영역의 공간적 추적과 반례.** 청록색은 결함 정답 윤곽, N과 D는 고정된 정상·결함 영역이다. 위는 쿼리와 두 해상도의 보정·계층 결합 거리 맵이며, 아래는 동일 영역의 계층·해상도별 평균과 영역 내부 사분위 범위다. 원시 기준 점수는 거의 같지만 최종 정상 점수가 더 높아, 개별 사례의 한계를 보여준다.

합도 1.084와 0.878로 같은 순서를 보인다. 따라서 관측별 반응이 달라진다는 사실만으로 각 영역의 점수 순서가 올바르게 바뀌지는 않는다. 이 사례는 성공 사례가 아닌 반례이며, 본문 집단 프로파일의 원자료를 대신하지 않는다. 표시한 거리 맵은 두 해상도에 동일한 $[0, 2]$ 범위를 적용하고 초과값을 표시했다. 영역별 재정규화는 하지 않았다.

A.4. HSA 진단의 프로토콜과 반례

Fig. 4는 MVTec AD 2 `test_public`의 2-shot, seed 0 캐시를 재사용한 사후 분석이다. (a,b)는 각 이미지에서 정상 픽셀을 100개당 1개, 결함 픽셀을 10개당 1개 추출하고, 단일 관측 점수가 클래스 정상 Q99(t)의 0.9–1.1배인 위치를 모든 구성에 같은 위치로 사용했다. 구성마다 t를 따로 구했으며, (b)의 AUROC는 구간 안의 모든 표본으로 계산했다. (a)의 분포는 클래스·라벨별 최대 2,000개 표본으로 클래스마다 밀도를 구한 뒤 평균했다. 같은 단일 관측에 Q99 보정만 적용하면 구간 내 AUROC는 58.1 %로 변하지 않는다. 이 구간은 Fig. 1(c)의 위치 집단과 같다. 동일한 1,084개 쿼리의 원본 크기 점수에서 정상 약 44.25억 픽셀과 결함 약 2,911만 픽셀을 집계했다. 기준선은 1120 해상도 L23의 원시 거리를 배그 평균한 지도이며, ScopeAD는 같은 캐시의 Q99 보정, 계층 가중합, 배그 평균, 해상도별 보간 및 Rényi 집계를 적용한 지도다. 추가 적합이나 파라미터 변경 없이 재생했으며, 정답 마스크는 점수 산출 이후에만 사용했다.

임계값 t는 Tab. 10과 동일하게 각 이미지의 정상 픽셀을 100개당 1개씩 추출한 뒤 클래스·방법별로 합친 분포의 99백분위수다. 정상 이미지와 결함 이미지의 정상 배경을 모두 포함하고, regular 및 비정규 획득 조건을 함께 사용했다. 이 임계값을 이미지나 획득 조건마다 다시 맞추지 않고, 전체 원본 픽셀에서 FPR과 결함 검출률을 측정했다(Tab. 11). 실제 FPR의 macro는 기준선 0.991 %, ScopeAD0.992 %이며, 표본 추정으로 클래스별 FPR은 목표 1%와 다를 수 있다. Fig. 10의 네 패널은 조건군별로 클래스의 정상·결함 밀도를 각각 계산한 뒤 macro 평균하며, 표시 범위 밖의 픽셀도 정규화에 포함한다. 따라서 이는 비슷한 오경보 예산에서의 점수 분리도를 비교하는 진단이며, 정답 없이 배포 임계값을 추정하거나 미사용 테스트에서 일반화를 검증하는 실험은 아니다.

동일 FPR에서의 곡선 비교. 본문 Fig. 4(c,d)는 위 고정 임계값 진단과 달리, 클래스·방법·조건군별로 임계값을 변화시킨 Recall–FPR 곡선을 비교한다. 저장된 정상·결함 점수 히스토그램의 누적합으로 구간 경계의 FPR과 Recall을 계산하고, $A/t = 1$에서 별도로 집계한 정확한 검출 수를 추가했다. 각 클래스의 곡선을 공통 FPR 격자

Table 10. MVTec AD 2 저-FPR 결함 검출률 (8개 클래스 macro, seed 0, %). 테스트 정상 픽셀 표본으로 임계값을 정한 사후 진단이며, 열의 FPR은 목표값이다. 굵은 값과 밑줄은 최고·차순위다.

	2-shot		16-shot	
단계별 구성	FPR=0.01	FPR=0.05	FPR=0.01	FPR=0.05
Raw L23 1120 (단일 관측)	36.24	56.88	39.78	60.65
Raw Fusion 1120 (미보정 결합)	39.65	60.71	43.01	62.81
Q99 Fusion 1120 (정규 계층)	38.51	60.68	42.71	62.53
ScopeAD (전체 관측 확장)	**45.95**	**66.14**	**50.04**	**66.95**

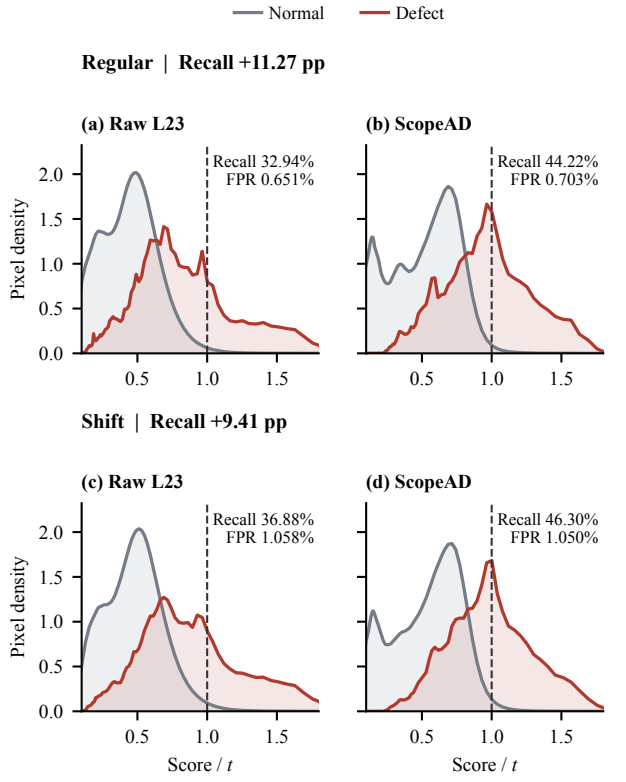


Figure 10. **고정 임계값에서의 정상·결함 점수 분포.** 전체 조건의 테스트 정상 표본에서 추정한 클래스·방법별 99백분위수 t로 점수를 나누고 밀도를 macro 평균했다. 점선은 $A/t = 1$이며, 수치는 해당 임계값의 실제 FPR과 Recall이다(2-shot, seed 0).

에서 선형 보간한 뒤 8개 클래스를 동일 비중으로 평균했다. 따라서 본문의 FPR 1% 표시는 조건군별로 같은 FPR에서 비교한 값이며, 위 고정 임계값의 평균 검출률과 구분된다. 히스토그램은 0과 무한대 경계 사이에 0.001–8의 로그 간격 경계를 사용한 242개 구간으로 구성되어, 구간 내부의 점수 순위와 최상위 열린 구간을 복원할 수 없다. 따라서 곡선은 원본 픽셀 점수로 계산한 정확한 ROC가 아닌 근사이며, 별도 모델 적합이나 새로운 평가 표본은 사용하지 않았다.

Table 11. HSA 진단의 실제 FPR과 결함 픽셀 Recall (2-shot, seed 0, %). 전체 조건의 테스트 정상 표본에서 추정한 임계값을 고정 적용했다. Recall의 굵은 값과 밑줄은 클래스별 최고·차순위다.

	실제 FPR		Recall	
클래스	Raw L23	ScopeAD	Raw L23	ScopeAD
can	0.996	0.998	6.54	**15.87**
fabric	1.002	1.006	29.68	**35.41**
fruit_jelly	0.995	1.044	23.16	**33.40**
rice	1.004	0.996	79.53	**85.74**
sheet_metal	0.995	1.000	46.54	**52.78**
vial	0.941	0.901	19.77	**27.44**
wallplugs	1.001	0.995	8.55	**44.21**
walnuts	0.994	0.998	**76.12**	72.76
Macro	0.991	0.992	36.24	**45.95**

조건별 분석은 regular 184개 쿼리와 비정규 획득 조건 900개 쿼리를 구분한다. 본문의 shift는 `overexposed`, `underexposed` 및 클래스마다 제공되는 `shift_1`–`shift_4`를 합친 조건군이며, 클래스 내 각 획득 조건과 regular의 정상·결함 장면 ID가 일치함을 확인했다. 클래스 내 해당 조건군의 전체 픽셀로 지표를 계산한 뒤 8개 클래스를 동일 비중으로 평균한다. Regular에서 검출률은 32.94→44.22 %, 실제 FPR은 0.651→0.703 %이고, shift에서는 각각 36.88→46.30 %, 1.058→1.050 %다. 과노출·저노출을 제외한 `shift_*`만의 532개 쿼리에서도 검출률은 39.28→47.44 %(+8.16 pp), 실제 FPR은 1.271→1.266 %다. 모든 조건군에 같은 클래스·방법별 임계값을 적용했으므로 조건군별 FPR은 1%로 고정되지 않으며, regular와 shift 사이의 검출률 차이를 조건 변화로 인한 손실로 해석하지 않는다.

Fig. 11는 전체 획득 조건에서 Raw L23 대비 새로 검출한 결함과 놓치게 된 결함을 분리한다. 전체 결함 픽셀 대비 검출 회복은 macro 13.57 %, 손실은 3.85 %로, 순이득은 9.72 pp다. 8개 클래스 중 7개에서 순이득이 있으며, `walnuts`는 3.36 pp 낮아진다. 정상 픽셀에서도 제거된 오경보와 새로 생긴 오경보가 공존하므로, 이 결과를 모든 정상 고점수의 제거로 해석하지 않는다.

실패 사례는 클래스 전체의 검출률이 낮아진 `walnuts`에서 선택했다. 비정규 조건의 결함 이미지 중 결함 픽셀 500개 이상을 대상으로, 클래스의 비정규 조건 검출률 변화 및 기준선 검출률에 가까운 이미지를 정했다. 구체적으로 $|\Delta_{\text{image}} - \Delta_{\text{class}}| + 0.25|R^{\text{raw}}_{\text{image}} - R^{\text{raw}}_{\text{class}}|$를 최소화하고, 동률은 경로순으로 정했다. 이는 최대 개선 사례를 고르는 규칙은 아니지만, 정답을 사용한 사후 대표 사례 선택이다. 지표는 모두 원본 픽셀에서 계산하며, 표시용 축소

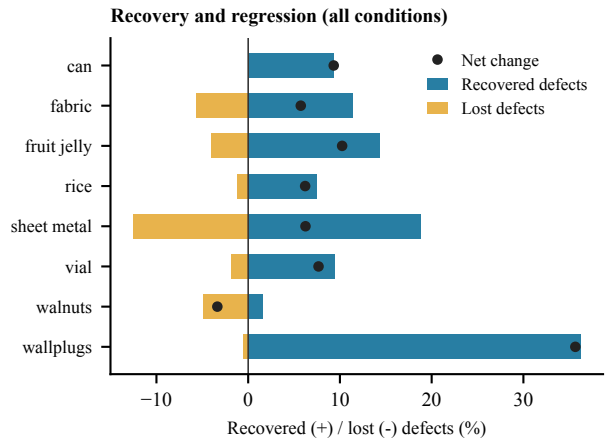


Figure 11. **클래스별 결함 검출 회복과 손실.** 전체 획득 조건의 결함 픽셀 대비 비율(2-shot, seed 0). Raw L23 대비 새로 검출한 결함은 파랑, 놓치게 된 결함은 노랑, 순이득은 검은 점이다.

지도에는 최근접 보간을 사용했다. Fig. 12의 이미지에서는 오경보가 줄어도 결함 검출률은 88.58→85.96 %로 낮아진다. 클래스 전체에서도 76.12→72.76 %로 낮아져, 개선이 모든 클래스와 이미지에서 성립하지 않음을 보여준다.

저-FPR 검출 회복은 모든 정상·결함 쌍의 점수 순서 개선과도 구분된다. 별도 진단에서 Q99 보정된 1120 단일 해상도의 정상 고점수와 가까운 결함 점수를 짝지었을 때, 2-shot 비정규 조건의 결함 우위 비율은 단일 해상도 82.79 %, 전체 Rényi 결합 72.09 %였다(3-seed, 이미지·클래스별 평균). 이 진단은 기준선 점수로 쌍을 선택하고 정규화·계층 결합을 이미 적용한 비교로, 본문의 원시 L23 기준선 및 전체 픽셀 검출률과 비교 조건이 다르다. 기준선에 조건화한 쌍의 선택 편향도 있으므로 전체 모집단의 악화로 일반화할 수 없지만, 모든 모호한 쌍이 해소된다는 주장도 뒷받침하지 않는다. 본 논문의 직접 근거는 명시된 저-FPR 구간의 검출 회복이며, 이 사후 진단 한 시드만으로 미관측 조건의 강건성을 확정하지 않는다.

A.5. 보정과 Rényi 집계의 메커니즘 분석

Table 12. 집계 방식과 척도 보정의 상호작용, $\mathrm{pAUROC}_{0.05}$ (MVTec AD 2, 3-seed 평균 ± 표본 표준편차, %). $\mathrm{AUPRO}_{0.05}$는 Tab. 8. 굵은 값과 밑줄은 최고·차순위 평균이다.

집계 방식	척도 보정	2-shot	16-shot
Mean	없음	76.10 ± 0.49	77.76 ± 0.32
Mean	Q99	75.86 ± 0.59	77.60 ± 0.37
Rényi	없음	**76.18 ± 0.40**	**77.96 ± 0.25**
Rényi (Ours)	Q99	75.83 ± 0.51	77.77 ± 0.34

추가 응답의 정의. Rényi 결합 점수는 해상도 점수의 평균 응답 $\mu(p)$와 해상도 간 순위 간격 $g_k(p)$에 따른 추가 응답 $E(p) \geq 0$의 합으로 분해된다:

$$\tilde{A}(p) = \mu(p) + E(p), \quad E(p) = \frac{9g_1(p) + 14g_2(p) + 13g_3(p)}{48}. \tag{9}$$

$E(p)$는 해상도 간 점수 편차가 클수록 커지므로, 척도 보정이 없으면 기저 거리가 큰 해상도 때문에 정상 영역에서도 커질 수 있다. 아래에서는 평균 응답 대비 비율 E/μ로 이 효과를 비교한다.

상대 추가 응답(E/μ). 분석은 같은 특징과 거리를 재사용한다. 같은 픽셀 표본의 보정 전후 차이를 이미지·seed·클래스 순으로 평균했다. Rényi 집계에서 정상 이미지의 E/μ는 Q99 보정 후 2-shot에서 7.74 → 7.10 %, 16-shot에서 8.56 → 7.55 %로 감소했다(Fig. 13(a)). 결함 영역에서는 5.34 → 5.36 %, 6.36 → 6.11 %로 변화가 작았다. 결함과 정상 배경의 E/μ 차이는 +0.74/ + 0.80 pp 커졌고, 정상 이미지 E/μ의 Q99는 −1.30/ − 1.61 pp 줄었다. 이는 상대 추가 응답 분포의 변화이며, 고정 임계값에서의 오경보율 변화를 직접 측정한 것은 아니다.

순위 변경과 점수 크기 변경의 분리. Q99로 순위만 정하고 원점수를 합산하는 조건과, 원점수 순위를 유지한 채 Q99 점수를 합산하는 조건을 비교했다(Fig. 13(b)). 순위만 바꾼 효과는 +0.05/ − 0.14 pp인 반면, 크기만 바꾼 효과는 +0.46/ + 0.70 pp로 최종 이득의 대부분을 차지했다. 따라서 보정의 효과는 주로 점수 크기의 조정에서 나온다.

보정 오차에 대한 민감도. Fig. 13(c)는 보정 분모에 평균 1의 log-normal 오차를 넣고 오차가 없는 경우와 비교한다. 각 σ에서 seed별 3회 동일한 오차를 두 집계에 적용해 평균했다. $\sigma = 0.3$에서 Mean의 $\mathrm{AUPRO}_{0.05}$변화는 −0.03/ + 0.06 pp인 반면 Rényi는 −0.74/ − 0.47 pp였다. Rényi 집계는 Mean보다 분모의 정확도에 더 민감하다.

단위에 따른 분포 비교. E/μ는 해당 픽셀의 평균 응답을 분모로 쓰므로 결함에서 μ가 커지는 효과도 포함한다. 이를 확인하기 위해 다른 fold 정상 이미지 μ의 Q99로 나눈 E도 측정했다. 이 값의 정상/결함 평균은 2-shot에서 4.31 → 3.80 / 6.18 → 6.19 %, 16-shot에서 4.57 → 3.80 / 8.01 → 7.66 %로, 정상 추가 응답이 줄고 결함 응답이 상대적으로 유지되는 방향은 같았다. 결함−배경 E/μ 차이 변화의 클래스 bootstrap 95 % 구간은 $[+0.06, +1.72]/[+0.00, +2.02]$ pp이며, 16-shot 하한이 0에 가깝다. 정상 이미지 E/μ의 Q99 변화 구간은 $[-2.29, -0.50]/[-3.00, -0.48]$ pp이고, 감소한 클래스는 7/8과 6/8이다.

Tab. 13의 coverage 상호작용은 (Q99+R − Q99+Mean) − (None+R − None+Mean)이다(R: Rényi). GT 영역 coverage를 이미지 안에서 평균한 뒤 이미지와 seed를 평균했다. 임계값은 정상 이미지의 교차검증으로 목표 FPR 1 %에 맞추었으며, 실제 평가 FPR은 조건마다 다르다.

클래스와 이미지의 불확실성. Tab. 13의 coverage 상호작용은 클래스에 따라 부호가 다르다. 클래스 bootstrap 구간은 0을 포함하지만, 서포트·임계값·클래스를 고정하고 이미지만 재표집한 구간은 $[+0.18, +1.16]/[+0.61, +1.92]$ pp다. 두 구간은 서로 다른 변동을 나타내며, 후자는 클래스 구성이나 서포트 선택의 변동을 포함하지 않는다.

결함 크기와 대비. GT 면적이 이미지의 0.1 % 미만인 작은 영역의 coverage 상호작용은 +0.86/ + 1.53 pp지만 fabric

Table 13. **검출 변화와 해상도 응답 집중도의 연관** (MVTec AD 2, 3-seed 평균). 상호작용은 보정 유무에 따른 Rényi−Mean coverage 차이의 변화(pp)다. ρ는 Q99 상태의 응답 집중도와 Mean→Rényi coverage 차이의 클래스 내 Spearman 상관이다.

클래스	2-shot 상호작용 (pp)	16-shot 상호작용 (pp)	2-shot ρ	16-shot ρ
can	−0.05	−0.06	0.48	0.39
fabric	+7.24	+11.50	0.56	0.31
fruit_jelly	+0.23	+0.72	0.48	0.46
rice	−0.38	−0.71	0.38	0.22
sheet_metal	−1.86	−1.78	0.48	0.43
vial	+0.12	−0.18	0.30	0.03
wallplugs	−0.19	−0.59	0.51	0.52
walnuts	+0.05	+0.79	0.29	0.30
Macro	+0.65	+1.21	—	—
fabric 제외	−0.30	−0.26	—	—

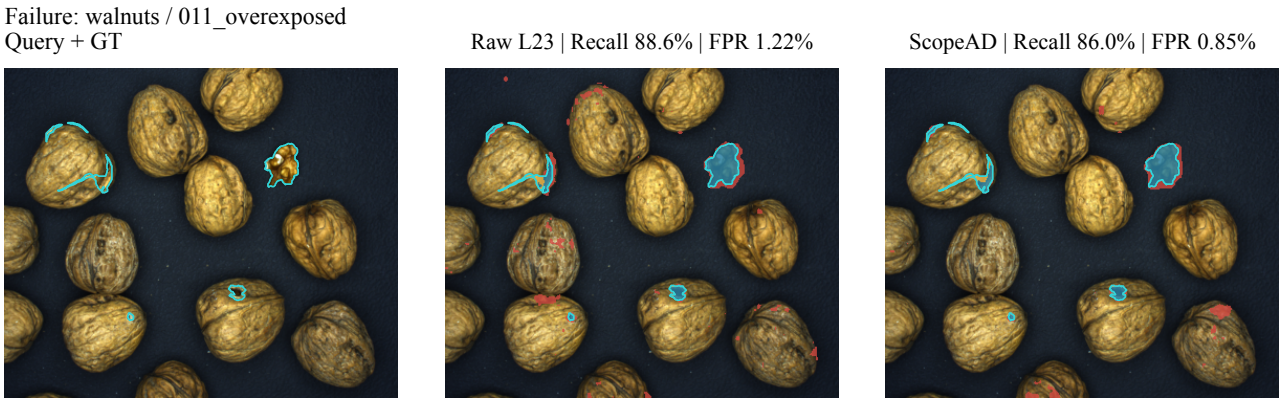


Figure 12. **검출 회복이 보장되지 않는 반례.** `walnuts`의 과노출 쿼리. 파랑: 검출 결함, 노랑: 미검출 결함, 빨강: 오경보, 하늘색: 정답 윤곽. 검출률은 88.58→85.96 %로 낮아진다.

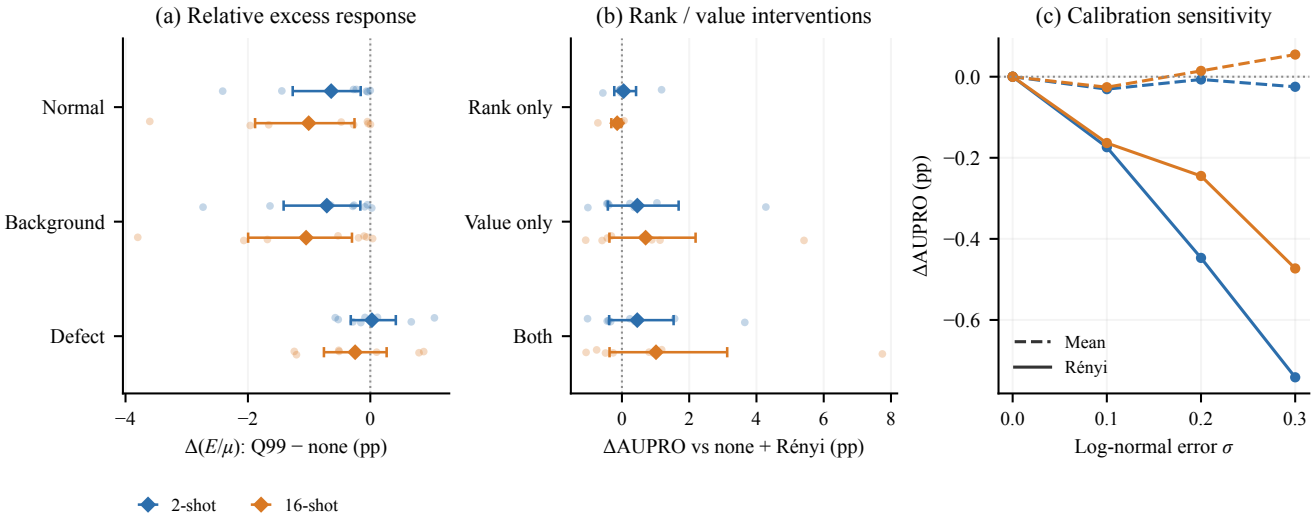


Figure 13. **Q99 보정과 Rényi 집계의 메커니즘 분석** (MVTec AD 2, 2/16-shot, 3-seed). (a) Q99−None의 E/μ 변화: Normal은 정상 이미지, Background는 결함 이미지의 정상 배경, Defect는 결함 영역. (b) None+Rényi 대비 순위·크기 보정의 $\text{AUPRO}_{0.05}$ 변화. (a,b)의 점은 클래스별 평균, 마름모와 막대는 macro와 클래스 bootstrap 95 % 구간이다. (c) 분모 오차에 따른 $\text{AUPRO}_{0.05}$ 변화. 색은 shot, 점선/실선은 Mean/Rényi다.

을 제외하면 −0.18/ − 0.06 pp다. 0.1–1 % 및 1 % 이상 구간은 can이 없어 7개 클래스 범위다. 회색조 대비(GT 영역 평균과 8픽셀 주변 정상 영역의 차이를 주변 표준편차로 나눈 값)와 결함 크기의 상관 방향은 클래스마다 달랐다. 따라서 작은 결함이나 저대비 결함 전반에서 이득이 있다고 보기는 어렵다.

해상도 순위 점유율. Fig. 14는 seed 0에서 각 픽셀의 최고 점수를 낸 해상도의 비율이다. Q99 보정 후 448의 정상 점유율은 47.5/50.7 %에서 33.9/36.4 %로 줄고, 16-shot 작은 결함의 1120 점유율은 14.5 %에서 29.2 %로 늘었다. 정상 픽셀의 1120 점유율도 13.7 %에서 22.3 %로 늘었으므로, 이 그림은 순위 편중의 변화를 보여주는 보조 자료로 사용한다.

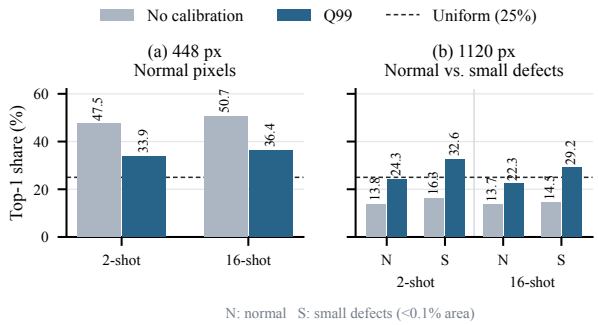


Figure 14. **정상 참조 보정과 해상도 순위 점유율.** MVTec AD 2, seed 0, 8개 클래스 macro. 점선은 균등 점유율 25 %다.

A.6. 관측 간 정상 거리 척도의 정렬

Fig. 15는 Q99 보정 전후의 관측 간 정상 거리 척도를 비교한다. 보정 후 최대/최소 척도 비율은 8개 클래스 × 2/16-shot의 16개 조건 중 14개에서 줄었다.

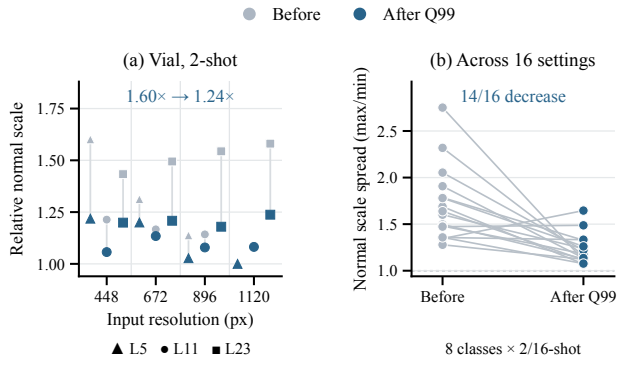


Figure 15. **Q99 보정에 따른 관측 간 정상 거리 척도의 정렬.** (a) Vial 2-shot의 12개 관측에서 정상 쿼리 Q99를 최솟값으로 나눈 상대 척도. (b) 8개 클래스 × 2/16-shot의 보정 전후 최대/최소 척도 비율. 선 하나는 한 조건이며, 아래로 향하면 척도 차이가 줄었음을 뜻한다(16개 중 14개). 비율이 1이면 관측 간 척도가 같다.

Table 14. **Q99 보정 분모의 축별 성분 분리** (MVTec AD 2, 3-seed 평균 $\mathrm{AUPRO}_{0.05}$, %). Global: 배그별 공통 배율, Layer/Resolution: 해당 축 추가, Separable: 두 축 추가, Full: 원래 Q99. 굵은 값과 밑줄은 열별 최고·차순위이며, 동점은 함께 표시했다.

	2-shot		16-shot	
분모	Mean	Rényi	Mean	Rényi
None	56.12	56.32	59.73	59.72
Global	56.12	56.32	59.73	59.72
Layer	55.91	56.13	59.90	59.82
Resolution	**56.26**	**56.87**	59.89	60.55
Separable	56.02	56.78	60.02	60.73
Full Q99	56.03	56.78	**60.06**	**60.74**

A.7. 계층·해상도 보정 축의 분리

분모 분해. 정상 서포트 Q99 $c_{l,r,b}$의 로그를 각 배그에서 다음과 같이 분해한다:

$$\log c_{l,r,b} = \gamma_b + u_{l,b} + v_{r,b} + h_{l,r,b}. \tag{10}$$

γ_b는 계층·해상도 전체 평균이고, $u_{l,b}$와 $v_{r,b}$는 각 축 평균에서 γ_b를 뺀 값이며, $h_{l,r,b}$는 잔여 항이다. Global, Layer, Resolution, Separable은 각각 $\exp(\gamma_b)$, $\exp(\gamma_b + u_{l,b})$, $\exp(\gamma_b + v_{r,b})$, $\exp(\gamma_b + u_{l,b} + v_{r,b})$를 분모로 쓴다. Full은 원래 $c_{l,r,b}$이며 None은 1이다. 모든 축 개입은 배그 공통 척도를 유지하므로 Global을 대조로 사용한다. 특징, 뱅크, 계층 가중치, FP16을 고정하고 분모만 바꾸었으며(8개 클래스 × 2/16-shot × 3 seed), None과 Full의 결과는 Tab. 8와 일치한다.

축 효과. Rényi 아래에서 Resolution−Global은 +0.55/ + 0.82 pp이며, seed별 macro 효과는 2-shot +0.56/+0.64/+ 0.45 pp, 16-shot +0.82/ + 0.78/ + 0.87 pp로 모두 양수다. Mean 아래의 같은 효과는 +0.15/ + 0.15 pp로 작다. Layer−Global은 Rényi 아래에서 −0.19/ + 0.10 pp로 shot에 따라 방향이 달랐고, Full−Separable은 두 shot 모두 0.01 pp 이내로 잔여 항의 macro 영향은 작았다. 다만 Resolution−Global에서 양의 효과를 보인 클래스는 두 shot 모두 8개 중 4개이고, fabric의 효과가 +5.18/ + 7.26 pp로 크다. 클래스 bootstrap 95 % 구간은 [−0.36, +1.99]/[−0.40, +2.80] pp로 0을 포함하며, fabric을 제외하면 −0.11/ − 0.10 pp다.

A.8. 평균 응답 조건부 분석과 영역·픽셀 가중

같은 평균 응답 구간에서의 비교. 두 보정 조건의 같은 픽셀을 보정 전 평균 응답 μ의 10분위 구간에 배정했다. 구간 경계는 다른 정상 fold에서 정했다. 이미지→seed→클래스 순으로 집계하면 정상과 배경의 Q99−None E/μ 변화는 두 shot 모두 10개 구간 전체에서 음수였다. 결함−배경 변화는 8개 클래스가 모두 관측된 구간(2-shot 5–9, 16-shot 6–9)에서 모두 양수였다. 따라서 평균 응답 수준이 다른 픽셀이 섞여서 생긴 현상으로 보기는 어렵다. 다만 보정 후의 μ까지 고정한 비교는 아니다.

Fabric의 영역 수와 결함 픽셀 수. Fabric의 GT 영역 192개 중 180개(93.75 %)는 이미지 면적의 0.1 % 미만이지만, 이 영역들은 전체 결함 픽셀의 1.39 %만 차지한다. 목표 FPR 1 % 임계값에서 Q99+Rényi−None+Rényi의 영역

Table 15. 획득 조건별 $\text{AUPRO}_{0.05}$ (MVTec AD 2 `test_public`, 3-seed 평균, %). 기본: regular, 변화: 비정규 조건 평균. 손실은 단일 임계값 점수에서 전체 조건별 점수의 평균을 뺀 값(pp)이다. 굵은 값과 밑줄은 열별 최고·차순위이며, 손실은 0에 가까울수록 우수하다.

	1-shot			2-shot			4-shot			8-shot			16-shot		
방법	기본	변화	손실	기본	변화	손실	기본	변화	손실	기본	변화	손실	기본	변화	손실
PatchCore	39.09	38.46	−0.11	42.98	42.30	−0.16	47.72	47.10	−0.27	51.31	50.20	−0.40	54.32	52.97	−0.46
AnomalyDINO	39.82	37.12	−1.58	42.79	39.52	−1.83	46.31	42.04	−2.39	48.08	43.15	−2.29	49.91	44.12	−2.74
FastRecon	15.61	14.87	−0.07	17.61	16.82	−0.23	23.02	21.99	−0.28	28.77	27.52	−0.41	38.19	35.54	−0.74
RAD	26.28	26.50	**−0.04**	31.53	31.71	−0.06	36.37	36.74	−0.16	41.03	41.10	−0.30	43.14	43.02	−0.46
SubspaceAD	**56.76**	48.20	−4.75	**58.86**	49.65	−5.28	**61.27**	51.35	−5.86	**62.21**	51.82	−6.26	**63.10**	52.37	−6.52
SuperAD	47.08	46.46	−0.24	51.06	49.96	−0.33	56.15	54.50	−0.51	57.92	55.71	−0.62	58.58	56.33	−0.80
RegAD (224)	14.09	12.67	−0.17	16.75	14.95	−0.20	19.59	17.39	−0.35	22.09	19.38	−0.58	24.11	20.88	−1.14
Ours (ScopeAD)	53.10	**52.09**	−0.06	58.09	**56.60**	**−0.05**	60.97	**59.27**	**−0.05**	61.94	**60.22**	**−0.10**	62.42	**60.74**	**−0.27**

평균 coverage 변화는 작은 영역에서 $+6.85/+10.41$ pp, 나머지 영역에서 $-1.36/-0.84$ pp다(2/16-shot). 같은 변화를 GT 픽셀 수로 가중하면 작은 영역의 TPR 기여는 $+0.06/+0.08$ pp, 나머지는 $-2.66/-1.64$ pp다. 즉 많은 작은 영역의 coverage 증가와 큰 영역의 손실이 함께 나타나며, 영역 단위 지표($\text{AUPRO}_{0.05}$)와 픽셀 단위 지표($\text{pAUROC}_{0.05}$)가 다르게 움직이는 이유를 설명한다.

A.9. 획득 조건별 상세 결과

MVTec AD 2 `test_public`은 클래스마다 같은 장면을 기본 조건(regular)과 바뀐 조건(overexposed, underexposed, 클래스별 1–4개의 shift)에서 같은 수로 포함한다. 조건별 $\text{AUPRO}_{0.05}$는 각 조건 안에서, 단일 임계값 $\text{AUPRO}_{0.05}$는 클래스 내 모든 조건에 공통으로 임계값을 변화시키며 FPR 0.05까지 적분한 값이다. 후자는 Tab. 1과 같다. 두 표의 손실은 단일 임계값 $\text{AUPRO}_{0.05}$에서 전체 조건별 $\text{AUPRO}_{0.05}$의 평균을 뺀 값(pp)이다. 이는 조건을 함께 평가할 때 생기는 손실이며, 정상·결함 점수의 중첩 정도나 사전에 정한 배포 임계값의 FPR을 직접 나타내지는 않는다. Tab. 15은 모든 shot의 결과이고, Tab. 16는 ScopeAD의 보정·집계 변형과 단일 해상도 구성의 손실이다. 손실은 보정 유무와 집계 방식에 따라 2-shot에서 0.06–0.07 pp, 16-shot에서 0.33–0.39 pp로 거의 변하지 않았고, 단일 1120 구성(0.18 pp)도 4해상도 구성(0.33 pp)보다 크지 않았다. 따라서 ScopeAD의 작은 손실을 특정 구성 요소의 효과로 보기는 어렵다.

Table 16. ScopeAD 변형의 획득 조건별 $\text{AUPRO}_{0.05}$ (MVTec AD 2, seed 0, %). 단일/조건별은 공통/조건별 임계값 평가이며, 손실은 단일−조건별(pp)이다. 굵은 값과 밑줄은 열별 최고·차순위이며, 손실은 0에 가까울수록 우수하다.

	2-shot			16-shot		
구성	단일	조건별	손실	단일	조건별	손실
보정 없음 + Rényi	58.99	59.05	**−0.06**	59.03	59.41	−0.38
Q99 + Mean	59.33	59.40	−0.07	59.57	59.96	−0.39
Q99 + Rényi (Ours)	**59.92**	**59.98**	**−0.06**	**60.19**	**60.49**	−0.30
단일 1120 (cap 256)	—	—	—	57.48	57.66	**−0.18**

A.10. 단일 해상도와 해상도 조합 결합

Fig. 16 및 Tab. 17는 최종 방법의 Q99 보정과 계층 결합을 유지한 채 단일 해상도 및 다양한 해상도 부분집합 조합과 4해상도 결합을 비교한다. 단일 해상도 중에서는 2-shot에서 672(54.38 %), 16-shot에서 1120(57.48 %)이 가장 높은 성능을 기록했다. 중간 문맥과 미세 분해능을 대표하는 2개 해상도 조합 $\{672, 1120\}$은 단일 최고 성능 대비 2/16-shot에서 각각 +3.72 pp, +1.67 pp 향상되며, 쿼리 시간(980 ms) 대비 높은 효율을 보인다. 4개 해상도를 모두 결합하면 가장 높은 단일 해상도보다 2-shot에서 5.54 pp, 16-shot에서 2.71 pp 높아 결함 크기별 반응이 고르게 보존된다.

Table 17. 해상도 조합에 따른 국소화 성능 (MVTec AD 2, Q99, %). 各 조합은 Rényi 순서 통계량으로 집계했다.

해상도 조합	R	2-shot $\text{AUPRO}_{0.05}$	16-shot $\text{AUPRO}_{0.05}$
{672} (최고 2-shot)	1	54.38	55.01
{1120} (최고 16-shot)	1	54.27	57.48
{448, 1120}	2	56.84	58.20
{672, 1120}	2	58.10	59.15
{448, 672, 1120}	3	59.22	59.80
{448, 672, 896, 1120} **(Ours)**	4	**59.92**	**60.19**

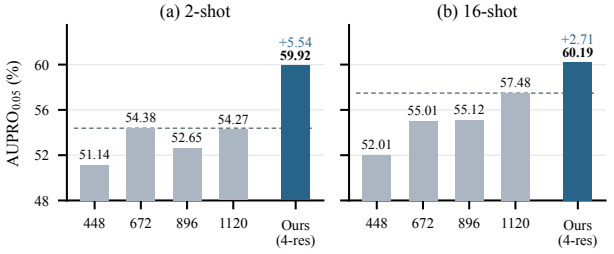


Figure 16. **단일·다해상도 $\text{AUPRO}_{0.05}$ 비교 (MVTec AD 2, seed 0).** 회색 막대는 단일 해상도, 점선은 그중 최고 성능, 파란 숫자는 4해상도 결합의 향상 폭(pp)이다.

Table 18. MVTec AD 및 VisA few-shot $AUPRO_{0.05}$ (seed 0, %). Tab. 4과 같은 실행에서 집계했다. 굵은 값과 밑줄은 행별 최고·차순위다.

Dataset	Shot	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	Ours (ScopeAD)
MVTec AD	1	69.94	71.20	71.80	65.27	**82.48**	77.29	78.81
	2	75.30	73.46	76.66	69.74	**83.49**	80.06	81.53
	4	78.44	75.98	80.69	72.24	**83.96**	81.99	83.28
	8	82.17	76.24	83.54	77.28	83.99	83.33	**84.59**
	16	83.97	77.62	**85.74**	80.12	83.89	84.49	85.08
VisA	1	60.92	67.88	63.60	51.19	**84.32**	72.06	74.00
	2	64.94	72.48	69.52	59.07	**85.22**	75.64	79.02
	4	69.80	76.04	72.84	68.85	**85.62**	77.94	81.95
	8	73.53	78.03	74.75	74.41	**86.19**	79.64	84.07
	16	75.05	79.83	76.59	77.44	**86.21**	80.21	85.29

A.11. MVTec AD·VisA의 저-FPR 국소화

Tab. 18는 Tab. 4과 같은 seed 0 실행에서 $AUPRO_{0.05}$를 집계한 결과다. RegAD는 본문 표와 같은 설정의 $AUPRO_{0.05}$가 두 데이터셋 모두에 있지 않아 제외했다. ScopeAD는 10개 조합 모두에서 최고 또는 차순위이며, 최고는 MVTec AD 8-shot이다. MVTec AD 16-shot에서는 FastRecon(85.74 %)이 가장 높고, SubspaceAD는 VisA 전 shot과 MVTec AD 1–4-shot에서 가장 높다. 같은 백본의 SuperAD 대비 차이는 MVTec AD에서 $+0.59$–$+1.52$ pp, VisA에서 $+1.94$–$+5.08$ pp다.