ScopeAD: Observation Expansion and Support-Referenced Asymmetric Fusion for Few-Shot Industrial Anomaly Localization

Anonymous CVPR submission

Abstract

*소수의 정상 이미지만 사용하는 few-shot 산업 이상 국소화에서는 서포트에 없는 정상 외관 변화도 큰 최근접 거리를 만들 수 있어, 높은 점수만으로 정상 변동과 결함을 구분하기 어렵다. 획득 조건이 바뀌면 정상 영역의 점수 수준도 조건마다 달라져, 하나의 저-FPR 임계값으로 결함을 가려내기가 더 어려워진다. 본 논문은 제한된 서포트에서 비교 단서를 늘리기 위해 동결 백본의 표현 계층과 입력 해상도를 독립 매칭 단위로 확장하고, 그 거리를 정상 서포트 기준으로 통합하는 **ScopeAD**를 제안한다. ScopeAD는 각 관측의 거리를 정상 참조 거리의 상위 분위수(Q95)로 나누어 단위를 맞추고, 깊은 계층의 평균에 얕은 계층을 작은 가중치로 더한다. 해상도 축에서는 위치별 점수 순위에 따라 Rényi 가중치를 적용하여 산술 평균에서 생기는 국소 반응의 희석을 줄인다. 백본의 추가 학습이나 쿼리 시점 파라미터 갱신은 사용하지 않는다. MVTec AD 2에서 ScopeAD는 1–16-shot 모두에서 비교 방법보다 높은 $\mathrm{AUPRO}_{0.05}$, $\mathrm{pAUROC}_{0.05}$, I-AUROC를 기록했으며, 1-shot $\mathrm{AUPRO}_{0.05}$는 52.18 %로 차순위보다 5.87 pp 높다. 획득 조건이 바뀐 이미지만 평가해도 ScopeAD의 $\mathrm{AUPRO}_{0.05}$가 모든 shot에서 가장 높았고, 조건별 임계값 대비 단일 임계값 평가의 손실도 0.27 pp 이하로 작았다. 공식 `test_private` 리더보드에서도 16-shot 기준 66.53 %의 $\mathrm{AUPRO}_{0.05}$를 기록하여 비교 모델 대비 높은 성능을 보였다. 구성 요소 분석에서는 다해상도 관측이 가장 큰 향상을 주었고, Q95 보정 아래에서 Rényi 집계가 추가 향상을 주었다. MVTec AD와 VisA에서도 비교 방법과 대등한 성능을 보였다.*

1. 서론

다품종 소량 생산과 빈번한 라인 전환이 발생하는 제조 환경에서는 제품별 결함 표본을 충분히 수집하기 어렵다. 이에 따라 소수의 정상 참조 이미지만으로 결함 위치를 특정하는 few-shot 이상 국소화(few-shot anomaly localization)가 실용적인 대안으로 활용된다. 대표적으로, 동결된 사전학습 백본 [12]으로 정상 패치의 메모리 뱅크를 구축한 후, 테스트 패치와의 최근접 이웃 거리를 계산하여 이상치를 탐지하는 방법이 있다 [3, 15, 19]. 이러한 거리 기반 점수는 정상 패치가 메모리 뱅크의 특징과 유사하다는 가정에 기반한다. 그러나 실제 공정에서는 조명 드리프트, 부품 자세 변동, 표면 난반사 등 다양한 distribution shift가 빈번히 발생한다 [6, 21]. 소수의 정상 표본만 주어지는 few-shot 환경에서는 이러한 외부 조건 변화에 따른 정상 외관의 변동폭을 메모리 뱅크에 충분히 담기 어렵다. 그 결과 서포트 셋에서 관측되지 않은 정상 변동 영역에서도 최근접 거리가 상승하여 실제 결함 점수와 겹칠 수 있다. 이처럼 정상 표본의 희소성과 획득 환경 변화가 함께 작용하면, 단일 거리값만으로는 고점수의 원인이 실제 결함인지 미관측 정상 변동인지 판별하기 어렵다. 본 논문은 이러한 한계를 **High-Score Ambiguity**로 정의한다(Fig. 1). 이 현상은 오경보를 엄격히 제한해야 하는 저-FPR 구간의 결함 국소화 성능을 저해한다. 정상 위치의 높은 점수를 배제하기 위해 임계값을 높이면, 그만큼 탐지 가능한 결함 영역 또한 함께 줄어들기 때문이다 [2]. 실제로 MVTec AD 2에서 조건마다 임계값을 따로 정한 평가와 하나의 임계값으로 평가한 결과를 비교하면, 기존 방법의 $\mathrm{AUPRO}_{0.05}$는 후자에서 최대 6.52 pp 낮아진다(Sec. 4.2).

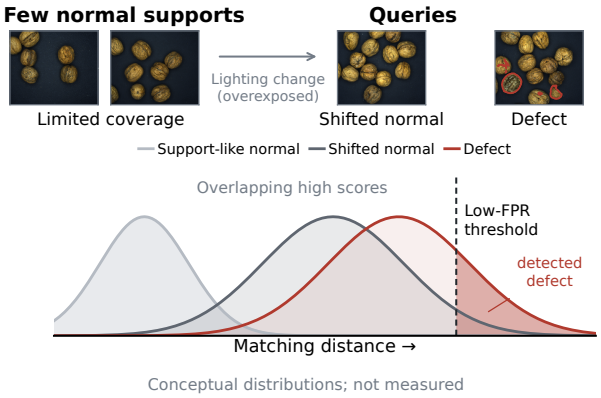


Figure 1. **Few-shot 서포트와 획득 조건 변화.** 적은 정상 참조는 정상 외관의 일부만 포함한다. 조명이 바뀌면 정상 쿼리와 결함 쿼리가 모두 큰 매칭 거리를 가질 수 있고, 저-FPR 임계값에서는 결함 분포의 꼬리만 검출된다. 이미지는 MVTec AD 2 walnuts 표본이며(서포트는 regular, 쿼리는 overexposed, 결함은 빨간 윤곽), 분포는 측정값이 아닌 개념도다.

High-Score Ambiguity를 완화하려면 단일 관측에서 유사한 거리를 보이는 미관측 정상 변동과 실제 결함을 구분

할 추가 단서가 필요하다. 소수의 정상 참조만 주어지는 few-shot 환경에서는 획득 조건 변화에 맞춰 모델을 추가 학습하기보다, 동결된 사전학습 표현을 유지한 채 비교 관점을 넓히는 접근이 효과적이다. 이때 단일 관측에서 모호한 정상 변동과 결함은 국소 외관부터 전역 문맥을 아우르는 표현 계층의 추상화 수준 [13, 14]과 고정 패치 백본에서 토큰의 물리적 수용영역 크기를 결정하는 입력 해상도 [5, 16]에 따라 서로 다른 반응 양상을 보인다. 이를 활용하여 본 논문은 추가 학습이나 서포트 증강 없이, 동일한 정상 서포트를 계층과 해상도의 두 축으로 분리·확장하는 관측 확장(observation expansion)을 수행한다. 다만 다중 척도의 특징을 단일 고차원 벡터로 연결해 매칭하면 [15] 분산이 큰 특정 계층이 이웃 탐색을 지배하여 다른 척도의 단서가 묻힐 수 있으므로, 각 계층·해상도 조합마다 독립된 메모리 뱅크와 개별 1-NN 매칭을 수행해 국소 결함 단서와 전역 문맥 차이를 별도의 비교 단서로 보존한다.

그러나 관측 확장으로 확보한 다중 단서를 최종 이상 점수로 통합하는 과정에서, 단순 결합 방식은 두 가지 구조적 한계를 지닌다. 첫째는 관측 간 척도 불균형(scale discrepancy)이다. 산출되는 거리의 분포는 계층 깊이와 입력 해상도에 따라 상이하므로(Fig. 3), 별도의 보정 없이 합산할 경우 기저 거리(baseline distance)가 큰 특정 관측이 전체 결합 점수와 순위를 지배하게 된다. 둘째는 균등 가중 결합(uniform averaging)의 한계이다. 해상도 측면에서 결함은 그 물리적 크기에 부합하는 특정 해상도에서 두드러지는데, 단순 산술 평균은 이러한 유의미한 반응을 타 해상도의 낮은 점수와 평균화하여 희석(dilution)시킨다. 또한 계층 측면에서는 정상 외관 변동에 민감한 얕은 계층이 깊은 계층과 동일한 비중으로 반영되어, 정상 변동에 의한 노이즈가 최종 점수에 그대로 누적된다. 따라서 효과적인 다관측 통합을 위해서는 정상 참조를 기준으로 관측 간 거리 척도를 먼저 정렬(normalization)하고, 정상 외관 변동에 의한 반응은 억제하면서 특정 관측에서 발현되는 유의미한 결함 단서는 보존하는 결합 메커니즘이 요구된다.

이에 본 논문은 distribution shift가 수반되는 few-shot 환경에서 High-Score Ambiguity를 완화하기 위해, 다축 관측 확장과 강건한 점수 통합 메커니즘을 결합한 **ScopeAD**를 제안한다. 먼저 ScopeAD는 소수의 정상 서포트만 주어지는 제약 하에서도 관측 간 거리 척도를 안정적으로 정렬하기 위해, 서포트 내부의 교차 매칭(cross-matching) 거리 분포에서 관측별 상위 분위수를 추출하여 정규화 기준 단위로 삼는다. 계층 결합 단계에서는 전역 문맥을 담는 깊은 계층을 주축으로 삼고, 얕은 계층의 국소 단서는 작은 가중치로 반영하여 정상 외관 변화에 민감한 반응의 기여를 제한한다. 이어지는 해상도 결합에서는 위치별로 다중 해상도 점수를 정렬한 뒤 상위 순위에 높은 Rényi 가중치를 부여하여, 특정 해상도에서 포착된 결함 반응의 희석을 줄인다. 모든 뱅크와 정규화 척도는 추가 학습이나 쿼리 적응(query adaptation) 없이 소수의 정상 서포트만으로 산출된다. HSA 완화는 낮은 오경보 수준에서 더 많은 결함을 검출하는지로 평가한다. MVTec AD 2의 2-shot 사후 진단에서, ScopeAD는 단일 심층 관측 대비 기존 shift 조건의 실제 FPR을 비슷하게 유지하면서 (1.058→1.050 %) 결함 검출률을 9.41 pp 높였다(Fig. 6). 이 직접 진단과 함께 MVTec AD 2의 저-FPR 국소화 성능 및 MVTec AD·VisA에서의 성능을 평가한다.

본 논문의 기여는 다음과 같다.

- 추가 학습 없이 동결 백본의 사전학습 표현을 보존하면서, 제한된 정상 서포트의 계층과 입력 해상도를 독립 매칭 단위로 분리·확장하여 High-Score Ambiguity를 완화하는 few-shot 이상 국소화 방법 ScopeAD를 제시한다. 총 토큰 수를 맞춘 대조와 단일 해상도 비교에서 이 관측 확장이 성능 향상의 주된 원천임을 보인다.
- 정상 참조 척도 정렬, 계층별 비대칭 가중합, 위치별 해상도 순위 집계로 이루어진 점수 통합 규칙을 제안하고, 척도 정렬과 순위 집계를 함께 쓸 때 이득이 나타남을 분석한다.
- regular와 shift 조건의 점수 분포 및 실제 오경보율에 따른 결함 검출률로 HSA 완화를 직접 분석하고, MVTec AD 2의 저-FPR 국소화 성능, 공식 `test_private` 블라인드 평가, 구성 요소별 기여, 계산 비용과 MVTec AD·VisA 교차 평가를 보고한다.

2. 관련 연구

2.1. Few-shot 이상 탐지의 참조 매칭

Few-shot 이상 탐지는 소수의 정상 참조 이미지와 테스트 쿼리 간의 특징 차이를 비교하여 결함을 탐지 및 국소화한다. 제한된 참조 표본의 한계를 보완하기 위해 이미지 간 기하학적 정합을 학습하거나 [7], 시각-언어 모델의 사전 지식을 결합하여 정상과 이상을 구분하는 연구가 진행되었다 [8, 11]. 또한 보조 데이터셋에서 일반화된 비교 규칙 및 프롬프트를 메타 학습하는 접근 [22, 23]이나, 정상 서포트 없이 레이블이 없는 테스트 이미지 간의 상호 유사도를 비교하는 방식 [10]도 제안되었다. 반면, 본 논문과 같이 소수의 정상 서포트와 동결된(frozen) 사전학습 시각 특징만을 활용하는 접근은 정상 참조와의 괴리를 최근접 이웃 거리 [3, 15, 19], 특징 복원 오차 [4], 또는 부분공간 투영 거리 [9]로 정량화한다. 특히 동결 특징 기반의 패치 매칭은 별도의 추가 학습 없이 새로운 제품군에 즉각 적용할 수 있어 실용적이며 [3, 19], 최근 MVTec AD 2의 few-shot 기초 연구 [17]에서도 백본 계층과 서포트 수에 따른 매칭 성능 변화가 분석된 바 있다. 그러나 단일 관측에 의존하는 기존 참조 매칭은 획득 조건이 변화할 때 미관측 정상 변동과 실제 결함의 거리가 동시에 상승하는 High-Score Ambiguity에 취약하다. ScopeAD는 동결 백본 기반의 참조 매칭을 다중 계층과 해상도의 관측 공간으로 확장하고, 관측별 거리 척도와 기여도를 적응적으로 통합함으로써 정상 변동과 결함 간의 점수 중첩을 효과적으로 완화한다.

2.2. 다중 척도 관측과 점수 결합

다중 계층과 해상도의 특징을 결합하면 국소적 외관 질감부터 전역적 문맥까지 다각적인 비교 단서를 확보할

수 있다. 다층 ViT 특징을 밀집 예측을 위해 재조합하는 DPT [14]나, 다중 해상도 입력을 통해 동결 백본의 수용영역을 확장하는 S^2 [16]가 대표적인 예다. 이상 탐지에서는 이러한 다중 척도 단서를 특징 수준에서 먼저 결합하여 매칭하거나, 관측별 매칭 점수를 개별 산출한 뒤 후처리로 통합한다. 전자인 PatchCore [15]의 특징 연결(concatenation) 방식은 모든 계층이 단일 최근접 이웃 탐색을 공유하므로 분산이 큰 특정 계층에 매칭이 지배될 위험이 있는 반면, SuperAD [19]와 FreePatch [18]는 관측별 개별 점수를 산출한 후 결합하는 점수 수준 통합을 채택한다. 점수 수준 결합은 각 관측의 독립적인 비교 단서를 보존할 수 있으나, 관측 간 거리 척도 불균형(scale discrepancy)을 보정하지 않으면 기저 거리가 큰 관측으로 결합 점수가 편향될 수 있다. 나아가 척도를 정렬한 이후에도 계층별 정상 변동 민감도와 해상도별 결함 반응 특성이 상이하므로, 모든 관측을 균등 가중 평균하는 방식은 유의미한 결함 신호를 희석(dilution)하거나 정상 노이즈를 누적시키는 한계를 지닌다. 이를 해결하기 위해 ScopeAD는 정상 서포트 내부 분포를 기준으로 관측 간 거리 척도를 정렬한 뒤, 계층별 비대칭 가중 결합과 위치별 점수 순위 기반의 집계를 수행하여 정상 변동 노이즈는 억제하고 국소 결함 반응의 희석을 방지한다(Secs. 3.3 and 3.4).

2.3. 획득 조건 변화와 저-FPR 국소화

실제 제조 환경에서 정상 참조와 테스트 쿼리 간에 획득 조건 변화(distribution shift)가 발생하면, 무결함 영역에서도 외관 차이로 인해 매칭 거리가 급격히 상승할 수 있다. 이러한 도메인 변화를 반영하기 위해 최근 AeBAD [21]는 실제 공정 내 배경 및 조명 변화를 도입했으며, MVTec AD 2 [6]는 학습 데이터에 부재한 극단적 조명 및 노출 조건을 포함하여 평가 난이도를 높였다. 특히 소수의 정상 표본만 주어지는 few-shot 환경에서는 서포트 셋이 이러한 외관 변동폭을 포괄하지 못하므로, 조건 변화에 따른 정상 영역의 점수 상승이 실제 오경보로 직결되는지 면밀히 검증해야 한다. 그러나 기존의 표준 지표인 AUROC는 전체 FPR 구간을 통합 요약하므로, 엄격한 오경보 제한이 요구되는 실제 공정에서의 성능 저하를 민감하게 반영하지 못한다. 이에 반해 AUPIMO [2]와 저-FPR 구간의 $\text{AUPRO}_{0.05}$는 낮은 오경보 임계값 하에서 실제 결함 영역의 검출률을 정밀하게 평가한다. 본 논문은 MVTec AD 2를 기반으로 서포트의 희소성(few-shot)과 획득 조건 변화(distribution shift)가 동시에 작용하는 복합적인 난제를 다루며, 백본 학습이나 테스트 시점의 쿼리 적응 없이도 조건 간 분포 이동을 극복하는 ScopeAD의 저-FPR 국소화 성능을 규명한다. 아울러 표준 벤치마크인 MVTec AD와 VisA에서의 교차 평가를 통해 일반적인 환경에서의 범용성 또한 함께 검증한다.

3. 제안 방법

ScopeAD는 동결 백본의 표현을 보존하는 관측 확장(observation expansion)과 정상 참조 기반 점수 통합을 결합하여, 소수 서포트와 획득 환경 변화로 인한 High-Score Ambiguity를 완화하는 이상 국소화 프레임워크다(Fig. 2). 단일 관측에서 유사한 거리를 보이는 미관측 정상 변동과 결함 영역을 분리하기 위해, ScopeAD는 추가 학습 없이 동일한 정상 서포트의 계층과 입력 해상도를 독립 매칭 단위로 확장하여 다각도의 비교 단서를 확보한다. 이 단서를 최종 점수에 반영하기 위해 세 가지 요소를 결합한다: (1) 관측별 거리 스케일을 정상 서포트 기준으로 정렬하는 **정상 참조 척도화(Reference Scaling)**, (2) 깊은 계층을 주축으로 삼고 얕은 계층의 반응을 작은 비중으로 반영하는 **계층별 비대칭 결합(Asymmetric Layer Fusion)**, 그리고 (3) 특정 해상도에 집중된 반응의 희석을 줄이는 **Rényi 순서 통계량 집계(Rényi Order-Rank Aggregation)**이다. 이 설계의 목표는 정상 고점수를 배제하는 과정에서 함께 누락되던 결함을 낮은 오경보 수준에서 더 많이 검출하는 것이다. Sec. 4.4에서는 단일 관측과 전체 방법의 정상·결함 점수 분포 및 검출률을 regular와 shift 조건으로 나누어 이 목표를 검증한다. 추론 시 ScopeAD는 백본의 추가 학습이나 쿼리 적응 없이, 정상 서포트에서 구한 뱅크와 기준 척도만으로 픽셀 단위 결함 맵과 이미지 점수를 산출한다.

3.1. 문제 설정

입력으로 N장의 정상 서포트 이미지 집합 $\mathcal{S} = \{x_1^s, \ldots, x_N^s\}$, 테스트 쿼리 이미지 x^q, 그리고 동결된 사전학습 비전 트랜스포머(ViT) 백본이 주어진다. 특징을 추출할 백본 계층 집합을 $\mathcal{L}$, 입력 해상도(짧은 변 기준) 집합을 $\mathcal{R}$, 서브샘플 배그(bag) 수를 N_b로 정의한다. 본 연구에서는 $\mathcal{L} = \{5, 11, 23\}$, $\mathcal{R} = \{448, 672, 896, 1120\}$, $N_b = 4$를 사용하여 총 $|\mathcal{L}| \times |\mathcal{R}| \times N_b = 48$개의 독립 관측을 구성한다(Sec. 4.1). ScopeAD는 픽셀 단위 결함 국소화 맵 $A(x^q) \in \mathbb{R}^{H \times W}$와 이미지 단위 이상 점수 $s(x^q) \in \mathbb{R}$를 출력한다.

3.2. 관측 확장과 독립 참조 매칭

관측별 독립 매칭 (Independent Matching). 획득 조건이 달라지면 정상 영역이라도 국소 외관을 반영하는 관측에서 거리가 커질 수 있다. 이때 다른 계층에서 정상 구조와 유사하게 매칭되거나, 다른 해상도에서 결함 반응이 더 뚜렷해진다면 단일 거리에서 구분하기 어려웠던 영역을 판별할 추가 단서를 얻을 수 있다. 그러나 기존처럼 다층 특징을 단일 벡터로 연결해 매칭하면 [15], 분산이나 척도가 큰 계층이 최근접 이웃 탐색을 지배하여 정상 외관 변화에 따른 국소적 거리 상승이 다른 계층의 비교 단서를 가릴 수 있다. 이러한 간섭을 줄이기 위해 ScopeAD는 계층 $l \in \mathcal{L}$, 해상도 $r \in \mathcal{R}$, 배그 인덱스 $b \in \{1, \ldots, N_b\}$의 조합 $m = (l, r, b)$를 개별 관측 단위로 분리하고, 각 관측마다 독립적인 정상 메모리 뱅크 B_m을 구축한다. 쿼리 이미지 x^q의 공간 위치 p에서 추출된 ℓ_2 정규화 패치 토큰 $f_m(x^q, p)$는 오직 대응하는 뱅크 B_m 내에서만 독립적으로 최근접 이웃을 탐색하여 코사인 거리 점수를 계산한다:

$$d_m(x^q, p) = \min_{u \in B_m} \left[1 - f_m(x^q, p)^\top u\right]. \qquad (1)$$

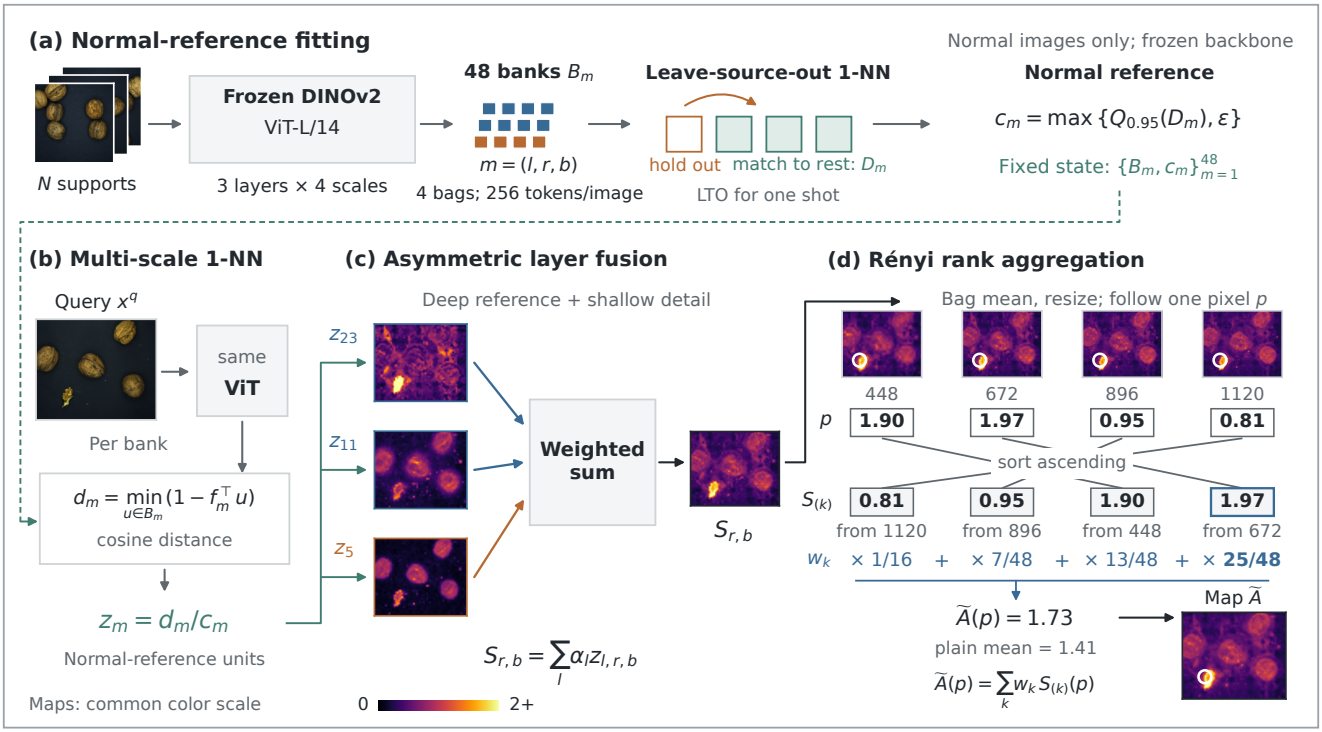


Figure 2. **Overview of ScopeAD.** (a) 정상 서포트에서 48개의 독립 메모리 뱅크를 구성하고, leave-source-out (1-shot에서는 leave-token-out) 교차 매칭으로 참조 척도 c_m을 추정한다. (b) 코사인 1-NN 거리 d_m을 해당 척도로 정규화하여 공통 단위 점수 $z_m = d_m/c_m$을 도출한다. (c) 전역 문맥을 담은 깊은 계층을 주축으로 얕은 계층의 단서를 보조 결합하는 비대칭 선형 가중합을 수행한다. (d) 배그 평균 및 원본 해상도 보간 후, 각 픽셀 위치에서 정렬된 해상도 점수에 Rényi 순서 통계량 가중치를 적용하여 최종 이상 맵을 집계한다. 가중치는 해상도 크기가 아닌 점수 크기 순위에 따라 비대칭적으로 부여된다. 예시는 결함 픽셀 p의 실제 점수다(평균 1.41).

이 분리 매칭 구조에서는 각 관측이 자신의 표현·공간 척도 안에서 가장 가까운 정상 토큰을 독립적으로 탐색한다. 그 결과 한 관측의 거리 상승이 다른 관측의 최근접 이웃 선택에 영향을 주지 않으며, 국소 질감 단서와 전역 문맥 단서가 별도의 거리 신호로 보존되어 후속 점수 통합 단계로 전달된다.

패치 서브샘플 배깅 (Patch Subsample Bagging). 입력 해상도가 증가함에 따라 서포트 패치 토큰의 수가 급격히 팽창하며, 단일 무작위 샘플링은 토큰 구성에 따른 추정 분산을 유발할 수 있다. 이를 완화하기 위해 각 해상도 r에서 서포트 이미지당 K개($K = 256$)의 패치 토큰을 비복원 균등 추출하여 단일 배그를 구성하며, 서로 다른 난수 시드로 N_b개의 배그를 생성한다. 이때 일관된 공간 대응을 유지하기 위해 동일 배그 내의 모든 계층은 완전히 일치하는 공간 좌표의 토큰을 공유한다. 각 배그에서 산출된 이상 점수는 이후 Eq. (6)에서 앙상블 평균된다.

3.3. 정상 참조 기반 비대칭 선형 결합

독립적으로 획득한 원시 거리 d_m을 통합하기 위해서는 (1) 관측 간 척도 불균형(scale discrepancy)과 (2) 계층별 의미론적 민감도 차이를 단계적으로 다루어야 한다. 계층 깊이와 입력 해상도에 따라 원시 거리의 척도가 상이하므로(Fig. 3), 보정 없이 결합하면 스케일이 큰 관측이 결합 점수와 순위를 지배한다. 또한 척도를 정규화하더라도 국소 질감에 민감한 얕은 계층은 조명이나 자세 변화 등 정상 외관 변동에 큰 거리를 유발하기 쉽다. 따라서 ScopeAD는 서포트 교차 매칭 기반의 척도 c_m으로 단위를 정렬한 뒤, 비대칭 계층 가중치 α_l을 적용하여 선형 결합을 수행한다.

서포트 교차 매칭 기반 척도 추정 (Cross-Validation Scale Estimation). 새 이미지와 비교할 때 정상 패치 사이에서도 발생하는 거리의 크기를 기준으로 삼기 위해, 서포트 집합 내부의 교차 매칭 거리 표본 D_m으로 관측별 척도를 추정한다. 다중 샷($N > 1$) 환경에서는 동일 이미지 내의 자기 유사 패치와 매칭되어 거리가 과소 추정되는 편향을 방지하고자, 서포트 이미지 i의 토큰 부분집합 $B_m^{(i)}$를 해당 이미지를 제외한 나머지 뱅크 토큰들과 매칭하는 Leave-Source-Out (LSO) 방식을 적용한다:

$$D_m^{\mathrm{LSO}} = \bigcup_{i=1}^{N} \left\{ \min_{u \in B_m \setminus B_m^{(i)}} \left[1 - v^\top u\right] : v \in B_m^{(i)} \right\}. \quad (2)$$

단일 샷($N = 1$) 환경에서는 이미지 간 교차 비교가 불가능하므로, 단일 이미지 내에서 자기 자신을 제외한 타

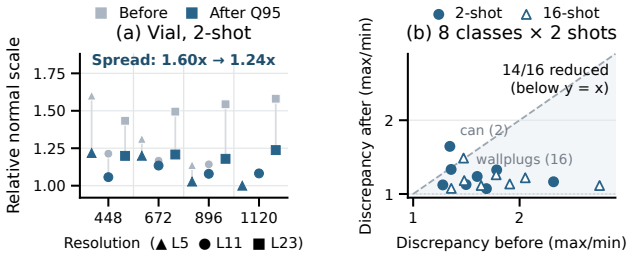


Figure 3. **정상 참조 보정(Q95)을 통한 관측 간 거리 척도 정렬.** (a) Vial 2-shot 정상 쿼리에서 12개 관측(4개 해상도 × 3개 계층)의 상대 정상 척도($\mathcal{Q}_{0.95}/\min \mathcal{Q}_{0.95}$). 관측 간 최대 차이가 보정 전(회색) 1.60배에서 보정 후(청색) 1.24배로 줄어든다. (b) 8개 클래스 × 2/16-shot의 16개 조건에서 관측 간 최대/최소 척도 비율. 14개 조건에서 보정 후 비율이 감소했다(대각선 $y = x$ 아래).

위치 토큰들과 매칭하는 Leave-Token-Out (LTO) 표본을 대리 통계량으로 사용한다:

$$D_m^{\mathrm{LTO}} = \left\{ \min_{j \neq i} \left(1 - v_i^\top v_j\right) : i = 1, \ldots, K \right\}. \tag{3}$$

동일 이미지 내의 토큰은 촬영 조건을 공유하므로 D_m^{LTO}가 이미지 간 정상 변동을 직접 반영하지는 못하지만, 관측 간 상대적 거리 스케일 차이를 보정하는 기준으로는 유효하게 작동한다.

각 관측의 정상 거리 분포는 비대칭성과 꼬리 두께가 상이하므로, 특정 확률분포 형태를 가정하는 모수적 통계량 대신 비모수적 순서 통계량인 상위 분위수 $\mathcal{Q}_q$로 기준 척도 c_m을 정의하고 정규화 점수 z_m을 산출한다:

$$c_m = \max\left\{\mathcal{Q}_q(D_m),\, \epsilon\right\}, \qquad z_m(x^q, p) = \frac{d_m(x^q, p)}{c_m}, \tag{4}$$

여기서 $q = 0.95$이며, $\epsilon = 10^{-4}$는 수치적 안정성을 위한 하한값이다. 기준 척도 c_m은 서포트에서 관측된 정상 거리의 상위 기준값이며, 미관측 정상 거리의 상한을 보장하지는 않는다. 따라서 z_m은 모든 관측에서 '정상 참조 거리의 상위 기준값 대비 비율'을 나타내며, $z_m = 1$ 자체가 결함 판정 임계값은 아니다. 보정 후 관측 간 정상 거리 척도의 차이는 줄어들며(Fig. 3), 이 정렬은 기저 거리가 큰 계층이나 해상도가 결합 점수와 순위를 지배하지 않도록 한다.

계층 간 비대칭 결합 (Asymmetric Layer Fusion). 척도를 정렬한 뒤에도 계층마다 포착하는 정보의 특성이 다르다. 국소 외관에 반응하는 얕은 계층은 조명이나 표면 질감이 바뀌면 정상 영역에서도 거리가 커지기 쉬운 반면, 전역 문맥을 담은 깊은 계층은 이러한 국소 변화에 덜 민감하다. 이에 따라 깊은 계층들($\mathcal{L}_{\mathrm{deep}} = \{11, 23\}$)의 정규화 점수 평균을 기저 점수로 삼고, 얕은 계층($l = 5$)은 작은 가중치 $\lambda = 0.125$로 결합한다:

$$S_{r,b}(x^q, p) = \frac{1}{2} \sum_{l \in \{11,23\}} z_{l,r,b}(x^q, p) + \lambda\, z_{5,r,b}(x^q, p). \tag{5}$$

이 비대칭 결합은 얕은 계층의 정상 외관 변동 반응을 억제하면서도, 깊은 계층만으로 놓칠 수 있는 국소 결함 단서를 보조적으로 반영한다. 실제로 얕은 계층을 배제하거나($\lambda = 0$) 세 계층에 동일한 비중을 두면($\lambda = 0.5$) 성능이 낮아진다(Tab. 8). 정규화 점수가 $z_m = d_m/c_m$이므로, Eq. (5)은 원시 거리 $d_{l,r,b}$에 계수 $\alpha_l/c_{l,r,b}$를 곱해 합산한 선형 결합과 같으며, 여기서 $(\alpha_5, \alpha_{11}, \alpha_{23}) = (0.125, 0.5, 0.5)$이다.

3.4. 다해상도 순서 통계량 집계

앞선 계층 결합을 거친 이상 점수는 여전히 $R = |\mathcal{R}|$개의 입력 해상도별 맵으로 분리되어 있다. 먼저 각 해상도 r에서 N_b개 배그의 점수를 평균하여 패치 서브샘플링에 따른 추정 분산을 완화한 뒤, 양선형 보간(bilinear interpolation)을 통해 모든 해상도 맵 S_r을 원본 이미지 크기 (H, W)로 공간 정렬한다:

$$S_r(x^q, p) = \frac{1}{N_b} \sum_{b=1}^{N_b} S_{r,b}(x^q, p). \tag{6}$$

Rényi 순서 통계량 집계 (Order-Statistics Aggregation). 결함은 물리적 크기와 수용 영역이 부합하는 해상도에서 가장 강하게 나타나므로, 단순 산술 평균($1/R$)은 그 반응을 다른 해상도의 낮은 점수와 평균화하여 희석한다. 반대로 최댓값(max)만 취하면 정상 영역에서 단일 해상도에 우연히 나타난 높은 점수가 그대로 최종 점수에 반영된다. 이를 절충하기 위해 ScopeAD는 각 위치 p의 해상도 점수를 오름차순으로 정렬한 $S_{(1)}(x^q, p) \leq \cdots \leq S_{(R)}(x^q, p)$에 대해 높은 순위에 더 큰 가중치를 부여하는 순위 가중 평균(ordered weighted averaging)을 사용한다. 별도의 가중치 조정 없이 비율을 정하기 위해 표준 지수 분포 순서 통계량의 기댓값(Rényi 표현, $a_k = \sum_{j=1}^{k} \frac{1}{R-j+1}$)에 비례하도록 설정하며($w_k = a_k / \sum_{j=1}^{R} a_j$), $R = 4$에서 $w = (\frac{1}{16}, \frac{7}{48}, \frac{13}{48}, \frac{25}{48}) \approx (0.063, 0.146, 0.271, 0.521)$이다:

$$\tilde{A}(x^q, p) = \sum_{k=1}^{R} w_k\, S_{(k)}(x^q, p). \tag{7}$$

이 가중치는 해상도의 크기가 아니라 각 위치의 점수 순위에 따라 정해진다. 최상위 점수에 52.1 %(25/48)를 두어 특정 해상도에 집중된 결함 반응의 희석을 줄이고, 차상위 두 순위에도 41.7 %(20/48)를 분배하여 단일 해상도의 단발성 점수가 그대로 최종 점수가 되지 않게 한다. 선형 순위 가중치도 유사한 결과를 보이므로(Appendix A.2), 핵심은 높은 순위에 큰 비중을 두는 형태에 있다. 이 집계는 관측 간 척도가 정렬되어 있을 때 의도대로 작동한다. 척도가 다르면 기저 거리가 큰 해상도가 결함 여부와 관

계없이 상위 순위를 차지하기 쉽기 때문이며(Fig. 10), 두 요소의 상호작용은 Sec. 4.4에서 분석한다.

이미지 수준 이상 점수. 최종 픽셀 단위 결함 국소화 맵은 $A(x^q) = \tilde{A}(x^q)$로 정의된다. 이미지 수준 이상 점수 $s(x^q)$는 $A(x^q)$ 내 상위 1% 픽셀 집합 $\Omega_{0.01}(|\Omega_{0.01}| = \max\{1, \lfloor 0.01HW \rfloor\})$의 평균값으로 산출한다:

$$s(x^q) = \frac{1}{|\Omega_{0.01}|} \sum_{p \in \Omega_{0.01}} A(x^q, p). \tag{8}$$

4. 실험

4.1. 평가 설정

데이터셋 및 평가 지표. 조명·시점 등 획득 조건 변화를 포괄하는 MVTec AD 2 [6](`test_public`, 8개 클래스)를 주 벤치마크로 사용하며, 기존 환경 검증을 위해 MVTec AD(15개) [1] 및 VisA(12개) [24]를 평가한다. 정상 서포트 수는 $N \in \{1, 2, 4, 8, 16\}$이며 고정 시드 0/1/2의 평균을 보고한다. 평가 지표는 저-FPR 구간(FPR ≤ 0.05)의 국소화 성능인 클래스 macro $\text{AUPRO}_{0.05}$및 $\text{pAUROC}_{0.05}$, 그리고 이미지 수준 판별 지표인 I-AUROC를 사용하며, 기존 벤치마크에는 픽셀 단위 P-AUROC도 함께 보고한다.
비교군 및 구현 세부사항. 동결 DINOv2 ViT-L/14 백본에서 계층 $\{5, 11, 23\}$과 4개 해상도 $\{448, 672, 896, 1120\}$을 추출하고, 토큰 상한은 서포트당 256으로 설정한다. 정상 참조 분위수 $q = 0.95$와 얕은 계층 가중치 $\lambda = 0.125$는 모든 실험에 동일하게 고정 적용한다. 비교 방법은 PatchCore [15], SuperAD [19], AnomalyDINO [3], FastRecon [4], RAD [20], SubspaceAD [9], RegAD [7]이며, 동일한 서포트 분할과 평가 프로토콜 아래 단일 1120 해상도(RegAD는 STN 제약으로 224)에서 공정하게 평가한다.

4.2. Few-shot 주 비교

Tab. 1는 MVTec AD 2 `test_public`에서의 few-shot 비교 결과다. ScopeAD는 1–16-shot 전 구간에서 $\text{AUPRO}_{0.05}$, $\text{pAUROC}_{0.05}$, I-AUROC모두 최고 평균을 기록했다. 1-shot $\text{AUPRO}_{0.05}$는 52.18 %로 동일 백본의 PatchCore(38.45 %)와 SuperAD(46.31 %)를 각각 13.73 pp, 5.87 pp 상회하며, 2–16-shot에서도 차순위 대비 4.85–6.98 pp의 격차를 유지했다. 이미지 단위 I-AUROC 또한 1-shot 73.59 %를 포함해 모든 shot에서 가장 높아, 픽셀 국소화와 이미지 판별 성능이 함께 향상됨을 보여준다. 정성 비교(Fig. 4)는 해상도 결합에 따른 결함 지도의 변화를 보여준다. 색상 대비만으로 오경보율을 비교할 수는 없으므로, 정상·결함의 점수 중첩과 저-FPR 검출 변화는 Sec. 4.4에서 별도로 분석한다.
공식 `test_private` 블라인드 평가. 서버 비공개 정답 기반의 MVTec AD 2 공식 리더보드 평가(Tab. 2)에서, ScopeAD는 16-shot `test_private`(66.53 %)과 조명이 혼합된 `test_private_mixed`(64.40 %) 모두에서 few-shot 최고 $\text{AUPRO}_{0.05}$를 달성했다. 이는 차순위인 SuperAD 대비 각각 3.71 pp, 4.32 pp, PatchCore 대비

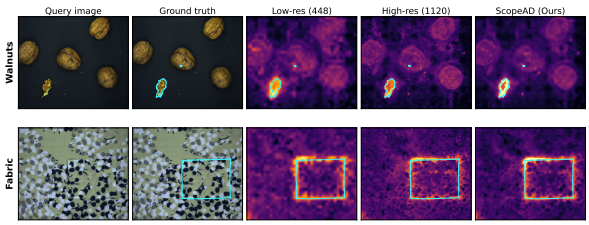


Figure 4. **MVTec AD 2 결함 국소화 정성 비교.** 열은 쿼리, 정답, 단일 해상도(448, 1120), ScopeAD 순이다. 위: 과노출 Walnuts, 아래: Fabric. 하늘색 윤곽은 정답이다.

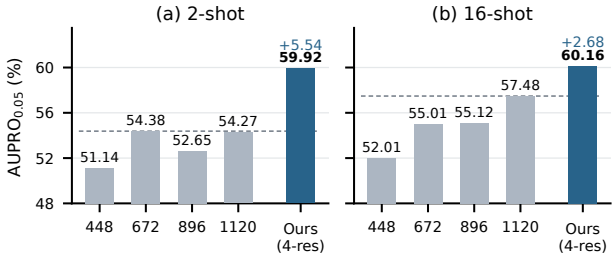


Figure 5. **단일·다해상도 $\text{AUPRO}_{0.05}$ 비교 (MVTec AD 2, seed 0).** 회색 막대는 단일 해상도, 점선은 그중 최고 성능, 파란 숫자는 4해상도 결합의 향상 폭(pp)이다.

8.20 pp, 7.37 pp 높은 결과다. 전수 정상 데이터를 학습한 참고 모델(RoBiS, SuperADD 등)과 비교해도 대등하거나 우수한 국소화 성능을 보여, 동결 백본 기반 관측 확장의 실효성을 뒷받침한다.

획득 조건 변화가 제한적인 표준 벤치마크인 MVTec AD 및 VisA(Tab. 4)에서도 ScopeAD는 대다수 shot에서 최고 수준의 I-AUROC와 96 % 이상의 안정적인 P-AUROC를 유지하여, 조건 변화 대응 설계가 일반적인 산업 검사 환경에서도 유효함을 확인했다.

4.3. 구성 요소 분석

Tab. 3는 단일 해상도 기준선(A)에서 최종 모델(F)까지 구성 요소를 차례로 더한 결과다. 가장 큰 향상은 다해상도 관측(B, +5.11/ + 4.12 pp)에서 나오며, 관측별 개별 뱅크(C)는 2-shot에서 2.61 pp를 더하지만 16-shot에서는 변화가 거의 없다(+0.03 pp). 이후 얕은 계층 결합(D), 정상 척도 보정(E), Rényi 집계(F)가 각각 +0.83/+1.24, +0.27/+0.40, +0.59/+0.59 pp를 더해 F는 2-shot 59.92 %, 16-shot 60.16 %다. 누적 비교는 추가 순서에 의존하므로, 보정(E)과 집계(F)의 상호작용은 Sec. 4.4에서 3-seed로 따로 분석한다.
다해상도 관측과 토큰 수. Tab. 5에서 단일 1120 해상도의 토큰 상한을 1024로 늘려 총 토큰 상한을 맞추면 $\text{AUPRO}_{0.05}$는 57.13 %로, 같은 총량을 4개 해상도(각 256)에 나눈 ScopeAD(60.16 %)보다 3.03 pp 낮다. 따라서 다해상도의 이득은 토큰 수 증가만으로 설명되지 않는다. Fig. 5의 단일 해상도 구성은 최종 방법의 보정과 계층 결합을 유지하므로, Tab. 3의 기준선 A와 다르다. 이

Table 1. MVTec AD 2 `test_public` few-shot 비교 (8개 클래스 macro, 3-seed 평균 ± 표본 표준편차, %). †: RegAD는 STN 제약으로 해상도 224에서 평가. 굵은 값과 밑줄은 최고·차순위 평균이다.

Shot	Metric	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD (224)†	Ours (ScopeAD)
1	$AUPRO_{0.05}$	38.45 ± 1.85	35.95 ± 2.24	14.92 ± 2.27	26.42 ± 1.71	44.87 ± 1.87	46.31 ± 3.73	12.73 ± 0.38	**52.18 ± 4.07**
	$pAUROC_{0.05}$	64.19 ± 0.68	70.67 ± 0.69	55.70 ± 0.67	59.57 ± 0.35	70.56 ± 0.56	70.13 ± 1.14	57.76 ± 0.30	**73.01 ± 1.60**
	I-AUROC	65.51 ± 1.91	66.83 ± 1.08	58.10 ± 4.46	58.68 ± 3.03	67.02 ± 2.27	67.68 ± 0.32	57.73 ± 1.82	**73.59 ± 0.36**
2	$AUPRO_{0.05}$	42.25 ± 2.08	38.20 ± 1.90	16.73 ± 2.39	31.61 ± 1.47	45.90 ± 0.75	49.80 ± 2.33	15.05 ± 0.30	**56.78 ± 2.77**
	$pAUROC_{0.05}$	65.43 ± 0.38	72.26 ± 0.56	57.14 ± 1.03	61.78 ± 0.15	71.53 ± 0.18	71.52 ± 0.58	58.76 ± 0.49	**75.83 ± 0.51**
	I-AUROC	67.53 ± 1.55	68.95 ± 3.84	57.63 ± 6.82	59.37 ± 2.54	70.42 ± 1.79	70.19 ± 2.16	60.56 ± 3.94	**75.04 ± 1.48**
4	$AUPRO_{0.05}$	46.94 ± 1.00	40.32 ± 0.75	21.88 ± 1.73	36.51 ± 1.02	47.14 ± 0.76	54.25 ± 0.86	17.40 ± 1.07	**59.49 ± 0.12**
	$pAUROC_{0.05}$	66.90 ± 0.22	73.09 ± 0.91	59.26 ± 0.80	63.84 ± 0.41	72.45 ± 0.20	73.59 ± 0.13	60.36 ± 0.48	**76.96 ± 0.55**
	I-AUROC	68.62 ± 2.28	70.90 ± 0.97	59.73 ± 4.40	62.31 ± 4.84	71.02 ± 0.56	70.97 ± 2.08	63.79 ± 2.34	**76.14 ± 0.50**
8	$AUPRO_{0.05}$	49.98 ± 1.90	41.64 ± 1.01	27.32 ± 0.14	40.79 ± 0.79	47.28 ± 0.40	55.44 ± 1.21	19.25 ± 0.64	**60.40 ± 0.89**
	$pAUROC_{0.05}$	68.22 ± 0.53	73.71 ± 0.20	61.74 ± 0.50	65.62 ± 0.69	72.56 ± 0.21	74.31 ± 0.38	62.02 ± 0.32	**77.57 ± 0.17**
	I-AUROC	69.20 ± 0.75	71.29 ± 1.69	63.46 ± 4.29	65.84 ± 0.43	70.46 ± 1.18	70.75 ± 0.58	64.34 ± 1.05	**76.39 ± 0.67**
16	$AUPRO_{0.05}$	52.73 ± 1.36	42.30 ± 1.25	35.23 ± 0.57	42.58 ± 1.10	47.63 ± 0.14	55.89 ± 1.07	20.28 ± 0.80	**60.74 ± 0.72**
	$pAUROC_{0.05}$	69.36 ± 0.51	73.97 ± 0.23	65.63 ± 0.43	66.62 ± 0.89	72.78 ± 0.07	74.60 ± 0.52	63.46 ± 0.76	**77.77 ± 0.34**
	I-AUROC	69.00 ± 0.53	72.07 ± 1.27	67.45 ± 1.16	67.60 ± 1.35	70.46 ± 1.07	69.79 ± 0.52	65.64 ± 1.34	**76.40 ± 0.95**

Table 2. MVTec AD 2 공식 비공개 평가 (%). 각 셀은 `test_private` / `test_private_mix`. ∗: 전체 정상 데이터 사용. 굵은 값은 few-shot 내 최고값이다.

방법	$AUPRO_{0.05}$	ClassF1	SegF1
Few-shot (16-shot)			
AnomalyDINO	50.35 / 44.86	77.87 / 77.91	26.65 / 18.62
PatchCore	58.33 / 57.03	**78.21** / 78.02	29.96 / 27.75
SuperAD	62.82 / 60.08	78.14 / 78.19	**39.43 / 33.86**
Ours (ScopeAD)	**66.53 / 64.40**	78.03 / **78.86**	36.33 / 32.47
Full-data Reference∗			
SuperAD∗	60.51 / 58.37	70.20 / 74.40	47.18 / 42.51
SuperADD∗	61.36 / 59.07	68.03 / 73.25	57.42 / 54.35
RoBiS∗	67.25 / 59.65	79.62 / 79.86	51.00 / 46.52

Table 3. 구성 요소의 누적 ablation (MVTec AD 2 `test_public`, seed 0, $AUPRO_{0.05}$, %). A: 1120 해상도, 계층 [11, 23] 연결 뱅크, 보정 없음. B–F: 이전 행에 구성 요소를 순차 추가.

구성	2-shot	16-shot
A. Single-resolution	50.51	53.78
B. + Multi-resolution	55.62	57.90
C. + Separate banks	58.23	57.93
D. + Shallow fusion	59.06	59.17
E. + Scale calibration	59.33	59.57
F. + Rényi aggregation (Ours)	**59.92**	**60.16**

구성과 비교해도 4해상도 결합은 가장 높은 단일 해상도보다 2-shot에서 5.54 pp, 16-shot에서 2.68 pp 높다. 해상도를 1120 하나만 쓰더라도 ScopeAD는 같은 백본과 해상도를 쓰는 SuperAD보다 seed 0에서 2-shot 1.97 pp(52.30 → 54.27 %), 16-shot 1.75 pp(55.73 → 57.48 %) 높다. 이 결과는 서로 다른 해상도의 단서를 함께 활용하는 설계의 유효성을 지지한다. 다만 $AUPRO_{0.05}$향상만으로는 정상 고점수의 영향이 줄었는지, 결함 반응이 강화되었는지를 구분할 수 없다.

특징 연결 대 관측별 독립 매칭. 세 계층 특징을 하나의 벡터로 연결해 최근접 이웃을 찾는 구성(Layer concat)은 ScopeAD의 Rényi 집계 전 구성(E)보다 MVTec AD 2 $AUPRO_{0.05}$가 2-shot에서 7.21 pp(52.12 대 59.33 %), 16-shot에서 2.09 pp(57.48 대 59.57 %) 낮았다. MVTec AD (98.19 대 98.74 %)와 VisA(94.09 대 95.99 %)의 16-shot I-AUROC도 낮았다. 다만 두 구성은 정규화와 계층 가중치도 함께 다르므로, 이 차이를 뱅크 분리만의 효과로 볼 수는 없다.

4.4. High-Score Ambiguity 완화와 점수 통합 분석

낮은 오경보 수준에서의 결함 검출 회복. Tab. 6은 정상 점수의 상위 꼬리와 겹쳐 검출되지 않던 결함이 ScopeAD에서 더 잘 구분되는지 평가한다. 동일한 서포트와 쿼리의 캐시를 사용하고, 전체 획득 조건을 합친 클래스·구성별 테스트 정상 픽셀 표본의 상위 1% 및 5%를 기준으로 임계값을 정한 뒤 전체 결함 픽셀의 검출률을 측정했다(seed 0, `test_public` 사후 진단). 단일 심층 관측(Raw L23 1120) 대비 ScopeAD의 1% 기준 검출률은 2-shot에서 36.24→45.95 %(반올림 전 차이 +9.72 pp), 16-shot에서 39.78→50.04 %로 높아졌다. 단일 해상도의 미보정 계층 결합에 Q95 보정을 추가한 구성에서는 검출률이 높아지지 않았으므로, 이 결과는 개별 보정이나 Rényi만의 효과가 아닌 전체 방법의 근거다.

Regular와 shift 조건의 직접 진단. Fig. 6는 2-shot 결과를 regular와 기존 비정규 획득 조건(shift)으로 나눈 것이다. Shift는 과노출·저노출 및 데이터셋의 `shift_1`–`shift_4` 조건을 포함하며, 인위적인 변환은 추가하지 않았다. 위에서 구한 클래스·방법별 1% 기준 임계값을 두 조건군에 고정 적용했다. Regular에서 검출률은 32.94→44.22 %(+11.27 pp), 실제 FPR은 0.651→0.703 %다. Shift에서는 실제 FPR이 1.058→1.050 %로 거의 같으면서 검출률이 36.88→46.30 %(+9.41 pp)로 높아진다. 즉, ScopeAD는 획득 조건이 달라진 쿼리에서도 정상 상위 꼬리와 겹쳐 누락되던 결함을 더 많이 검출한다. 이는 저-FPR 구간의 HSA 완화를 지지하며, 정상 점수의 절대적 감소나 분포 중첩의 완전한 해소를 뜻하지 않는다. 두 조건군 모두 8개 클래스 중 7개에서 검출률이 높아졌으며, `walnuts`는 감소했다(Appendix A.3). 이 진단은 조건별 FPR을 정확히

Table 4. MVTec AD 및 VisA few-shot 비교 (seed 0, %). 각 셀은 I-AUROC / P-AUROC. 굵은 값과 밑줄은 최고·차순위이며, —는 미보고 값이다.

Dataset	Shot	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD	Ours (ScopeAD)
MVTec AD	1	88.12 / 96.22	92.52 / 94.49	88.84 / 96.60	80.83 / 93.25	89.25 / 96.92	**92.54 / 96.93**	— / —	92.32 / 96.62
	2	92.67 / 96.97	95.17 / 95.56	93.51 / 97.29	84.15 / 94.27	90.95 / 97.24	95.43 / **97.36**	— / —	**95.49** / 97.28
	4	95.06 / 97.37	95.92 / 96.07	95.61 / **97.87**	85.38 / 94.67	91.35 / 97.16	96.65 / 97.70	— / —	**96.82** / 97.59
	8	96.13 / 97.80	96.67 / 96.45	96.76 / **98.16**	87.85 / 95.29	92.94 / 97.17	**97.39** / 97.95	— / —	97.35 / 97.86
	16	98.15 / 97.99	97.48 / 96.80	98.52 / **98.38**	90.29 / 95.61	92.51 / 97.19	**98.94** / 98.09	— / —	98.66 / 97.99
VisA	1	86.09 / 95.56	87.06 / 95.62	84.65 / 96.75	72.67 / 95.37	85.44 / **98.09**	**90.29** / 97.06	71.12 / 93.41	88.52 / 96.53
	2	87.87 / 96.29	90.64 / 96.63	87.67 / 97.43	77.24 / 96.37	— / —	**92.20 / 97.68**	71.59 / 94.59	91.59 / 97.14
	4	89.52 / 96.92	91.37 / 97.57	89.21 / 97.91	— / —	— / —	92.94 / **98.02**	76.42 / 96.14	**94.28** / 97.69
	8	92.36 / 97.18	93.11 / 97.99	91.53 / 98.11	— / —	— / —	94.50 / **98.29**	80.19 / 96.64	**94.97** / 98.12
	16	93.64 / 97.30	93.53 / 98.30	93.38 / 98.32	— / —	— / —	95.19 / **98.43**	81.22 / 96.98	**95.86** / 98.37

Table 5. 토큰 상한에 따른 성능과 비용 (MVTec AD 2, 16-shot, seed 0, FP16; 성능은 %). cap은 해상도별 서포트당 토큰 상한이다. 시간은 클래스 평균, Peak는 쿼리 최대 GPU 메모리다.

구성	cap	$\text{AUPRO}_{0.05}$	$\text{pAUROC}_{0.05}$	Fit (s)	Query (ms/img)	Peak (GiB)
단일 1120	256	57.48	74.86	11.09	861	1.91
단일 1120	1024	57.13	75.49	12.48	1053	3.04
4해상도 (Ours)	256	**60.16**	77.52	17.21	1365	3.12
4해상도	1024	60.33	77.94	22.42	1789	6.71

Table 6. MVTec AD 2 저-FPR 결함 검출률 (8개 클래스 macro, seed 0, %). 테스트 정상 픽셀 표본으로 임계값을 정한 사후 진단이며, 열의 FPR은 목표값이다.

	2-shot		16-shot	
단계별 구성	FPR=0.01	FPR=0.05	FPR=0.01	FPR=0.05
Raw L23 1120 (단일 관측)	36.24	56.88	39.78	60.65
Raw Fusion 1120 (미보정 결합)	39.65	60.71	43.01	62.81
Q95 Fusion 1120 (정규 계층)	38.51	60.68	42.71	62.53
ScopeAD (전체 관측 확장)	**45.95**	**66.14**	**50.04**	**66.95**

일치시킨 평가나 미사용 조건의 일반화 검증은 아니며, 픽셀 검출률 향상이 영역별 검출률을 적분하는 $\text{AUPRO}_{0.05}$의 향상을 수학적으로 보장하지는 않는다.

보정과 집계의 상호작용. Tab. 7는 척도 보정과 집계 방식 간의 상호작용을 보여준다. Rényi 집계의 성능 이득은 Q95 보정과 결합될 때 두드러지게 나타난다($\text{AUPRO}_{0.05}$ 기준 2/16-shot에서 각각 $+0.75/+0.68$ pp; 반올림 전 값으로 계산). 보정 없이 단순 결합할 경우 특정 관측의 큰 기저 거리가 순위를 왜곡하여 Rényi의 이점이 제한되지만, 정상 참조 척도로 단위를 정렬한 후에는 상위 순위 반응이 결함 신호 보존에 효과적으로 기여한다. 단, 클래스별 반응 편차로 인해 평균 상호작용의 신뢰구간은 0을 포함하며(Appendix A.4), $\text{pAUROC}_{0.05}$에서는 동일한 상호작용이 나타나지 않았다.

추가 응답의 변화. Rényi 결합 점수는 평균 응답 $\mu(p)$와 해상도 간 순위 간격에 따른 추가 응답 $E(p) \geq 0$의 합으로 분해된다:

$$\tilde{A}(p) = \mu(p) + E(p), \quad E(p) = \frac{9g_1(p) + 14g_2(p) + 13g_3(p)}{48}. \tag{9}$$

추가 응답 $E(p)$는 해상도 간 응답 편차가 클수록 커지므로, 보정이 없으면 기저 거리가 큰 해상도로 인해 정상

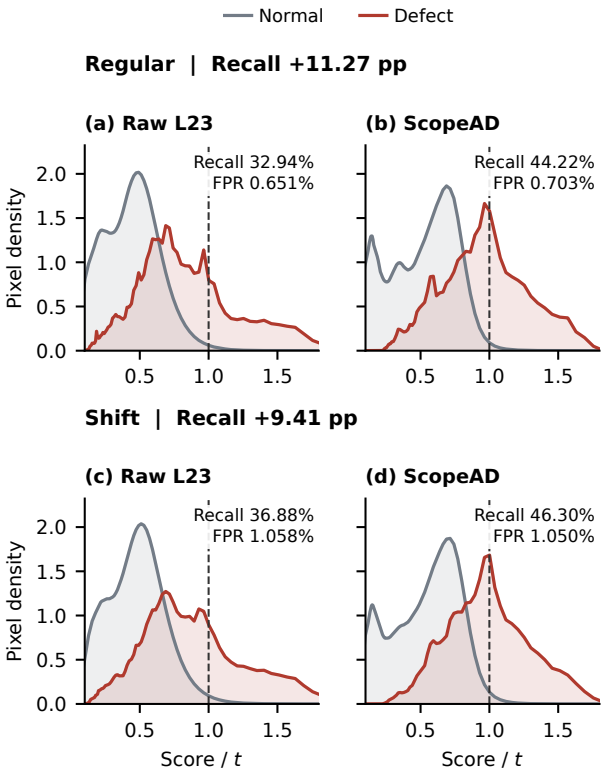


Figure 6. **Regular와 shift 조건의 HSA 완화.** MVTec AD 2 `test_public`, 2-shot, seed 0. 전체 조건의 테스트 정상 표본의 99백분위수 t로 점수를 나눈 뒤 클래스별 밀도를 macro 평균했다. t는 클래스·방법별로 추정하며, 점선($A/t = 1$)과 실제 FPR·Recall을 표시했다.

영역에서도 불필요하게 커질 수 있다. Q95 보정은 정상 영역에서 해상도 간 편차에 기인한 $E(p)$의 상대적 팽창 (E/μ)을 억제하여, Rényi 집계가 정상 잡음의 증폭 없이 유효한 결함 반응에 집중하도록 보조한다(Appendix A.4).

4.5. 계산 비용과 파라미터 민감도

계산 비용. Tab. 5에서 4해상도 ScopeAD(cap 256)는 이미지당 1.37초, 최대 3.12 GiB를 사용한다. 토큰 상한을 1024로 늘리면 $\text{AUPRO}_{0.05}$는 0.17 pp 높아지지만, 쿼리 시간은 1.31배, 최대 메모리는 2.15배 늘어난다. 따라서

Table 7. 집계 방식과 척도 보정의 상호작용 (MVTec AD 2, 3-seed 평균 ± 표본 표준편차, %). 굵은 값은 지표별 최고 평균이다.

집계 방식	척도 보정	2-shot	16-shot
$\mathrm{AUPRO}_{0.05}$			
Mean	없음	56.12 ± 2.76	59.73 ± 0.86
Mean	Q95	56.03 ± 3.00	60.06 ± 0.88
Rényi	없음	56.32 ± 2.49	59.72 ± 0.77
Rényi (Ours)	Q95	$\mathbf{56.78 \pm 2.77}$	$\mathbf{60.74 \pm 0.72}$
$\mathrm{pAUROC}_{0.05}$			
Mean	없음	76.10 ± 0.49	77.76 ± 0.32
Mean	Q95	75.86 ± 0.59	77.60 ± 0.37
Rényi	없음	$\mathbf{76.18 \pm 0.40}$	$\mathbf{77.96 \pm 0.25}$
Rényi (Ours)	Q95	75.83 ± 0.51	77.77 ± 0.34

cap 256을 기본값으로 사용한다.

파라미터 민감도. $q = 0.90, 0.95, 0.99$에서 $\mathrm{AUPRO}_{0.05}$의 범위는 2-shot 59.81–59.92 %, 16-shot 60.15–60.19 %로 작다(seed 0). 얕은 계층 가중치 λ를 0.125에서 0.25로 바꾸면 2-shot은 0.60 pp 낮아지고 16-shot은 0.20 pp 높아지며, 0.5에서는 두 shot 모두 낮아진다(Tab. 8).

5. 논의 및 한계

관측 확장의 효과와 비용. 다해상도 결합은 총 토큰 상한을 맞춘 단일 해상도 대조군보다 높은 $\mathrm{AUPRO}_{0.05}$를 보였고, 관측별 독립 매칭도 특징 연결보다 높은 성능을 보였다. 반면 여러 해상도를 추론하므로 단일 해상도보다 쿼리 시간과 메모리가 늘어난다.

관측 확장과 High-Score Ambiguity. 관측 확장이 모호성 완화에 기여하려면, 단일 관측에서 점수가 겹치는 정상 영역과 결함 영역이 추가 관측에서 구분 가능한 반응을 보여야 하며, 그 차이가 최종 점수에 반영되어야 한다. Fig. 6는 전체 방법이 regular와 shift 조건 모두에서 낮은 실제 FPR과 함께 더 높은 결함 검출률을 보임을 확인한다. 이는 단일 관측 대비 HSA 완화의 직접 근거이지만, 관측 확장과 점수 통합이 함께 바뀐 비교이므로 각 요소의 기여를 분리하지는 못한다. 모든 정상·결함 쌍의 분리가 개선되는 것도 아니며, `walnuts`에서는 두 조건군 모두 검출률이 낮아졌다. 한 시드의 `test_public` 사후 진단이므로 미관측 획득 조건으로의 일반화는 추가 검증이 필요하다.

보정과 집계의 효과 범위. Q95 보정과 Rényi 집계의 결합 이득은 $\mathrm{AUPRO}_{0.05}$에서 나타났으며 $\mathrm{pAUROC}_{0.05}$로 이어지지 않았다. 클래스별로 효과의 방향이 다르고 fabric의 기여가 크므로, 이 이득을 모든 결함 유형에 대한 일관된 개선으로 볼 수는 없다. 또한 정상 영역의 추가 응답 감소는 점수 분포의 변화이며, 고정 임계값에서의 오경보율 감소를 직접 보여주지는 않는다.

서포트 편차와 배포 임계값. 관측 확장은 주어진 정상 표본의 비교 단서를 늘리지만 미관측 정상 외관을 직접 보지는 못하므로, 서포트 선택에 따른 성능 변동이 남는다(1-shot 표준편차 4.07 pp). 또한 $\mathrm{AUPRO}_{0.05}$와 $\mathrm{pAUROC}_{0.05}$는 FPR 구간에 대한 적분 지표이므로, 실제 라인에 적용하려면 목표 오경보율에 맞춘 임계값 교정이 별도로 필요하다.

6. 결론

본 논문은 동결 백본의 계층과 해상도를 독립 매칭 단위로 확장하고, 정상 참조 분위수 정규화, 비대칭 계층 결합, Rényi 순위 집계로 점수를 통합하는 **ScopeAD**를 제안했다. MVTec AD 2의 few-shot 평가에서 ScopeAD는 모든 shot에서 비교 방법보다 높은 저-FPR 국소화 성능을 보였으며(16-shot $\mathrm{AUPRO}_{0.05}$ 60.74 %), 획득 조건이 바뀐 이미지와 공식 `test_private` 리더보드에서도 가장 높은 성능을 기록했다. MVTec AD와 VisA에서도 경쟁력 있는 성능을 유지했다.

References

[1] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD – a comprehensive real-world dataset for unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019. 6

[2] Joao P. C. Bertoldo, Dick Ameln, Ashwin Vaidya, and Samet Akcay. AUPIMO: Redefining visual anomaly detection benchmarks with high speed and low tolerance. *arXiv preprint arXiv:2401.01984*, 2024. 1, 3

[3] Simon Damm, Mike Laszkiewicz, Johannes Lederer, and Asja Fischer. Anomalydino: Boosting patch-based few-shot anomaly detection with dinov2. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1319–1329, 2025. 1, 2, 6

[4] Zheng Fang, Xiaoyang Wang, Haocheng Li, Jiejie Liu, Qiugui Hu, and Jimin Xiao. Fastrecon: Few-shot industrial anomaly detection via fast feature reconstruction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 17481–17490, 2023. 2, 6

[5] Stephanie Fu, Mark Hamilton, Laura E. Brandt, Axel Feldmann, Zhoutong Zhang, and William T. Freeman. FeatUp: A model-agnostic framework for features at any resolution. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[6] Lars Heckler-Kram, Jan-Hendrik Neudeck, Ulla Scheler, Rebecca König, and Carsten Steger. The MVTec AD 2 dataset: Advanced scenarios for unsupervised anomaly detection. *International Journal of Computer Vision*, 134(4), 2026. 1, 3, 6

[7] Chaoqin Huang, Haoyan Guan, Aofan Jiang, Ya Zhang, Michael Spratling, and Yan-Feng Wang. Registration based few-shot anomaly detection. *arXiv preprint arXiv:2207.07361*, 2022. 2, 6

[8] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19606–19616, 2023. 2

[9] Camile Lendering, Erkut Akdag, and Egor Bondarau. Subspacead: Training-free few-shot anomaly detection via subspace modeling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 28557–28566, 2026. 2, 6

[10] Xurui Li, Ziming Huang, Feng Xue, and Yu Zhou. MuSc: Zero-shot industrial anomaly classification and segmentation with mutual scoring of the unlabeled images. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[11] Xiaofan Li, Zhizhong Zhang, Xin Tan, Chengwei Chen, Yanyun Qu, Yuan Xie, and Lizhuang Ma. PromptAD: Learning prompts with only normal samples for few-shot anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16848–16858, 2024. 2

[12] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023. 1

[13] Maithra Raghu, Thomas Unterthiner, Simon Kornblith, Chiyuan Zhang, and Alexey Dosovitskiy. Do vision transformers see like convolutional neural networks? In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 12116–12128, 2021. 2

[14] Rene Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 12179–12188, 2021. 2, 3

[15] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14298–14308, 2022. 1, 2, 3, 6

[16] Baifeng Shi, Ziyang Wu, Maolin Mao, Xin Wang, and Trevor Darrell. When do we not need larger vision models? In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2024. 2, 3

[17] Weilin Tu. Few-shot anomaly detection on MVTec AD 2: A systematic study and a strong frozen baseline. *IEEE Access*, 14:152500–152511, 2026. 2

[18] Jin Wang, Ying-Hang Li, Bo-Wen Jiang, and Shi-Chao Li. FreePatch: A training-free multiscale patch matching method for few-shot industrial anomaly detection. In *International Conference on Computer Vision, Graphics, and Artificial Intelligence (CVGAI 2026)*, 2026. 3

[19] Huaiyuan Zhang, Hang Chen, Yu Cheng, Shunyi Wu, Linghao Sun, Linao Han, Zeyu Shi, and Lei Qi. Superad: A training-free anomaly classification and segmentation method for cvpr 2025 vand 3.0 workshop challenge track 1: Adapt & detect. *arXiv preprint arXiv:2505.19750*, 2025. 1, 2, 3, 6

[20] Xingwu Zhang, Guanxuan Li, Paul Henderson, Gerardo Aragon-Camarasa, and Zijun Long. Is task-specific training necessary for anomaly detection? *arXiv preprint arXiv:2601.22763*, 2026. Version 3. 6

[21] Zilong Zhang, Zhibin Zhao, Xingwu Zhang, Chuang Sun, and Xuefeng Chen. Industrial anomaly detection with domain shift: A real-world dataset and masked multi-scale reconstruction. *Computers in Industry*, 151:103990, 2023. 1, 3

[22] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024. 2

[23] Jiawen Zhu and Guansong Pang. Toward generalist anomaly detection via in-context residual learning with few-shot sample prompts. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 17826–17836, 2024. 2

[24] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. *arXiv preprint arXiv:2207.14315*, 2022. 6

A. 결합 규칙과 파라미터의 추가 분석

본문의 분석을 보완하기 위해 계층 가중치와 해상도 집계 대안, 보정과 집계의 메커니즘 분석을 제시한다. 계층 가중치와 집계 대안 표는 MVTec AD 2 `test_public`, seed 0의 8개 클래스 macro이며, 메커니즘 분석은 별도로 명시한 3-seed 결과를 사용한다.

A.1. 계층 가중치

최종 구성(Q95, Rényi)에서 $z_d = (z_{11} + z_{23})/2$에 더하는 얕은 계층 가중치 λ를 바꾸어 비교한다(Tab. 8). $\lambda = 0.5$에서는 세 계층의 계수가 같다. $\lambda = 0$은 얕은 계층의 점수 기여만 제외한다.

Table 8. 얕은 계층 가중치 λ의 민감도 (MVTec AD 2, seed 0, Q95, Rényi, $\text{AUPRO}_{0.05}$, %). 굵은 값은 최고값이다.

λ	2-shot	16-shot
0	59.05	59.11
0.0625	59.76	59.73
0.125 (사용값)	**59.92**	60.16
0.25	59.32	**60.36**
0.5	56.23	59.47

얕은 계층을 제외하거나($\lambda = 0$) 가중치를 0.5로 높이면 두 shot 모두 성능이 낮아진다. 16-shot에서는 0.25가 0.125보다 0.20 pp 높아, 최적값은 shot에 따라 조금 다르다.

A.2. 해상도 집계 대안

최종 구성의 특징, 뱅크, Q95 보정, 계층 가중치를 고정하고 해상도 집계 규칙만 바꾸었다(Tab. 9). 선형 순위 가중치는 $(0.1, 0.2, 0.3, 0.4)$다. 두 순위 가중 집계는 Mean보다 $\text{AUPRO}_{0.05}$가 높고, Rényi와 선형 가중의 차이는 0.1 pp 이내다. 따라서 이 결과는 높은 순위에 큰 가중치를 주는 집계의 효과를 보여주며, 특정 Rényi 가중치가 다른 순위 가중치보다 뚜렷하게 낫다는 근거는 아니다.

Table 9. 해상도 집계 대안 (MVTec AD 2, seed 0, Q95, %). 각 셀은 $\text{AUPRO}_{0.05}$ / $\text{pAUROC}_{0.05}$이며, 굵은 값은 열별 최고값이다.

집계 방식	2-shot	16-shot
Mean	59.33 / **76.48**	59.57 / 77.46
Order (linear)	59.91 / 76.45	60.08 / **77.55**
Order (Rényi, Ours)	**59.92** / 76.36	**60.16** / 77.52

A.3. HSA 진단의 프로토콜과 반례

Fig. 6는 MVTec AD 2 `test_public`의 2-shot, seed 0 캐시를 재사용한 사후 분석이다. 동일한 1,084개 쿼리의 원본 크기 점수에서 정상 약 44.25억 픽셀과 결함 약 2,911만 픽셀을 집계했다. 기준선은 1120 해상도 L23의 원시 거리를 배그 평균한 지도이며, ScopeAD는 같은 캐시의 Q95 보정, 계층 가중합, 배그 평균, 해상도별 보간 및 Rényi 집계를 적용한 지도다. 추가 적합이나 파라미터 변경 없이 재생했으며, 정답 마스크는 점수 산출 이후에만 사용했다.

Table 10. HSA 진단의 실제 FPR과 결함 픽셀 Recall (2-shot, seed 0, %). 전체 조건의 테스트 정상 표본에서 추정한 임계값을 고정 적용했다.

	실제 FPR		Recall	
클래스	Raw L23	ScopeAD	Raw L23	ScopeAD
can	0.996	0.998	6.54	15.87
fabric	1.002	1.006	29.68	35.41
fruit_jelly	0.995	1.044	23.16	33.40
rice	1.004	0.996	79.53	85.74
sheet_metal	0.995	1.000	46.54	52.78
vial	0.941	0.901	19.77	27.44
wallplugs	1.001	0.995	8.55	44.21
walnuts	0.994	0.998	76.12	72.76
Macro	0.991	0.992	36.24	45.95

임계값 t는 Tab. 6과 동일하게 각 이미지의 정상 픽셀을 100개당 1개씩 추출한 뒤 클래스·방법별로 합친 분포의 99백분위수다. 정상 이미지와 결함 이미지의 정상 배경을 모두 포함하고, regular 및 비정규 획득 조건을 함께 사용했다. 이 임계값을 이미지나 획득 조건마다 다시 맞추지 않고, 전체 원본 픽셀에서 FPR과 결함 검출률을 측정했다(Tab. 10). 실제 FPR의 macro는 기준선 0.991 %, ScopeAD0.992 %이며, 표본 추정으로 클래스별 FPR은 목표 1%와 다를 수 있다. Fig. 6의 네 패널은 조건군별로 클래스의 정상·결함 밀도를 각각 계산한 뒤 macro 평균하며, 표시 범위 밖의 픽셀도 정규화에 포함한다. 따라서 이는 비슷한 오경보 예산에서의 점수 분리도를 비교하는 진단이며, 정답 없이 배포 임계값을 추정하거나 미사용 테스트에서 일반화를 검증하는 실험은 아니다.

조건별 분석은 regular 184개 쿼리와 비정규 획득 조건 900개 쿼리를 구분한다. 본문의 shift는 `overexposed`, `underexposed` 및 클래스마다 제공되는 `shift_1`–`shift_4`를 합친 조건군이며, 클래스 내 각 획득 조건과 regular의 정상·결함 장면 ID가 일치함을 확인했다. 클래스 내 해당 조건군의 전체 픽셀로 지표를 계산한 뒤 8개 클래스를 동일 비중으로 평균한다. Regular에서 검출률은 32.94→44.22 %, 실제 FPR은 0.651→0.703 %이고, shift에서는 각각 36.88→46.30 %, 1.058→1.050 %다. 과노출·저노출을 제외한 `shift_*`만의 532개 쿼리에서도 검출률은 39.28→47.44 %(+8.16 pp), 실제 FPR은 1.271→1.266 %다. 모든 조건군에 같은 클래스·방법별 임계값을 적용했으므로 조건군별 FPR은 1%로 고정되지 않으며, regular와 shift 사이의 검출률 차이를 조건 변화로 인한 손실로 해석하지 않는다.

Fig. 7는 전체 획득 조건에서 Raw L23 대비 새로 검출한 결함과 놓치게 된 결함을 분리한다. 전체 결함 픽셀 대비 검출 회복은 macro 13.57 %, 손실은 3.85 %로, 순이득은 9.72 pp다. 8개 클래스 중 7개에서 순이득이 있으며, `walnuts`는 3.36 pp 낮아진다. 정상 픽셀에서도 제거된 오경보와 새로 생긴 오경보가 공존하므로, 이 결과를 모든 정상 고점수의 제거로 해석하지 않는다.

실패 사례는 클래스 전체의 검출률이 낮아진 `walnuts`에서 선택했다. 비정규 조건의 결함 이미지 중 결함 픽셀 500개 이상을 대상으로, 클래스의 비정규 조건 검출률 변화 및 기준선 검출률에 가까운 이미지를 정했다. 구체적

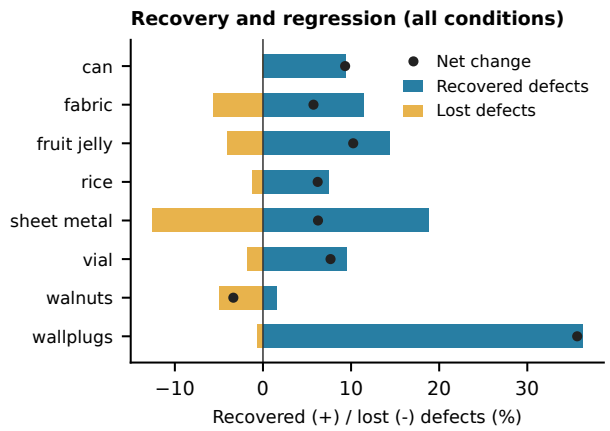


Figure 7. **클래스별 결함 검출 회복과 손실.** 전체 획득 조건의 결함 픽셀 대비 비율(2-shot, seed 0). Raw L23 대비 새로 검출한 결함은 파랑, 놓치게 된 결함은 노랑, 순이득은 검은 점이다.

으로 $|\Delta_{\text{image}} - \Delta_{\text{class}}| + 0.25|R^{\text{raw}}_{\text{image}} - R^{\text{raw}}_{\text{class}}|$를 최소화하고, 동률은 경로순으로 정했다. 이는 최대 개선 사례를 고르는 규칙은 아니지만, 정답을 사용한 사후 대표 사례 선택이다. 지표는 모두 원본 픽셀에서 계산하며, 표시용 축소 지도에는 최근접 보간을 사용했다. Fig. 8의 이미지에서는 오경보가 줄어도 결함 검출률은 88.58→85.96 %로 낮아진다. 클래스 전체에서도 76.12→72.76 %로 낮아져, 개선이 모든 클래스와 이미지에서 성립하지 않음을 보여준다.

저-FPR 검출 회복은 모든 정상·결함 쌍의 점수 순서 개선과도 구분된다. 별도 진단에서 Q95 보정된 1120 단일 해상도의 정상 고점수와 가까운 결함 점수를 짝지었을 때, 2-shot 비정규 조건의 결함 우위 비율은 단일 해상도 82.79 %, 전체 Rényi 결합 72.09 %였다(3-seed, 이미지·클래스별 평균). 이 진단은 기준선 점수로 쌍을 선택하고 정규화·계층 결합을 이미 적용한 비교로, 본문의 원시 L23 기준선 및 전체 픽셀 검출률과 비교 조건이 다르다. 기준선에 조건화한 쌍의 선택 편향도 있으므로 전체 모집단의 악화로 일반화할 수 없지만, 모든 모호한 쌍이 해소된다는 주장도 뒷받침하지 않는다. 본 논문의 직접 근거는 명시된 저-FPR 구간의 검출 회복이며, 이 사후 진단 한 시드만으로 미관측 조건의 강건성을 확정하지 않는다.

A.4. 보정과 Rényi 집계의 메커니즘 분석

상대 추가 응답(E/μ). 분석은 같은 특징과 거리를 재사용한다. 같은 픽셀 표본의 보정 전후 차이를 이미지·seed·클래스 순으로 평균했다. Rényi 집계에서 정상 이미지의 E/μ는 Q95 보정 후 2-shot에서 7.74 → 7.10 %, 16-shot에서 8.56 → 7.55 %로 감소했다(Fig. 9(a)). 결함 영역에서는 5.34 → 5.36 %, 6.36 → 6.11 %로 변화가 작았다. 결함과 정상 배경의 E/μ 차이는 $+0.74/+0.80$ pp 커졌고, 정상 이미지 E/μ의 Q99는 $-1.30/-1.61$ pp 줄었다. 이는 상대 추가 응답 분포의 변화이며, 고정 임계값에서의 오경보율 변화를 직접 측정한 것은 아니다.

순위 변경과 점수 크기 변경의 분리. Q95로 순위만 정하고 원점수를 합산하는 조건과, 원점수 순위를 유지한 채 Q95 점수를 합산하는 조건을 비교했다(Fig. 9(b)). 순위만 바꾼 효과는 $+0.05/-0.14$ pp인 반면, 크기만 바꾼 효과는 $+0.46/+0.70$ pp로 최종 이득의 대부분을 차지했다. 따라서 보정의 효과는 주로 점수 크기의 조정에서 나온다.

보정 오차에 대한 민감도. Fig. 9(c)는 보정 분모에 평균 1의 log-normal 오차를 넣고 오차가 없는 경우와 비교한다. 각 σ에서 seed별 3회 동일한 오차를 두 집계에 적용해 평균했다. $\sigma = 0.3$에서 Mean의 $\text{AUPRO}_{0.05}$ 변화는 $-0.03/+0.06$ pp인 반면 Rényi는 $-0.74/-0.47$ pp였다. Rényi 집계는 Mean보다 분모의 정확도에 더 민감하다.

단위에 따른 분포 비교. E/μ는 해당 픽셀의 평균 응답을 분모로 쓰므로 결함에서 μ가 커지는 효과도 포함한다. 이를 확인하기 위해 다른 fold 정상 이미지 μ의 Q95로 나눈 E도 측정했다. 이 값의 정상/결함 평균은 2-shot에서 4.31 → 3.80 / 6.18 → 6.19 %, 16-shot에서 4.57 → 3.80 / 8.01 → 7.66 %로, 정상 추가 응답이 줄고 결함 응답이 상대적으로 유지되는 방향은 같았다. 결함−배경 E/μ 차이 변화의 클래스 bootstrap 95 % 구간은 $[+0.06, +1.72]/[+0.00, +2.02]$ pp이며, 16-shot 하한이 0에 가깝다. 정상 이미지 E/μ의 Q99 변화 구간은 $[-2.29, -0.50]/[-3.00, -0.48]$ pp이고, 감소한 클래스는 7/8과 6/8이다.

Tab. 11의 coverage 상호작용은 (Q95+R − Q95+Mean) − (None+R − None+Mean)이다(R: Rényi). GT 영역 coverage를 이미지 안에서 평균한 뒤 이미지와 seed를 평균했다. 임계값은 정상 이미지의 교차검증으로 목표 FPR 1 %에 맞추었으며, 실제 평가 FPR은 조건마다 다르다.

클래스와 이미지의 불확실성. Tab. 11의 coverage 상호작용은 클래스에 따라 부호가 다르다. 클래스 bootstrap 구간은 0을 포함하지만, 서포트·임계값·클래스를 고정하고 이미지만 재표집한 구간은 $[+0.18, +1.16]/[+0.61, +1.92]$ pp다. 두 구간은 서로 다른 변동을 나타내며, 후자는 클래스 구성이나 서포트 선택의 변동을 포함하지 않는다.

결함 크기와 대비. GT 면적이 이미지의 0.1 % 미만인 작은 영역의 coverage 상호작용은 $+0.86/+1.53$ pp지만 fabric을 제외하면 $-0.18/-0.06$ pp다. 0.1–1 % 및 1 % 이상 구간은 can이 없어 7개 클래스 범위다. 회색조 대비(GT 영역 평균과 8픽셀 주변 정상 영역의 차이를 주변 표준편차로 나눈 값)와 결함 크기의 상관 방향은 클래스마다 달랐다. 따라서 작은 결함이나 저대비 결함 전반에서 이득이 있다고 보기는 어렵다.

해상도 순위 점유율. Fig. 10는 seed 0에서 각 픽셀의 최고점수를 낸 해상도의 비율이다. Q95 보정 후 448의 정상 점유율은 47.5/50.7 %에서 33.9/36.4 %로 줄고, 16-shot 작은 결함의 1120 점유율은 14.5 %에서 29.2 %로 늘었다. 정상 픽셀의 1120 점유율도 13.7 %에서 22.3 %로 늘었으므로, 이 그림은 순위 편중의 변화를 보여주는 보조 자료로 사용한다.

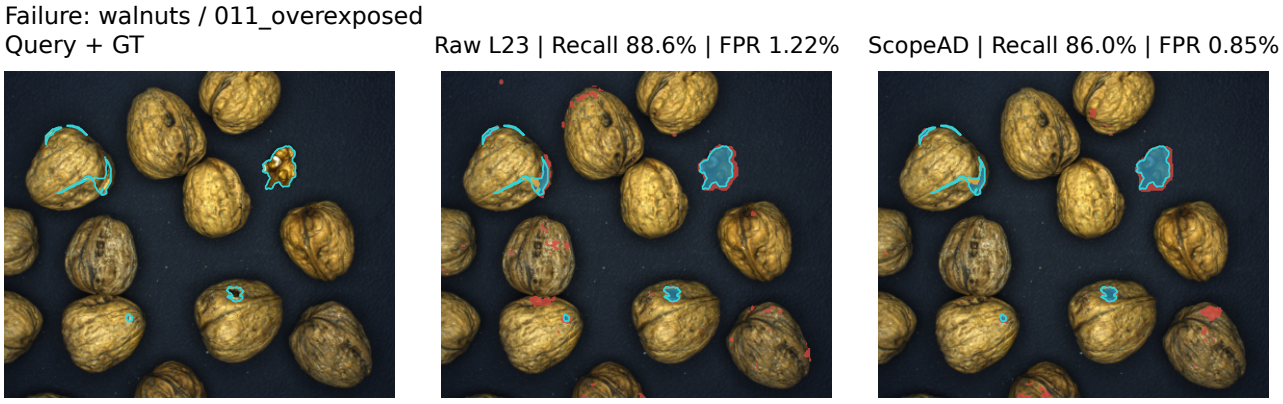


Figure 8. **검출 회복이 보장되지 않는 반례.** `walnuts`의 과노출 쿼리. 파랑: 검출 결함, 노랑: 미검출 결함, 빨강: 오경보, 하늘색: 정답 윤곽. 검출률은 88.58→85.96 %로 낮아진다.

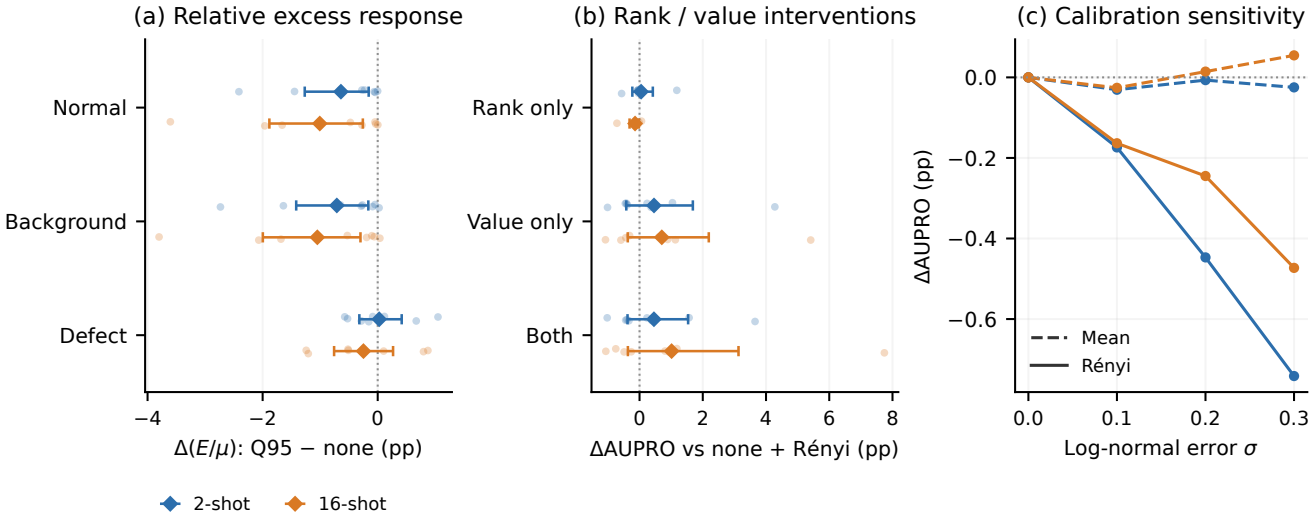


Figure 9. **Q95 보정과 Rényi 집계의 메커니즘 분석** (MVTec AD 2, 2/16-shot, 3-seed). (a) Q95−None의 E/μ 변화: Normal은 정상 이미지, Background는 결함 이미지의 정상 배경, Defect는 결함 영역. (b) None+Rényi 대비 순위·크기 보정의 $\text{AUPRO}_{0.05}$ 변화. (a,b)의 점은 클래스별 평균, 마름모와 막대는 macro와 클래스 bootstrap 95 % 구간이다. (c) 분모 오차에 따른 $\text{AUPRO}_{0.05}$ 변화. 색은 shot, 점선/실선은 Mean/Rényi다.

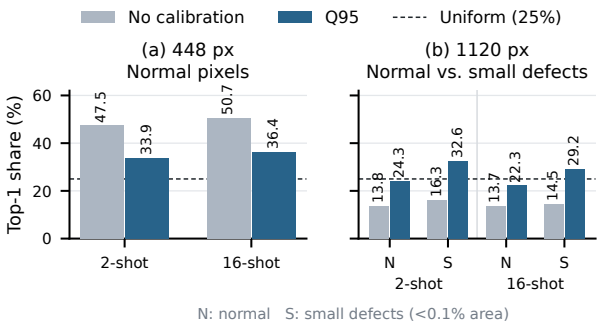


Figure 10. **정상 참조 보정과 해상도 순위 점유율.** MVTec AD 2, seed 0, 8개 클래스 macro. 점선은 균등 점유율 25 %다.

A.5. 계층•해상도 보정 축의 분리

분모 분해. 정상 서포트 Q95 $c_{l,r,b}$의 로그를 각 배그에서 다음과 같이 분해한다:

$$\log c_{l,r,b} = \gamma_b + u_{l,b} + v_{r,b} + h_{l,r,b}. \tag{10}$$

γ_b는 계층·해상도 전체 평균이고, $u_{l,b}$와 $v_{r,b}$는 각 축 평균에서 γ_b를 뺀 값이며, $h_{l,r,b}$는 잔여 항이다. Global, Layer, Resolution, Separable은 각각 $\exp(\gamma_b)$, $\exp(\gamma_b + u_{l,b})$, $\exp(\gamma_b + v_{r,b})$, $\exp(\gamma_b + u_{l,b} + v_{r,b})$를 분모로 쓴다. Full은 원래 $c_{l,r,b}$이며 None은 1이다. 모든 축 개입은 배그 공통 척도를 유지하므로 Global을 대조로 사용한다. 특징, 뱅크, 계층 가중치, FP16을 고정하고 분모만 바꾸었으며(8개 클래스 × 2/16-shot × 3 seed), None과 Full의 결과는 Tab. 7와 일치한다.

Table 11. **검출 변화와 해상도 응답 집중도의 연관** (MVTec AD 2, 3-seed 평균). 상호작용은 보정 유무에 따른 Rényi−Mean coverage 차이의 변화(pp)다. ρ는 Q95 상태의 응답 집중도와 Mean→Rényi coverage 차이의 클래스 내 Spearman 상관이다.

클래스	2-shot 상호작용 (pp)	16-shot 상호작용 (pp)	2-shot ρ	16-shot ρ
can	−0.05	−0.06	0.48	0.39
fabric	+7.24	+11.50	0.56	0.31
fruit_jelly	+0.23	+0.72	0.48	0.46
rice	−0.38	−0.71	0.38	0.22
sheet_metal	−1.86	−1.78	0.48	0.43
vial	+0.12	−0.18	0.30	0.03
wallplugs	−0.19	−0.59	0.51	0.52
walnuts	+0.05	+0.79	0.29	0.30
Macro	+0.65	+1.21	—	—
fabric 제외	−0.30	−0.26	—	—

Table 12. **Q95 보정 분모의 축별 성분 분리** (MVTec AD 2, 3-seed 평균 $\text{AUPRO}_{0.05}$, %). Global: 배그별 공통 배율, Layer/Resolution: 해당 축 추가, Separable: 두 축 추가, Full: 원래 Q95.

	2-shot		16-shot	
분모	Mean	Rényi	Mean	Rényi
None	56.12	56.32	59.73	59.72
Global	56.12	56.32	59.73	59.72
Layer	55.91	56.13	59.90	59.82
Resolution	56.26	56.87	59.89	60.55
Separable	56.02	56.78	60.02	60.73
Full Q95	56.03	56.78	60.06	60.74

축 효과. Rényi 아래에서 Resolution−Global은 $+0.55/+0.82$ pp이며, seed별 macro 효과는 2-shot $+0.56/+0.64/+0.45$ pp, 16-shot $+0.82/+0.78/+0.87$ pp로 모두 양수다. Mean 아래의 같은 효과는 $+0.15/+0.15$ pp로 작다. Layer−Global은 Rényi 아래에서 $-0.19/+0.10$ pp로 shot에 따라 방향이 달랐고, Full−Separable은 두 shot 모두 0.01 pp 이내로 잔여 항의 macro 영향은 작았다. 다만 Resolution−Global에서 양의 효과를 보인 클래스는 두 shot 모두 8개 중 4개이고, fabric의 효과가 $+5.18/+7.26$ pp로 크다. 클래스 bootstrap 95 % 구간은 $[-0.36, +1.99]/[-0.40, +2.80]$ pp로 0을 포함하며, fabric을 제외하면 $-0.11/-0.10$ pp다.

A.6. 평균 응답 조건부 분석과 영역•픽셀 가중

같은 평균 응답 구간에서의 비교. 두 보정 조건의 같은 픽셀을 보정 전 평균 응답 μ의 10분위 구간에 배정했다. 구간 경계는 다른 정상 fold에서 정했다. 이미지→seed→클래스 순으로 집계하면 정상과 배경의 Q95−None E/μ 변화는 두 shot 모두 10개 구간 전체에서 음수였다. 결함−배경 변화는 8개 클래스가 모두 관측된 구간(2-shot 5–9, 16-shot 6–9)에서 모두 양수였다. 따라서 평균 응답 수준이 다른 픽셀이 섞여서 생긴 현상으로 보기는 어렵다. 다만 보정 후의 μ까지 고정한 비교는 아니다.

Fabric의 영역 수와 결함 픽셀 수. Fabric의 GT 영역 192개 중 180개(93.75 %)는 이미지 면적의 0.1 % 미만이지만, 이 영역들은 전체 결함 픽셀의 1.39 %만 차지한다. 목표 FPR 1 % 임계값에서 Q95+Rényi−None+Rényi의 영역 평균 coverage 변화는 작은 영역에서 $+6.85/+10.41$ pp, 나머지 영역에서 $-1.36/-0.84$ pp다(2/16-shot). 같은 변화를 GT 픽셀 수로 가중하면 작은 영역의 TPR 기여는 $+0.06/+0.08$ pp, 나머지는 $-2.66/-1.64$ pp다. 즉 많은 작은 영역의 coverage 증가와 큰 영역의 손실이 함께 나타나며, 영역 단위 지표($\text{AUPRO}_{0.05}$)와 픽셀 단위 지표($\text{pAUROC}_{0.05}$)가 다르게 움직이는 이유를 설명한다.

A.7. 획득 조건별 상세 결과

MVTec AD 2 `test_public`은 클래스마다 같은 장면을 기본 조건(regular)과 바뀐 조건(overexposed, underexposed, 클래스별 1–4개의 shift)에서 같은 수로 포함한다. 조건별 $\text{AUPRO}_{0.05}$는 각 조건 안에서, 단일 임계값 $\text{AUPRO}_{0.05}$는 클래스 내 모든 조건에 공통으로 임계값을 변화시키며 FPR 0.05까지 적분한 값이다. 후자는 Tab. 1과 같다. 두 표의 손실은 단일 임계값 $\text{AUPRO}_{0.05}$에서 전체 조건별 $\text{AUPRO}_{0.05}$의 평균을 뺀 값(pp)이다. 이는 조건을 함께 평가할 때 생기는 손실이며, 정상·결함 점수의 중첩 정도나 사전에 정한 배포 임계값의 FPR을 직접 나타내지는 않는다. Tab. 13은 모든 shot의 결과이고, Tab. 14는 ScopeAD의 보정·집계 변형과 단일 해상도 구성의 손실이다. 손실은 보정 유무와 집계 방식에 따라 2-shot에서 0.06–0.07 pp, 16-shot에서 0.33–0.39 pp로 거의 변하지 않았고, 단일 1120 구성(0.18 pp)도 4해상도 구성(0.33 pp)보다 크지 않았다. 따라서 ScopeAD의 작은 손실을 특정 구성 요소의 효과로 보기는 어렵다.

Table 13. 획득 조건별 $AUPRO_{0.05}$ (MVTec AD 2 `test_public`, 3-seed 평균, %). 기본: regular, 변화: 비정규 조건 평균. 손실은 단일 임계값 점수에서 전체 조건별 점수의 평균을 뺀 값(pp)이다.

	1-shot			2-shot			4-shot			8-shot			16-shot		
방법	기본	변화	손실	기본	변화	손실	기본	변화	손실	기본	변화	손실	기본	변화	손실
PatchCore	39.09	38.46	−0.11	42.98	42.30	−0.16	47.72	47.10	−0.27	51.31	50.20	−0.40	54.32	52.97	−0.46
AnomalyDINO	39.82	37.12	−1.58	42.79	39.52	−1.83	46.31	42.04	−2.39	48.08	43.15	−2.29	49.91	44.12	−2.74
FastRecon	15.61	14.87	−0.07	17.61	16.82	−0.23	23.02	21.99	−0.28	28.77	27.52	−0.41	38.19	35.54	−0.74
RAD	26.28	26.50	−0.04	31.53	31.71	−0.06	36.37	36.74	−0.16	41.03	41.10	−0.30	43.14	43.02	−0.46
SubspaceAD	56.76	48.20	−4.75	58.86	49.65	−5.28	61.27	51.35	−5.86	62.21	51.82	−6.26	63.10	52.37	−6.52
SuperAD	47.08	46.46	−0.24	51.06	49.96	−0.33	56.15	54.50	−0.51	57.92	55.71	−0.62	58.58	56.33	−0.80
RegAD (224)	14.09	12.67	−0.17	16.75	14.95	−0.20	19.59	17.39	−0.35	22.09	19.38	−0.58	24.11	20.88	−1.14
Ours (ScopeAD)	53.10	52.09	−0.06	58.09	56.60	−0.05	60.97	59.27	−0.05	61.94	60.22	−0.10	62.42	60.74	−0.27

Table 14. ScopeAD 변형의 획득 조건별 $AUPRO_{0.05}$ (MVTec AD 2, seed 0, %). 단일/조건별은 공통/조건별 임계값 평가이며, 손실은 단일−조건별(pp)이다.

	2-shot			16-shot		
구성	단일	조건별	손실	단일	조건별	손실
보정 없음 + Rényi	58.99	59.05	−0.06	59.03	59.41	−0.38
Q95 + Mean	59.33	59.40	−0.07	59.57	59.96	−0.39
Q95 + Rényi (Ours)	59.92	59.98	−0.06	60.16	60.49	−0.33
단일 1120 (cap 256)	—	—	—	57.48	57.66	−0.18