ScopeAD: Observation Expansion and Support-Referenced Asymmetric Fusion for Few-Shot Industrial Anomaly Localization

Anonymous CVPR submission

Abstract

*동결 특징 기반의 최근접 이웃 매칭은 소수의 정상 참조 이미지만으로 결함을 찾는 few-shot 산업 이상 탐지 방식이다. 그러나 조명이나 자세 같은 획득 조건이 바뀌면 서포트에 없는 정상 외관에서도 거리가 커져, 높은 점수가 실제 결함 때문인지 미관측 정상 변동 때문인지 구분하기 어렵다. 본 논문은 이 문제를 **High-Score Ambiguity**로 정의한다. 단일 관측에서 정상과 결함의 점수가 비슷한 위치라도, 다른 표현 계층이나 입력 해상도에서는 두 영역의 반응 차이가 드러난다. 이 관찰을 바탕으로, 동일한 정상 서포트를 여러 계층과 해상도에서 독립 비교한 뒤 단일 점수로 통합하는 **ScopeAD**를 제안한다. ScopeAD는 정상 서포트 내부 교차 비교 거리의 통계적 분포를 기준으로 관측 간 척도를 정렬하고, 깊은 계층을 중심으로 얕은 계층을 보조 결합한다. 이어 위치별 해상도 점수 순위에 Rényi 가중치를 적용하여, 특정 해상도에서 포착된 결함 반응이 단순 평균 과정에서 희석되는 것을 줄인다. 모든 과정은 백본의 추가 학습이나 쿼리 시점 적응 없이 이루어진다. MVTec AD 2에서 ScopeAD는 1–16-shot 전 구간에서 비교 방법 중 가장 높은 $\mathrm{AUPRO}_{0.05}$를 달성했으며 (1-shot 52.18 %, 차순위 대비 +5.87 pp), 획득 조건 변화 환경(2-shot)에서도 동일 오경보율(1 %) 하에 결함 픽셀 재현율을 36.2 %에서 45.5 %로 높였다. 아울러 MVTec AD와 VisA에서도 경쟁력 있는 성능을 보였다.*

1. 서론

다품종 소량 생산과 빈번한 라인 전환이 발생하는 제조 환경에서는 제품별 결함 표본을 충분히 수집하기 어렵다. 이에 따라 소수의 정상 참조 이미지만으로 결함 위치를 특정하는 few-shot 이상 탐지(few-shot anomaly detection)가 실용적인 대안으로 활용된다. 대표적으로, 동결된 사전학습 백본 [?]으로 정상 패치의 메모리 뱅크를 구축한 후, 테스트 패치와의 최근접 이웃 거리를 계산하여 이상치를 탐지하는 방법이 있다 [? ? ?]. 이러한 거리 기반 점수는 정상 패치가 메모리 뱅크의 특징과 유사하다는 가정에 기반한다. 그러나 실제 공정에서는 조명 드리프트, 부품 자세 변동, 표면 난반사 등 다양한 distribution shift가 빈번히 발생한다 [? ?]. 소수의 정상 표본만 주어지는

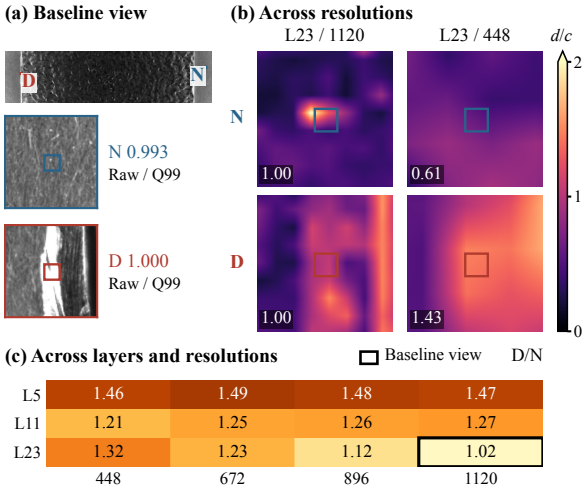


Figure 1. **단일 관측의 모호함과 관측 확장의 단서.** MVTec AD 2에서 정상 서포트 이미지 2장(2-shot)을 기준으로 계산한 패치 거리를 분석했다. 기준 관측(L23/1120)에서 정상·결함 점수가 비슷한 위치를 고정하고, 같은 위치를 각 계층·해상도에서 따로 측정했다(결합 없음). (a,b) Sheet metal `007_shift_2`에서 사후 선택한 정상 N·결함 D 영역의 기준 점수와 해상도별 거리 맵(d/c, 수치는 영역 평균). (c) 8개 클래스 고정 위치의 관측별 결함/정상 평균 비(D/N).

few-shot 환경에서는 이러한 외부 조건 변화에 따른 정상 외관의 변동폭을 메모리 뱅크에 충분히 담기 어렵다. 그 결과 서포트 셋에서 관측되지 않은 정상 변동 영역에서도 최근접 거리가 상승하여 실제 결함 점수와 겹칠 수 있다. 이처럼 정상 표본의 희소성과 획득 환경 변화가 함께 작용하면, 단일 거리값만으로는 고점수의 원인이 실제 결함인지 미관측 정상 변동인지 판별하기 어렵다. 본 논문은 이러한 한계를 **High-Score Ambiguity (HSA)**로 정의한다(??). 정상 영역의 오탐을 배제하고자 임계값을 높일수록 실제 결함 검출 영역 또한 함께 축소되므로, 이 현상은 저-FPR 구간의 결함 국소화 성능을 저해한다 [?]. 실제로 MVTec AD 2에서 기본 조건 성능이 가장 높은 기존 방법도, 획득 조건이 바뀐 영상에서는 $\mathrm{AUPRO}_{0.05}$가 최대 10.73 pp 낮아진다(??).

High-Score Ambiguity(HSA) 완화를 위해서는 단일 관측에서 유사한 거리를 보이는 미관측 정상 변동과 실제

결함을 구분할 추가 단서가 요구된다. **??**은 판별 단서가 타 관측 공간에 존재함을 보여준다. 구체적으로 기준 관측에서 유사한 이상 점수를 나타내는 정상 및 결함 영역이라도, 더 낮은 입력 해상도에서는 결함 반응이 유지되는 반면 정상 변동에 의한 반응은 크게 감소한다(**??**b). 8개 클래스를 합친 위치 집단에서도 같은 경향이 나타난다. 기준 관측에서 정상과 결함의 평균 점수가 비슷한 위치($D/N = 1.02$)에서도, 나머지 11개 관측에서는 모두 결함 영역의 평균 점수가 더 높게 형성된다(1.12–1.49, **??**c). 이러한 차이는 계층과 해상도가 서로 다른 시각적 단서를 포착하기 때문에 나타날 수 있다. 표현 계층은 국소 외관부터 전역 문맥까지 깊이에 따른 추상화 수준을 담고 [**?** **?**], 입력 해상도는 고정 패치 백본에서 한 토큰이 덮는 원본 영상의 공간 범위를 바꾼다 [**?** **?**]. 이를 바탕으로 추가 학습이나 서포트 증강 없이, 동일한 정상 서포트를 계층과 해상도의 두 축으로 분리·전개하는 관측 확장(observation expansion)을 수행한다.

확장된 다중 관측을 활용할 때는 각 관측 고유의 단서가 손실되지 않도록 매칭 방식을 설계해야 한다. 특징 연결 공간에서는 거리 기여가 큰 계층이 최근접 이웃 선택을 지배할 수 있다 [**?**]. ScopeAD는 계층·해상도별로 뱅크를 분리하여 각 관측의 비교 단서를 유지한다. 그러나 이처럼 독립 산출된 점수들을 통합할 때는 관측 간 척도 불균형(**??**)과 단순 평균 시 국소 결함 반응이 희석되는 두 가지 문제가 뒤따른다. 이에 본 논문은 소수의 정상 서포트만으로 이 다중 점수를 통합하는 **ScopeAD**를 제안한다. ScopeAD는 서포트 내부 교차 매칭(cross-matching) 거리의 상위 분위수(Q99)로 관측 간 거리 척도를 먼저 정렬한 뒤, 깊은 계층을 주축으로 삼고 얕은 계층의 단서를 작은 가중치로 더한다. 이어 위치별 다중 해상도 점수의 상위 순위에 높은 Rényi 가중치를 부여하여, 특정 해상도에서 포착된 결함 반응의 희석을 완화한다. MVTec AD 2의 2-shot 사후 진단에서, 선택 구간 내 정상·결함 구분 AUROC는 단일 관측의 58.0 %에서 ScopeAD의 79.6 %로 높아졌고, shift 조건의 FPR 1%에서 결함 픽셀 재현율은 36.2 %에서 45.5 %로 높아졌다(**??**). 또한 MVTec AD 2의 $\mathrm{AUPRO}_{0.05}$의 전 구간에서 비교 방법 중 가장 높은 성능을 기록했으며, MVTec AD와 VisA에서도 경쟁력 있는 성능을 보였다.

본 논문의 기여는 다음과 같다.

- 제한된 정상 서포트의 계층과 입력 해상도를 독립 매칭 단위로 분리·확장하여 High-Score Ambiguity를 완화하는 few-shot 이상 국소화 방법 ScopeAD를 제시한다.
- 정상 참조 척도 보정, 계층별 비대칭 가중합, 위치별 해상도 순위 집계로 이루어진 점수 통합 규칙을 제안하고, 척도 정렬과 순위 집계를 함께 적용할 때 이득이 커짐을 분석한다.
- 단일 관측이 구분하지 못하는 위치에서의 정상·결함 분리와 같은 오경보율에서의 결함 픽셀 재현율로 HSA 완화를 분석하고, MVTec AD 2의 저-FPR 국소화 성능, 공식 `test_private` 평가, 구성 요소·하이퍼파라미터 분석, MVTec AD·VisA 결과를 보고한다.

2. 관련 연구

2.1. Few-shot 이상 탐지의 참조 매칭

Few-shot 이상 탐지는 소수의 정상 참조 이미지와 테스트 쿼리 간의 특징 차이를 비교하여 결함을 탐지 및 국소화한다. 제한된 참조 표본의 한계를 보완하기 위해 이미지 간 기하학적 정합을 학습하거나 [**?**], 시각-언어 모델의 사전 지식을 결합하여 정상과 이상을 구분하는 방법론이 제안되었다 [**?** **?**]. 또한 보조 데이터셋에서 일반화된 비교 규칙 및 프롬프트를 메타 학습하는 접근 [**?** **?**]이나, 정상 서포트 없이 레이블이 없는 테스트 이미지 간 상호 유사도를 비교하는 방식 [**?**]도 연구되었다. 반면, 본 논문과 같이 소수의 정상 서포트와 동결된(frozen) 사전학습 특징만을 활용하는 접근은 정상 참조와의 차이를 최근접 이웃 거리 [**?** **?** **?**], 특징 복원 오차 [**?**], 또는 부분공간 투영 거리 [**?**]로 정량화한다. 특히 동결 특징 기반 패치 매칭은 백본에 대한 추가 학습 없이 새로운 제품군에 즉각 적용할 수 있어 실용적이며 [**?** **?**], 최근 MVTec AD 2 few-shot 연구 [**?**]에서도 백본 계층과 서포트 수에 따른 매칭 특성이 분석되었다. 그러나 단일 관측에 의존하는 기존 참조 매칭은 획득 조건이 변화할 때 미관측 정상 변동과 실제 결함의 거리가 동시에 상승하는 High-Score Ambiguity에 취약하다. ScopeAD는 단일 관측 대신 계층과 해상도별 독립 매칭 결과를 함께 사용한다.

2.2. 다중 척도 관측과 점수 결합

다중 계층과 해상도의 특징을 활용하면 국소 외관 질감부터 전역 문맥까지 다각적인 비교 단서를 확보할 수 있다. 다층 ViT 특징을 조립하여 밀집 예측에 활용하는 DPT [**?**]나 다중 해상도 입력으로 동결 백본의 표현 척도를 확장하는 S^2 [**?**]가 대표적이다. 이상 탐지 분야에서는 이러한 다중 척도 단서를 특징 수준에서 연결(concatenation)하여 통합 매칭하거나 [**?**], 관측별 개별 점수를 산출한 후 결합하는 방식 [**?** **?**]이 주로 활용되었다. 특징 연결 방식은 하나의 공간에서 최근접 이웃을 선택하는 반면, 개별 점수 결합 방식은 관측별 매칭 결과를 통합한다. 그러나 점수 결합 방식 역시 관측 간 거리 척도 불균형(scale discrepancy)을 보정하지 않으면 기저 거리가 큰 특정 관측으로 결합 점수가 편향되는 한계를 지닌다. 나아가 척도를 정렬한 이후에도 모든 관측을 균등하게 평균하면, 특정 관측에 집중된 결함 반응이 다른 관측의 낮은 점수에 희석(dilution)될 수 있다. ScopeAD는 정상 서포트를 기준으로 척도를 맞춘 뒤 위치별 점수 순위를 이용해 결합한다(????).

2.3. 획득 조건 변화와 저-FPR 국소화

실제 제조 환경에서 획득 조건 변화(distribution shift)가 발생하면, 무결함 정상 영역이라도 외관 차이로 인해 참조 매칭 거리가 크게 증가할 수 있다. 이러한 도메인 변화를 반영하기 위해 AeBAD [**?**]는 공정 내 배경 및 조명 변화를 도입했으며, MVTec AD 2 [**?**]는 학습 데이터에 부재한 극단적 조명 및 노출 조건을 포함하여 평가 난이도를 높였다. 특히 소수의 정상 표본만 주어지는 few-shot

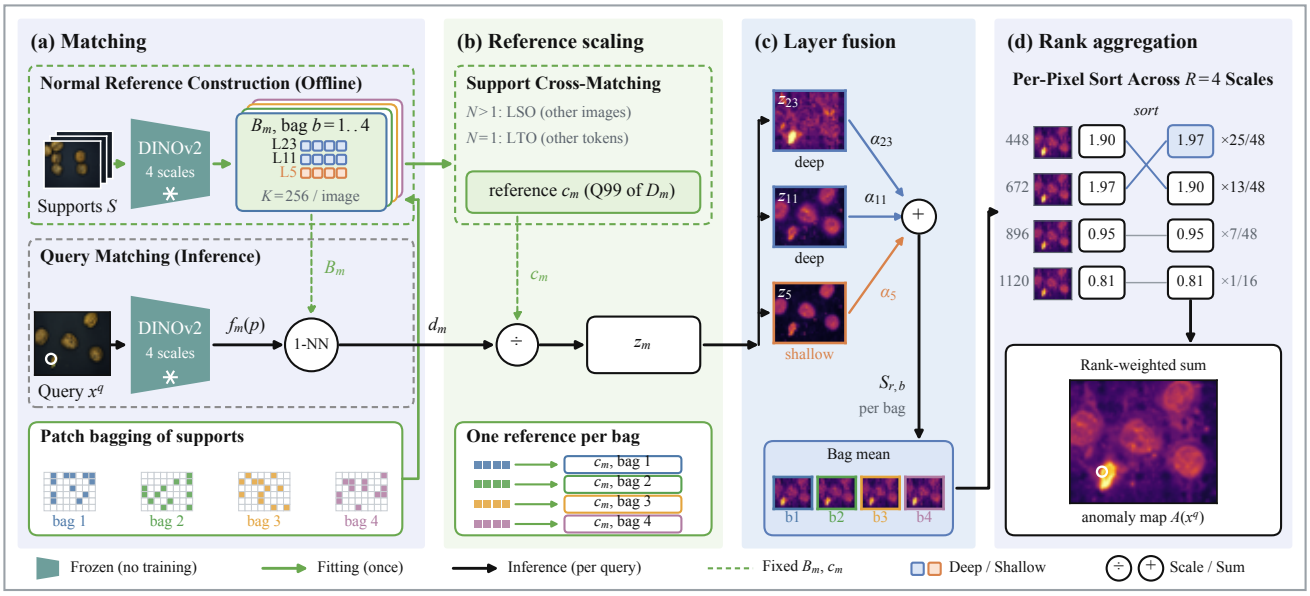


Figure 2. **Overview of ScopeAD.** (a) 정상 서포트로 관측 $m=(l,r,b)$별 뱅크 B_m을 구축하고 쿼리 패치를 각 뱅크에서 독립적으로 매칭한다. (b) 서포트 교차 매칭으로 관측별 기준 c_m을 정하고 쿼리 거리를 z_m으로 정규화한다. (c) 계층별 점수를 결합한 뒤 배그 평균으로 해상도별 점수를 얻는다. (d) 픽셀마다 해상도별 점수를 순위에 따라 가중합해 최종 이상 맵 $A(x^q)$를 얻는다. 맵과 수치는 MVTec AD 2 walnuts의 예시이다.

환경에서는 서포트가 이러한 외관 변동폭을 포괄하지 못하므로, 정상 영역의 점수 상승이 낮은 오경보율에서 결함 검출을 얼마나 줄이는지 평가할 필요가 있다. 그러나 전체 FPR 구간을 요약하는 표준 AUROC는 오경보를 엄격히 제한하는 구간의 성능 차이를 잘 드러내지 못한다. AUPIMO [?]와 저-FPR 구간의 $\text{AUPRO}_{0.05}$는 낮은 오경보율에서의 결함 영역 검출률을 직접 평가한다. 본 논문은 MVTec AD 2에서 few-shot 조건과 획득 조건 변화가 함께 있을 때의 저-FPR 국소화 성능을 비교한다.

3. 제안 방법

ScopeAD는 정상 서포트를 계층·해상도별로 독립 매칭하고, 산출된 거리 맵을 순차적으로 통합한다(??). 먼저 서포트 교차 매칭 거리의 상위 분위수로 관측 간 척도를 맞춘다. 다음으로 계층별 점수를 비대칭 가중합하고 배그별 결과를 평균한다. 마지막으로 공간 정렬한 해상도별 점수에 위치별 순위 가중치를 적용하여 최종 이상 맵을 얻는다. 메모리 뱅크와 기준 척도는 추론 전에 구성하며, 백본 추가 학습이나 쿼리 적응은 수행하지 않는다.

3.1. 문제 설정

입력으로 N장의 정상 서포트 이미지 집합 $\mathcal{S}=\{x_1^s,\dots,x_N^s\}$, 테스트 쿼리 이미지 x^q, 그리고 동결된 사전학습 비전 트랜스포머(ViT) 백본이 주어진다. 특징을 추출할 백본 계층 집합을 $\mathcal{L}$, 입력 해상도(짧은 변 기준) 집합을 $\mathcal{R}$, 서브샘플 배그(bag) 수를 N_b로 정의한다. 본 연구에서는 $\mathcal{L}=\{5,11,23\}$, $\mathcal{R}=\{448,672,896,1120\}$, $N_b=4$를 사용하여 총 $|\mathcal{L}|\times|\mathcal{R}|\times N_b=48$개의 관측별 매칭 단위를 구성한다(??). 이 관측들은 같은 이미지에서 추출되므로 서로 상관될 수 있으며, 여기서 독립 매칭은 각 관측이 별도 뱅크에서 최근접 이웃을 탐색한다는 뜻이다. ScopeAD는 픽셀 단위 결함 국소화 맵 $A(x^q)\in\mathbb{R}^{H\times W}$와 이미지 단위 이상 점수 $s(x^q)\in\mathbb{R}$를 출력한다.

3.2. 관측 확장과 독립 참조 매칭

다중 계층 특징을 연결하여 매칭하면, 연결 공간에서 거리 기여가 큰 계층이 최근접 이웃 선택을 지배할 수 있다 [?]. ScopeAD는 계층 $l\in\mathcal{L}$, 해상도 $r\in\mathcal{R}$, 배그 인덱스 $b\in\{1,\dots,N_b\}$의 조합 $m=(l,r,b)$별로 메모리 뱅크 B_m을 구성한다. 쿼리 이미지 x^q의 공간 위치 p에서 추출된 ℓ_2 정규화 패치 토큰 $f_m(x^q,p)$는 오직 대응하는 뱅크 B_m 내에서만 독립적으로 최근접 이웃을 탐색하여 코사인 거리 점수를 계산한다:

$$d_m(x^q,p)=\min_{u\in B_m}\left[1-f_m(x^q,p)^\top u\right]. \qquad (1)$$

이 구조에서는 각 관측이 자신의 표현 층위와 공간 척도 내에서 최적의 정상 토큰을 독립 탐색하므로, 특정 관측의 거리 상승이 타 관측의 이웃 선택에 간섭하지 않고 국소 결함과 전역 문맥 신호가 관측별 거리 신호로 보존된다. 이때 입력 해상도가 커질수록 서포트 패치 토큰 수가 급증하므로, 메모리와 계산 비용을 통제하고 토큰 구성에 따른 점수 변동을 줄이기 위해 패치 서브샘플 배깅을 적용한다. 구체적으로 각 해상도 r에서 서포트 이미지당 $K=256$개의 패치를 비복원 균등 추출하여 단일 배그를 구성하며, 서로 다른 난수로 $N_b=4$개의 배그를 생성한다. 계층 간 공간적 대응 관계를 유지하기 위해 동일 배그 내의 모든 계층($l\in\mathcal{L}$)은 완전히 일치하는 공간 좌표의

토큰을 공유하며, 각 배그에서 독립 계산된 이상 점수는 이후 다해상도 통합 단계(??)에서 앙상블 평균된다.

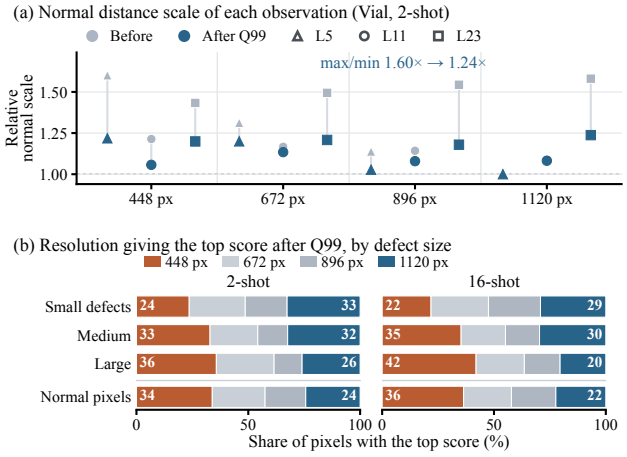


Figure 3. **Q99 보정에 따른 척도 정렬과 결함 크기별 최고 점수 해상도.** (a) Vial 2-shot에서 12개 관측의 서포트 Q99 보정 전후 정상 거리 척도(정상 쿼리 거리의 Q99, 최솟값=1). (b) Q99 보정 후 위치별로 가장 높은 점수를 낸 해상도의 비율(MVTec AD 2, 8개 클래스 평균). 결함 크기는 이미지 면적 대비 0.1 % 미만(small), 0.1–1 %(medium), 1 % 이상(large)이다.

3.3. 정상 참조 기반 비대칭 선형 결합

독립 매칭으로 산출된 원시 거리 d_m을 통합하려면 먼저 계층 깊이와 입력 해상도에 따른 관측 간 척도 불균형(scale discrepancy)을 해소해야 한다. 관측마다 정상 거리 척도가 다르므로(??의 Vial에서 최대 1.60배) 보정 없이 결합하면 기저 거리가 큰 관측이 결합 점수와 순위를 지배할 수 있다. 따라서 새 이미지와 비교할 때 정상 패치 사이에서도 발생하는 기준 거리의 크기를 측정하여 관측 간 척도를 정렬한다. 이를 위해 정상 서포트 내부의 교차 매칭 거리 표본 D_m을 먼저 수집한다. 다중 샷($N > 1$) 환경에서는 동일 이미지 내 자기 유사 패치와 매칭되어 거리가 과소 추정되는 편향을 막기 위해, 서포트 이미지 i의 토큰 부분집합 $B_m^{(i)}$를 해당 이미지를 제외한 나머지 뱅크 토큰들과 매칭하는 Leave-Source-Out (LSO) 방식을 적용한다:

$$D_m^{\mathrm{LSO}} = \bigcup_{i=1}^{N} \left\{ \min_{u \in B_m \setminus B_m^{(i)}} \left[1 - v^\top u\right] : v \in B_m^{(i)} \right\}. \quad (2)$$

단일 샷($N = 1$) 환경에서는 이미지 간 교차가 불가능하므로, 단일 이미지 내에서 자신을 제외한 타 위치 토큰들과 매칭하는 Leave-Token-Out (LTO) 표본을 대리 통계량으로 사용한다:

$$D_m^{\mathrm{LTO}} = \left\{ \min_{j \neq i} \left(1 - v_i^\top v_j\right) : i = 1, \ldots, K \right\}. \quad (3)$$

이렇게 얻은 거리 표본 집합 D_m으로부터 각 관측의 기준 척도 c_m을 산출한다. 관측에 따라 거리 분포의 비대칭성과 꼬리 두께가 상이하므로, 특정 분포를 가정하는 대신 비모수적 순서 통계량인 상위 분위수 $\mathcal{Q}_q$로 c_m을 정의하고 정규화 점수 z_m을 계산한다:

$$c_m = \max\left\{\mathcal{Q}_q(D_m),\, \epsilon\right\}, \qquad z_m(x^q, p) = \frac{d_m(x^q, p)}{c_m}, \quad (4)$$

여기서 $q = 0.99$이며, $\epsilon = 10^{-4}$는 수치적 안정성을 위한 하한값이다. 정규화 점수 z_m은 정상 참조 거리의 상위 기준값 대비 비율을 뜻하며, $z_m = 1$ 자체가 결함 판정 임계값은 아니다. 이 정렬로 관측 간 정상 거리 척도의 편차가 줄어든다(??a).

척도를 정렬한 뒤에도 계층마다 포착하는 정보의 특성이 다르므로 단순 균등 평균 대신 비대칭 결합을 적용한다. 계층별 결합 가중치는 국소화 성능을 기준으로 비교했다(??). 본 논문은 깊은 두 계층의 정규화 점수 평균을 기저 점수로 사용하고, 얕은 계층은 $\lambda = 0.125$의 가중치로 보조 결합한다:

$$S_{r,b}(x^q, p) = \frac{1}{2} \sum_{l \in \{11,23\}} z_{l,r,b}(x^q, p) + \lambda\, z_{5,r,b}(x^q, p). \quad (5)$$

정규화 점수가 $z_m = d_m / c_m$이므로, ??은 원시 거리 $d_{l,r,b}$에 계수 $\alpha_l / c_{l,r,b}$를 곱해 합산한 선형 결합과 같으며, 여기서 $(\alpha_5, \alpha_{11}, \alpha_{23}) = (0.125, 0.5, 0.5)$이다.

3.4. 다해상도 순서 통계량 집계

계층 결합 후 각 해상도 r에서 N_b개 배그 점수를 평균하고, 양선형 보간으로 원본 이미지 크기 (H, W)에 공간 정렬한다:

$$S_r(x^q, p) = \frac{1}{N_b} \sum_{b=1}^{N_b} S_{r,b}(x^q, p). \quad (6)$$

결함 크기에 따라 반응이 강한 해상도가 다르므로(??b), ScopeAD는 해상도별 고정 가중치 대신 위치별 점수 순위에 따라 가중치를 부여한다. 이는 산술 평균의 선호 희석과 최댓값 집계의 잡음 민감도를 절충하여 상위 순위에 더 큰 비중을 두기 위함이다. 구체적으로 위치 p에서 $R = |\mathcal{R}|$개 해상도의 점수를 $S_{(1)}(x^q, p) \le \cdots \le S_{(R)}(x^q, p)$로 오름차순 정렬한다. 이때 결함 검증 표본이 없는 환경에서 가중치 간격을 임의 조정하는 휴리스틱을 피하고자, 관측 수 R로부터 닫힌형태로 유도되는 비모수적 순서 통계량 가중치를 쓴다. 표준 지수 분포 순서 통계량의 기댓값인 Rényi 표현 $a_k = \sum_{j=1}^{k} (R - j + 1)^{-1}$을 정규화하여 $w_k = a_k / \sum_{j=1}^{R} a_j$로 정하며, $R = 4$일 때 $w = (\frac{1}{16}, \frac{7}{48}, \frac{13}{48}, \frac{25}{48})$이다. 최종 이상 맵 $A(x^q) = \tilde{A}(x^q)$는 이 가중치를 적용해 산출한다:

$$\tilde{A}(x^q, p) = \sum_{k=1}^{R} w_k\, S_{(k)}(x^q, p). \quad (7)$$

Table 1. MVTec AD 2 `test_public` few-shot 비교 (8개 클래스 macro, 평균 ± 표본 표준편차, %). †: RegAD는 STN 제약으로 해상도 224에서 평가. 굵은 값과 밑줄은 최고·차순위 평균이다.

Shot	Metric	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD (224)†	Ours (ScopeAD)
1	$\text{AUPRO}_{0.05}$	38.45 ± 1.85	35.95 ± 2.24	14.92 ± 2.27	26.42 ± 1.71	44.87 ± 1.87	46.31 ± 3.73	12.73 ± 0.38	**52.18 ± 4.07**
	$\text{pAUROC}_{0.05}$	64.19 ± 0.68	70.67 ± 0.69	55.70 ± 0.67	59.57 ± 0.35	70.56 ± 0.56	70.13 ± 1.14	57.76 ± 0.30	**73.01 ± 1.60**
	I-AUROC	65.51 ± 1.91	66.83 ± 1.08	58.10 ± 4.46	58.68 ± 3.03	67.02 ± 2.27	67.68 ± 0.32	57.73 ± 1.82	**73.59 ± 0.36**
2	$\text{AUPRO}_{0.05}$	42.25 ± 2.08	38.20 ± 1.90	16.73 ± 2.39	31.61 ± 1.47	45.90 ± 0.75	49.80 ± 2.33	15.05 ± 0.30	**56.78 ± 2.77**
	$\text{pAUROC}_{0.05}$	65.43 ± 0.38	72.26 ± 0.56	57.14 ± 1.03	61.78 ± 0.15	71.53 ± 0.18	71.52 ± 0.58	58.76 ± 0.49	**75.83 ± 0.51**
	I-AUROC	67.53 ± 1.55	68.95 ± 3.84	57.63 ± 6.82	59.37 ± 2.54	70.42 ± 1.79	70.19 ± 2.16	60.56 ± 3.94	**75.04 ± 1.48**
4	$\text{AUPRO}_{0.05}$	46.94 ± 1.00	40.32 ± 0.75	21.88 ± 1.73	36.51 ± 1.02	47.14 ± 0.76	54.25 ± 0.86	17.40 ± 1.07	**59.49 ± 0.12**
	$\text{pAUROC}_{0.05}$	66.90 ± 0.22	73.09 ± 0.91	59.26 ± 0.80	63.84 ± 0.41	72.45 ± 0.20	73.59 ± 0.13	60.36 ± 0.48	**76.96 ± 0.55**
	I-AUROC	68.62 ± 2.28	70.90 ± 0.97	59.73 ± 4.40	62.31 ± 4.84	71.02 ± 0.56	70.97 ± 2.08	63.79 ± 2.34	**76.14 ± 0.50**
8	$\text{AUPRO}_{0.05}$	49.98 ± 1.90	41.64 ± 1.01	27.32 ± 0.14	40.79 ± 0.79	47.28 ± 0.40	55.44 ± 1.21	19.25 ± 0.64	**60.40 ± 0.89**
	$\text{pAUROC}_{0.05}$	68.22 ± 0.53	73.71 ± 0.20	61.74 ± 0.50	65.62 ± 0.69	72.56 ± 0.21	74.31 ± 0.38	62.02 ± 0.32	**77.57 ± 0.17**
	I-AUROC	69.20 ± 0.75	71.29 ± 1.69	63.46 ± 4.29	65.84 ± 0.43	70.46 ± 1.18	70.75 ± 0.58	64.34 ± 1.05	**76.39 ± 0.67**
16	$\text{AUPRO}_{0.05}$	52.73 ± 1.36	42.30 ± 1.25	35.23 ± 0.57	42.58 ± 1.10	47.63 ± 0.14	55.89 ± 1.07	20.28 ± 0.80	**60.74 ± 0.72**
	$\text{pAUROC}_{0.05}$	69.36 ± 0.51	73.97 ± 0.23	65.63 ± 0.43	66.62 ± 0.89	72.78 ± 0.07	74.60 ± 0.52	63.46 ± 0.76	**77.77 ± 0.34**
	I-AUROC	69.00 ± 0.53	72.07 ± 1.27	67.45 ± 1.16	67.60 ± 1.35	70.46 ± 1.07	69.79 ± 0.52	65.64 ± 1.34	**76.40 ± 0.95**

이미지 단위 이상 점수는 최종 이상 맵의 상위 1% 픽셀 집합 $\Omega_{0.01}$의 평균으로 계산한다. 집합 크기는 $|\Omega_{0.01}| = \max\{1, \lfloor 0.01HW \rfloor\}$이다:

$$s(x^q) = \frac{1}{|\Omega_{0.01}|} \sum_{p \in \Omega_{0.01}} A(x^q, p). \tag{8}$$

4. 실험

4.1. 평가 설정

데이터셋 및 평가 지표. 조명 및 노출 등 다양한 획득 조건 변화를 포함하는 MVTec AD 2 [**?**](`test_public`, 8개 클래스)를 주 벤치마크로 사용하며, 표준 환경 검증을 위해 MVTec AD(15개) [**?**] 및 VisA(12개) [**?**]를 함께 평가한다. 정상 서포트 수는 $N \in \{1, 2, 4, 8, 16\}$이며, 다중 서포트 분할에 대한 평균을 보고한다. 평가 지표로는 저-FPR 구간(FPR ≤ 0.05)의 결함 국소화 성능을 정밀 측정하는 클래스 macro $\text{AUPRO}_{0.05}$및 $\text{pAUROC}_{0.05}$와, 이미지 단위 판별 지표인 I-AUROC를 채택한다. 기존 벤치마크에는 픽셀 단위 P-AUROC도 병기한다.

비교군 및 구현 세부사항. 동결된 DINOv2 ViT-L/14 백본에서 계층 $\{5, 11, 23\}$과 4개 해상도 $\{448, 672, 896, 1120\}$을 추출하고, 토큰 상한은 해상도별 서포트 이미지당 256으로 설정한다. 정상 참조 분위수는 $q = 0.99$로 설정하며, 계층별 결합 가중치는 깊은 계층 $\{11, 23\}$에 각 0.5, 얕은 계층 5에 $\lambda = 0.125$를 부여하여 모든 실험에 동일하게 적용한다. 비교 방법은 PatchCore [**?**], SuperAD [**?**], AnomalyDINO [**?**], FastRecon [**?**], RAD [**?**], SubspaceAD [**?**], RegAD [**?**]이며, 동일한 서포트 분할과 평가 프로토콜 하에 단일 1120 해상도(RegAD는 STN 제약상 224)에서 평가를 수행한다.

4.2. Main results

먼저 획득 조건 변화가 포함된 few-shot 환경에서 ScopeAD가 기존 방법 대비 저-FPR 구간의 결함 국소화 성능을 개선하는지 확인한다. **??**에서 ScopeAD는 1–16-shot 전 구간에 걸쳐 $\text{AUPRO}_{0.05}$, $\text{pAUROC}_{0.05}$, I-AUROC 모두 최고 평균을 기록했으며, 차순위 대비 각각 4.85–6.98 pp, 2.34–3.57 pp, 4.33–5.91 pp 높았다. 1-shot $\text{AUPRO}_{0.05}$는 52.18 %로 동일 백본 기반의 PatchCore(38.45 %)와 차순위 SuperAD(46.31 %)를 각각 13.73 pp, 5.87 pp 상회했다. 또한 ScopeAD의 2-shot $\text{AUPRO}_{0.05}$(56.78 %)는 모든 비교 방법의 16-shot 평균(최고 55.89 %)보다 높았다.

획득 조건별 성능. **??**는 기본 조건(regular)과 획득 조건이 바뀐 영상(과노출·저노출·`shift_*`)의 $\text{AUPRO}_{0.05}$를 분리하여 비교한 결과다. ScopeAD는 변화 조건 평가에서 2-shot 56.60 %, 16-shot 60.74 %를 기록하며 모든 비교 방법군을 상회했다. 기본 조건에서는 SubspaceAD가 가장 높은 성능을 보였으나 변화 조건에서는 2-shot과 16-shot에서 각각 9.21 pp, 10.73 pp의 큰 폭으로 하락한 반면, ScopeAD의 성능 하락폭은 각각 1.49 pp, 1.68 pp에 그쳐 획득 조건 변화에 대한 강건성을 보였다.

공식 비공개 벤치마크 평가. MVTec AD 2 공식 블라인드 리더보드(**??**)에서 ScopeAD는 16-shot 기준 `test_private`(66.53 %)와 조건 혼합 평가셋 `test_private_mixed`(64.40 %) 모두에서 few-shot 최고 $\text{AUPRO}_{0.05}$를 기록했으며, 차순위 SuperAD보다 각각 3.71 pp, 4.32 pp 높았다. 전체 정상 데이터를 사용한 참고 모델과 비교하면 RoBiS보다 `test_private`에서 0.72 pp 낮고 `test_private_mixed`에서 4.75 pp 높았다. 반면 SegF1은 few-shot SuperAD와 전체 데이터 모델보다 낮았다. 본 평가에서는 SuperADD [**?**]의 임계값 규칙인 정상 픽셀 점수의 95백분위수 × 1.421을 ScopeAD에 별도 조정 없이 적용했다. 임계값 선택이 결과에 영향을 주었을 가능성은 있으나, 현재 평가만으로 낮은 SegF1의 원인을 분리할 수는 없다. 전체 데이터 모델은 더 많은 정상 데이터와 각자의 후처리를 사용하므로 직접 비교에도 한계가 있다.

MVTec AD와 VisA. 획득 조건 변화가 제한적인 MVTec AD 및 VisA(**??**)에서는 ScopeAD의 우위가 뚜렷하지 않았다. I-AUROC는 10개 조건 중 5개에서 최고였고(나머

Table 4. MVTec AD 및 VisA few-shot 비교 (%). 각 셀은 I-AUROC / P-AUROC. 굵은 값과 밑줄은 최고·차순위다.

Dataset	Shot	PatchCore	AnomalyDINO	FastRecon	RAD	SubspaceAD	SuperAD	RegAD (224)	Ours (ScopeAD)
MVTec AD	1	88.12 / 96.22	92.52 / 94.49	88.84 / 96.60	80.83 / 93.25	89.25 / 96.92	**92.54** / **96.93**	77.52 / 93.88	92.32 / 96.62
	2	92.67 / 96.97	95.17 / 95.56	93.51 / 97.29	84.15 / 94.27	90.95 / 97.24	95.43 / **97.36**	81.60 / 95.14	**95.49** / 97.28
	4	95.06 / 97.37	95.92 / 96.07	95.61 / **97.87**	85.38 / 94.67	91.35 / 97.16	96.65 / 97.70	84.13 / 96.32	**96.82** / 97.59
	8	96.13 / 97.80	96.67 / 96.45	96.76 / **98.16**	87.85 / 95.29	92.94 / 97.17	**97.39** / 97.95	86.36 / 96.85	97.35 / 97.86
	16	98.15 / 97.99	97.48 / 96.80	98.52 / **98.38**	90.29 / 95.61	92.51 / 97.19	**98.94** / 98.09	89.56 / 97.22	98.66 / 97.99
VisA	1	86.09 / 95.56	87.06 / 95.62	84.65 / 96.75	72.67 / 95.37	85.44 / **98.09**	**90.29** / 97.06	71.12 / 93.41	88.52 / 96.53
	2	87.87 / 96.29	90.64 / 96.63	87.67 / 97.43	77.24 / 96.37	86.36 / **98.21**	**92.20** / 97.68	71.59 / 94.59	91.59 / 97.14
	4	89.52 / 96.92	91.37 / 97.57	89.21 / 97.91	79.16 / 97.45	86.85 / **98.26**	92.94 / 98.02	76.42 / 96.14	**94.28** / 97.69
	8	92.36 / 97.18	93.11 / 97.99	91.53 / 98.11	86.32 / 97.93	88.29 / **98.33**	94.50 / 98.29	80.19 / 96.64	**94.97** / 98.12
	16	93.64 / 97.30	93.53 / 98.30	93.38 / 98.32	88.56 / 98.18	88.99 / 98.37	95.19 / **98.43**	81.22 / 96.98	**95.86** / 98.37

Table 2. 획득 조건별 $AUPRO_{0.05}$ (MVTec AD 2 `test_public`, 평균, %). 기본: regular 조건. 변화: 과노출·저노출과 클래스별 1–4개의 shift 조건에서 각각 계산한 $AUPRO_{0.05}$의 평균. 클래스마다 계산한 뒤 8개 클래스를 동일 비중으로 평균했다. 굵은 값과 밑줄은 열별 최고·차순위다.

	2-shot		16-shot	
방법	기본	변화	기본	변화
PatchCore	42.98	42.30	54.32	52.97
AnomalyDINO	42.79	39.52	49.91	44.12
FastRecon	17.61	16.82	38.19	35.54
RAD	31.53	31.71	43.14	43.02
SubspaceAD	**58.86**	49.65	**63.10**	52.37
SuperAD	51.06	49.96	58.58	56.33
RegAD (224)	16.75	14.95	24.11	20.88
Ours (ScopeAD)	58.09	**56.60**	62.42	**60.74**

Table 3. MVTec AD 2 공식 비공개 평가 (%). 각 셀은 `test_private` / `test_private_mix`. ∗: 전체 정상 데이터 사용. 굵은 값과 밑줄은 few-shot 내 최고·차순위다.

방법	$AUPRO_{0.05}$	ClassF1	SegF1
Few-shot (16-shot)			
AnomalyDINO	50.35 / 44.86	77.87 / 77.91	26.65 / 18.62
PatchCore	58.33 / 57.03	**78.21** / 78.02	29.96 / 27.75
SuperAD	62.82 / 60.08	78.14 / 78.19	**39.43** / **33.86**
Ours (ScopeAD)	**66.53** / **64.40**	78.03 / **78.86**	36.33 / 32.47
Full-data Reference∗			
SuperAD∗	60.51 / 58.37	70.20 / 74.40	47.18 / 42.51
SuperADD∗ [?]	61.36 / 59.07	68.03 / 73.25	57.42 / 54.35
RoBiS∗	67.25 / 59.65	79.62 / 79.86	51.00 / 46.52

지는 SuperAD가 0.04–1.77 pp 높음), P-AUROC는 조건별 최고치보다 0.06–1.56 pp 낮았다. 저-FPR $AUPRO_{0.05}$에서도 SubspaceAD가 MVTec AD 1–4-shot과 VisA 전 shot에서 가장 높았다(VisA 격차 1-shot 10.32 pp, 16-shot 0.92 pp). 획득 조건 변화가 포함된 MVTec AD 2의 결과와 비교하면, ScopeAD의 상대적 이점은 평가 환경에 따라 달라졌다.

4.3. Ablation study

제안 방법의 구성 요소별 기여도를 분석하고, 다해상도 확장의 이득이 단순 토큰 수 증가로 설명되는지 검증한다. 이어 주요 하이퍼파라미터에 대한 민감도를 평가한다. 모든 ablation과 비용 분석은 공정한 내부 조건 비교를 위해 동일한 고정 서포트 분할 조건에서 수행했다.

구성 요소별 기여도. **??**는 단일 해상도 기준선(A)에서 최종 모델(F)에 이르기까지 각 구성 요소를 순차적으로 누적 적용한 결과다. 전체 성능 향상폭은 2-shot과 16-shot에서 각각 +9.41 pp, +6.41 pp에 달했다. 이러한 향상의 과반은 다해상도 확장(B, +5.11/ + 4.12 pp)에서 비롯되어, 관측 확장이 전체 성능 개선의 핵심 요인임을 보여준다. 관측별 독립 뱅크(C)는 특징을 연결하여 매칭하는 B와 달리 각 관측에서 최근접 이웃을 독립적으로 탐색하여, 특정 계층이 다른 계층의 이웃 선택에 간섭하지 않도록 한다. B에서 C로 전환하면 2/16-shot 성능이 각각 +2.61/ + 0.03 pp 높아져, 독립 매칭의 추가 이득은 서포트가 적은 2-shot에서 두드러졌다. 독립 뱅크 구성(C)과 최종 구성(F)의 $AUPRO_{0.05}$차이는 2/16-shot에서 각각 1.69/2.26 pp였다. 표에 제시한 두 shot 설정에서는 각 단계에서 성능이 증가했다.

Table 5. 구성 요소의 누적 ablation (MVTec AD 2 `test_public`, $AUPRO_{0.05}$, %). A: 1120 해상도, 계층 [11, 23] 연결 뱅크, 보정 없음. B–F: 이전 행에 구성 요소를 순차 추가. 굵은 값과 밑줄은 최고·차순위다.

구성	2-shot	16-shot
A. Single-resolution	50.51	53.78
B. + Multi-resolution	55.62	57.90
C. + Separate banks	58.23	57.93
D. + Shallow fusion	59.06	59.17
E. + Scale calibration	59.33	59.57
F. + Rényi aggregation (Ours)	**59.92**	**60.19**

Table 6. 해상도 조합 및 토큰 상한에 따른 성능과 비용 (MVTec AD 2, 16-shot, FP16; 성능은 %). cap은 해상도별 서포트당 토큰 상한이다. 시간은 클래스 평균, Peak는 쿼리 최대 GPU 메모리다. 굵은 값과 밑줄은 1·2위다.

구성	cap	$AUPRO_{0.05}$	$pAUROC_{0.05}$	Fit (s)	Query (ms)	Peak (GiB)
단일 1120	256	57.48	74.86	**11.09**	**861**	**1.91**
단일 1120	1024	57.13	75.49	12.48	1053	3.04
2-res {672, 1120}	256	59.15	76.28	13.65	980	2.15
4-res (Ours)	256	60.19	77.52	17.21	1365	3.12
4-res	1024	**60.33**	**77.94**	22.42	1789	6.71

토큰 수와 계산 비용. 동일한 토큰 예산에서는 한 해상도의 토큰 수를 늘리는 것보다 여러 해상도에 토큰을 분배하는 편이 효과적이었다. **??**에서 4개 해상도에 각각 256개 토큰을 사용하는 ScopeAD는 단일 1120 해상도에 1024개 토큰을 사용하는 구성보다 $AUPRO_{0.05}$가 3.06 pp 높았다. 이는 다해상도의 이득이 토큰 수 증가만으로 설명되지 않음을 보여준다. 4개 해상도의 부분집합 조합을 보면, 중

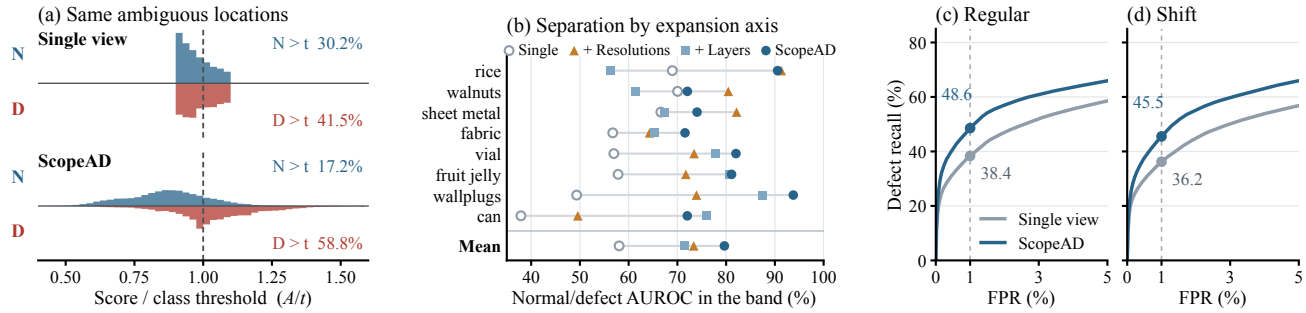


Figure 4. **HSA 구간의 정상·결함 점수와 결함 픽셀 재현율** (MVTec AD 2 `test_public`, 2-shot, 사후 분석). (a) 단일 관측(L23/1120) 점수가 클래스 임계값 t의 0.9–1.1배인 정상(N)·결함(D) 위치를 단일 관측과 ScopeAD로 점수화한 분포. t는 구성별 클래스 테스트 정상 Q99이며, 수치는 t를 넘는 위치의 비율이다. (b) 같은 위치의 클래스별 정상·결함 구분 AUROC. +Resolutions는 L23의 4개 해상도, +Layers는 1120 해상도의 세 계층 가중합이며, 둘 다 Q99 보정을 쓴다. 클래스는 두 축의 AUROC 차이 순으로 정렬했다. (c,d) Regular와 shift 조건의 결함 픽셀 재현율–FPR 곡선(8개 클래스 평균). 수치는 FPR 1%에서의 결함 픽셀 재현율이다.

Table 7. 하이퍼파라미터에 따른 $\text{AUPRO}_{0.05}$ (MVTec AD 2 `test_public`, %). 왼쪽은 $q = 0.95$에서 얕은 계층 가중치 λ를 바꾼 결과이며, 사용값 행에는 $q = 0.99$의 최종 구성 결과를 표시했다. 오른쪽은 $\lambda = 0.125$에서 정상 참조 분위수 q를 바꿨다. *는 사용값이다. 굵은 값과 밑줄은 열별 최고·차순위다.

λ	2-shot	16-shot	q	2-shot	16-shot
0	59.05	59.11	0.5	58.62	59.55
0.0625	<u>59.76</u>	59.73	0.8	59.53	60.01
0.125*	**59.92**	<u>60.19</u>	0.9	<u>59.81</u>	60.15
0.25	59.32	**60.36**	0.95	**59.92**	<u>60.16</u>
0.5	56.23	59.47	0.99*	**59.92**	**60.19**

간 문맥과 미세 분해능을 대표하는 2개 해상도 조합 672, 1120만으로도 2/16-shot에서 각각 58.10 %, 59.15 %를 달성하여 단일 최고 해상도(54.38 %, 57.48 %)를 상회하면서 쿼리 시간을 980 ms(4해상도 대비 약 28 % 절감)로 줄일 수 있다. 4개 해상도를 모두 쓸 때 결함 크기별 다양성이 온전히 포괄되어 최고 성능(59.92 %, 60.19 %)에 도달한다. 실제 공정에서는 저해상도로 정상을 조기 판정(early rejection)하고 모호한 구간에 한해 고해상도를 선택 순전파하여 평균 지연시간을 단축할 수 있다. 반면, 다해상도 구성에서 토큰 상한을 더 늘렸을 때의 성능 이득은 계산 비용 증가에 비해 작았다. cap을 256에서 1024로 늘리면 $\text{AUPRO}_{0.05}$는 0.14 pp 높아지는 데 그쳤으나, 쿼리 시간과 최대 메모리는 각각 1.31배, 2.15배로 증가했다. 따라서 성능과 계산 비용을 고려해 cap 256을 기본값으로 사용한다.

하이퍼파라미터. ??의 결과는 얕은 계층을 배제하거나 깊은 계층과 균등하게 결합하기보다, 낮은 가중치로 반영하는 편이 효과적임을 보여준다. 다만 최적 가중치는 shot에 따라 달랐다. 사용값 $\lambda = 0.125$는 2-shot에서 가장 높은 $\text{AUPRO}_{0.05}$를 보였으나, 16-shot에서는 $\lambda = 0.25$보다 0.17 pp 낮았다. 다만 다른 가중치 행은 $q = 0.95$ 조건이므로, 이 차이를 가중치만의 효과로 해석할 수는 없다. 분위수 q는 0.8–0.99 범위에서 성능 차이가 작아, 이 구간에서 낮은 민감도가 관찰되었다. 이 비교에서 $q = 0.95$를 0.99로 바꾸면 2-shot 성능은 반올림 기준으로 같고, 16-shot 성능은 0.03 pp 높아졌다. 두 패널의 사용값 행에는 동일한 최종 구성($\lambda = 0.125$, $q = 0.99$)의 결과를 표시했다. 반면 $q = 0.5$에서는 2-shot 성능이 사용값보다 1.30 pp 낮아, 정상 참조의 중앙값보다 높은 분위수를 사용하는 것이 유리했다.

순위 가중 집계와 비모수적 설계. 다해상도 통합에서 단순 산술 평균 대신 순위 가중 집계를 적용하면 결함 국소 반응의 희석을 줄여 저-FPR 성능이 향상된다(??, ??). 실제로 Q99 보정 하에서 Rényi 집계는 산술 평균 대비 $\text{AUPRO}_{0.05}$를 2-shot과 16-shot에서 각각 0.75 pp, 0.68 pp 높인다(??). 결함 검증 표본이 없는 few-shot 환경에서는 가중치 간격을 사후 튜닝하는 휴리스틱 대신, 관측 수 R만으로 닫힌형태로 유도되는 Rényi 순서 통계량을 비모수적(hyperparameter-free) 기준선으로 쓴다.

4.4. 분석: HSA 완화와 점수 통합

단일 관측이 정상과 결함을 구분하지 못하는 위치에서 ScopeAD가 둘을 어떻게 분리하는지 분석하고(??), 이 분리에 쓰이는 척도 보정과 Rényi 집계가 어떻게 함께 작동하는지 확인한다.

HSA 구간의 정상과 결함. 클래스 임계값 t는 각 구성의 점수에서 클래스별 테스트 정상 픽셀의 99백분위수(Q99)로 정했다. 즉 t를 넘는 정상 픽셀이 1 %가 되는, 오경보율 1 %의 판정 기준이다. HSA 구간은 단일 관측(L23/1120)의 클래스별 임계값 t를 기준으로 점수가 $0.9t$ 이상 $1.1t$ 이하인 정상 및 결함 위치로 정의하고 고정했다. 이하에서는 이 구간의 정상·결함 구분 AUROC를 구간 내 AUROC로 표기한다. 단일 관측의 구간 내 AUROC는 58.0 %로, 높은 점수만으로는 둘을 거의 구분하지 못한다. 같은 위치를 ScopeAD로 점수화하면 t를 넘는 정상 위치는 30.2 %에서 17.2 %로 줄고, 결함 위치는 41.5 %에서 58.8 %로 늘었다(??a). Q99 보정을 고정하고 관측만 바꾼 비교에서, 해상도를 늘리면 구간 내 AUROC가 73.4 %, 계층을 늘리면 71.5 %, 두 축을 함께 늘리면 79.8 %로 높아졌다. 두 축은 서로 다른 클래스에서 단서를 주었다(??b). 예를 들어 해상도 확장은 rice(91.3 %)에서, 계층 확장은 can(76.0 %)

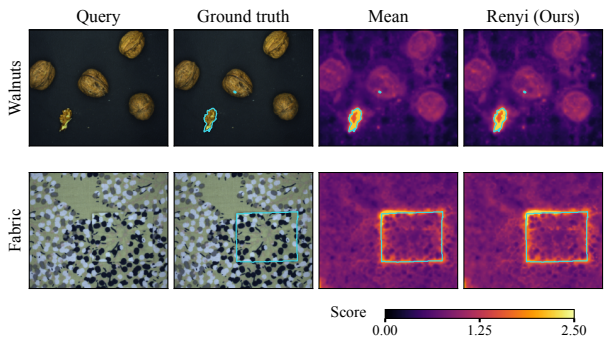


Figure 5. **MVTec AD 2 결함 국소화 정성 비교.** 열은 쿼리, 정답, 4해상도 Mean, 4해상도 Rényi 순이다(16-shot). 위: Walnuts `006_shift_2`, 아래: Fabric `000_regular`. 보정과 계층 결합을 고정하고 집계만 바꿨으며, 두 결과에 동일한 후처리를 적용했다. 짧은 변 256픽셀의 표시용 맵과 공통 색상 범위 $[0, 2.5]$를 사용했다. 하늘색 윤곽은 정답이다.

Table 8. 집계 방식과 척도 보정의 상호작용 (MVTec AD 2, $\text{AUPRO}_{0.05}$, 평균 ± 표본 표준편차, %). 굵은 값과 밑줄은 최고·차순위 평균이다.

집계 방식	척도 보정	2-shot	16-shot
Mean	없음	56.12 ± 2.76	59.73 ± 0.86
Mean	Q99	56.03 ± 3.00	60.06 ± 0.88
Rényi	없음	56.32 ± 2.49	59.72 ± 0.77
Rényi (Ours)	Q99	**56.78 ± 2.77**	**60.74 ± 0.72**

과 wallplugs(87.4 %)에서 크게 높았다. ScopeAD의 구간 내 AUROC는 8개 클래스 모두에서 단일 관측보다 높았으며, Rényi 집계는 평균 집계보다 구간 내 AUROC를 더 높이지는 않았다(79.6 대 79.8 %). HSA 구간 분석과 별도로, 조건별 영상 평가에서도 저-FPR 검출률의 개선이 관찰되었다. FPR 1%에서 결함 픽셀 재현율은 regular 조건에서 38.4 %에서 48.6 %로, shift 조건에서 36.2 %에서 45.5 %로 높아졌다(**??**c,d). 다만 이는 2-shot 사후 진단이며, `walnuts`에서는 검출률이 낮아졌다. **??**는 동일한 다해상도 점수에 Mean과 Rényi 집계를 적용한 결함 지도의 비교다. 정성 사례만으로 두 집계 방식의 성능 우위를 판단할 수 없으며, 색상 대비만으로 오경보율을 비교할 수도 없다.

보정과 집계의 상호작용 기전. ScopeAD는 관측 척도 정렬과 순위 집계를 함께 적용하여 저-FPR 국소화 성능을 높인다(**??**). 이 시너지는 Rényi 집계의 비선형 추가 응답 구조에서 비롯된다. Rényi 결합 점수는 평균 응답 $\mu(p)$와 해상도 간 순위 간격에 따른 비음수 추가 응답 $E(p) \geq 0$의 합으로 정의된다. 순위 집계는 결함이 특정 해상도에 집중될 때 신호를 보존하는 장점이 있지만, 척도를 보정하지 않으면 관측별 기저 거리 차이 때문에 정상 영역에서도 순위 간격이 벌어져 정상 잡음 비율(E/μ)이 커진다. 정상 서포트의 Q99 보정은 관측 간 기저 편차를 정렬하여 정상 영역의 불필요한 간격을 줄인다. 그 결과 정상 이미지의 상대 추가 응답(E/μ)은 줄어드는 반면(2-shot 7.74 → 7.10 %, 16-shot 8.56 → 7.55 %), 특정 해상도에서 강하게 반응하는 실제 결함 영역의 순위 간격은 유지된다(부록 **??**). 즉, Q99 보정이 정상 영역의 거짓 순위 반응을 억제하고 Rényi 집계가 유효한 결함 반응을 보존함으로써 저-FPR 구간의 결함-배경 대비를 강화한다.

5. 논의 및 한계

ScopeAD는 추가 학습 없이 관측 확장과 순위 통합으로 획득 조건 변화에 강건한 결함 국소화를 달성했으나 몇 가지 실용적 한계를 지닌다. 첫째, 관측 확장은 미관측 정상 변동 자체를 생성하지 못하므로, 정상 표본이 극히 적을 때는 서포트 선택에 따른 점수 분산이 존재하며(1-shot 표준편차 4.07 pp) 라인 배치 시 목표 오경보율에 따른 임계값 교정이 요구된다. 둘째, 다해상도 순전파로 인해 단일 해상도 대비 쿼리 시간과 메모리가 증가한다. 이는 본문에서 제시한 중간·고해상도 2개 조합({672, 1120}) 이나 저해상도 조기 판정(early rejection) 기반의 계층적 추론으로 실시간성을 확보할 수 있다. 셋째, HSA 진단(**??**)은 `test_public` 사후 분석에 기반하므로, 클래스별 이득 편차와 미관측 산업 도메인으로의 일반화 특성은 향후 연구 과제다.

6. 결론

본 논문은 동결 백본의 계층과 해상도를 독립 매칭 단위로 전개하고, 정상 참조 Q99 보정, 비대칭 계층 결합, 비모수적 Rényi 순위 집계로 점수를 통합하는 **ScopeAD**를 제안했다. 제안 방법은 추가 학습이나 쿼리 적응 없이도 획득 조건 변화 환경에서 발생하는 High-Score Ambiguity를 완화하고, 저-FPR 구간의 결함-배경 대비를 강화한다. MVTec AD 2 벤치마크의 1–16-shot 전 구간과 공식 비공개 평가에서 기존 비교군을 일관되게 상회하는 최고 저-FPR 국소화 성능을 달성했으며, 정적 벤치마크에서도 경쟁력 있는 결과를 확인했다. 본 연구는 소수의 정상 참조만 주어지는 환경에서 동결 특징의 다각적 관측 확장과 원칙적 순위 통합이 실용적인 대안이 됨을 시사한다.

References

[] Paul Bergmann, Michael Fauser, David Sattlegger, and Carsten Steger. MVTec AD – a comprehensive real-world dataset for unsupervised anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9592–9600, 2019.

[] Joao P. C. Bertoldo, Dick Ameln, Ashwin Vaidya, and Samet Akcay. AUPIMO: Redefining visual anomaly detection benchmarks with high speed and low tolerance. *arXiv preprint arXiv:2401.01984*, 2024.

[] Simon Damm, Mike Laszkiewicz, Johannes Lederer, and Asja Fischer. Anomalydino: Boosting patch-based few-shot anomaly detection with dinov2. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1319–1329, 2025.

[] Zheng Fang, Xiaoyang Wang, Haocheng Li, Jiejie Liu, Qiugui Hu, and Jimin Xiao. Fastrecon: Few-shot industrial anomaly detection via fast feature reconstruction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 17481–17490, 2023.

[] Stephanie Fu, Mark Hamilton, Laura E. Brandt, Axel Feldmann, Zhoutong Zhang, and William T. Freeman. FeatUp: A model-agnostic framework for features at any resolution. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024.

[] Lars Heckler-Kram, Jan-Hendrik Neudeck, Ulla Scheler, Rebecca König, and Carsten Steger. The MVTec AD 2 dataset: Advanced scenarios for unsupervised anomaly detection. *International Journal of Computer Vision*, 134(4), 2026.

[] Chaoqin Huang, Haoyan Guan, Aofan Jiang, Ya Zhang, Michael Spratling, and Yan-Feng Wang. Registration based few-shot anomaly detection. *arXiv preprint arXiv:2207.07361*, 2022.

[] Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, and Onkar Dabeer. WinCLIP: Zero-/few-shot anomaly classification and segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 19606–19616, 2023.

[] Camile Lendering, Erkut Akdag, and Egor Bondarau. Subspacead: Training-free few-shot anomaly detection via subspace modeling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 28557–28566, 2026.

[] Xurui Li, Ziming Huang, Feng Xue, and Yu Zhou. MuSc: Zero-shot industrial anomaly classification and segmentation with mutual scoring of the unlabeled images. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024.

[] Xiaofan Li, Zhizhong Zhang, Xin Tan, Chengwei Chen, Yanyun Qu, Yuan Xie, and Lizhuang Ma. PromptAD: Learning prompts with only normal samples for few-shot anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16848–16858, 2024.

[] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023.

[] Maithra Raghu, Thomas Unterthiner, Simon Kornblith, Chiyuan Zhang, and Alexey Dosovitskiy. Do vision transformers see like convolutional neural networks? In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 12116–12128, 2021.

[] Rene Ranftl, Alexey Bochkovskiy, and Vladlen Koltun. Vision transformers for dense prediction. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 12179–12188, 2021.

[] Lukas Roming, Felix Lehnerer, Jonas V. Funk, Andreas Michel, Georg Maier, Thomas Längle, and Jürgen Beyerer. Superadd: Training-free class-agnostic anomaly segmentation – cvpr 2026 vand 4.0 workshop challenge industrial track. *arXiv preprint arXiv:2605.14808*, 2026.

[] Karsten Roth, Latha Pemula, Joaquin Zepeda, Bernhard Schölkopf, Thomas Brox, and Peter Gehler. Towards total recall in industrial anomaly detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14298–14308, 2022.

[] Baifeng Shi, Ziyang Wu, Maolin Mao, Xin Wang, and Trevor Darrell. When do we not need larger vision models? In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2024.

[] Weilin Tu. Few-shot anomaly detection on MVTec AD 2: A systematic study and a strong frozen baseline. *IEEE Access*, 14:152500–152511, 2026.

[] Jin Wang, Ying-Hang Li, Bo-Wen Jiang, and Shi-Chao Li. FreePatch: A training-free multiscale patch matching method for few-shot industrial anomaly detection. In *International Conference on Computer Vision, Graphics, and Artificial Intelligence (CVGAI 2026)*, 2026.

[] Huaiyuan Zhang, Hang Chen, Yu Cheng, Shunyi Wu, Linghao Sun, Linao Han, Zeyu Shi, and Lei Qi. Superad: A training-free anomaly classification and segmentation method for cvpr 2025 vand 3.0 workshop challenge track 1: Adapt & detect. *arXiv preprint arXiv:2505.19750*, 2025.

[] Xingwu Zhang, Guanxuan Li, Paul Henderson, Gerardo Aragon-Camarasa, and Zijun Long. Is task-specific training necessary for anomaly detection? *arXiv preprint arXiv:2601.22763*, 2026. Version 3.

[] Zilong Zhang, Zhibin Zhao, Xingwu Zhang, Chuang Sun, and Xuefeng Chen. Industrial anomaly detection with domain shift: A real-world dataset and masked multi-scale reconstruction. *Computers in Industry*, 151:103990, 2023.

[] Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, and Jiming Chen. AnomalyCLIP: Object-agnostic prompt learning for zero-shot anomaly detection. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2024.

[] Jiawen Zhu and Guansong Pang. Toward generalist anomaly detection via in-context residual learning with few-shot sample prompts. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 17826–17836, 2024.

[] Yang Zou, Jongheon Jeong, Latha Pemula, Dongqing Zhang, and Onkar Dabeer. Spot-the-difference self-supervised pre-training for anomaly detection and segmentation. *arXiv preprint arXiv:2207.14315*, 2022.